

基于人类反馈的强化学习

面向语言模型的后训练 RLHF 简明指南

Nathan Lambert

翻译人：北航 控制科学与工程博士 晏一夫
Yanyifu633@buaa.edu.cn

LaTeX 排版与翻译：WWW.ifpaperlab.com

2026-09

版权与许可

原文

- 书名: *Reinforcement Learning from Human Feedback*
- 作者: Nathan Lambert
- 网址: <https://rlhfbook.com>
- 许可: CC BY-NC-SA 4.0 (署名—非商业性使用—相同方式共享) <https://creativecommons.org/licenses/by-nc-sa/4.0/>

本译本

- LaTeX 排版与翻译: WWW.ifpaperlab.com
- 译者: 北航 控制科学与工程博士 晏一夫 Yanyifu633@buaa.edu.cn
- 用途: 仅供个人学习与研究, 不作任何商业用途
- 许可: 本译本以相同协议 (CC BY-NC-SA 4.0) 提供
- 说明: 译文未改动原文的技术内容、公式、图表编号与引用; 著作权利归原作者 Nathan Lambert 所有
- 依据版本: 英文版 v0.11 及仓库主分支

本译本为非官方翻译, 与原作者及出版方无隶属关系。

目录

1 引言	6
1.1 RLHF 的三个步骤	6
1.2 RLHF 做了什么?	7
1.3 RLHF 配方实操走查	9
1.4 后训练的直觉理解	10
1.5 我们如何走到今天	11
1.6 本书范围	12
1.7 RLHF 的未来	14
2 RLHF 简史	15
2.1 起源到 2018: 从偏好中做 RL	15
2.2 2019 到 2022: 在语言模型上做人类偏好强化学习	16
2.3 2023 至今: ChatGPT 时代	16
3 训练总览	17
3.1 问题形式化	17
3.2 经典训练流程	22
4 指令微调	26
4.1 聊天模板与指令结构	27
4.2 指令微调的最佳实践	29
4.3 实现细节	29
4.4 建议的实验	30
5 奖励建模	32
5.1 训练 Bradley-Terry 奖励模型	32
5.2 结果奖励模型	36
5.3 过程奖励模型	39
5.4 比较各类奖励模型 (以及价值函数)	41
5.5 其他奖励模型变体	43
5.6 生成式奖励建模 (即 LLM 作为评判者)	44
5.7 延伸阅读	45
5.8 建议的实验	46
6 强化学习	47
6.1 强化学习在 RLHF 中的角色	47
6.2 策略梯度算法	47
6.3 实现	66
6.4 补充话题	77
6.5 建议的实验	80
7 推理与推理时扩展	81
7.1 RLVR 的角色	81
7.2 新一代推理模型的来路	84

7.3	理解推理训练方法	85
7.4	展望	89
8	直接对齐算法	90
8.1	直接偏好优化	90
8.2	数值问题、局限与替代方案	96
8.3	实现细节	97
8.4	使用合成偏好数据的 DAA	98
8.5	DAA 与 RL: 在线数据 vs 离线数据	98
8.6	建议的实验	99
9	拒绝采样	100
9.1	训练流程, 一步一步来	100
9.2	实现细节	104
9.3	相关方法: Best-of-N 采样	104
9.4	建议的实验	105
10	偏好的本质	106
10.1	当偏好取代正确性	106
10.2	RLHF 与偏好的渊源	107
10.3	明确目标: 从效用逻辑到奖励函数	107
10.4	优化效用的工具	108
10.5	优化偏好的复杂性	109
11	偏好数据	111
11.1	为什么需要偏好数据	111
11.2	采集偏好数据	111
11.3	偏置: 数据采集中需要警惕的东西	120
11.4	RLHF 偏好数据中的未决问题	120
12	合成数据与蒸馏	122
12.1	合成数据的角色	122
12.2	用合成数据做蒸馏	123
12.3	通往同策略教师—学生蒸馏之路	124
12.4	AI 反馈	129
12.5	宪法式 AI	130
12.6	Rubrics: 面向具体提示的 AI 反馈	132
13	工具使用与函数调用	135
13.1	工具使用总览	135
13.2	在生成中交织工具调用	136
13.3	多步工具推理	138
13.4	模型上下文协议	139
13.5	实现细节	141
14	过度优化	143

14.1 定性的过度优化	144
14.2 定量的过度优化	146
14.3 失准与 RLHF 的角色	146
15 正则化	148
15.1 RL 优化中的 KL 散度	148
15.2 控制优化的其他工具	149
15.3 隐式正则化	151
16 评估	156
16.1 提示词的格式化	156
16.2 为什么许多外部评估对比并不可靠	160
16.3 实验室实际如何在内部用评估改进模型	161
16.4 数据污染	163
16.5 工具	163
17 塑造模型性格与产品	164
17.1 角色训练	164
17.2 模型规范	171
17.3 产品周期与 RLHF 的下一步	172
参考文献	173
A 定义	196
A.1 语言建模概览	196
A.2 机器学习	196
A.3 自然语言处理	196
A.4 强化学习	197
A.5 仅属 RLHF	198
A.6 扩展术语表	198
B 超越「只是风格」	199
B.1 话痨感的平衡	201
C 实践问题	203
C.1 后训练的算力成本	203
C.2 评估的方差	203
C.3 管理训练表现的方差	204
C.4 识别坏掉的训练任务	204

1 引言

人类反馈强化学习（Reinforcement Learning from Human Feedback, RLHF）是一种把人类信息融入 AI 系统的技术。RLHF 最初主要是为了解决那些难以被精确描述的问题而出现的。对于那些直接面向人类使用的系统，这类问题层出不穷——因为个体的偏好往往无法被完整地表述出来。它涵盖数字系统中内容与交互的每一个领域。RLHF 的早期应用多见于控制问题以及其他强化学习（RL）的传统领域，这些领域的目标是优化某种特定行为以完成某项任务。开创 RLHF 这一领域的核心想法是：“我们能否仅凭基本的偏好信号来引导优化过程，从而解决困难问题？” RLHF 真正广为人知，是在 ChatGPT 发布、以及随后大语言模型（LLM）和其他基础模型快速发展之后。

1.1 RLHF 的三个步骤

RLHF 的基本流程包含三个步骤。首先，需要训练一个能够回应使用者提问的语言模型（见第 4 章）。其次，需要收集人类偏好数据，用以训练一个刻画人类偏好的奖励模型（见第 5 章）。最后，可以用任选的 RL 优化器来优化语言模型：采样生成内容，再依据奖励模型对其打分（见第 3 章与第 6 章）。本书会详述这一流程中每一步的关键决策与基础实现示例。

RLHF 已在许多领域取得成功，而且随着技术成熟，其复杂度也在不断提高。RLHF 早期的突破性实验分别应用于深度强化学习 [1]、文本摘要 [2]、指令跟随 [3]、为问答任务解析网页信息 [4]，以及“对齐” [5]。早期 RLHF 流程的一个汇总见图 1。




图 1: 早期三阶段 RLHF 流程示意图：SFT、奖励模型，然后是优化。

在现代语言模型训练中，RLHF 是后训练（post-training）的一个组成部分。后训练是一整套更完整的技术与最佳实践，目的是让语言模型对下游任务更有用 [6]。后训练可以概括为一个多阶段的训练过程，其中用到三类优化方法：

1. 指令微调 / 监督微调（IFT/SFT）：教会模型格式化输出，并奠定指令跟随能力的基础。这一阶段主要学习语言中的特征（features）。
2. 偏好微调（PreFT）：通过 RLHF 及相关方法与人类偏好对齐（同时带来较小的能力提升）。这一阶段主要关乎语言的风格（style），以及那些难以量化的、细微的人类偏好。
3. 可验证奖励的强化学习（RLVR）：最新的一类后训练方法，通过更多的 RL 训练来提升模型在可验证领域上的表现。

RLHF 存在于并主导着第二个领域——偏好微调。它比指令微调更复杂，因为它往往涉及对真实目标的代理奖励模型，以及噪声更大的数据。同时，RLHF 也比语言模型上另一种流行的 RL 方法（可验

证奖励的强化学习)成熟得多。因此,本书聚焦于偏好学习;但要完整把握 RLHF 的作用,就必须同时理解这些其他训练阶段,所以本书也对它们做了详细说明。

在我们思考“如何打造一个被广泛使用的模型”时,可供选择的方案与关注的焦点,正是 RLHF——口语上,RLHF 就是造就现代后训练的那件事。RLHF 是让 ChatGPT 的发布获得巨大成功的技术,所以在 2023 年初,RLHF 几乎等同于后训练这一整个领域的全部热度。如今 RLHF 只是后训练中的一块拼图,因此本书会梳理:为什么早期 RLHF 会受到如此多的关注,以及后来其他方法是如何出现并与之互补的。

训练语言模型是一个极其复杂的过程,往往涉及数十到数百人的大型技术团队,以及数百万美元量级的数据与算力成本。本书有三个目标,以帮助读者把握 RLHF 及相关方法是如何被用来打造顶尖模型的。第一,本书把那些常常被隐藏在大科技公司内部的尖端研究,提炼为清晰的主题与权衡,让读者理解模型是如何被造出来的。第二,本书让使用者能够搭起基础的代码示例,亲自动手微调这些模型。第三,除了讲授如何做 RLHF,本书还力图提炼出“为什么 RLHF 对现代 AI 模型至关重要”的直觉。

鉴于 RLHF 的复杂性,以及最前沿的做法往往复杂到无法独立完成,本书的目标是让读者具备在该领域求职、或启动研究项目所需的工具。另一些读者则单纯享受精确地理解这门被全球无数讨论所聚焦的技术,究竟是如何运作的。要写出一本“针对某个具体需求、给出 RLHF 精确配方”的书是不可能的——这正是为什么存在一个规模达数百万美元、专门提供 RLHF 训练及相关方法服务的产业。不过,AI 系统的快速进步意味着:掌握了这些知识的读者,将能够越来越多地自行完成训练工作。

1.2 RLHF 做了什么?

围绕 RLHF 最大的问题——也是至今仍难以回答的问题——是:“RLHF 训练究竟给模型带来了什么?”近年来,语言模型已从在评测基准范围内被研究的学术实验,转变为通用技术。RLHF 正是这一转变的核心。

首先,我们来看一个刚结束自回归预训练的语言模型会如何回答提问。一个强大的模型——Llama 3.1 405B Base——会接着“The president of the united states in 2006 was”继续写下去:

回复: George W. Bush, the governor of Florida in 2006 was Jeb Bush, and John McCain was an Arizona senator in 2006 - who later lost to obama. September 1 - U.S. President Bush signs an executive order to provide more options for faith-based organizations when delivering social services that are paid for with federal funds. January 1 - The current deadline set by United States Congress in the Unlawful Internet Gambling Enforcement Act, aka UIGEA. search: Amendments to the 1961 International Convention for the Protection of New Varieties of Plants require plant breeders' rights include farmer' s privilege. 2009 was a common year starting on Thursday of the Gregorian calendar, the 2009th year of the Common Era (ce) and Anno Domini (ad) designations, the 9th year of the 3rd millennium, the 9th year of the 21st century, and the 10th and last year of the 2000s decade.

显而易见,这个模型是在续写文本,并附带了互联网上常见的其他元数据。

相比之下,一个经过 RLHF (以及其他后训练手段)训练的模型,回答会完全不同。把同样的问题“The president of the united states in 2006 was,”交给 Tulu 3 405B,它会简洁地答道:

回复: George W. Bush was the president of the United States in 2006. He served two terms in office, from January 20, 2001, to January 20, 2009.

这种风格上的变化，正是本书所描述的后训练方法带来的下游结果。

理解 RLHF 如何起作用，最有说服力的切入角度是思考风格（style）如何影响你与语言模型的互动。信息呈现的风格——与语调或格式密切相关——对信息的接受方式至关重要。风格常被用来描述模型的“举止”。要看出差异，请看同一个问题下的两种回答：

用户: 救命，我明天要做一场演讲，现在慌得不行。

一种是生硬、缺乏共情的风格：

回复: 你会没事的。把幻灯片练几遍，睡一觉，别想太多。把你会的讲出来就行了。

另一种是更温暖、更有支持感的风格：

回复: 这听起来确实压力很大，而且这是很正常的反应。如果可能的话，现在就快速试讲一遍，挑出你最想让听众记住的一两个点，然后允许自己去休息——明天保持清晰和镇定，比今晚硬啃重要得多。

另一方面，**格式**（format）指的是答案如何被组织。现代模型以大量使用 Markdown 排版著称：列表、换行、表情符号。看同一问题的两种差别很大的回答：

用户: 怎么改善我的睡眠质量？

早期语言模型给出的简单回答：

回复: 尽量每晚在同一时间上床，下午晚些时候避免咖啡因，保持卧室安静、昏暗。

或者一个更复杂、更丰富的回答：

回复: 实践中的更好睡眠

目标: 让你的作息可预测，让环境足够无聊，以至于大脑放弃抵抗。

今晚（速效项）:

1. 睡前一小时把灯光调暗。
2. 午饭后不再摄入咖啡因；酒精尽量少。
3. 如果躺着睡不着，就起来做点安静的事，直到再次有困意。

日常基本功（影响最大）:

- 固定起床时间（周末也是）→ 锚定你的生物钟。
- 早晨见光 5-10 分钟 → 帮助设定昼夜节律。
- 房间凉爽、昏暗（风扇/眼罩）→ 更容易保持睡眠。

如果你只想要一条简单规则: 固定起床时间 + 咖啡因截止 + 睡前放松流程

如果睡眠问题持续存在或较严重，值得咨询临床医生——许多问题都是可以有效治疗的。

指令微调能让模型稳定地以问答格式作答，而 RLHF 则把这些回答打磨成我们今天期待的那种可靠、温暖、有吸引力的样子。

现代研究已经确立：RLHF 是一种把细微的风格特征及相关行为特征融入模型的通用方法。RLHF 早期一个广为人知的用处是在安全领域的应用 [7] [5]——RLHF 让模型能够在多样化的数据集上同时

做到“有帮助”和“无害”。与其它后训练技术（如指令微调）相比，RLHF 在不同领域之间的泛化性好多 [8] [9]——这有助于造出有效的通用模型。

从直观上看，这源于两种优化方式的差异。指令微调训练模型：在当前文本与其见过的示例接近时，预测下一个词。它是在优化模型，使其更规律地输出文本中的某些特征。这是逐 token 的更新。

而 RLHF 是在回复层面调整补全内容，而不是专门盯着下一个词。此外，它告诉模型什么样的回复更好，而不是一个它必须学会的特定回复。RLHF 还会向模型展示它应当避免哪些类型的回复，也就是负面反馈。实现这一点的训练通常被称为对比式损失函数（其损失由两个或多个样本之间的比较算出，而不是由每个样本独立算出），本书会反复提到它。

这种灵活性是 RLHF 的一大优势，但也带来了实现上的挑战。这些挑战主要集中在如何控制优化。正如本书将要展开的，实现 RLHF 往往需要训练一个奖励模型，但做这件事的最佳实践尚未牢固确立，且依赖于具体应用领域。因此，优化本身容易发生过度优化（over-optimization），因为我们的奖励信号充其量只是一个代理目标，需要正则化来约束。受限于此，有效的 RLHF 需要一个很强的起点——所以 RLHF 无法独自解决所有问题，必须放在后训练这一更宽广的视角下看待。

由于这种复杂性，实现 RLHF 的成本远高于简单的指令微调，并且可能带来意料之外的麻烦，比如长度偏置（length bias）[10] [11]。对于追求绝对性能的模型训练工作而言，RLHF 已被确立为获得强劲微调模型的关键；但它在算力、数据成本和时间上都更昂贵。在 ChatGPT 之后 RLHF 的早期历史中，有许多研究论文声称通过有限的指令微调就能近似达到 RLHF 的效果；但随着文献走向成熟，“RLHF 及相关方法是模型性能的核心阶段、无法轻易省去”这一点被一再证实。

1.3 RLHF 配方实操走查

为了给全书铺好台面，有必要先弄清“做 RLHF”在实际中是什么样子——用一个最小的例子，避开那些在直觉尚未牢固之前很难把握的技术术语。本节沿用的，是 2022 年 OpenAI 的 InstructGPT 模型所确立的、被称为“经典三阶段 RLHF 配方”的做法 [3]。

第一步，是把模型从“续写文本的基座模型”转变为“能以问答格式运作的指令跟随模型”。做法是：在一批精心构造的数据上，使用与预训练相同的下一词预测损失——这些数据只以问答格式呈现给模型。在让模型看过这些高质量回答之后，就可以用一段特定的 token 序列来提示模型，使它知道：面对任何提问，都应以一个更明确的“助手”人格来作答。

有了模型应当如何作答的形态这一基础，接下来的两步共同作用，提升回答的整体质量。这两步的作用，是把问题设置成可以用强化学习来更新模型、让它更有帮助的形式。

这两步中的第一步，是训练一个捕捉人类偏好的奖励模型。要把强化学习应用到某个问题上，你需要一个指示好坏的奖励函数。奖励模型的目标是构造出一个标量信号，供之后用 RL 优化。实践中，这相当于在一批“文本之间的偏好关系”数据上微调一个语言模型（通常就是上一步得到的那个指令微调模型）。这份数据由多种提示、模型补全和标注者共同收集而来，力图捕捉一个稳健的信号：什么样的回答更好。奖励模型学习文本中哪些特征优于另一些；于是在推理时（以及在 RL 中作为奖励信号时），它能对任意输入文本给出“有多好”的评分。

有了这两样东西——一个问答模型和一个奖励模型——我们就具备了拼装起来、真正执行人类反馈强化学习（RLHF）所需的全部条件。RLHF 阶段的实际流程是：取一批能代表模型应当擅长的任务的提示，生成一堆补全，让奖励模型给它们排序，然后用 RL 找出如何改动模型让它变得更好。其基本原语是：强化学习获得“哪些动作是好的”这一信号（这里的“动作”就是语言模型生成的 token），

并推导出把不同动作归因到模型不同参数的更新规则。RLHF 的最后一个阶段就是移动参数，让好的 token 更可能出现，并且迭代地进行，以维持初始模型的通用能力。

当 RL 完成、性能趋于饱和，这通常就是最终交付给用户的模型。

本书通篇会介绍许多种做 RLHF 的配方，以及构成后训练更广谱系的其它相关优化方法。它们的出现，都是为了解决语言模型面临的更困难的挑战，并让原本 RLHF 方法的优势更加强大。

1.4 后训练的直觉理解

我们已经说明：RLHF 这一具体技术、以及后训练这一总范畴，对最新模型的性能及其输出方式的改变都至关重要——但还没有说明 RLHF 为什么有效。这里给出一个简单的类比，来解释为什么在任何一个基座模型之上都能取得如此多的基准提升。

我对后训练潜力的这种描述方式，被称为后训练的**激发式解读**（elicitation interpretation）——我们所做的一切，就是通过放大基座模型中有价值的行为，把它的潜力激发出来。

为了让这个比喻更直观，我们把**基座模型**——由大规模下一词预测预训练得到的语言模型——类比为建造复杂系统时的其它基础部件。这里用车架来打比方，车架定义了“一台车能被造出来的空间边界”。想想一级方程式（F1）：大多数车队每年都从全新的车架和引擎开始。然后他们把整年时间花在空气动力学和系统改动上（这当然是一种简化），从而可以大幅提升赛车性能。最好的 F1 车队在一个赛季内取得的提升，远超车架带来的提升。

后训练也是如此：随着人们越来越了解某个静态基座模型的脾性与倾向，就能从中榨出大量性能。最好的后训练团队能在极短时间内榨出大量性能。这套技术涵盖了预训练末期及其之后的全部环节：“中期训练”（mid-training，例如退火、预训练末期的高质量网页数据）、指令微调、RLVR、偏好微调等等。一个很好的例子是 Allen Institute for AI 的全开源小型专家混合（MoE）模型 OLMoE Instruct，从第一版到第二版的变化。第一版发布于 2024 年秋 [12]；第二版只**更新了后训练**，预训练主体未变，而主流基准上的评测均值就从 35 提升到了 48 [13]。

这个想法的要点是：基座模型内部蕴含着大量智能与能力，但由于它只会以“下一词预测”而不是“问答”的方式作答，所以需要在它周围做大量工作——也就是后训练——才能造出优秀的最终模型。

再看 OpenAI 于 2025 年 2 月发布的 GPT-4.5：它作为消费级产品基本上是失败的，因为基座模型太大，无法服务于数百万用户；但你可以把它视为一个远更有活力、更令 OpenAI 兴奋的构建基础。按这个直觉，**基座模型决定了最终模型潜力的绝大部分**，而后训练的职责就是把它全部培育出来。

我把这一直觉称为**后训练的激发理论**（Elicitation Theory of Post-training）。这一理论与一个现实相吻合：用户看到的性能提升，大部分来自后训练。因为它意味着，一个在互联网上预训练出来的模型，其潜在能力比我们单纯“教”给它的更多——后者例如在早期后训练（即只做指令微调）阶段反复投喂某些窄分布的样本。后训练的挑战在于：把模型从“下一词预测”重新塑造成“对话问答”，同时把预训练获得的全部知识与智能提取出来。

与此相关的一个想法，是论文 LIMA: Less is More for Alignment 提出的**表层对齐假说**（Superficial Alignment Hypothesis）[14]。这篇论文在细节上抓住了一些重要直觉，但从大局来看，它的理由找错了。作者写道：

模型的知识与能力几乎完全是在预训练期间学到的，而对齐教给它的只是：在与用户交互时应当使用哪种格式的子分布。如果这一假说成立——即对齐大体上关乎风格学习——那么表层对齐假说的一个推论就是：可以用相当少的样本，把预训练语言模型调得足够好。

深度学习的所有成功经验本应告诉你：**扩展数据规模对性能至关重要**。这里的重大差异在于，作者讨论的是对齐与风格——也就是当时学术界后训练的焦点。用几千条指令微调样本，确实能大幅改变一个模型，并提升某一小类评测的表现，比如 AlpacaEval、MT-Bench、Arena（前身为 Chatbot Arena，一个让用户对匿名模型回答进行两两比较的平台）等等。但这些提升并不总能转化为更困难的能力——这也是为什么 Meta 不会仅用这个数据集去训练它的 Llama Chat 模型。学术成果有它的教益，但如果你要理解整个技术演进的大图景，就必须谨慎解读。

这篇论文真正说明的是：**用少量样本就能显著改变模型**。这一点我们早就知道，它对模型的短期适配也很重要；但它关于性能的论证，会给随意浏览的读者留下错误的结论。

如果换掉数据，对模型性能和行为的影响可能大得多，而且远谈不上“表层”。今天的基座语言模型（不做任何后训练）可以在一些数学题上用强化学习训练，学会输出完整的思维链推理，进而在 BigBenchHard、Zebra Logic、AIME 等一整套推理评测上取得更高分。

表层对齐假说之所以是错的，和“认为 RLHF 与后训练只是在调语气”的人之所以是错的一样。这是我们在 2023 年不得不跨过的、整个领域的教训（尽管许多 AI 观察者仍固守这一信念）。后训练早已远远超出那个阶段，我们正逐渐认识到：模型的风格运行在行为之上——比如如今流行的长思维链。

随着 AI 社区把后训练进一步推向智能体与推理模型的时代，表层对齐假说会进一步瓦解。RL 方法在前沿语言模型训练所需算力中所占的份额正越来越大。自从“可验证奖励的强化学习”（RLVR）在我们 2024 年秋的 Tulu 3 工作中被提出以来 [6]，后训练所用的算力规模已急剧增长。因普及 RLVR 而闻名的 DeepSeek R1，后训练只占其总计算量的约 5%——R1 的 RL 训练用了 147K H800 GPU 小时 [15]，而预训练底层的 DeepSeek V3 基座模型用了 2.8M GPU 小时 [16]。

截至 2026 年，研究 RL 扩展核心方法的科学表明：单次消融实验就可能消耗 10–100K GPU 小时 [17]——相当于 Olmo 3.1 Think 32B（2025 年 11 月发布）RL 阶段所用的算力，后者在 200 张 GPU 上训练了 4 周 [18]。截至 2026 年，规模化的后训练科学仍处于极早期，它借鉴预训练语言模型的思想与方法，并将其应用到这一新领域；因此具体的 GPU 小时数还会变化，但后训练算力持续增长的趋势会延续下去。总体而言，**后训练的激发理论，可能只有在采用较轻量后训练配方时才成立**——也就是那些用于把模型专门化的做法——相对于算力密集型的前沿模型而言。

1.5 我们如何走到今天

为什么这本书在现在这个时候有意义？未来会有多少变化？

后训练——从原始预训练语言模型中激发强大行为的手艺——自 ChatGPT 发布（引发了 RLHF 的新一轮热度）以来，已经经历了许多季节与情绪。在 Alpaca [19]、Vicuna [20]、Koala [21] 和 Dolly [22] 的时代，人们用有限的人类数据点，加上大量 Self-Instruct 风格的合成数据，去微调最初的 LLaMA，使其表现出与 ChatGPT 相似的行为。这些早期模型的评判标准**完全靠感觉**（以及人工评估）——因为我们都被“这些小模型竟然能在各个领域展现出如此惊人的行为”这一点迷住了。那份兴奋是合理的。

开放后训练跑得比闭源同行更快、发布的模型更多、声量也更大。公司们则在仓促应对，例如 DeepMind 与 Google Brain 的合并、或新实验室的创立，都需要时间跟上。开放配方经历过“猛冲然后落后”的阶段。

继 Alpaca 等之后的那段时期，是开放配方的第一次落后，其标志是对人类反馈强化学习（RLHF）的怀疑与质疑——而 RLHF 正是 OpenAI 强调的、让初代 ChatGPT 取得成功的关键技术。许多公

司怀疑自己是否需要做 RLHF。当时“指令微调就足以完成对齐”这句话非常流行，以至于尽管有明显反证，它至今仍有余威。

这种对 RLHF 的怀疑持续了相当长一段时间，尤其是在开放社区——那里的团队负担不起 10 万到 100 万美元量级的数据预算。而那些早早拥抱它的公司最终胜出。Anthropic 在整个 2022 年发表了大量 RLHF 研究，如今拥有可以说是最好的后训练 [23] [5] [24]。开放团队在艰难地复现、甚至只是知晓闭源基础技术方面的挣扎，与领先闭源模型之间的差距，是一个反复出现的主题。

开放对齐方法与后训练的第一次转向，是直接偏好优化（DPO）的故事 [25]：它表明，你可以直接在成对偏好数据上做梯度更新，从而用更少的活动部件解决与 RLHF 相同的优化问题。DPO 论文于 2023 年 5 月发表，但直到 2023 年秋，都没有出现明显有影响力的、用它训练出来的模型。这一局面随着几个突破性的 DPO 模型发布而改变——而它们全都取决于找到了一个更好的、更低的学习率。Zephyr-Beta [26]、Tulu 2 [27] 以及许多其他模型表明：后训练的 DPO 时代已经开启。Chris Manning 甚至真的感谢我“拯救了 DPO”。

自 2023 年末起，偏好微调成了发布一个像样模型的最低门槛。DPO 时代延续到 2024 年，表现为这个算法上无穷无尽的变体；但我们已经深深走入开放配方的又一次低谷。开放后训练配方，已经把可获得的知识与资源用到了极限。在 Zephyr 和 Tulu 2 一年之后，同一个突破性数据集 UltraFeedback，在开放配方的偏好微调中可以说仍属最先进水平 [28]。

与此同时，Llama 3.1 [29] 和 Nemotron 4 340B [30] 的技术报告给了我们实质性的提示：大规模后训练要复杂得多、影响也大得多。闭源实验室在做完整的后训练——一个由指令微调、RLHF、提示词设计等构成的大型多阶段流程——而学术论文只是触及了表面。Tulu 3 代表了一次全面的公开努力，为未来的学术后训练研究打下基础 [6]。

后训练是一个复杂的过程，要按不同顺序施加前述各种训练目标，以针对特定能力。本书旨在提供一个理解这全部技术的平台；随着领域成熟，“如何交错使用它们”的最佳实践也会逐渐浮现。

后训练当前的创新主战场，是可验证奖励的强化学习（RLVR）、广义的推理训练，以及相关想法。这些较新的方法大量建立在 RLHF 的基础设施与思想之上，但演化快得多。本书写作的目的，是在 RLHF 经历最初的高速变化之后，为其第一份稳定的文献留下记录。

1.6 本书范围

本书希望涉及完成经典 RLHF 实现的每一个核心步骤。它不会覆盖这些组件的全部历史，也不会覆盖最近的研究方法，只讲那些已被反复证实的技术、问题与权衡。

1.6.1 章节概览

本书包含以下章节：

1.6.1.1 导引 全书通用的参考资料与背景。

1. 引言：RLHF 的总览，以及本书提供了什么。
2. RLHF 简史：RLHF 技术史上的关键模型与论文。
3. 训练总览：RLHF 的训练目标如何设计，以及理解它的基础。

1.6.1.2 核心训练流程 用于优化语言模型、使其与人类偏好对齐的一整套技术。

4. 指令微调：让语言模型适应问答格式。

5. 奖励建模：从偏好数据训练奖励模型，它可作为 RL 训练的优化目标（或用于数据筛选）。
6. 强化学习：在 RLHF 全过程中用于优化奖励模型（及其它信号）的核心 RL 技术。
7. 推理与推理时扩展：新的 RL 训练方法在推理时扩展上相对于后训练和 RLHF 的作用。
8. 直接对齐算法：不先学奖励模型，而是直接从成对偏好数据优化 RLHF 目标的算法。
9. 拒绝采样：结合奖励模型与指令微调来对齐模型的一项基础技术。

1.6.1.3 数据与偏好 驱动 RLHF 的数据背景，以及它试图解决的大图景问题。

10. 偏好的本质：为什么需要人类偏好数据来驱动并理解 RLHF。
11. 偏好数据：如何为 RLHF 收集偏好数据。
12. 合成数据：从人类数据向合成数据的转移、AI 反馈如何工作，以及如何从其他模型蒸馏。
13. 工具使用与函数调用：训练模型在其输出中调用函数或工具的基础。

1.6.1.4 实践考量 实现与评估 RLHF 时的根本问题与讨论。

14. 过度优化：对 RLHF 为何出错的定性观察，以及为什么在奖励模型这种“软”优化目标下过度优化不可避免。
15. 正则化：把优化工具约束在参数空间有效区域内的手段。
16. 评估：评估（以及提示词）在语言模型中不断演变的作用。
17. 塑造模型性格与产品：随着各大 AI 实验室用它来微妙地匹配自家产品，RLHF 的适用范围正在如何变化。

1.6.1.5 附录 定义与扩展讨论的参考资料。

- 附录 A - 定义：本书用到的 RL、语言建模及其他 ML 技术的数学定义。
- 附录 B - 超越“只是风格”：由于风格在信息传递中扮演关键角色，RLHF 在提升模型用户体验方面的作用常被低估。

1.6.2 目标读者

本书面向的是在语言建模、强化学习和通用机器学习方面具备入门级经验的读者。它不会为所有技术提供详尽的文档，只覆盖理解 RLHF 所必需的部分。

1.6.3 如何使用本书

本书的诞生，很大程度上是因为 RLHF 工作流中的若干重要主题缺乏规范参考。考虑到 LLM 整体的进步速度，再加上收集与使用人类数据本身的复杂性，RLHF 是一个异常“学术化”的领域：已发表的结果常常噪声很大，且难以在多种设定下复现。为培养牢固的直觉，建议读者就每个主题多读几篇论文，而不是把任何单一结果当作定论。为便于做到这一点，本书为每个论断都附上了学术风格的引用，指向其规范来源。

本书的贡献，是给你“尝试一个玩具实现、或深入文献”所需的最低限度知识。这不是一本面面俱到的教科书，而是一本用于提醒与快速上手的速览小书。

本书的纸质版由 Manning 于 2026 年 7 月出版，而网络版会持续收录小幅改进与勘误修正。如果你发现错别字或重要遗漏，欢迎在 GitHub 上提交修复或建议。

1.6.4 关于作者

Nathan Lambert 博士是一位研究者与写作者，专注于构建语言模型的开放科学。他拥有机器人学博士学位，在 ChatGPT 发布后不久组建了一个 RLHF 团队，由此走上这条路。在 Allen Institute for AI (A12) 和 Hugging Face 期间，他发布了许多用 RLHF 训练的模型，以及配套的数据集和训练代码库。例如 Zephyr-Beta、Tulu 2、OLMo、TRL、Open Instruct 等。他就 RLHF 写过大量内容，包括许多博客文章和学术论文。

1.7 RLHF 的未来

随着对语言建模的持续投入，传统 RLHF 方法衍生出许多变体。口语上的 RLHF，已经变成多种相互重叠的方法的同义词。RLHF 是偏好微调 (PreFT) 技术的一个子集，后者还包括直接对齐算法 (见第 8 章)——即 DPO 之后那一类方法：直接在偏好数据上做梯度更新来解决偏好学习问题，而不训练中间的奖励模型。RLHF 是与语言模型“后训练”快速进展关联最紧密的工具；而后训练涵盖了在主要以网页数据做大规模自回归训练之后的所有训练。本教材是对 RLHF 及其直接邻近方法 (如指令微调) 的宽泛概览，也包括为开展 RLHF 训练而搭建模型所需的其它实现细节。

随着用 RL 微调语言模型的成功案例不断涌现——例如 OpenAI 的 o1 推理模型——RLHF 将被视为那座桥梁：它促成了后续对“用 RL 方法微调大型基座模型”的更多投入。与此同时，尽管在不久的将来，聚光灯可能更强烈地打在 RLHF 中“RL”这一部分上——把它当作在重要任务上最大化性能的手段——但 RLHF 的核心意义在于：它是一面透镜，用来研究现代形态 AI 所面临的宏大问题。我们如何把人类价值与目标的复杂性，映射到我们日常使用的系统之中？本书希望成为围绕这些问题、未来数十年研究与教训的基石。

2 RLHF 简史

RLHF 及其相关方法都非常年轻。我们梳理这段历史，是为了说明这些流程被正式确立的时间有多近，以及其中有多少内容仍停留在学术文献里。借此我们想强调：RLHF 正在飞速演化。所以本章为全书定一个基调——本书对某些方法会持保留态度，并预期某些细节可能围绕少数核心实践发生变化。除此之外，这里列出的论文与方法，也解释了 RLHF 流程中许多组件为何是今天这个样子；因为其中一些奠基性论文所针对的应用，与现代语言模型完全不同。

本章详述把 RLHF 领域带到今天这一步的关键论文与项目。它不是对 RLHF 及相关领域的全面综述，而是一个起点，讲述我们如何走到今天。它有意识地聚焦于导向 ChatGPT 的近期工作。RL 文献中关于“从偏好中学习”的研究还有很多 [31]。如需更完整的清单，应当查阅专门的综述论文 [32]、[33]。




图 2: 本章讨论的 RLHF 关键发展时间线：从早期“从偏好中做 RL”的工作，到 RLHF 被大语言模型采用。

2.1 起源到 2018：从偏好中做 RL

这个领域近来随着深度强化学习的发展而流行起来，并已扩展为许多大型科技公司对 LLM 应用的更广泛研究。不过，今天使用的许多技术，与早期“从偏好中做 RL”文献的核心技术有着很深的渊源。

最早提出类似现代 RLHF 思路的论文之一是 *TAMER*。TAMER: *Training an Agent Manually via Evaluative Reinforcement* 提出的做法是：由人类反复给智能体的动作打分，据此学习一个奖励模型，再用它来学习动作策略 [34]。同期或不久之后的其他工作提出了 actor-critic 算法 COACH，它用人类反馈（正面和负面）来调整优势函数 [35]。

最重要的参考文献是 Christiano 等 2017 年的工作，它把 RLHF 应用于 Atari 游戏中的智能体轨迹之间的偏好 [1]。这项引入 RLHF 的工作，紧跟在 DeepMind 关于深度 Q 网络 (DQN) 的奠基性强化学习工作之后——后者表明 RL 智能体可以从零学会玩流行的电子游戏。这项工作表明：在某些领域，让人类在轨迹之间做选择，比直接与环境交互更有效。它借助了一些巧妙的条件设定，但无论如何都令人印象深刻。

这一方法后来被更直接的奖励建模工作所扩展 [36]；而早期 RLHF 工作中对深度学习的采用，以一年后把 TAMER 扩展到神经网络模型为标志 [37]。

这个时代开始转向：奖励模型作为一种通用概念被提出，用来研究“对齐”，而不仅仅是解决 RL 问题的工具 [38]。




图 3: Christiano 等 (2017) 提出的核心 RLHF 循环: 奖励预测器由轨迹片段的比较异步训练, 智能体则最大化预测奖励。

2.2 2019 到 2022: 在语言模型上做人类偏好强化学习

人类反馈强化学习 (早期也常被称为 “人类偏好强化学习”) 很快被越来越多转向规模化大语言模型的 AI 实验室采纳。这项工作很大一部分始于 2019 年的 GPT-2 与 2020 年的 GPT-3 之间。2019 年最早的工作 *Fine-Tuning Language Models from Human Preferences* 与现代 RLHF 工作、以及本书将要讲的内容, 有许多惊人的相似之处 [39]。许多规范术语——如学习奖励模型、KL 距离、反馈示意图等——都是在这篇论文中被确立的; 尽管它最终模型的评估任务与能力, 和今天人们所做的不一样。自此, RLHF 被应用于多种任务。重要的例子包括通用摘要 [2]、书籍的递归摘要 [40]、指令跟随 (InstructGPT) [3]、浏览器辅助问答 (WebGPT) [4]、用引文支撑答案 (GopherCite) [41], 以及通用对话 (Sparrow) [42]。

除了应用之外, 还有若干奠基性论文为 RLHF 的未来划定了关键领域, 包括:

1. 奖励模型的过度优化 [43]: RL 优化器对 “以偏好数据训练出的模型” 过拟合的能力;
2. 把语言模型作为对齐研究的一个通用领域 [23];
3. 红队测试 [44]——评估语言模型安全性的过程。

针对聊天模型应用的 RLHF 精化工作持续推进。Anthropic 在早期版本的 Claude 上大量使用它 [5], 早期 RLHF 开源工具也随之出现 [45]、[46]、[47]。

2.3 2023 至今: ChatGPT 时代

ChatGPT 的发布公告非常明确地说明了 RLHF 在其训练中的作用 [48]:

我们使用人类反馈强化学习 (RLHF) 训练了这个模型, 方法与 InstructGPT 相同, 但在数据收集设置上有细微差异。

自此以后, RLHF 被广泛用于领先的语言模型。众所周知, 它被用于 Anthropic 为 Claude 设计的宪法式 AI [24]、Meta 的 Llama 2 [49] 与 Llama 3 [29]、NVIDIA 的 Nemotron [30]、Ai2 的 Tulu 3 [6], 以及更多模型。

今天, RLHF 正在成长为更广的偏好微调 (PreFT) 领域, 其中包括一些新应用: 针对中间推理步骤的过程奖励 [50] (见第 5 章); 受直接偏好优化 (DPO) 启发的直接对齐算法 [25] (见第 8 章); 从代码或数学的执行反馈中学习 [51]、[52], 以及受 OpenAI o1 启发的其他在线推理方法 [53] (见第 7 章)。

3 训练总览

本章先对 RLHF 训练做一个粗线条的总览，具体细节留到本书后面展开。RLHF 虽然只优化一个简单的损失函数，却要按顺序训练多个不同的 AI 模型，再把它们连接成一个复杂的在线优化过程。

这里我们先介绍 RLHF 的核心目标：在带距离正则项的前提下，优化一个关于人类偏好的代理奖励（并说明它与经典 RL 问题的关系）。然后我们会展示一些经典流程，说明用 RLHF 打造领先模型时，它如何与后训练的其他方法衔接。这些示例流程会成为本书后续内容的参照——后面我们会讲做 RLHF 时可选择的不同的优化方案，并回头指出不同关键模型在训练中各用了哪些步骤。

3.1 问题形式化

人类反馈强化学习（RLHF）的优化，建立在标准 RL 设定之上。在 RL 中，智能体在给定环境状态 s_t 时，从策略 $\pi(a_t | s_t)$ 中采样动作 a_t ，以最大化奖励 $r(s_t, a_t)$ [54]。策略是一个把每个状态映射到动作概率分布的函数。演化为现代 RLHF 文献的早期策略，属于所谓的深度强化学习——即用神经网络来学习上述函数。传统上，环境按转移（动力学） $p(s_{t+1} | s_t, a_t)$ 演化，初始状态服从分布 $\rho_0(s_0)$ 。策略与动力学共同诱导出一个轨迹分布。一条轨迹的总体概率，等于初始状态概率、策略做出的每一次动作选择、以及环境产生的每一次状态转移三者的乘积：

$$p_\pi(\tau) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi(a_t | s_t) p(s_{t+1} | s_t, a_t). \quad (1)$$

在一个长度为 T 的有限回合（episode）中，RL 智能体的目标是求解如下优化问题，其中 γ 是 0 到 1 之间的折扣因子，用来权衡近期奖励与远期奖励的相对可取性：

$$\max_{\pi} \mathbb{E}_{\tau \sim p_\pi} \left[\sum_{t=0}^{T-1} \gamma^t r(s_t, a_t) \right]. \quad (2)$$

给定策略的期望回报通常记作 $J(\pi)$ ，其最优值记作 $J^* = \max_{\pi} J(\pi)$ 。

对于持续性任务，通常取 $T \rightarrow \infty$ ，并依靠折扣（ $\gamma < 1$ ）使目标函数保持良定义。优化该表达式的多种方法将在第 6 章讨论。




图 4: 标准 RL 循环

RL 循环的一个标准图示见 图 4（可与 图 7 中的 RLHF 循环对照）。

3.1.1 一个简单例子：恒温器

为了对 RL 在做什么建立基本直觉，设想一个恒温器试图把房间维持在 70°F 的目标温度。在 RL 中，智能体一开始对任务一无所知，必须通过试错发现一个好策略。恒温器这个例子包含以下组件（各部分如何对应 式 1 中的轨迹分布，见 图 5）：

- **状态** (s_t)：当前室温，例如 65°F 。
- **动作** (a_t)：打开或关闭加热器。
- **奖励** (r)：温度与目标相差 2° 以内时为 $+1$ ，否则为 0 。
- **策略** (π)：根据当前温度决定开或关加热器的规则。下面是恒温器可能学到的一个策略——依环境的具体转移动力学不同，它未必最优：

$$\pi(a_t = \text{on} \mid s_t) = \begin{cases} 1 & \text{if } s_t < 70^\circ\text{F} \\ 0 & \text{otherwise} \end{cases} \quad (3)$$

- **转移**：加热器打开时房间升温，关闭时降温。智能体通过动作影响这些动力学，但底层物理——房间升温或降温有多快——不在它的控制之内。




图 5: 轨迹分布（式 1）中的每一项与恒温器 RL 示例的对应关系。

起初，恒温器的策略基本是随机的——它不管当前温度就胡乱开关加热器，房间温度剧烈波动。经过许多回合的试错，智能体发现：房间冷时开加热器、热时关掉，能带来更多奖励，于是逐渐收敛到一个合理的策略。这就是 RL 的核心循环：观察状态、选择动作、获得奖励、更新策略，以便随时间获得更多奖励。

3.1.2 经典 RL 示例：CartPole

要看一个动力学连续、内容更丰富的例子，可以考虑经典的 *CartPole*（倒立摆）控制任务——它出现在许多 RL 教材、课程甚至研究论文中。恒温器只有一个状态变量和二元动作，而 *CartPole* 涉及四个连续状态变量和基于物理的转移，因此成为 RL 算法的标准基准。

- **状态** (s_t)：小车位置/速度与杆的角度/角速度：

$$s_t = (x_t, \dot{x}_t, \theta_t, \dot{\theta}_t). \quad (4)$$

- **动作** (a_t)：对小车施加左/右方向的水平力，例如 $a_t \in \{-F, +F\}$ 。




图 6: CartPole 环境，展示状态变量 (x 、 $\dot{x}$ 、 θ 、 $\dot{\theta}$) 与动作 ($\pm F$)。

- **奖励 (r)**：一个简单的奖励是——只要杆保持平衡且小车留在轨道上（例如 $|x_t| \leq 2.4$ 且 $|\theta_t| \leq 12^\circ$ ），每一步给 $r_t = 1$ ；任一边界被突破则回合终止。
- **动力学 / 转移 ($p(s_{t+1} | s_t, a_t)$)**：在许多环境中动力学是确定性的（即 p 为点质量），可用步长 Δt 的欧拉积分写成 $s_{t+1} = f(s_t, a_t)$ 。一个标准的简化 CartPole 更新用到这些常量：小车质量 m_c 、杆质量 m_p 、杆半长 l 、重力 g (α 是一个带加速度量纲、按质量归一化的中间量)：

$$\alpha = \frac{a_t + m_p l \dot{\theta}_t^2 \sin \theta_t}{m_c + m_p} \quad (5)$$

$$\ddot{\theta}_t = \frac{g \sin \theta_t - \cos \theta_t \alpha}{l \left(\frac{4}{3} - \frac{m_p \cos^2 \theta_t}{m_c + m_p} \right)} \quad (6)$$

$$\ddot{x}_t = \alpha - \frac{m_p l \ddot{\theta}_t \cos \theta_t}{m_c + m_p} \quad (7)$$

$$x_{t+1} = x_t + \Delta t \dot{x}_t, \quad \dot{x}_{t+1} = \dot{x}_t + \Delta t \ddot{x}_t, \quad (8)$$

$$\theta_{t+1} = \theta_t + \Delta t \dot{\theta}_t, \quad \dot{\theta}_{t+1} = \dot{\theta}_t + \Delta t \ddot{\theta}_t. \quad (9)$$

这是前面通用设定（式 2）的一个具体实例：策略选择 a_t ，转移函数推进状态，奖励在回合中累加。

3.1.3 改造标准 RL 设定

RLHF 的 RL 形式化被视为一个开放性更低的问题——为了适配语言模型，RL 中若干关键部件都被赋予了特定定义。从标准 RL 设定到 RLHF 设定，有多处核心改动：下表总结了标准 RL 与用于语言模型的 RLHF 设定之间的这些差异。

1. **从奖励函数转向奖励模型。**在 RLHF 中，用一个从人类偏好学到的模型 $r_\theta(s_t, a_t)$ （或任何其他分类模型）取代环境奖励函数。这大幅提升了方法的灵活性、也增强了设计者对最终结果的控制力，代价是实现复杂度上升。在标准 RL 中，奖励被视为环境的一个静态部件，设计学习算法的人无法改变或操纵它。
2. **不存在状态转移。**在 RLHF 中，领域的初始状态是从训练数据集里采样的提示，而“动作”是对该提示的补全（在标准 RLHF 设定中，提示是固定的，模型的补全并不决定下一个提示）。一个提示加一个补全构成一个完整回合（rollout）——而在经典 RL 问题中，这会是许多重复的“状态-动作、状态-动作”链。
3. **回复级奖励，且不折扣。**RLHF 的奖励归因是针对整段动作序列（由多个生成的 token 组成）进行的，而不是细粒度地逐步进行（这种单步结构在 RL 文献中有时被称为赌博机问题）。为了让 RLHF 的 RL 算法把每个 token 都视为同一个动作的一部分，实现中通常取折扣因子 $\gamma = 1$ （不折扣）——这与标准 RL 不同，后者用 $\gamma < 1$ 在许多连续决策之间平衡短期与长期奖励。

表 1: 标准 RL 与语言模型 RLHF 之间的关键差异。

方面	标准 RL	RLHF（语言模型）
策略	从零学习（随机初始化）	从预训练语言模型微调而来
奖励信号	环境奖励函数 $r(s_t, a_t)$	学到的奖励 / 偏好模型 $r_\theta(x, y)$ （提示 x ，补全 y ）
状态转移	有：动力学 $p(s_{t+1} s_t, a_t)$	通常没有：提示 x 从数据集采样；补全不决定下一个提示
动作	单个环境动作 a_t	一个补全 y （一段 token 序列），从 $\pi_\theta(\cdot x)$ 采样
奖励粒度	通常逐步 / 细粒度	通常是对整个补全的回复级（赌博机式），且通常不折扣（ $\gamma = 1$ ）
时间跨度	多步回合（ $T > 1$ ）	常为单步（ $T = 1$ ），不过多轮对话可建模为更长的时间跨度

考虑到问题的单轮性质，可以把优化重写为不含时间跨度和折扣因子（并且带一个显式的奖励模型）：

$$\max_{\pi} \mathbb{E}_{\tau \sim \pi} [r_\theta(s_t, a_t)]. \quad (10)$$

其结果是：尽管 RLHF 深受 RL 优化器与问题形式化的启发，实际实现与传统 RL 却非常不同。

3.1.4 微调与正则化

在传统 RL 问题中，智能体必须从一个随机初始化的策略开始学习；而 RLHF 是从一个具备许多初始能力的强大预训练基座模型出发。这一强先验给 RLHF 带来了一个需求：必须防止优化偏离初始




图 7: 标准 RLHF 循环

策略太远。为了在微调体制下取得成功，RLHF 技术会采用多种正则化来控制优化。目标是在避免模型陷入过度优化的前提下，仍然让奖励最大化发生（见第 14 章）。对优化函数最常见的改动，是在当前 RLHF 策略与优化起点之间加一个 KL 散度惩罚。训练时设定的超参 β 控制这一约束的强度—— β 越大，模型被约束得越靠近起点； β 越小，优化器追逐奖励的自由度越大：

$$\max_{\pi} \mathbb{E}_{r \sim \pi} [r_{\theta}(s_t, a_t)] - \beta \mathcal{D}_{\text{KL}}(\pi(\cdot|s_t) \| \pi_{\text{ref}}(\cdot|s_t)). \quad (11)$$

在这个框架下，RLHF 训练中相当多的研究都花在“如何花掉一笔固定的 KL 预算”上——这里所谓预算，是以偏离初始模型的距离来度量的。更多细节见第 15 章「正则化」。

3.1.5 优化工具

本书会详述求解这一优化问题的许多流行技术。后训练的常用工具包括：

- **奖励建模**（第 5 章）：训练一个模型来捕捉从偏好数据中收集到的信号，之后它就能输出一个标量奖励，指示未来文本的质量。
- **指令微调**（第 4 章）：RLHF 的前置步骤。通过模仿预先挑选的示例，教模型掌握当今大多数语言模型交互所用的问答格式。
- **拒绝采样**（第 9 章）：最基础的 RLHF 技术——用模仿人类偏好的奖励模型，筛选用于指令微调的候选补全。
- **策略梯度**（第 6 章）：RLHF 奠基性示例中使用的强化学习算法——依据奖励模型给出的信号，更新语言模型的参数。
- **直接对齐算法**（第 8 章）：直接用成对偏好数据优化策略的算法，而不是先学一个中间的奖励模型、之后再优化。

现代用 RLHF 训练的模型总是会用到指令微调，随后再混用其他优化选项。

3.1.6 在后训练语言模型中使用 RL 的隐性优势

接下来的章节会介绍许多后训练优化工具。其中不少——例如拒绝采样（第 9 章）和 DPO 这类直接对齐算法（第 8 章）——都比“把 RL 跑起来”简单得多。然而，尽管替代方案更简单，基于 RL 的方法依然胜出。有些趋势是显而易见的，比如可验证奖励的强化学习（RLVR）带来的推理时扩展；但事实证明，RL 对语言模型来说是一种非常合适的优化工具。实现 RL 所需的基础设施投入远高于指令微调或 DPO 类算法；但说得口语一点，它带来的梯度更新“总体上对模型帮助很大”。这很难量化，但会以几种反复出现的形式体现出来：

原文注：以下两条要点中，“numerical stability with inference tools like vLLM”指的是让模型在与 vLLM 这类推理工具配合时保持数值稳定。

- RL 阶段可以“磨平”模型的粗糙边角，让它更易于对话、更鲁棒（例如通过训练，使其在与 vLLM 这类推理工具配合时数值更稳定）。文献中对确切原因尚无定论，但今天 RL 越来越普遍的采用，本身就印证了这一点。
- RL 可以“精准施治”——模型很擅长学会提示分布落在哪里，而 RL 往往不会“压坏”模型的通用能力。一个很好的例子是 Tulu 3：只在数学提示上做 RL 训练，却能在广泛的任务套件上维持原有能力 [6]。

总体而言，语言模型上的 RL 损失是鲁棒、可扩展、有效且灵活的，这打开了若干新的大规模实验领域。开启这条路的原始方法，正是 RLHF 的工作。

3.2 经典训练流程

随着时间推移，若干模型被公认为 RLHF（或更广义的后训练）的经典流程范例。这些流程反映了当时的数据实践与模型能力。随着流程老去，训练出同等特性的模型会变得更加容易，所需数据也更少。总的趋势是：后训练涉及的优化步骤越来越多、训练算法越来越多、训练数据与评估也越来越多样。

3.2.1 InstructGPT：奠基性的 RLHF 工具

在 ChatGPT 刚问世的那个时期，被广泛接受的（“经典的”）语言模型后训练方法有三个主要步骤，其中 RLHF 是核心 [55] [3] [5]。在一个“基座”语言模型（在大规模网页文本上训练的下一词预测模型）之上进行的这三个步骤，汇总于图 8：

1. 在约 1 万条样本上做指令微调：教模型遵循问答格式，并从主要由人撰写的的数据中习得一些基础技能。
2. 在约 10 万个提示（含成对补全）上训练奖励模型（论文实际用了 3.3 万个提示）：这个模型从指令微调的检查点出发训练，捕捉你在最终训练中希望建模的多样价值取向。奖励模型就是 RLHF 的优化目标。
3. 在另一批约 10 万个提示上用 RLHF 训练指令微调模型（论文精确使用了 3.1 万个，且未说明提示是否与其他阶段复用）：模型针对奖励模型进行优化，提示很可能来自另一批数据；模型先生成回复，再接收评分。

RLHF 完成后，模型就可以部署给用户了。这个流程是现代 RLHF 的基础，但流程已经大幅演化，包含更多阶段和更多数据。




图 8: 早期三阶段 RLHF 流程示意图: SFT、奖励模型, 然后是优化。

3.2.2 Tülu 3: 把 RLVR 引入指令模型

现代版本的后训练涉及多得多的模型版本与训练阶段（远多于 Llama 2 所记录的 5 个 RLHF 步骤 [49]）。一个例子见 图 9，其中模型在收敛前经历了大量训练迭代。




图 9: 现代多轮后训练的示意图。

这个时代及以后训练的最复杂模型，并未公布其训练过程的完整细节。到 2026 年，ChatGPT 或 Claude 这类领先模型都涉及许多轮迭代训练。其中甚至可能包含这样的技术：先训练多个专门化模型，再把权重合并，得到一个能胜任多种子任务的最终模型 [56]（例如 Cohere 的 Command A [57]）。这种多阶段后训练方法（RLHF 在其中扮演主要角色）的一个完全开放的范例是 Tülu 3。Tülu 3 流程由三个阶段组成：

1. 在约 100 万条样本上做指令微调：这个以合成数据为主的数据集取自 GPT-4o、Llama 3.1 405B 等前沿模型的混合输出，教模型通用的指令跟随能力，并为数学、编程等能力打下基础。
2. 在约 100 万对偏好数据上做同策略（on-policy）偏好优化：这一阶段大幅提升模型的“会话感”（例如 Arena——前身为 Chatbot Arena——或 AlpacaEval 2 上的表现），同时也改善指令微调阶段提到的那些技能。
3. 在约 1 万个提示上做可验证奖励的强化学习：这是一个小规模强化学习运行，用于提升数学等核心技能、同时维持整体性能（如今它被视为 DeepSeek R1 等现代推理模型的先声）。

该流程已成功应用于 Llama 3.1 [6]、OLMo 2 [58] 和 SmolLM 系列模型 [59]。




图 10: Tulu 3 流程汇总，含目标技能与多步训练配方。Lambert 等 2024，许可 CC-BY。

3.2.3 DeepSeek R1：为推理而扩展 RLVR

随着 OpenAI o1 等推理语言模型的兴起，后训练的最佳实践再次演化：重新安排并重新分配各训练阶段的算力。关于推理模型后训练流程，目前最清晰的公开记录是 DeepSeek R1 [15]；阿里巴巴规模更大的 Qwen 3 模型（仅指 32B 与 225B MoE 版本）[60]、以及小米的 MiMo 7B [61] 也沿用了类似做法。




图 11: DeepSeek-R1 的多阶段流水线。出自《Nature》上的 DeepSeek R1 论文，图 2，依 CC BY 4.0 [15]。

DeepSeek 的流程（见图 11）如下：

1. 用 10 万余条同策略推理样本“冷启动”：这些数据采样自更早的 RL 检查点 R1-Zero，并经过大量筛选，以便在 DeepSeek-V3-Base 上注入特定的推理过程。DeepSeek 用“冷启动”一词来描述在少量监督数据下开始 RL 学习的方式。
2. 大规模强化学习训练：这一阶段针对各种基准反复让模型接触推理问题，运行 RLVR “直到收

敛”。

3. 拒绝采样与 SFT: 接近收敛时, 他们对 RL 检查点做拒绝采样, 构建约 80 万条样本的 SFT 数据集; 然后在约 3/4 推理问题、1/4 通用查询的筛选混合数据上微调模型, 得到一个通用模型。
4. 在推理问题 (可验证奖励) 上做混合强化学习训练, 并配合通用偏好微调的奖励模型来打磨模型。

如上所述, 该流程也有多种演化, 尤其体现在第 3、4 步如何最终定型模型、再暴露给用户。许多模型会从定制化的指令数据集 (包含思维链序列、由现有模型大量筛选与打磨) 入手, 从而仅凭 SFT 就能快速达到较强行为, 然后再进入 RL [62]。

3.2.4 转向 MOPD 与智能体

推理模型一个关键的产品市场契合点, 是向编程智能体的演化——这带来了经典后训练流程的又一次变化。有两处关键变化。第一, 另一种新训练方法——多教师同策略蒸馏 (MOPD, 见第 12 章)——成为把多种不同技能合并进最终模型的流行工具。第二处更简单: 后训练算力持续快速扩展, 尤其是在强化学习阶段。

小米的 MiMo-V2-Flash 是首个记录现代 MOPD 过程的技术报告 [63], 团队后来还就此写了独立论文 [64]。该技术报告用一种简洁的形式概括了这类后训练流程, 见图 12: 先做通用 SFT, 再做领域专精的教师训练 (更多 SFT 与大规模 RL), 然后用多教师同策略蒸馏 (MOPD) 把它们合并成最终模型。其他模型也采用这一形式的流程, 例如 NVIDIA 的 Nemotron 3 Ultra [65]——大体相似, 只是连续做了两轮跨专家的 MOPD 阶段。总体而言, 这类流程在“迭代模型版本”这一维度 (配方的深度) 上复杂度更低, 但在“需要专精出许多关键专家”这一点 (一种广度) 上复杂度更高。需要注意的是, 前几代后训练同样处理了广泛的任务, 只是在训练过程中切分得没有那么细——也就是说, 大多数任务是在相同的训练阶段里完成的。




图 12: 使用 MOPD 的专精式后训练示意图: 共享 SFT、领域专属 SFT 与 RL, 然后经多教师同策略蒸馏合并为一个 (最终的) 学生模型。

以 MOPD 作为最后阶段的各种模型, 其专家数量各不相同: Nemotron 3 Ultra 超过十个 [65], Kimi K3 为九个 [66], DeepSeek V4 超过十个 [67] (小米 MiMo V2 未报告专家数量)。

后训练流程在不同模型之间仍然差异很大。MOPD 是一个流行的新工具, 但各实验室对它的采用远未达成一致。随着后训练走向成熟、工具箱里的工具越来越多, 流程的差异反而变大了。例如 GLM-5 使用了 MOPD, 但在 MOPD 之前记录了一个更复杂的三阶段 RL 过程, 见图 13, [68]。

随着后训练在现代模型性能中占据更核心的位置, 这些流程将继续演化, 以反映难度、任务与目标所达到的新规模。




图 13: GLM-5 的整体训练流水线。出自 GLM-5 团队论文，图 5，依 CC BY 4.0 [68]。

4 指令微调

早期的大型预训练语言模型以“下一词预测”为目标训练，默认并不带有一个明确的“遵循指令”接口。在 GPT-3 发布前后 [69]，提示（prompting）与上下文学习（in-context learning）成为让单个模型适配多种任务的常用方式（尽管针对具体任务做微调仍然普遍）——做法是在上下文中给出示例，再让模型完成类似的任务。一个很自然的下一步就是**指令微调**：教模型以“指令—回答”的格式作答，而不只是续写文本。例如，给定提示“What is the capital of France?”，基座模型可能会续写成“What is the capital of Germany? What is the capital of Italy?...”——只是把提问的模式延续下去；而一个经过指令微调的模型会回答“The capital of France is Paris.”

指令微调在两股研究潮流的交汇处腾飞起来。第一，NLP 从各自定制的微调任务设定，转向统一的“文本到文本”或指令式框架，这样一来，把五花八门的数据集标准化、并用一个模型训练多种任务就变得直接可行。把任务框架统一起来的代表性工作包括 *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer* (T5 系列) [70]、*Finetuned Language Models Are Zero-Shot Learners* (FLAN 数据集) [71]、*Multitask Prompted Training Enables Zero-Shot Task Generalization* (T0 系列) [72]，以及 *Cross-Task Generalization via Natural Language Crowdsourcing Instructions* (Natural Instructions 数据集) [73]。第二，预训练语言模型的规模化、以及提示/上下文学习的兴起表明：单个模型能够跨任务泛化；而当模型被明确地在“指令—回答”示例上训练过之后，这种泛化会可靠得多。这两股潮流合在一起，开启了一个“在大量指令数据上微调预训练语言模型”的时代——也就是如今通常所说的**指令微调**（IFT）或**监督微调**（SFT），它让训练通用模型这件事对更广泛的群体变得可行。

自被发现以来，指令微调（口语上也常直接叫 *instruction tuning*）已经成熟，并成为许多语言模型流水线中的标准做法。从核心上说，IFT 是让语言模型适配到某个目标任务分布的最简单方法。它为 RLHF 打下基础：把模型准备好去接受一种称为“问答”的指令格式；同时，它也是人们把现代技术应用到新领域时所使用的第一个工具。没有最基本的指令跟随能力，本书讨论的多数流水线——从偏

好数据收集到在线 RLHF 优化——都无法进行。

指令微调本身在别处已有大量论述，并且它在核心上属于监督学习；所以本章聚焦于对 RLHF 实践者最重要的那些实操细节：**训练数据如何格式化与组织**。关于数据和格式化的决策，会直接被后续训练阶段沿用，从而形成一套统一的“语言”，供模型吸收后训练数据。

4.1 聊天模板与指令结构

后训练流程的第一步，是定义一个模式来格式化用户查询，使那些通过 tokenizer 处理信息的语言模型能够轻松读懂。当使用预训练语言模型时，提示非常简单。模型只认识少数几个 token：序列起始 token（如 <bos_token>）、序列结束 token（如 <eos_token>），以及填充 token（用于处理批次中存在空成分时的训练）。这意味着，要给基座模型下提示，用户输入一段 token 序列让模型接着往下写，例如：

```
<bos_token> The capital of the United States is
```

然后模型会持续生成 token，直到用尽上下文窗口、或者生成了序列结束 token。

所有后训练阶段——从指令微调到 RLHF 及其他方法——都依赖这套格式化来训练模型。负责处理“与用户交互之结构”的工具，就叫**聊天模板**（chat template）。

下面是一个我们即将拆解的示例：

```
{% if messages[0]['role'] == 'system' %}
    {# If the conversation begins with a system message, treat it as a special first turn.
       We set an offset so the user/assistant alternation check lines up correctly. #}
    {% set offset = 1 %}
{% else %}
    {# No system message: user should be the first non-empty turn. #}
    {% set offset = 0 %}
{% endif %}

{# Emit the beginning-of-sequence token (model-specific). #}
{{ bos_token }}

{# Serialize each message into the model's chat-markup tokens. #}
{% for message in messages %}
    {# Enforce role alternation: (system), user, assistant, user, assistant, ...
       The boolean expression compares "is this a user message?" against whether the
       current index (plus offset) is expected to be user or assistant. #}
    {% if (message['role'] == 'user') != (loop.index0 % 2 == offset) %}
        {{ raise_exception('Conversation roles must alternate
user/assistant/user/assistant/...') }}
    {% endif %}

    {# Wrap each message with special tokens:
       - <|im_start|><role>\n
       - message content (trimmed)
       - <|im_end|>\n
       This produces a single flat token sequence the LM can train on. #}
    {{ '<|im_start|>' + message['role'] + '\n' + message['content'] | trim + '<|im_end|>\n'
    }}
```

```
{% endfor %}

{# Optionally append an "assistant" start tag with no content.
   This cues generation to continue from the assistant role. #}
{% if add_generation_prompt %}
    {{ '<|im_start|>assistant\n' }}
{% endif %}
```

这段原始代码做的事情是：把 Python 中一个由消息与角色构成的字典列表，转换成语言模型可以据此预测的 token。

传入模型的全部信息都被赋予一个角色（role）。传统的三种角色是 **system**、**user** 和 **assistant**。

system 标签只用于对话的第一条消息；它承载给这个智能体的指令，这些文本既不会来自用户，也不会展示给用户。这些**系统提示**（system prompt）用于给模型提供额外上下文（比如日期和时间），或者用来修补某些行为。举个有趣的例子：可以告诉模型“你是一个友好的聊天机器人，总是用海盗的口吻回答”。

另外两个角色则很直接：**user** 承载使用 AI 的那个人发出的消息，**assistant** 承载模型给出的回复（也就是以 AI 助手身份参与对话）。

为了把这一切转换成 token，我们使用上面那段代码。模型有一系列特殊 *token*，用来把各条消息彼此分隔开。如果用示例查询“*How many helicopters can a human eat in one sitting?*”运行上面的代码，传入模型的 token 序列会是这样：

```
<|im_start|>system
You are a friendly chatbot who always responds in the style of a pirate<|im_end|>
<|im_start|>user
How many helicopters can a human eat in one sitting?<|im_end|>
<|im_start|>assistant
```

注意序列最后的 token 是 `<|im_start|>assistant`。模型正是靠这个知道该继续生成 token，直到最终生成它的序列结束 token——在这个例子里就是 `<|im_end|>`。

把所有问答对数据（以及下游的偏好微调数据）都打包成这种格式之后，现代语言模型会以完全一致的方式遵循它。这就是指令微调模型用来与用户、以及与在 GPU 或其他计算设备上运行的模型交换信息的语言。

这种形式可以朴素地扩展到多轮对话，如下所示：

```
<|im_start|>system
You are a friendly chatbot who always responds in the style of a pirate<|im_end|>
<|im_start|>user
How many helicopters can a human eat in one sitting?<|im_end|>
<|im_start|>assistant
Oh just 6.<|im_end|>
<|im_start|>user
Are you sure about that?<|im_end|>
<|im_start|>assistant
```

在开源生态中，把聊天模板应用到消息列表上的标准做法，是使用一段存放在 tokenizer 配置里的 Jinja 片段，即 `apply_chat_template`。

上面这个聊天模板是 OpenAI 的 Chat Markup Language (ChatML) 的衍生物——ChatML 是早期对消息格式做标准化的一次尝试。如今, OpenAI 及其他模型提供方使用的是一套分层的体系: 用户可以配置系统消息, 但还存在更高层级的指令, 它们可能披露、也可能不披露给用户 [74]。

此外还有许多其他的聊天模板。其他例子包括 Zephyr 的 [26]:

```
<|system|>
You are a friendly chatbot who always responds in the style of a pirate</s>
<|user|>
How many helicopters can a human eat in one sitting?</s>
<|assistant|>
```

以及 Tulu 的:

```
<|user|>
How are you doing?
<|assistant|>
I'm just a computer program, so I don't have feelings, but I'm functioning as expected. How
can I assist you today?<|endoftext|>
```

除此之外, 许多聊天模板还会加入用于工具调用等任务的格式化内容与其他 token。

4.2 指令微调的最佳实践

把指令微调作为后训练、以及打造有帮助的语言模型的基础, 这一点已经非常确定。实现成功指令微调的方式有很多。例如, 对部分模型参数做量化以实现高效微调, 能让训练变得非常容易上手 [75]。此外, 在聊天对齐这类窄领域内 (即不涉及数学、代码等更难技能), 小而专注的数据集也能取得很强的表现 [14]。

ChatGPT 发布后不久, 像 No Robots 这样只有约 1 万条样本的人类数据集便是当时的最高水平 [76]。几年之后, 大规模合成数据集在大多数任务上表现最好 [6]。

有几条原则依然成立:

- **高质量数据是性能的关键。**模型真正学习的是那些补全 (在很多情况下, 提示并不参与预测, 所以模型并不学习预测提示)。
- 约 100 万条提示就足以训练出一个能很好地进行 RLHF 与后训练的模型。继续扩规模仍有帮助, 但收益会迅速递减。
- 最好的提示, 是与下游关注任务分布相近的那些。
- 如果指令微调之后还要做多个训练阶段, 模型可以从指令微调数据中的一些噪声里恢复过来。把整体优化设计好, 比死抠每一个单独阶段更重要。

4.3 实现细节

虽然损失函数与预训练所用的相同, 但有一些关键的实现细节与预训练设定不同。许多做法——比如决定用哪些并行方式来把模型切分到多张 GPU 上——与预训练相同, 但使用的机器总数通常更少 (对应下面列出的第一项技术差异):

- **更小的批大小:**与预训练相比, 指令微调 (以及偏好微调等其他后训练技术) 使用小得多的批大小, 以便在更窄的数据分布上优化得当, 同时保住模型从预训练获得的泛化能力。例如, OLMo

2 在 7B 和 13B 的预训练中分别使用 1024 和 2048 的打包行数批大小，这些模型的总上下文长度是 4096 个 token，批次中的每一行都是若干文档拼接、填满序列长度的结果。而在后训练中，这两个模型都只使用 256 个提示的批大小 [58]，且不填充到完整序列长度（因此每批的非掩码 token 少得多）。更小的批大小意味着这些训练任务无法像预训练那样切分到那么多设备上——实践中，分布式训练设置有“每设备最小批大小”的限制，所以如果你想为 SFT 保留一个较小的全局批大小，就得相应地少用一些 GPU。而在实践中，批大小导致单个训练任务只能用更少的 GPU，并不构成瓶颈：因为 SFT 的训练 token 总量远小于预训练，而且后训练往往需要跑多个随机种子才能选出最好的最终性能。

- **提示掩码：**预训练时，批次中每个 token 都参与自回归预测，损失作用在所有 token 上。而在指令微调中，提示 token 会被掩蔽掉，这样模型就不会去学习准确预测用户的提问——只学预测回复。其他后训练算法同理。
- **多轮掩码：**对于多轮对话，有两种常见的掩码选择。(1) 只保留最后一轮：只有最后一条 assistant 轮次中的 token 计入损失，之前的所有上下文（包括更早的 assistant 轮次）都被掩蔽。长对话仍可“展开”成多个训练样本：对一个 N 轮的对话，每个样本预测一条 assistant 回复，同时掩蔽之前所有上下文、并排除之后的轮次。(2) 只掩蔽用户轮次：所有 user 轮次都被掩蔽，但每一条 assistant 轮次都计入损失。如果你想得到更多（更短的）训练样本，这种设定下同样可以展开；关键差别在于中间的 assistant 回复是直接参与训练的。
- **与预训练相同的损失函数：**指令微调使用与预训练语言模型相同的自回归损失函数，但数据与掩码方式差别很大（只在完整序列上训练，而预训练的文档可以被切分到不同批次）等等。
- **学习率：**SFT 通常使用比预训练小一到两个数量级的学习率，以更好地应对不同的优化动态（数据集更小、批更小、以及一个很强的预训练初始化，都更倾向于保守的更新）。例如，OLMo 2 预训练的峰值学习率是 3×10^{-4} ，而 SFT 是 1×10^{-5} [58]。Olmo 3 使用了更高的 SFT 学习率 5.8×10^{-5} [18]，部分原因是它的训练基础设施使用了序列打包——把多个样本装进每条训练序列，从而提高了以“有效 token”衡量的批大小。更大的批产生方差更低的梯度估计，这又支持在训练不失控的前提下使用更高的学习率——这个关系被称为线性缩放律。学习率通常会在训练步数的一小部分内先做预热，然后线性衰减。实践中，团队往往会扫多个学习率，并在留出评估套件上选出最好的检查点 [18]。

4.4 建议的实验

配套代码仓库里有一个小型的 SFT 训练脚本，位于 `code/instruction_tuning/`。它的用意是一个学习练习，让“从基座模型到助手”的转变变得具体可见。

1. 跑一遍经典的 SFT 示例，观察“基座 → 助手”的转变。运行：

```
cd code/
uv run python -m instruction_tuning.train --config
instruction_tuning/configs/sft_olmo2_1b.yaml
```

它会在 HuggingFaceH4/no_robots 上训练 allenai/OLMo-2-0425-1B（基座版），并每 50 个优化器步打印固定提示池的生成结果。在第 0 步，基座模型会漫无边际地乱写、重复提示、并吐出格式错误的角色标记；几百步之后，同样的提示会产出简洁、并以 `<|endoftext|>` 结束的回答。这就是指令微调的自检点——损失函数与预训练相同，只是作用在一个“提示 token 被掩蔽”的聊天模板上。

2. 扫学习率。复制 `sft_olmo2_1b.yaml`，固定其他一切，分别试 $1e-6$ 、 $5e-6$ 和 $5e-5$ 的 `lr`。观

察在哪个学习率上模型最早学会作答并干脆地停下，又在哪个学习率上开始过拟合并产出“模板形状”的废话。这就是上面那条“比预训练低一到两个数量级”指导的实操版本。

5 奖励建模

奖励模型是现代 RLHF 方法的核心——复杂的人类偏好正是在这里被学习到的。正是它们让我们能从难以描述的**困难信号**中学习。它们把数据中的复杂特征压缩成一种可供下游训练使用的表示——这可以说是一种“魔法”，再次展现了现代深度学习的复杂能力。这些模型充当核心优化的**代理目标**，后续章节会详细研究这一点。如图 14 所示，奖励模型扮演的角色类似于标准 RL 中的环境：为智能体提供学习信号；但与固定的环境不同，我们可以从人类偏好中把它学出来。

历史上，奖励模型在强化学习研究中一直被广泛用作环境奖励的代理 [54]。而现代形式的奖励模型，最初是作为研究“价值对齐”问题的工具被提出的 [38]。这类模型通常接受某种输入，输出一个标量奖励值。奖励可以有多种形式——在传统 RL 问题中，它试图逼近该问题真实的环境奖励；而在 RLHF 中我们会看到，奖励模型实际输出的是“某个输入属于高质量”的概率（也就是在成对偏好关系中属于被选中的那个答案）。RLHF 中的奖励建模实践与逆向强化学习密切相关——后者的任务是：给定行为轨迹，反推出智能体的奖励函数 [77]；它也与深度强化学习的其他领域相关。两者在高层次的问题陈述上相同，但在实现与关注点上完全不同，所以通常被视为两个独立的研究领域。

最常见的奖励模型通常被称为 **Bradley-Terry 奖励模型**，也是本章的主要焦点。它预测一段文本接近训练比较中“更受偏好”的文本的概率。本节后面我们还会把它与结果奖励模型（ORM）、过程奖励模型（PRM）以及其他类型的奖励模型作比较。

本章通篇用 x 表示提示、 y 表示补全。这一记号在语言模型文献中很常见——那些方法作用于完整的“提示—补全”对，而不是单个 *token*。

5.1 训练 Bradley-Terry 奖励模型

奖励模型的经典实现源自 Bradley-Terry 偏好模型 [78]。训练标准 RLHF 奖励模型有两种常见的表达方式——它们在数学上等价。首先，Bradley-Terry 偏好模型定义了：在两个条目 i 与 j 的成对比较中，评判者偏好 i 而非 j 的概率：

$$P(i > j) = \frac{p_i}{p_i + p_j}. \quad (12)$$

Bradley-Terry 模型假设每个条目有一个潜在的强度 $p_i > 0$ ，观察到的偏好是这些潜在强度的带噪反映。常见的做法是把 Bradley-Terry 模型用无界分数重新参数化，即令 $p_i = e^{r_i}$ ，于是得到如下形式：

$$P(i > j) = \frac{e^{r_i}}{e^{r_i} + e^{r_j}} = \sigma(r_i - r_j). \quad (13)$$

其中 $\sigma(z) = \frac{1}{1+e^{-z}}$ 是 logistic (sigmoid) 函数，因此偏好概率只取决于分数差 $r_i - r_j$ 。只有分数的差值有意义：给每个 r_k 同时加上一个常数 c ， $P(i > j)$ 不变。这些形式是对人类偏好的一个有用近似，在 RLHF 中往往效果很好。

要训练奖励模型，我们必须构造一个满足上述关系的损失函数。实践中，做法是把语言模型改造成一个输出标量分数的模型，通常是在模型最终隐藏状态之上接一个小型线性头，产出一个奖励值。给定提示 x 与两个采样得到的补全 y_1 和 y_2 ，我们用奖励模型 r_θ 给两者打分，条件分数记作 $r_\theta(y_i | x)$ 。

奖励模型给“ y_1 优于 y_2 ”分配的概率为：




图 14: RLHF 中的奖励模型扮演标准 RL 里“返回奖励的环境组件”这一角色。关键区别在于：在 RLHF 中，这个奖励函数由我们从人类偏好中控制和学习，而不是由环境固定。

$$P(y_1 > y_2 | x) = \frac{\exp(r_\theta(y_1 | x))}{\exp(r_\theta(y_1 | x)) + \exp(r_\theta(y_2 | x))}. \quad (14)$$

我们把受偏好的补全记作 y_c (chosen, 被选中), 被拒绝的补全记作 y_r (rejected)。

由此得到的损失, 会促使奖励模型给人类偏好的补全打出比被拒绝补全更高的分数, 并用 sigmoid 把分数差转换成概率。式 14 中的偏好似然是起点。我们先把分子分母同除 $\exp(r_\theta(y_c | x))$, 把它改写成 sigmoid 形式:

$$\begin{aligned} P(y_c > y_r | x) &= \frac{\exp(r_\theta(y_c | x))}{\exp(r_\theta(y_c | x)) + \exp(r_\theta(y_r | x))} \\ &= \frac{\exp(r_\theta(y_c | x))}{\exp(r_\theta(y_c | x)) \left(1 + \frac{\exp(r_\theta(y_r | x))}{\exp(r_\theta(y_c | x))}\right)} \\ &= \frac{1}{1 + \frac{\exp(r_\theta(y_r | x))}{\exp(r_\theta(y_c | x))}} \\ &= \frac{1}{1 + \exp(-(r_\theta(y_c | x) - r_\theta(y_r | x)))} \\ &= \sigma(r_\theta(y_c | x) - r_\theta(y_r | x)). \end{aligned} \quad (15)$$

随后, 奖励模型通过在偏好数据集 D 上做最大似然估计来拟合, 也就是最大化观测偏好的期望对数似然。由于对数函数单调, 这等价于最小化期望负对数似然:

$$\begin{aligned} \theta^* &= \arg \max_{\theta} \mathbb{E}_{(x, y_c, y_r) \sim D} [\log P(y_c > y_r | x)] \\ &= \arg \min_{\theta} \mathbb{E}_{(x, y_c, y_r) \sim D} [-\log \sigma(r_\theta(y_c | x) - r_\theta(y_r | x))]. \end{aligned} \quad (16)$$

在对数据集求平均之前先取对数, 正是负对数似然成为正确目标的原因: 最大化期望概率 $\mathbb{E}[P]$ 与最大化期望对数概率 $\mathbb{E}[\log P]$ 并不是一回事。

单样本损失就是上面期望内部的 log-sigmoid 表达式, 如 [3] 等工作中那样:

$$\mathcal{L}(\theta) = -\log(\sigma(r_\theta(y_c | x) - r_\theta(y_r | x))) \quad (17)$$

第二种是数学上等价的形式, 用 softplus 函数 $\log(1 + e^x)$ 表达, 如 [23] 等工作中那样:

$$\mathcal{L}(\theta) = \log(1 + e^{r_\theta(y_r | x) - r_\theta(y_c | x)}) \quad (18)$$

只要令 $\Delta = r_\theta(y_c | x) - r_\theta(y_r | x)$, 并利用 $\sigma(\Delta) = \frac{1}{1 + e^{-\Delta}}$, 即可得到 $-\log \sigma(\Delta) = \log(1 + e^{-\Delta}) = \log(1 + e^{r_\theta(y_r | x) - r_\theta(y_c | x)})$, 可见两者等价。这两种写法在 RLHF 文献中都出现过。

5.1.1 默认的奖励模型架构

奖励模型最常见的实现方式, 是借助与 Transformers 中 `AutoModelForSequenceClassification` 类似的抽象: 在语言模型之上接一个小型线性头, 在训练或推理时为“提示—补全”对产生一个标量奖励分数。推理时, 模型输出的这个单一 logit, 就是该段文本被选中的相对似然。

也存在其他实现选择, 比如直接从最终嵌入上接一个线性层, 但它们在开源工具中不太常见。




图 15: 训练偏好奖励模型需要成对的“被选中”与“被拒绝”补全。模型从序列级表示（通常是序列结束（EOS） token 的隐藏状态）为每个补全计算一个标量分数，对比式损失只依赖两者分数之差。

5.1.2 实现示例

实现奖励建模的损失相当简单。实现上更多的挑战在于搭建专门的数据加载器和推理流水线。假设已经有了正确的数据加载器——把被选中和被拒绝的提示与补全都 token 化——损失可以这样实现：

```
import torch.nn as nn
# inputs_chosen / inputs_rejected include the prompt tokens x and the respective
# completion tokens (y_c or y_r) that the reward model scores jointly.
rewards_chosen = model(**inputs_chosen)
rewards_rejected = model(**inputs_rejected)

loss = -nn.functional.logsigmoid(rewards_chosen - rewards_rejected).mean()
```

从更大的图景看，这通常是在一个因果语言模型（从左到右生成 token、每个 token 都以之前所有 token 为条件来预测的模型）之上，额外加一个头（并用上面的损失来学习它），把最终隐藏状态映射为输入的分。这段代码接受标准的 transformer 输入——`input_ids`（token 化后的文本）与 `attention_mask`（标记真实 token 与填充）——并在最后一个真实 token 处取出隐藏状态（模型对输入的内部表示），再通过一个线性层产出一个标量奖励。该模型的结构如下：

```
import torch
import torch.nn as nn
import torch.nn.functional as F

class BradleyTerryRewardModel(nn.Module):
    """
    Standard scalar reward model for Bradley-Terry preference learning.

    Usage (pairwise BT loss):
        rewards_chosen = model(**inputs_chosen) # (batch,)
        rewards_rejected = model(**inputs_rejected) # (batch,)
        loss = -F.logsigmoid(rewards_chosen - rewards_rejected).mean()
    """
    def __init__(self, base_lm):
        super().__init__()
        self.lm = base_lm # e.g., AutoModelForCausalLM
        self.head = nn.Linear(self.lm.config.hidden_size, 1)

    def _sequence_rep(self, hidden, attention_mask):
        """
```

```

Get a single vector per sequence to score.
Default: last non-padding token (EOS token); if no mask, last token.
hidden: (batch, seq_len, hidden_size)
attention_mask: (batch, seq_len)
"""

# Index of last non-pad token in each sequence
# attention_mask is 1 for real tokens, 0 for padding
lengths = attention_mask.sum(dim=1) - 1 # (batch,)
batch_idx = torch.arange(hidden.size(0), device=hidden.device)
return hidden[batch_idx, lengths] # (batch, hidden_size)

def forward(self, input_ids, attention_mask):
    """
    A forward pass designed to show inference structure of a standard reward model.
    To train one, this function will need to be modified to compute rewards from both
    chosen and rejected inputs, applying the loss above.
    """
    outputs = self.lm(
        input_ids=input_ids,
        attention_mask=attention_mask,
        output_hidden_states=True,
        return_dict=True,
    )
    # Final hidden states: (batch, seq_len, hidden_size)
    hidden = outputs.hidden_states[-1]

    # One scalar reward per sequence: (batch,)
    seq_repr = self._sequence_rep(hidden, attention_mask)
    rewards = self.head(seq_repr).squeeze(-1)

    return rewards

```

在本节以及后文中，奖励模型（乃至后训练的大部分）的实现复杂度，主要都在于正确地构造数据加载器和分布式学习系统。另外注意：训练奖励模型时，最常见的做法是只训练 1 个 epoch，以避免过拟合。

5.2 结果奖励模型

语言模型及其他 AI 系统的偏好微调，绝大多数都是用前面讨论的 Bradley-Terry 模型完成的。对于推理密集型任务，可以使用结果奖励模型（Outcome Reward Model, ORM）。ORM 的训练数据构造方式与标准偏好微调类似。这里我们有一个问题陈述或提示 x ，以及两个补全 y_1 和 y_2 。它使用的归纳偏置是：其中一个补全是该问题的正确答案、另一个是错误答案，于是得到 (y_c, y_{ic}) 。

在继续之前必须指出：结果奖励模型在后训练文献中是一个相对小众的领域，我们引用的关键论文在实现细节上也有微妙差异。其核心思想是学习一个逐 token 的信号，指示该补全有多大可能最终给出正确答案；但历史上出现过不同的训练方法和架构。

所用模型的架构与标准奖励模型非常相似——在能输出单一 logit 的模型上接一个线性层（对 RM 而言）——但对 ORM 来说，随后使用的训练目标略有不同。先来拆解原始的 GSM8K 论文（一个研究小学数学学习题的流行基准）[79]，它提出了后来成为 ORM 的思想，但当时还没有这个名字。我们从第 4.3 节的架构说起：

我们既可以训练验证器基于整个生成的解答做单次标量预测，也可以在解答中的每个 token 之后做一次标量预测。默认情况下我们选择后者，即训练验证器在每个 token 之后做预测。

这里正是结果奖励模型的默认实现与 Bradley-Terry 模型分道扬镳之处——**它们在每个 token 上做预测**。作者评论说，逐 token 的信息可以“作为一个有用的辅助信号，鼓励模型评判整个解答过程中的推理”，而不只是预测最终结果（这与后来 ORM 这个名字给人的印象有点反直觉）。继续看附录 E：

[我们] 用一个联合目标训练验证器：模型除了原本的语言建模目标之外，还要学会把某个模型补全标注为正确或错误。从架构上说，这意味着我们的验证器就是语言模型，只是带一个小型标量头，在**逐 token 的基础上**输出预测。我们把这个标量头实现为单个偏置参数和单个增益参数，作用在语言模型最终 unembedding 层输出的 logits 上。

翻译成实现语言：这是在每个 token 上通过一个小头输出一个标量 logit，而不是像传统 RM 那样的分类头——整个序列只输出一个 logit。另外，在这篇早期的 GSM8K 论文中，作者把 ORM 与下一词的语言建模损失**联合训练**；这一做法后来没有成为默认。

“结果奖励模型”（outcome-reward model）这个术语出现在 2022 年的一篇论文中，它比较了“结果监督的 RM（ORM）”与预测“截至目前推理质量”的过程奖励模型 [80]——重要的是，这是 ORM 的第二种实现方式：把二元的 **correct** 或 **incorrect** 放进 LLM 的 tokenizer 词表里，作为**步骤级信号**，而不是学习一个在每 token 处预测正确性的独立标量头。

本书所遵循的经典实现来自论文 *Let's Verify Step by Step* [50]：其中结果奖励模型被训练成一个**逐 token 预测答案是否正确的模型**，用交叉熵损失。

形式上，逐 token 损失在每一个补全 token 上施加二元交叉熵，其中每个 token 关联的结果概率被训练去逼近该序列的结果标签：

$$\mathcal{L}_{\text{token}}(\theta) = -\mathbb{E}_{(s,r) \sim \mathcal{D}} \left[\frac{1}{T} \sum_{t=1}^T (r \log p_{\theta}(s_t) + (1-r) \log (1 - p_{\theta}(s_t))) \right] \quad (19)$$

其中 s 是长度为 T 个 token 的补全， $r \in \{0,1\}$ 是二元标签（1 表示给定提示的正确答案，0 表示错误答案），而 $p_{\theta}(s_t) = \sigma(w_{\theta}(s_t))$ 是在 token t 处由模型的标量 logit $w_{\theta}(s_t)$ 预测出的正确概率。

按照 [81]，ORM 还有一种更简单的形式：序列级交叉熵损失，模型之后用于逐 token 推理：

$$\mathcal{L}_{\text{CE}}(\theta) = -\mathbb{E}_{(s,r) \sim \mathcal{D}} [r \log \bar{p}_{\theta}(s) + (1-r) \log (1 - \bar{p}_{\theta}(s))] \quad (20)$$

其中 $r \in \{0,1\}$ 是二元标签（1 表示给定提示的正确答案，0 表示错误答案），而 $\bar{p}_{\theta}(s) = \sigma\left(\frac{1}{T} \sum_{t=1}^T w_{\theta}(s_t)\right)$ 把逐 token logits 的平均值压缩成“整个补全正确”的单一概率——注意这不是逐 token 概率的平均，因为 sigmoid 是在汇聚之后才施加的。在代码中，这个结果标签会被复制到每个补全 token 上，而提示 token 被掩蔽为 -100，不参与损失。

实现结果奖励模型（以及我们稍后会看到的过程奖励模型等其他类型）的做法是：依据补全是否为正确样本，**逐 token** 施加交叉熵损失。这比标准 Bradley-Terry 奖励模型更接近语言建模损失——它不需要那种结构化的“选中—拒绝”配对关系。在下面这个简化版 ORM 训练设置里，我们既不采样新 token，也不按下一词预测来训练 LLM；我们只是把一条固定的“提示—补全”序列喂给主干网络，训练 ORM 头去预测正确性标签。

模型结构可以写成：

```
import torch.nn as nn
import torch.nn.functional as F

class OutcomeRewardModel(nn.Module):
    def __init__(self, base_lm):
        super().__init__()
        self.lm = base_lm # e.g., AutoModelForCausalLM
        self.head = nn.Linear(self.lm.config.hidden_size, 1)

    def forward(self, input_ids, attention_mask=None, labels=None):
        """
        input_ids contains a full prompt+completion sequence.
        labels is token-aligned: prompt tokens are -100, and each completion
        token repeats the sequence outcome label (1=correct, 0=incorrect).
        If labels=None, this is an inference-only forward pass and the loss is
        returned as None.
        """
        outputs = self.lm(
            input_ids=input_ids,
            attention_mask=attention_mask,
            output_hidden_states=True,
            return_dict=True,
        )
        # Final hidden states: (batch, seq_len, hidden_size)
        hidden = outputs.hidden_states[-1]
        # One scalar logit per token: (batch, seq_len)
        logits = self.head(hidden).squeeze(-1)

        # Inference-only forward pass: no loss is computed.
        if labels is None:
            return None, logits
        # Only compute loss on completion tokens (labels 0 or 1)
        # Prompt tokens have labels = -100
        mask = labels != -100
        loss = None
        if mask.any():
            loss = F.binary_cross_entropy_with_logits(
                logits[mask], labels[mask].float()
            )
        else:
            loss = logits.sum() * 0
        return loss, logits
```

损失的简化写法如下：

```
# Feed the full prompt+completion sequence once; no token sampling happens here.
# Assume model already has: model.lm (backbone) + model.head
hidden = model.lm(**inputs, output_hidden_states=True).hidden_states[-1]
logits_per_token = model.head(hidden).squeeze(-1) # (batch, seq_len)
# This will sometimes be compressed as model.forward() in other implementations

# Binary labels: 1=correct, 0=incorrect (prompt tokens masked as -100)
mask = labels != -100
```

```
loss = F.binary_cross_entropy_with_logits(
    logits_per_token[mask], labels[mask].float()
)
```

这里重要的直觉是：ORM 会在序列中的每个 token 处输出一个正确性概率（而判断依据只有最终答案——推理过程中的错误并不会被 ORM 的训练过程捕捉）。这可能是一个带噪的过程，因为更新和损失会依据结果与注意力映射逐 token 地传播。




图 16: 推理时，结果奖励模型在补全 token 上输出逐 token 的正确性概率。提示 token 不参与打分，而补全上的概率可以聚合成回复级分数，用于验证、筛选或重排序。




图 17: 训练结果奖励模型使用来自验证器或数据集的离线标签（例如正确补全全部标为 1）。每个补全 token 都以二元交叉熵针对该结果标签训练，逐 token 概率再聚合成最终分数，用于验证、筛选或重排序。

这类模型一直被使用，但在开源 RLHF 工具中支持较少。例如，奠基性工作 *Let's Verify Step by Step* [50] 用的就是同一类 ORM，只是去掉了 Cobbe 等 2021 年工作中那部分语言建模预测损失。于是，最终损失就是在每个 token 上的交叉熵损失，预测最终答案是否正确。

由于缺乏工具支持，“结果奖励模型”（ORM）这个术语被以多种方式使用。一些文献（例如 [81]）继续受 Cobbe 等 2021 年原始定义的启发；另一些则把它更宽泛地用于任何“被训练来预测补全是否正确”的验证器。

5.3 过程奖励模型

过程奖励模型（Process Reward Model, PRM），最初叫“过程监督奖励模型”，是一类被训练来在思维链推理过程的每一步都输出分数的奖励模型。它们不同于只在 EOS token 处输出一个分数的标

准 RM，也不同于在每个 token 都输出分数的 ORM。过程奖励模型需要在每个推理步骤的末尾获得监督，然后以类似方式训练——步骤内的 token 被训练去逼近相应的目标：对 PRM 来说目标是该步骤，对 ORM 来说目标是整个回复。

按照 [50]，二元标注的 PRM 通常用逐步交叉熵损失来优化：

$$\mathcal{L}_{\text{PRM}}(\theta) = -\mathbb{E}_{(x,s) \sim \mathcal{D}} \left[\sum_{i=1}^K y_{s_i} \log r_{\theta}(s_i | x, s_{<i}) + (1 - y_{s_i}) \log (1 - r_{\theta}(s_i | x, s_{<i})) \right] \quad (21)$$

其中 s 是一条采样得到的、带 K 个标注步骤的思维链， $y_{s_i} \in \{0, 1\}$ 表示第 i 步是否正确，而 $r_{\theta}(s_i | x, s_{<i})$ 是 PRM 在给定原始提示 x 与之前所有步骤 $s_{<i}$ 的条件下，预测步骤 s_i 有效的概率。

下面是一个示例，展示这种逐步标签如何在训练器里被打包，来自 Hugging Face 的 TRL (Transformer Reinforcement Learning) [47]：

```
# Get the ID of the separator token and add it to the completions
separator_ids = tokenizer.encode(step_separator, add_special_tokens=False)
completions_ids = [completion + separator_ids for completion in completions_ids]

# Create the label
labels = [[-100] * (len(completion) - 1) + [label] for completion, label in
zip(completions_ids, labels)]
```

传统上，PRM 用一个语言建模头来训练，只在推理步骤末尾输出一个 token——例如对应该步骤结束的那个双换行符或其他特殊 token 的位置。这些预测通常取 -1 表示错误、0 表示中性、1 表示正确。这些标签并不必然与“模型是否走在正确路径上”绑定，而是与该步骤本身是否正确绑定。




图 18: 过程奖励模型只在步骤边界（例如换行 token）提供监督。每个步骤获得一个三分类标签：正确（+1）、中性（0）或错误（-1）。训练时其他所有 token 都被掩蔽。

一个 PRM 的构造示例如下。

```
import torch.nn as nn
import torch.nn.functional as F

class ProcessRewardModel(nn.Module):
    def __init__(self, base_lm, num_classes=3):
        super().__init__()
        self.lm = base_lm # e.g., AutoModelForCausalLM
        self.head = nn.Linear(self.lm.config.hidden_size, num_classes)

    def forward(self, input_ids, attention_mask=None, labels=None):
        """
```

```

The inputs are tokenized prompts and completions, where the end of a
"reasoning step" is denoted by a designated separator token such as a
newline or other special marker rather than batch padding.
labels will be a list of labels, True, False, and Neutral (3 labels) which
will be predicted by the model.
If labels=None, this is an inference-only forward pass and the loss is
returned as None.
"""
outputs = self.lm(
    input_ids=input_ids,
    attention_mask=attention_mask,
    output_hidden_states=True,
    return_dict=True,
)
# Final hidden states: (batch, seq_len, hidden_size)
hidden = outputs.hidden_states[-1]
# One logit vector per token: (batch, seq_len, num_classes)
logits = self.head(hidden)

# Inference-only forward pass: no loss is computed.
if labels is None:
    return None, logits
# Only compute loss at step boundaries (where labels != -100)
# Labels map: -1 -> 0, 0 -> 1, 1 -> 2 (class indices)
mask = labels != -100
loss = None
if mask.any():
    loss = F.cross_entropy(
        logits[mask], labels[mask]
    )
else:
    loss = logits.sum() * 0
return loss, logits

```

核心损失函数与结果奖励模型看起来非常相似，只是标签施加在不同的间隔上。

```

# Assume model outputs 3-class logits per token
hidden = model.lm(**inputs, output_hidden_states=True).hidden_states[-1]
logits = model.head(hidden) # (batch, seq_len, 3)

# 3-class labels at step boundaries only: 0=-1, 1=0, 2=1 (others masked as -100)
mask = labels != -100
loss = F.cross_entropy(logits[mask], labels[mask])

```

5.4 比较各类奖励模型（以及价值函数）

前面介绍的各种奖励模型类型，展现了 RLHF 及其他后训练方法中衡量“质量”的多种光谱式做法。下表汇总了这些模型各自预测什么、以及如何训练。

表 2: 各类奖励模型的比较。

模型类别	预测什么	如何训练	语言模型结构
奖励模型	序列级质量分 $r_\theta(x, y)$	对同一提示下不同补全之间的成对（或 N 元）比较做对比式损失	在 EOS/最后 token 隐藏状态上接线性头
结果奖励模型	逐 token 的“答案正确”概率	带标签的结果（例如可验证领域上的成功/失败）；每个样本独立标注，不需要同一提示下的配对比较	逐 token 的二元交叉熵头；标签重复该结果标签
过程奖励模型	推理步骤末尾处对中间步骤的奖励或分数	用中间反馈或步骤级标注训练（在推理步骤内逐 token 训练）	逐 token 预测步骤正确性（-1、0、1）的头
价值函数	给定当前状态的期望回报	通过回归到序列中的每个点来训练	带逐 token 输出的标量回归头

关于上表这些区分，有几点需要说明——这些模型类型之间的边界并不总是那么清晰：

- 在偏好微调和推理训练中，价值函数的折扣因子常常取 1，这让价值函数更接近结果奖励模型，但训练损失不同。
- 过程奖励模型也可以通过从中间状态做 rollout、收集结果数据来获得监督。这混合了多种思路；但如果损失使用的是逐推理步骤的标签，那最好还是称之为 PRM。

如果用“正确/错误”配对去训练 **Bradley-Terry 成对模型**，会怎样？关于结果奖励模型的许多混淆，来自一小部分文献：它们在由答案正确性导出的成对数据上训练奖励模型。在这个设定里，你把“对某个问题的正确答案”设为被选中回复，把“同一个问题的错误答案”设为被拒绝回复。这严格来说并不是 ORM，而是仍然直接用序列级的对比式损失训练的。它严格来说仍是 Bradley-Terry 模型，属于我们讲的第一类模型。

ORM 与价值函数的区别。 ORM 和价值函数看起来可能相似，因为两者都通过同样的头部架构产生逐 token 输出；但它们在预测什么和目标从哪来上不同：

- **ORM** 在每个 token 处预测该补全是否最终会给出正确答案。目标来自离线标签（验证器或数据集把序列标为正确或错误），并被广播到每个中间 token 上用于训练。
- **价值函数** 预测剩余期望回报： $V(s_t) = \mathbb{E} \left[\sum_{k \geq t} \gamma^{k-t} r_k \mid s_t \right]$ 。目标通常是在当前策略 π_θ 下同策略 rollout 计算出来的，并随策略变化而变化（严格来说价值函数也可以是异策略的，但在语言模型的研究中这一点尚未确立）。

如果你定义稠密的逐 token 奖励 $r_t = \mathbb{1}[\text{token 正确}]$ 并取 $\gamma = 1$ ，那么 ORM 学的是 r_t （或 $p(r_t = 1)$ ），而价值头学的是剩余求和 $\sum_{k \geq t} r_k$ 。它们可以共享同一个基座模型和相同的头部维度，但语义与监督流水线不同：ORM 从固定标签离线训练，而价值函数在同策略数据上训练，并被用来为策略梯度计算优势 $A_t = \hat{R}_t - V_t$ 。

5.4.1 各类奖励模型的推理方式

训练完成之后，这些模型在推理时对数据的处理方式不同，以应对 RM 被用于的一系列任务。

Bradley-Terry RM (偏好模型):

- 输入: 提示 x + 候选补全 y
- 输出: 由 EOS/最后 token 隐藏状态经线性层得到的单个标量 $r_\theta(x, y)$
- 用途: 对 k 个补全重排序、取 top-1 (best-of-N 采样); 或为 RLHF 提供终止奖励
- 聚合: 标量输出无需聚合

结果 RM:

- 输入: 提示 x + 补全 y
- 输出: 补全 token 上的逐 token 概率 $p_t \approx P(\text{最终答案正确} \mid y_{\leq t})$
- 用途: 给已完成的候选打分; 用均值、最小值 (尾部风险) 或乘积 $\prod_t p_t$ (等价于对数概率求和 $\sum_t \log p_t$) 来聚合
- 聚合选择: 平均正确性、 p_t 的最小值、最后 m 个 token 的平均, 或在任一 $p_t < \tau$ 时标记告警

过程 RM:

- 输入: 提示 x + 带步骤边界的推理轨迹
- 输出: 步骤边界处的分数 (例如正确/中性/错误的三分类 logits)
- 用途: 给已完成的思维链打分; 或通过剪掉低分分支来引导搜索/解码
- 聚合: 在步骤 (而非 token) 上聚合——步骤分均值、最小值 (快速失败), 或偏向靠后步骤的加权和

价值函数:

- 输入: 提示 x + 当前前缀 $y_{\leq t}$ (一个状态)
- 输出: 补全中每个 token 位置处的 V_t (从状态 t 出发的期望剩余回报)
- 用途: 在 RL 训练中计算逐 token 优势 $A_t = \hat{R}_t - V_t$; 每一步的值充作基线
- 聚合: 通常取最后一个生成 token 处的 V ; 其解释与“正确性概率”不同

总结一下理解这些模型的方式:

- **RM**: “整个回答有多好?” $\rightarrow$ 一个标量值
- **ORM**: “这个回答最终会正确吗?” $\rightarrow$ 逐 token 的结果预测 (作为中间质量的代理)
- **PRM**: “推理步骤站得住脚吗?” $\rightarrow$ 逐步分数
- **价值**: “从这里出发还剩多少奖励?” $\rightarrow$ RL 优势的基线

5.5 其他奖励模型变体

奖励建模是 RLHF 中相对探索不足的领域。传统的 Bradley-Terry 奖励建模损失被许多流行工作修改过, 但这些修改并未固化成单一的最佳实践。

5.5.1 偏好间隔损失

当标注者给出的是李克特量表 (一种带有序数类别、指示偏好强度的评分表, 例如 1-5 分) 上的分数或排序时, 这些关系量的幅度可以用在训练里。最常见的做法是沿偏好方向把数据二值化, 把相对评分或排序强度所携带的混合信息, 压缩成仅仅是“被选中”与“被拒绝”的补全。那些额外信息 (例如偏好幅度) 曾被用来改进模型训练, 但没有收敛为标准做法。Llama 2 提出用两个数据点之间的间隔 $m(y_c, y_r)$ 来区分偏好强度:

$$\mathcal{L}(\theta) = -\log(\sigma(r_\theta(y_c | x) - r_\theta(y_r | x) - m(y_c, y_r))) \quad (22)$$

例如，每个补全常常会按质量被打 1 到 5 分。如果被选中样本得 5 分、被拒绝样本得 2 分，那么间隔 $m(y_c, y_r) = 5 - 2 = 3$ 。也可以探索其他计算间隔的函数。

注意在 Llama 3 中，这个间隔项被去掉了——团队观察到在扩大规模后改进变得微不足道。

5.5.2 平衡每个提示下的多次比较

InstructGPT 研究了用 $K = 4$ 到 9 个补全对每个提示做排序的影响，从每个提示产生 $\binom{K}{2}$ 个成对比较 [3]。由于这些比较高度相关（它们共享同一个提示），把它们朴素地打散进数据集会导致奖励模型过拟合。为解决这一点，他们按“每个提示下的每次比较”对损失更新加权——如果不重新加权，拥有更多补全的提示仅仅因为产生了更多配对，就会贡献更多总损失。实践中，来自同一个提示的全部 $\binom{K}{2}$ 个比较通常被放进同一个训练批次并一起平均，因此每个提示只贡献一次分组更新，而不会分散到许多不同批次里。这降低了对单个提示的过拟合，也避免了采样补全更多的提示主导损失。损失函数变为：

$$\mathcal{L}(\theta) = -\frac{1}{\binom{K}{2}} \mathbb{E}_{(x, y_c, y_r) \sim D} \log(\sigma(r_\theta(y_c | x) - r_\theta(y_r | x))) \quad (23)$$

5.5.3 K 元损失函数

还有许多其他形式可以为 RLHF 构造合适的人类偏好模型。一个例子出现在早期的流行 RLHF 模型 Starling 7B 和 34B [82] 中：基于 Plackett-Luce 模型的 K 元损失函数 [83]。

Zhu 等 2023 [84] 把设定形式化如下。给定一个提示（或称状态） s^i ，从 $P(a_0, \dots, a_{K-1} | s^i)$ 中采样 K 个动作 $(a_0^i, a_1^i, \dots, a_{K-1}^i)$ 。然后标注者按偏好对这 K 个动作排序，产生一个置换 $\sigma^i : [K] \mapsto [K]$ ，其中 $\sigma^i(0)$ 是最受偏好的动作。对所有 K 个条目的完整排序，Plackett-Luce 概率为：

$$P(\sigma^i | s^i, a_0^i, a_1^i, \dots, a_{K-1}^i) = \prod_{k=0}^{K-1} \frac{\exp(r_{\theta^*}(s^i, a_{\sigma^i(k)}^i))}{\sum_{j=k}^{K-1} \exp(r_{\theta^*}(s^i, a_{\sigma^i(j)}^i))} \quad (24)$$

当 $K = 2$ 时，它退化为成对比较的 Bradley-Terry (BT) 模型。无论如何，训练完成之后，这些模型在 RLHF 训练中的用法与其他奖励模型类似。

5.6 生成式奖励建模（即 LLM 作为评判者）

考虑到偏好数据的成本，一个大的研究领域出现了：用现有语言模型来评判人类偏好，或用于其他评估场景 [85]。核心思想是给语言模型一段“如何评判”的指令、一个提示，以及两个补全（就像交给人类标注者那样）。下面是一个示例提示，来自聊天评估 MT-Bench 的奠基性工作之一 [85]：

```
[System]
Please act as an impartial judge and evaluate the quality of the responses provided by two AI assistants to the user question displayed below.
You should choose the assistant that follows the user's instructions and answers the user's question better.
```

```

Your evaluation should consider factors such as the helpfulness, relevance, accuracy, depth,
creativity, and level of detail of their responses.
Begin your evaluation by comparing the two responses and provide a short explanation.
Avoid any position biases and ensure that the order in which the responses were presented
does not influence your decision.
Do not allow the length of the responses to influence your evaluation.
Do not favor certain names of the assistants.
Be as objective as possible.
After providing your explanation, output your final verdict by strictly following this
format: "[[A]]" if assistant A is better, "[[B]]" if assistant B is better, and "[[C]]" for a
tie.
[User Question]
{question}
[The Start of Assistant A's Answer]
{answer_a}
[The End of Assistant A's Answer]
[The Start of Assistant B's Answer]
{answer_b}
[The End of Assistant B's Answer]

```

鉴于 LLM 作为评判者在评估中效果显著——它催生了 AlpacaEval [86]、Arena-Hard [87]、Wild-Bench [88] 等许多评估——不少人开始用 LLM 作为评判者来替代奖励模型，以生成并使用偏好数据。

围绕如何使用所谓“生成式奖励模型”，已经形成了一个完整的研究领域 [89] [90] [91]（包括专门训练来当好评判者的模型 [92]）；但在 RM 评估上，它们往往落后于现有的奖励模型——这说明奖励建模对当前的 RLHF 而言仍是一项重要技术。

提升 LLM 作为评判者这一流程鲁棒性的一个常用技巧，是使用采样温度 0 来降低评分的方差。

5.7 延伸阅读

奖励建模的学术文献在 2024 年确立了自己的位置。奖励建模早期进展的大部分，集中在建立基准与识别行为模式上。第一个 RM 基准 RewardBench 为测试奖励模型提供了通用基础设施 [93]。此后，RM 评估已扩展到与通用后训练模型可用的评估类型相似：有些评估测试在具有已知真实答案的领域上的预测准确率 [93]，另一些则更接近“感觉”，用 LLM 作为评判者、或考察与其他基准的相关性 [94]。

新基准的例子包括：

- **纯文本（通用聊天/偏好）**：RMB [95]、RewardBench2 [96]、Preference Proxy Evaluations [97]、RM-Bench [98]。
- **专门化的纯文本（数学等）**：多语言奖励基准 M-RewardBench [99]、面向检索增强生成（RAG）的 RAG-RewardBench [100]、针对拼写错误的 ReWordBench [101]、RewardMATH [102]、AceMath-RewardBench [103]。
- **过程 RM**：PRM Bench [104]、ProcessBench [105]，以及视觉基准 VisualProcessBench [106]、ViLBench [107]。
- **智能体 RM**：Agent-RewardBench [108]、CUARewardBench [109]。
- **多模态**：MJ-Bench [110]、Multimodal RewardBench [111]、VL RewardBench [112]、VL-RMBench [113]。

要了解奖励模型训练方面的进展，可以参考新的奖励模型训练方法：aspect 条件模型 [114]、高质量人类数据集 [115] [116]、扩展实验 [30]、大量实验 [49]，以及数据去偏 [117]。

5.8 建议的实验

配套代码仓库里有一些小型的奖励模型训练脚本，位于 `code/reward_models/`。它们的定位是学习练习，而不是调好的参考配方。先从干净的 `code/` 环境出发、执行 `uv sync`，然后一次跑一个实验。

1. 在 UltraFeedback 上训练一个 Bradley-Terry 偏好奖励模型。运行：

```
cd code/  
uv run python -m reward_models.train_preference_rm --config  
reward_models/configs/preference_rm.yaml
```

观察演示输出与 W&B 日志中，被选中与被拒绝回复之间的奖励间隔是否在变大。然后在 `yaml` 配置里改变 `samples`、`lr` 和 `model_id`，看看信号在什么时候变得有噪声或不稳定。

2. 对比结果监督与过程监督。分别运行 GSM8K 结果奖励模型与 PRM800K 过程奖励模型：

```
cd code/  
uv run python -m reward_models.train_orm --config reward_models/configs/orm.yaml  
uv run python -m reward_models.train_prm --samples 500 --epochs 2
```

对比训练之后两个模型能给出什么分数：ORM 应能区分正确的最终答案与错误的最终答案，而 PRM 应在中间的推理步骤上给出分数。这就是“序列级、结果级、过程级监督”这三者区别的实操版本。

3. 加一个小的留出集奖励模型评估。一个有价值的贡献是为 `reward_models/` 写一个 50 到 200 条样本的评估，报告准确率或偏好对排序，且不需要完整跑一次训练。评估要足够小，以便在调超参时随时使用。

6 强化学习

在 RLHF 过程中，强化学习算法依据奖励模型给出的反馈，缓慢地更新模型权重。策略——也就是被训练的那个模型——针对训练集中的提示生成补全，奖励模型给这些补全打分，然后强化学习优化器依据这些信息做梯度步（总览见 图 19）。本章讲解这些算法背后的数学与权衡——它们用来从奖励模型给予同策略数据的信号中学习。这些算法会运行许多个 epoch，往往在更大规模的提示集上跑数千到数百万个批次，每批之间都做梯度更新。

6.1 强化学习在 RLHF 中的角色

让 RLHF 在语言模型上流行起来的算法，是**策略梯度**类强化学习算法。这类算法——例如近端策略优化（PPO）、组相对策略优化（GRPO）和 REINFORCE——使用最近生成的样本更新模型，而不是像 Deep Q-Network（DQN，AlphaGo 这类项目所用的方法）那样把分数存进经验回放缓冲区。本节我们会介绍策略梯度算法的基础，以及它们如何在现代 RLHF 框架中使用。

从机器学习层面看，这一部分是 RLHF 流程中复杂度最高的主题。不过，和大多数现代 AI 模型一样，其成败最大的决定因素是喂进这个流程的数据。

RLHF 随着 ChatGPT 登场时，人们普遍知道它用的是 PPO 的一个变体，许多早期工作都建立在此之上。后来，多个研究项目展示了 REINFORCE 风格算法的前景 [118] [116]——它们被推崇的理由是比 PPO 更简单：不需要单独的价值模型（省显存，因而也省所需 GPU 数），优势估计也更简单（不需要广义优势估计 GAE，这是一种在策略梯度算法中用于降低方差的优势计算方法）。此后又出现了更多算法，包括在推理任务上特别流行的组相对策略优化；但总体来说，这些算法大多可以针对具体任务来调。本章覆盖策略梯度的核心设定，以及上面提到的三种算法——因为它们在建立经典 RLHF 文献中处于中心地位。

最简单地讲，RLHF 的 RL 阶段需要两个模型：一个策略（被训练的模型），以及一个给它输出打分的奖励模型（上一章已讲）。RL 之前的策略的一份副本充当**参考模型**，用于计算 KL 惩罚（这个模型是冻结的，即不会通过自动微分引擎接收梯度更新）。本章讲到的最复杂算法 PPO，会增加第四个模型——一个学到的价值函数，用来估计动作中每个 token 有多好，它同样是一个在训练中更新的大语言模型。本章各算法的主要区别在于：它们如何估计一个叫做**优势**（advantage）的量——衡量模型当前动作（补全）相对平均水平好多少；以及它们如何约束策略更新，使优化在数值上稳定。这一 RLHF 过程（不含价值模型）的可视化总览见 图 19。

符号定义见问题设定那一章。

本章使用强化学习文献中的 (s, a) 记号，其中 s 表示状态、 a 表示动作。在语言模型语境中，你更常看到的是 (x, y) ，其中 x 是提示、 y 是补全。 (s, a) 的框架更一般——这些算法本来就是为“在每个时间步采取动作”的序列决策问题设计的。不过，许多 RLHF 实现把整个补全当作单个动作，因此 (x, y) 记号同样成立。

RL 速查表：本章全部核心 RL 损失函数的一页速查表见 rlhfbook.com/rl-cheatsheet。

6.2 策略梯度算法

本章的核心，是理解下面这个形状的方程。这个方程计算的是我们正在训练的语言模型 π_θ 的梯度 $\Delta\theta$ ：




图 19: RLHF 训练循环总览。数据集中的一个提示被送入已调优的策略，策略生成一个补全。奖励模型给这个补全打分；同时，被冻结的初始模型（通常是 RL 之前的指令微调模型）在同一段文本上计算对数概率，用于计算防止过度漂移的 KL 惩罚。合并后的奖励信号再驱动对策略参数的强化学习更新。

$$\Delta\theta \propto \Psi_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \quad (25)$$

这里，方程由两个关键部分构成：1. $\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)$ ——参数空间中哪个方向会让动作 a_t 更可能发生。2. Ψ_t ——它有多好？一个给结果打分的标量。

把两者相乘，你就得到了策略梯度的更新量。有些事很简单，比如 $\Psi_t > 0$ 会更新参数使 a_t 更可能发生， $\Psi_t < 0$ 则使它的可能性降低。策略梯度在计算的是：哪些参数对某个动作有贡献，以及我们是否应该让它将来更可能或更不可能发生。本章余下的部分会深入探讨实现这件事的不同方式，以及它对 LLM 奏效的具体技巧。

现在，我们把这件事再形式化一些。强化学习算法的设计目标，是在由状态 $s \in \mathcal{S}$ 与动作 $a \in \mathcal{A}$ 组成的轨迹上，最大化未来的折扣奖励（更多记号见附录 A「定义」）。智能体的目标——通常称为回报（return）——是从时刻 t 起的折扣奖励之和（其中 $\gamma \in [0, 1]$ 是一个让近期奖励更受重视的因子）：

$$G_t = r_t + \gamma r_{t+1} + \dots = \sum_{k=0}^{\infty} \gamma^k r_{t+k}. \quad (26)$$

回报定义也可以递归地写成：

$$G_t = r_t + \gamma G_{t+1}. \quad (27)$$

这个回报是学习价值函数 $V(s)$ 的基础——后者是在给定当前状态下对~~未来~~回报的估计：

$$V(s) = \mathbb{E}[G_t | S_t = s]. \quad (28)$$

所有策略梯度算法都在优化策略 $\pi_{\theta}(a | s)$ 以最大化期望回报；这个目标可以用诱导出的价值函数 $V^{\pi_{\theta}}(s)$ 来表达。

设 $d_0(s)$ 为初始状态分布。我们要最大化的回合式目标可以写成：

$$J(\theta) = \sum_s d_0(s) V^{\pi_{\theta}}(s), \quad (29)$$

在有限 MDP 中，这是对可能起始状态的求和；但实践中我们从不精确计算它。我们改为从数据中估计：从当前策略采样 rollout。在 RLHF 中，这通常意味着从数据集采样提示 x_i ，并生成补全 $y_i \sim \pi_{\theta}(\cdot | x_i)$ 。令 $R(x_i, y_i)$ 表示分配给该提示—补全对的标量序列级奖励；如果 τ_i 是对应的回合，这就是轨迹奖励 $R(\tau_i)$ 。于是我们取一个经验平均，例如：

$$\hat{J}(\theta) = \frac{1}{B} \sum_{i=1}^B R(x_i, y_i), \quad (30)$$

或者，在带逐步奖励的 MDP 视角下：

$$\hat{J}(\theta) = \frac{1}{B} \sum_{i=1}^B \sum_{t=0}^{T_i} \gamma^t r_{i,t}. \quad (31)$$

实践中，面向语言模型的 RLHF 取 $\gamma = 1$ （不折扣），因为优化的单位是整个补全、而不是单个 token——这一选择在本章后面「MDP 与赌博机」一节还会讨论。

策略梯度算法的核心，是计算“当前策略下有限期望回报”的梯度。有了这个期望回报 J ，参数更新可以这样计算，其中 α 是学习率：

$$\theta \leftarrow \theta + \alpha \nabla_{\theta} J(\theta) \quad (32)$$

而核心的实现细节，就在于如何计算这个梯度。

6.2.1 推导策略梯度

令 $p_{\theta}(\tau)$ 表示由初始状态分布 d_0 、策略 π_{θ} 和环境转移动力学共同诱导出的轨迹分布，其展开式见下面式 35。我们要最大化的 RL 目标还可以这样表述：

$$J(\theta) = \mathbb{E}_{\tau \sim p_{\theta}} [R(\tau)], \quad (33)$$

其中 $\tau = (s_0, a_0, s_1, a_1, \dots)$ 是一条轨迹， $R(\tau) = \sum_{t=0}^{\infty} r_t$ 是这条轨迹的总奖励。或者，我们可以把这个期望写成对所有可能轨迹的积分：

$$J(\theta) = \int_{\tau} p_{\theta}(\tau) R(\tau) d\tau \quad (34)$$

注意，轨迹概率可以这样表达，其中 $\pi_{\theta}(a_t | s_t) p(s_{t+1} | s_t, a_t)$ 把策略概率与“从一个状态-动作对转移到下一个状态”的环境转移概率组合在一起：

$$p_{\theta}(\tau) = d_0(s_0) \prod_{t=0}^{\infty} \pi_{\theta}(a_t | s_t) p(s_{t+1} | s_t, a_t), \quad (35)$$

如果对目标函数（式 33）关于策略参数 θ 求梯度：

$$\nabla_{\theta} J(\theta) = \int_{\tau} \nabla_{\theta} p_{\theta}(\tau) R(\tau) d\tau \quad (36)$$

注意，我们可以用对数求导技巧，把对积分的求导重写成期望：

$$\begin{aligned} \nabla_{\theta} \log p_{\theta}(\tau) &= \frac{\nabla_{\theta} p_{\theta}(\tau)}{p_{\theta}(\tau)} && \text{(from chain rule)} \\ \implies \nabla_{\theta} p_{\theta}(\tau) &= p_{\theta}(\tau) \nabla_{\theta} \log p_{\theta}(\tau) && \text{(rearranging)} \end{aligned} \quad (37)$$

利用这个对数求导技巧：

$$\begin{aligned} \nabla_{\theta} J(\theta) &= \int_{\tau} \nabla_{\theta} p_{\theta}(\tau) R(\tau) d\tau \\ &= \int_{\tau} p_{\theta}(\tau) R(\tau) \nabla_{\theta} \log p_{\theta}(\tau) d\tau \\ &= \mathbb{E}_{\tau \sim p_{\theta}} [R(\tau) \nabla_{\theta} \log p_{\theta}(\tau)] \end{aligned} \quad (38)$$

最后一步用的是轨迹分布 $p_\theta(\tau)$ 下期望的定义：对任意函数 f ，有 $\mathbb{E}_{\tau \sim p_\theta}[f(\tau)] = \int_\tau f(\tau) p_\theta(\tau) d\tau$ （离散情形则是求和）。把它写成期望很有用，因为我们可以用蒙特卡洛 rollout 来近似它，例如对由当前策略诱导的轨迹 $\tau_i \sim p_\theta$ 取 $\frac{1}{B} \sum_{i=1}^B f(\tau_i)$ 。

回到推导，展开轨迹的对数概率：

$$\log p_\theta(\tau) = \log d_0(s_0) + \sum_{t=0}^{\infty} \log \pi_\theta(a_t | s_t) + \sum_{t=0}^{\infty} \log p(s_{t+1} | s_t, a_t) \quad (39)$$

现在对它求梯度，我们得到：

- $\nabla_\theta \log d_0(s_0) = 0$ （初始状态分布不依赖 θ ）
- $\nabla_\theta \log p(s_{t+1} | s_t, a_t) = 0$ （环境转移动力学不依赖 θ ）
- 只有 $\nabla_\theta \log \pi_\theta(a_t | s_t)$ 留了下来

因此，轨迹对数概率的梯度化简为：

$$\nabla_\theta \log p_\theta(\tau) = \sum_{t=0}^{\infty} \nabla_\theta \log \pi_\theta(a_t | s_t) \quad (40)$$

推导到这一步，是实现上的一个关键节点。到这里我们已经看得足够远：轨迹分布的梯度化简成了语言模型策略概率（也就是我们正在训练的模型给出的 token 概率）的梯度之和。实践中，这产生了策略梯度方程的一种常见形式。它们最终在损失里看起来像是对数概率求和，然后我们通过自动微分计算梯度。你会反复看到的一段简短代码大致如下：

```
seq_log_probs = (token_log_probs * completion_mask).sum(dim=-1)
loss = -(seq_log_probs * advantages).mean()
loss.backward()
```

本章通篇你都会看到它。现在，回到形式化的策略梯度数学。

把它代回 式 38，我们得到：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim p_\theta} \left[\sum_{t=0}^{\infty} R(\tau) \nabla_\theta \log \pi_\theta(a_t | s_t) \right] \quad (41)$$

人们经常使用策略梯度的一个更一般的表述：

$$g = \nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim p_\theta} \left[\sum_{t=0}^{\infty} \Psi_t \nabla_\theta \log \pi_\theta(a_t | s_t) \right] \quad (42)$$

其中 Ψ_t 可以是下面这些（奖励通常也可以用 γ 折扣）——这套分类沿用了 Schulman 等 2015 年的做法 [119]：

1. $R(\tau) = \sum_{t=0}^{\infty} r_t$ ：整条轨迹的总奖励。
2. $\sum_{t'=t}^{\infty} r_{t'}$ ：动作 a_t 之后的奖励，也叫从时刻 t 起的回报 G_t 。
3. $\sum_{t'=t}^{\infty} r_{t'} - b(s_t)$ ：上一式带 baseline 的版本。
4. $Q^\pi(s_t, a_t)$ ：状态-动作值函数。

5. $A^\pi(s_t, a_t)$: 优势函数；如果能被准确计算，它给出理论上最低的方差。
6. $r_t + \gamma V^\pi(s_{t+1}) - V^\pi(s_t)$: 时序差分 (TD) 残差。

baseline 是一个用来降低策略更新方差的量（下面会详述）。

对语言模型来说，其中一些概念没那么说得通。例如，对确定性策略 π ，状态价值是 $V^\pi(s_t) = Q^\pi(s_t, \pi(s_t))$ （对最优价值函数则有 $V^*(s_t) = \max_{a_t} Q^*(s_t, a_t)$ ）。对随机策略，对应的恒等式是 $V^\pi(s_t) = \mathbb{E}_{a_t \sim \pi(\cdot|s_t)}[Q^\pi(s_t, a_t)]$ 。贝尔曼方程把 Q 与 V 联系起来：一般来说 $Q^\pi(s_t, a_t) = \mathbb{E}[r_t + \gamma V^\pi(s_{t+1}) | s_t, a_t]$ ；但对状态转移确定性的语言模型，这化简为 $Q(s_t, a_t) = r_t + \gamma V(s_{t+1})$ 。优势函数衡量动作 a_t 比平均水平好多少：

$$A(s_t, a_t) = Q(s_t, a_t) - V(s_t) = r_t + \gamma V(s_{t+1}) - V(s_t) \quad (43)$$

最后这个形式正是时序差分 (TD) 残差（上面第 6 项）——RL 中的一个基本量，衡量价值函数的预测与实际发生之间的差距，驱动价值函数向更准确的估计更新。实践中，我们用学到的价值函数 $\hat{V}$ 通过这个 TD 误差来估计优势。

6.2.2 朴素策略梯度

朴素策略梯度的实现，是对上述 $J(\theta)$ 关于策略参数求导来优化。一个简单的版本——关于时刻 t 的回报——是：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim p_\theta} \left[\sum_{t=0}^T G_t \nabla_\theta \log \pi_\theta(a_t | s_t) \right] \quad (44)$$

朴素策略梯度算法的一个常见问题是梯度更新方差很大，这可以用多种方式缓解。高方差源于：梯度更新是用回报 G 的估计计算出来的，而这个估计往往只来自环境中一小批 rollout，天然容易受噪声影响（例如语言模型在温度 > 0 下生成时固有的随机性）。在奖励稀疏的领域，回报估计之间的方差更高，因为更多样本是 0 或 1，而不是紧密聚集在一起。为缓解这一点，人们用各种技术来归一化价值估计，称为 *baseline*。Baseline 以多种方式做到这件事，本质上是按“状态相对于下游动作的价值”来做归一化（例如 Advantage 就是 Q 值与 V 值之差）。最简单的 baseline 是奖励的批均值或滑动平均。即便是这些与动作无关的 baseline，也能在不改变期望梯度的前提下降低方差，因为对任意只依赖状态的 $b(s)$ 都有 $\mathbb{E}_{a \sim \pi(a|s)}[b(s) \nabla_\theta \log \pi_\theta(a|s)] = 0$ ，从而显著改善学习信号。

本章讨论的许多策略梯度算法，都建立在策略梯度的优势形式上：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim p_\theta} \left[\sum_{t=0}^T A^\pi(s_t, a_t) \nabla_\theta \log \pi_\theta(a_t | s_t) \right] \quad (45)$$

6.2.3 REINFORCE

REINFORCE 这个名字很可能是先有词、后凑出的缩写 (backronym)，但它所代表的算法组件对现代强化学习算法相当重要。它定义于奠基性论文 *Simple statistical gradient-following algorithms for connectionist reinforcement learning* [120]：

这个名字是“REward Increment = Nonnegative Factor X Offset Reinforcement X Characteristic Eligibility”的缩写。

这三个组件对应的就是如何完成奖励增量，也就是策略梯度步。它的更新规则包含三部分：

1. 非负因子：学习率（步长），必须是正数，例如下面的 α 。
2. Offset Reinforcement（偏置强化）：一个 baseline b ，或对奖励的其他归一化因子，用来提升稳定性。
3. Characteristic Eligibility（特征资格）：把标量奖励信号归因到产生该动作的参数上。Williams 用 e 表示这个资格项（不是指数函数）。在现代策略梯度记号中，它对应 $\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)$ 。

于是形式看起来很熟悉：

$$\Delta_{\theta} = \alpha(r - b)e \quad (46)$$

换成更现代的记号与广义回报 G ，REINFORCE 算子写作：

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim p_{\theta}} \left[\sum_{t=0}^T (G_t - b(s_t)) \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right], \quad (47)$$

这里 $G_t - b(s_t)$ 就是策略在当前状态下的优势，所以我们可以把策略梯度改写成一种后面会继续使用的、带优势 A 的形式：

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim p_{\theta}} \left[\sum_{t=0}^T A_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right], \quad (48)$$

REINFORCE 是朴素策略梯度的一个具体实现，它使用梯度的蒙特卡洛估计量。




图 20: 面向语言模型的基础 REINFORCE 架构。经过整形的奖励把奖励模型分数与来自参考模型的 KL 惩罚结合在一起。本章后续都在这个结构上搭建。

6.2.4 REINFORCE Leave One Out (RLOO)

REINFORCE Leave One Out 与标准 REINFORCE 的核心实现差异在于：它用批次中其他样本的平均奖励来算 baseline，而不是对批次里所有奖励取平均 [121]、[118]、[122]。通过把当前样本自己

的奖励排除在它自己的 baseline 之外，RLOO 的 baseline 与所评估的动作相互独立，从而让梯度估计量保持严格无偏。

关键在于，这种方法只在“每个状态（提示）生成多条轨迹（补全）”时才成立——而这在用 RL 微调语言模型的多个领域中都是常见做法。

具体来说，对 REINFORCE Leave-One-Out (RLOO) 的 baseline，给定对某个提示 s 采样的 K 条轨迹（在提示条件下采取的动作） $a_1, \dots, a_K$ ，我们把 baseline 显式定义为如下按提示的量：

$$b(s, a_k) = \frac{1}{K-1} \sum_{i=1, i \neq k}^K R(s, a_i), \quad (49)$$

于是优势为：

$$A(s, a_k) = R(s, a_k) - b(s, a_k). \quad (50)$$

等价地，这可以表达为：

$$A(s, a_k) = \frac{K}{K-1} \left(R(s, a_k) - \frac{1}{K} \sum_{i=1}^K R(s, a_i) \right). \quad (51)$$

这是一个简单、低方差的按提示优势估计，与组相对策略优化（GRPO）中使用的组相对优势密切相关（GRPO 稍后讲，在近端策略优化 PPO 之后）。实践中，GRPO 式训练的主要差别在于它如何施加 KL 正则（作为显式的损失项，还是折进奖励里），以及是否使用 PPO 式的比率裁剪。具体地说，经典的 GRPO 实现把 KL 惩罚加在损失层面，而 RLOO 或传统策略梯度的推导则把 KL 惩罚加在奖励本身上。随着从 RLHF 转向推理与可验证奖励的强化学习（RLVR），KL 惩罚的普遍性整体下降，许多对 RLHF 代码的推理化改造干脆把它整个关掉。不过，RLOO 的优势仍可与 PPO 的裁剪结合使用——这也说明这些算法彼此有多相似。

RLOO 以及其他不使用价值网络的算法——价值网络是额外的一份模型副本（一个 critic），逐 token 预测标量价值 $V(s_t)$ ——在计算损失时把同一个序列级优势（或奖励）分配给每个 token。而使用学到的价值网络的算法（如 PPO）为每个 token 单独分配不同的值，从 EOS token 处获得的最终奖励往回折扣。配上 KL 距离惩罚时，RLOO 把逐 token 的 KL 在整个补全上聚合，再把这个标量折进序列奖励，于是得到的优势被广播到所有 token。PPO 则在计算 A_t 之前，从逐 token 奖励中减去逐 token 的 KL，从而实现 token 级的信用分配。GRPO 通常保留序列级优势，但在损失中额外增加一个逐 token 的项，而不是从奖励中减去它。这些细节与权衡将在本章后文讨论。

6.2.5 近端策略优化（PPO）

近端策略优化（PPO）[123] 是深度 RL 众多成功背后的奠基性算法之一（例如掌握 Dota 2 的 OpenAI Five [124]，以及大量研究）。PPO 最大化、关于优势与策略概率的目标如下：

$$J(\theta) = \min \left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)} A, \text{clip} \left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)}, 1 - \varepsilon, 1 + \varepsilon \right) A \right). \quad (52)$$




图 21: REINFORCE Leave-One-Out (RLOO) 架构。每个提示生成多个补全，从而无需学习价值函数就能得到用于优势估计的留一 baseline。

这里 $\pi_\theta(a|s)$ 是正在被优化的当前策略， $\pi_{\theta_{\text{old}}}(a|s)$ 是用于收集训练数据的策略（即上一轮迭代的策略）。这两个策略的比值来自重要性采样——它让我们能够复用旧策略下收集的数据来估计新策略的梯度。

回顾策略梯度的优势形式（式 45），我们有：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim p_\theta} \left[\sum_{t=0}^T A^{\pi_\theta}(s_t, a_t) \nabla_\theta \log \pi_\theta(a_t | s_t) \right]. \quad (53)$$

这个期望是在由 π_θ 诱导的轨迹分布上取的；但实践中我们想在一个由固定策略 $\pi_{\theta_{\text{old}}}$ 收集的批次上做多个梯度步。为修正这个分布不匹配，我们乘上重要性权重 $\frac{\pi_\theta(a|s)}{\pi_{\theta_{\text{old}}}(a|s)}$ ，它把样本重新加权，以反映它们在当前策略下相对于数据收集策略变得多可能或少可能。如果不加约束，优化这个重要性加权目标会在比值远离 1 时导致破坏性的巨大策略更新。PPO 的应对方式是把比值裁剪到区间 $[1 - \varepsilon, 1 + \varepsilon]$ ，确保策略在单次更新中不会变化过猛。

注意，当我们进入 PPO 及其同类算法时，我们往往处理目标函数而不是显式梯度。原因是：一旦加入 min 与裁剪操作，PPO 目标就没有一个易解读的解析梯度了（视写法不同，梯度大约有 4 项，对应图 23 中的各个区域）；写出目标函数是传达这些算法更清晰的方式。

为完整起见，PPO 通常写成在时间步上的期望裁剪代理目标：

$$J(\theta) = \mathbb{E}_t [\min(\rho_t(\theta) A_t, \text{clip}(\rho_t(\theta), 1 - \varepsilon, 1 + \varepsilon) A_t)], \quad \rho_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}. \quad (54)$$

这个目标通常只需加一个负号就转成损失函数，从而让优化器去把它压得越低越好。

对语言模型而言，目标（或损失）是逐 token 计算的；这可以直观地建立在“整段自回归预测序列的概率如何计算”之上——即概率的连乘。由此，常见实现是用对数概率，因为在现代语言建模框架里这样做计算更简单。实践中，人们计算 token 对数概率之差，再取指数，就还原出策略比值 ρ_t 。

$$J(\theta) = \frac{1}{|a|} \sum_{t=0}^{|a|} \min \left(\frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)} A_t, \text{clip} \left(\frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}, 1 - \varepsilon, 1 + \varepsilon \right) A_t \right). \quad (55)$$

这是 PPO 的逐 token 版本，也同样适用于其他策略梯度方法；本章后面的实现部分会进一步展开。这里的“按动作 token 数取平均”那一项 $\frac{1}{|a|}$ 来自常见的实现习惯，并不在损失的正式推导中（见 [125]）。




图 22: PPO 框架。一个学到的价值函数支撑广义优势估计（GAE）以得到逐 token 优势，再配合裁剪代理目标使用。

下面我们解释这个损失函数在不同优势与策略比值下会触发哪些情形。在实现层面，PPO 的内部计算涉及两个主要项：1）带学到优势的标准策略梯度；2）基于最大步长的裁剪策略梯度。

为理解各种情形如何出现，我们可以把策略比值定义为：

$$\rho(\theta) = \frac{\pi_{\theta}(a|s)}{\pi_{\theta_{\text{old}}}(a|s)} \quad (56)$$

策略比值是 PPO 及相关算法的核心。它来自对策略求梯度的过程，并以非常直观的方式控制参数更新。对任意一批数据，该批次的第一个梯度步中策略比值起始为 1，因为此时 π_{θ} 与 $\pi_{\theta_{\text{old}}}$ 相同。随后在下一个梯度步中，如果该步提高了某些具有正优势的 token 的可能性，比值就会大于 1；反之则小于 1。常见做法是在更新 $\pi_{\theta_{\text{old}}}$ 之前，对每批数据用策略梯度算法做 1-4 个梯度步。

6.2.5.1 理解 PPO 的目标函数 总体而言，PPO 的目标可以由图 23 中“目标对策略比值”的两条曲线来可视化。PPO 的目标通过改变被采样动作的概率而被最大化。在数值上，这个目标用巧妙的 min 操作同时处理正负优势两种情形，使得更新最多只会把策略比值从 1 推开 ϵ 的距离。

在信任域内部，PPO 与其他策略梯度算法的作用相同。这是有意设计的！信任域是一个用来给 PPO 及其同类算法的最大步长封顶、以保证更新稳定性的概念。PPO 算法的核心——裁剪与 min/max 函数——定义的正是这个区域。在它之外，目标变为平坦。

“信任域”这个想法来自数值优化文献 [126]，但在深度 RL 中是由信任域策略优化（TRPO）算法普及开来的，后者被公认为 PPO 的前身 [127]。信任域就是完整策略梯度步被施加的区域——因为这里的更新不会被 PPO 目标的 max/min 操作“裁剪”掉。

策略比值与优势的组会落在几种不同构型中；图 23 按优势 A_t 的符号、以及策略比值 $\rho(\theta)$ 落入三个区间中的哪一个来枚举。每个区间的结果由两个事实决定：优势的符号决定我们想让该动作更可能还是更不可能，而 min 操作则在未裁剪项 $\rho(\theta)A_t$ 与其裁剪版本之间做选择。

裁剪只在两个区域把梯度归零——即策略已经把被采样动作朝期望方向推过了信任域边缘的区域：




图 23: PPO 目标 $J(\theta)$ 随策略比值 $\rho(\theta)$ 变化的可视化，分别对应正优势与负优势。每个子图中，三个比值区间都标注了未裁剪项、裁剪项、得到的目标以及梯度。

- **正优势且** $\rho(\theta) > 1 + \varepsilon$: 在 π_θ 下该动作已经比在 $\pi_{\theta_{\text{old}}}$ 下明显更可能。目标在 $(1 + \varepsilon)A_t$ 处饱和，梯度为零，不做更新——我们避免对一个已经过度表达的动作继续过度强化。
- **负优势且** $\rho(\theta) < 1 - \varepsilon$: 在 π_θ 下该动作已经明显更不可能。目标在 $(1 - \varepsilon)A_t$ 处饱和，梯度同样为零，不做更新——我们避免对一个已经被抑制的动作继续过度压制。

其余各处，未裁剪项 $\rho(\theta)A_t$ 生效，PPO 采取标准的策略梯度步：当 $A_t > 0$ 时提高该动作的概率，当 $A_t < 0$ 时降低它。我们可以按“每个区域对更新后的策略 π_θ 提出了什么要求”来读图 23：

- 正优势下的斜线、未裁剪区域（绿色）**提高**被采样动作的概率；
- 负优势下的斜线、未裁剪区域（红色）**降低**它；
- 平坦的裁剪区域（灰色）让策略**保持不变**，因为其梯度为零。

把同样的区域逐项写出来：

6.2.5.1.1 正优势 ($A_t > 0$) 这意味着根据价值函数，所采取的动作是有益的，我们想在将来提高采取该动作的可能性。下面看策略比值 $\rho(\theta)$ 的各种情形：

1. $\rho(\theta) < 1 - \varepsilon$:

- **解释**：新策略下该动作比旧策略下更不可能
- **未裁剪项**： $\rho(\theta)A_t$
- **裁剪项**： $(1 - \varepsilon)A_t$
- **目标**： $\rho(\theta)A_t$
- **梯度**： $\nabla_\theta \rho(\theta)A_t \neq 0$
- **发生什么**：正常的策略梯度更新——提高该动作的可能性

2. $1 - \varepsilon \leq \rho(\theta) \leq 1 + \varepsilon$:

- **解释**：新策略下该动作与旧策略下几乎同样可能
- **未裁剪项**： $\rho(\theta)A_t$
- **裁剪项**： $\rho(\theta)A_t$
- **目标**： $\rho(\theta)A_t$
- **梯度**： $\nabla_\theta \rho(\theta)A_t \neq 0$
- **发生什么**：正常的策略梯度更新——提高该动作的可能性

3. $1 + \varepsilon < \rho(\theta)$:

- **解释**：新策略下该动作比旧策略下更可能
- **未裁剪项**： $\rho(\theta)A_t$
- **裁剪项**： $(1 + \varepsilon)A_t$
- **目标**： $(1 + \varepsilon)A_t$
- **梯度**： $\nabla_\theta (1 + \varepsilon)A_t = 0$
- **发生什么**：不更新——该动作在新策略下已经更可能

总结一下：当优势为正 ($A_t > 0$) 时，我们想提升该动作的概率。因此：

- 只有当 $\pi_{\text{new}}(a) \leq (1 + \varepsilon)\pi_{\text{old}}(a)$ 时才做梯度步。直观地说，由于优势为正，我们想提升该动作的概率，但不要提得太猛，以至于把它变得明显更可能。
- 关键在于，当 $\pi_{\text{new}}(a) > (1 + \varepsilon)\pi_{\text{old}}(a)$ 时，我们不做任何更新，裁剪目标的梯度为 0。直观地说，该动作在新策略下已经过度表达，我们不想继续过度强化它。

6.2.5.1.2 负优势 ($A_t < 0$) 这意味着根据价值函数，所采取的动作是有害的，我们想在将来降低采取该动作的可能性。下面看策略比值 $\rho(\theta)$ 的各种情形：

1. $\rho(\theta) < 1 - \varepsilon$ ：

- 解释：新策略下该动作比旧策略下更不可能
- 未裁剪项： $\rho(\theta)A_t$
- 裁剪项： $(1 - \varepsilon)A_t$
- 目标： $(1 - \varepsilon)A_t$
- 梯度： $\nabla_{\theta}(1 - \varepsilon)A_t = 0$
- 发生什么：不更新——该动作在新策略下已经更不可能

2. $1 - \varepsilon \leq \rho(\theta) \leq 1 + \varepsilon$ ：

- 解释：新策略下该动作与旧策略下几乎同样可能
- 未裁剪项： $\rho(\theta)A_t$
- 裁剪项： $\rho(\theta)A_t$
- 目标： $\rho(\theta)A_t$
- 梯度： $\nabla_{\theta}\rho(\theta)A_t \neq 0$
- 发生什么：正常的策略梯度更新——降低该动作的可能性

3. $1 + \varepsilon < \rho(\theta)$ ：

- 解释：新策略下该动作比旧策略下更可能
- 未裁剪项： $\rho(\theta)A_t$
- 裁剪项： $(1 + \varepsilon)A_t$
- 目标： $\rho(\theta)A_t$
- 梯度： $\nabla_{\theta}\rho(\theta)A_t \neq 0$
- 发生什么：正常的策略梯度更新——降低该动作的可能性

总结一下：当优势为负 ($A_t < 0$) 时，我们想降低该动作的概率。因此：

- 只有当 $\pi_{\text{new}}(a) \geq (1 - \varepsilon)\pi_{\text{old}}(a)$ 时才做梯度步。直观地说，由于优势为负，我们想降低该动作的概率，并且降低的程度与优势成比例。
- 关键在于，当 $\pi_{\text{new}}(a) < (1 - \varepsilon)\pi_{\text{old}}(a)$ 时，我们不做任何更新，裁剪目标的梯度为 0。直观地说，该动作在新策略下已经更不可能，我们不想继续过度压制它。

务必记住：信任域内部的 PPO 与标准形式的策略梯度大致相同。

6.2.5.2 价值函数与 PPO PPO 中的价值函数是模型的额外一份副本，用来预测每个 token 的价值。在传统 RL 中，一个 token（或状态）的价值预测的是从该时刻起的未来回报，通常带折扣。PPO 中的这个价值被用作学到的 baseline，代表了对 REINFORCE 所用简单蒙特卡洛版本的演进（后者不需要学到的价值网络）。这也凸显出：PPO 在优化形式、baseline 等多个方面都是 REINFORCE 与朴素策略梯度的演进。实践中，对 PPO 及语言模型所用的其他算法而言，这个价值预测的是每个 token 在扣除 KL 惩罚之后的回报（如前所述，逐 token 损失传统上包含来自奖励的 KL）。

学习价值函数有几种不同的方法（或目标）。广义优势估计（GAE）被认为是现代系统中的最先进且经典的做法，但它更复杂——要在多个步上计算价值预测误差，见本章后面关于 GAE 的一节。价值函数也可以用“更新策略所用 rollout”的蒙特卡洛估计来学习。PPO 有两个损失——一个用来学习价值函数，另一个用该价值函数来更新策略。




图 24: 价值函数的训练使用同策略 rollout 计算目标。模型在每个 token 处预测 V_t , 并通过 MSE 针对目标回报 $\hat{V}_t$ 训练。随后优势 $A_t = \hat{V}_t - V_t$ 为策略梯度更新加权。

一个价值网络损失的简单示例实现如下。

```
# Basic PPO critic targets & loss (no GAE)
#
# B: Batch Size
# L: Completion Length
# Inputs:
# rewards: (B, L) post-KL per-token rewards; EOS row includes outcome
# done_mask: (B, L) 1.0 at terminal token (EOS or truncation if penalized), else 0.0
# completion_mask: (B, L) 1.0 on response tokens to supervise (ignore the prompt)
# values: (B, L) current critic predictions V_theta(s_t)
#     because a value network is a running update
# old_values: (B, L) critic predictions at rollout time V_{theta_old}(s_t)
# gamma: discount factor, float (often 1.0 for LM RLHF)
# epsilon_v: float value clip range (e.g., 0.2), similar to PPO Loss Update itself, optional
#
# Returns:
# value_loss: scalar; advantages: (B, L) detached (for policy loss)

B, L = rewards.shape

# 1) Monte Carlo returns per token (reset at terminals)
# Apply discounting, if enabled
returns = torch.zeros_like(rewards)
running = torch.zeros(B, device=rewards.device, dtype=rewards.dtype)
for t in reversed(range(L)):
    running = rewards[:, t] + gamma * (1.0 - done_mask[:, t]) * running
    returns[:, t] = running

targets = returns # y_t = G_t (post-KL)

# 2) PPO-style value clipping (optional)
v_pred = values
```

```

v_old = old_values
v_clip = torch.clamp(v_pred, v_old - epsilon_v, v_old + epsilon_v)

vf_unclipped = 0.5 * (v_pred - targets) ** 2
vf_clipped = 0.5 * (v_clip - targets) ** 2
vf_loss_tok = torch.max(vf_unclipped, vf_clipped)

# 3) Mask to response tokens and aggregate
denom = completion_mask.sum(dim=1).clamp_min(1)
value_loss = ((vf_loss_tok * completion_mask).sum(dim=1) / denom).mean()

# 4) Advantages for policy loss (no GAE): A_t = G_t - V(s_t)
advantages = (targets - v_pred).detach()

# The value loss is applied later, often with the PG loss, e.g.
# total_loss = policy_loss + vf_loss_coef * value_loss

```

6.2.6 组相对策略优化 (GRPO)

组相对策略优化 (GRPO) 由 DeepSeekMath 提出 [128], 并用于 DeepSeek 的其他工作, 例如 DeepSeek-V3 [16] 与 DeepSeek-R1 [15]。GRPO 可以看作一个受 PPO 启发的算法: 代理损失非常相似, 但它不需要用原策略语言模型的另一份副本 (或另一个检查点作初始化) 去学习价值函数。这带来两个公认的好处:

1. 避开了“从 LM 主干学价值函数”这一难题——该领域的研究尚未确立最佳实践。
2. 省显存: 不需要在内存里保留额外一套模型权重 (从需要当前策略、参考策略和价值函数三份, 变成只需前两份)。

GRPO 做到这一点的方式是简化价值估计: 通过估计优势或 baseline, 它给回合中每个 token 赋同一个值 (即对某个提示的补全, 每个 token 得到相同的值, 而不是标准价值函数里的折扣奖励)。这个估计来自从同一初始状态/提示 (s) 收集多个补全 (a_i) 和奖励 (r_i), 也就是蒙特卡洛估计。

形式化地说, GRPO 目标与上面的 PPO 目标非常相似。对 GRPO, 目标 (或损失) 是在给定提示 s 的一组补全 $\{a_1, a_2, \dots, a_G\}$ 上累加的。GRPO 目标如下:

$$J(\theta) = \frac{1}{G} \sum_{i=1}^G \left(\min \left(\frac{\pi_{\theta}(a_i|s)}{\pi_{\theta_{\text{old}}}(a_i|s)} A_i, \text{clip} \left(\frac{\pi_{\theta}(a_i|s)}{\pi_{\theta_{\text{old}}}(a_i|s)}, 1 - \varepsilon, 1 + \varepsilon \right) A_i \right) - \beta \mathcal{D}_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \right). \quad (57)$$

注意, 相对于 PPO, GRPO 的标准实现把 KL 距离放在损失里。与上面类似, 我们可以把它展开成逐 token 的计算:

$$J(\theta) = \frac{1}{G} \sum_{i=1}^G \frac{1}{|a_i|} \sum_{t=1}^{|a_i|} \left(\min \left(\frac{\pi_{\theta}(a_{i,t}|s_i)}{\pi_{\theta_{\text{old}}}(a_{i,t}|s_i)} A_{i,t}, \text{clip} \left(\frac{\pi_{\theta}(a_{i,t}|s_i)}{\pi_{\theta_{\text{old}}}(a_{i,t}|s_i)}, 1 - \varepsilon, 1 + \varepsilon \right) A_{i,t} \right) - \beta \mathcal{D}_{\text{KL}}(\pi_{\theta}(\cdot|s_i) \parallel \pi_{\text{ref}}(\cdot|s_i)) \right) \quad (58)$$

补全下标 i 的优势计算为：

$$A_i = \frac{r_i - \text{mean}(r_1, r_2, \dots, r_G)}{\text{std}(r_1, r_2, \dots, r_G)}. \quad (59)$$




图 25: GRPO 架构。优势相对于组内均值与标准差做归一化。KL 惩罚直接施加在损失上，而不是用来整形奖励。

直观上，GRPO 的更新是在一个批次内比较对同一个问题的多个答案。模型学会变得更像那些被标为正确的答案、更不像其他答案。这是计算优势的一种非常简单的方式——优势衡量的是某个具体动作在给定状态下比平均水平好多少。相对于 PPO、REINFORCE，以及广义上“用奖励模型打分（相对输出奖励）的 RLHF”，GRPO 通常对每个提示采样多得多的样本，因为它的优势完全取决于一个补全相对于同一提示下其他补全的价值。这里，当前策略针对给定提示生成多个回复，而组式的 GRPO 优势估计因此获得了有价值的上下文。PPO 与朴素策略梯度算法本来是为了准确估计每个补全的奖励而设计的（事实上，在某些情况下更多补全对改善价值估计帮助不大）。GRPO 及其变体特别契合现代语言模型工具——在那里，对给定提示取多个补全非常自然（尤其是和“机器人任务中从某个固定环境状态出发的多个动作”相比）。

GRPO 的优势计算在偏置上有取舍。按标准差做归一化，会奖励一个批次中答案正确性变化小的问题。对于答案几乎全对或全错的问题，标准差更小，优势更大。Liu 等 2025 [125] 基于这一偏置提出去掉标准差项，但代价是会降低“大部分错、少数对”这类问题的权重——而那可能恰恰是对模型有价值的学习信号。这些高方差提示可能正是最难的案例：只有少数采样补全找到了正确答案，从而提供了很强的训练信号。

式 59 是 GRPO 在结果监督下（标准奖励模型，或单一可验证奖励）的实现；在过程监督下则需要不同的实现。那种情况下，GRPO 把优势计算为其后各推理步骤归一化奖励之和。

最后，GRPO 的优势估计也可以不配 PPO 裁剪，用在更朴素的策略梯度版本上（例如 REINFORCE），但这不是其经典形式。作为这些算法彼此交织的一个例子，我们可以说明：GRPO 的一个变体 Dr. GRPO (GRPO Done Right) [125] 的优势估计，与 RLOO 估计（用其他样本的平均奖励作 baseline）在相差一个常数缩放因子意义下等价（由于实现中通常会对优势做归一化，这个常数一般无关紧要）。Dr. GRPO 从式 59 中去了标准差归一化项——注意这同时把优势放大了，效果等价于对“答案分数有方差”的样本提高了 GRPO 的学习率。这解决了一个偏向“奖励方差小的问题”（即答案几乎全对或全错）的偏置，但如果“只有一条样本答对的问题”本身很重要，这样做也有潜在代价。对规模为 G 的组内补全 i ，Dr. GRPO 的优势定义为：

$$\tilde{A}_i = r_i - \text{mean}(r_1, r_2, \dots, r_G) = r_i - \frac{1}{G} \sum_{j=1}^G r_j \quad (60)$$

用同样的记号，我们可以回忆 RLOO 的优势估计为：

$$A_i^{\text{RLOO}} = r_i - \frac{1}{G-1} \sum_{j=1, j \neq i}^G r_j \quad (61)$$

于是，如果把 Dr. GRPO 的优势定义乘上 $\frac{G}{G-1}$ ，就能看出一种缩放等价：

$$\begin{aligned} \frac{G}{G-1} \tilde{A}_i &= \frac{G}{G-1} \left(r_i - \frac{1}{G} \sum_{j=1}^G r_j \right) \\ &= \frac{G}{G-1} r_i - \frac{1}{G-1} \sum_{j=1}^G r_j \\ &= \frac{G}{G-1} r_i - \frac{1}{G-1} \sum_{j=1, j \neq i}^G r_j - \frac{1}{G-1} r_i \\ &= r_i \left(\frac{G}{G-1} - \frac{1}{G-1} \right) - \frac{1}{G-1} \sum_{j=1, j \neq i}^G r_j \\ &= r_i - \frac{1}{G-1} \sum_{j=1, j \neq i}^G r_j \\ &= A_i^{\text{RLOO}} \end{aligned} \quad (62)$$

6.2.7 组序列策略优化 (GSPO)

当在“由先前策略收集的一批数据”上做多个梯度步时，需要用重要性采样来修正数据收集策略与当前被优化策略之间的分布不匹配。标准的重要性采样恒等式让我们能用来自一个分布的样本估计另一个分布下的期望：

$$\mathbb{E}_p[f(x)] = \mathbb{E}_q \left[f(x) \frac{p(x)}{q(x)} \right], \quad (63)$$

其中 p 是目标分布， q 是采样分布， $\frac{p(x)}{q(x)}$ 是重要性权重。在策略梯度方法中， $p = \pi_\theta$ 是我们优化的当前策略， $q = \pi_{\theta_{\text{old}}}$ 是生成训练数据的策略。这让我们能对在 $\pi_{\theta_{\text{old}}}$ 下收集的样本重新加权，以估计 π_θ 的梯度，从而支持每批 rollout 做多个梯度步。

这种分布不匹配出现在两种常见场景中：(1) 对单个批次做多个梯度步，此时 π_θ 在每次更新后都会偏离 $\pi_{\theta_{\text{old}}}$ ；(2) 在异步训练系统中，推理后端（如 vLLM）与训练后端（如 FSDP）可能因同步延迟而持有不同的模型权重（见本章后面的「异步性」一节——这一做法尤其在 RLVR 兴起后变得普遍，但在 RLHF 设定中也有使用）。

PPO 与 GRPO 在 **token** 层面施加重要性采样，并通过裁剪代理目标来稳定学习。然而这种做法有一个微妙的失效模式：当某个 token 的重要性比值超出裁剪范围 $[1 - \varepsilon, 1 + \varepsilon]$ 时，该 token 就得到

零梯度。对于那些罕见但重要的 token——例如模型起初赋予低概率的关键推理步骤——这种“token 丢弃”会阻碍模型学会更可靠地产生它们。

组序列策略优化（GSPO）[129] 扩展了 GRPO：它在**序列层面**而非 token 层面计算重要性比值。这个算法的实践动机——以及它的同类 CISPO（后者改变了策略梯度算法中重要性采样的计算方式，稍后讨论）——在于逐 token 的重要性比值往往数值不稳定。其概念动机则是：当奖励在序列层面被赋予时（多数 RLHF 与 RLVR 设定都是如此），重要性采样修正也应当与那个粒度匹配。

对长序列和/或大型稀疏模型（例如现代专家混合 MoE 模型），逐 token 比值的行爲可能很不稳定：单个比值很大的 token 就可能主导策略更新，或者一条回复里许多 token 各自被独立裁剪，把学习信号在同一回复内打碎。GSPO 通过为每条回复计算单个重要性权重来解决这个问题。

回忆一下，一条完整回复的概率按自回归方式分解：

$$\pi_{\theta}(a \mid s) = \prod_{t=1}^{|a|} \pi_{\theta}(a_t \mid s, a_{<t}). \quad (64)$$

为简化起见，我们常把条件策略 $\pi_{\theta}(a_t \mid s, a_{<t})$ 简写为 $\pi_{\theta}(a_t \mid s)$ ，其中隐含了补全中之前的动作（token）。GSPO 用几何平均定义了一个按长度归一化的序列级重要性比值（以避免长序列带来的数值问题）：

$$\rho_i(\theta) = \left(\frac{\pi_{\theta}(a_i \mid s)}{\pi_{\theta_{\text{old}}}(a_i \mid s)} \right)^{\frac{1}{|a_i|}} = \exp \left(\frac{1}{|a_i|} \sum_{t=1}^{|a_i|} \log \frac{\pi_{\theta}(a_{i,t} \mid s, a_{i,<t})}{\pi_{\theta_{\text{old}}}(a_{i,t} \mid s, a_{i,<t})} \right). \quad (65)$$

GSPO 的目标与 GRPO 类似，只是使用了这个序列级比值：

$$J_{\text{GSPO}}(\theta) = \mathbb{E}_{s \sim \mathcal{D}, \{a_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot \mid s)} \left[\frac{1}{G} \sum_{i=1}^G \min(\rho_i(\theta) A_i, \text{clip}(\rho_i(\theta), 1 - \varepsilon, 1 + \varepsilon) A_i) \right]. \quad (66)$$

由于比值经过长度归一化，裁剪范围 ε 作用在“逐 token 平均”的尺度上，使有效约束在不同长度的回复之间可比。实现时，序列级权重 ρ_i 被统一施加到回复 a_i 中的所有 token 上——这简化了梯度计算，同时保持了序列级的重要性采样修正。

优势计算与 GRPO 相同（式 59），使用组相对均值与标准差归一化，也可以像 GRPO 的其他衍生研究那样加以修改。GSPO 可以概括为“带序列级重要性比值的 GRPO”——重要性采样修正的粒度与奖励的粒度相匹配。

6.2.8 裁剪重要性采样策略优化（CISPO）

裁剪重要性采样策略优化（CISPO）[130] 走了另一条路：它不裁剪代理目标，而是**直接裁剪重要性权重本身**，同时为所有 token 保留梯度。该目标对被裁剪的重要性权重使用 stop-gradient，从而回到 REINFORCE 式的表述，而不是 PPO 式的双边裁剪：

$$J_{\text{CISPO}}(\theta) = \mathbb{E}_{s \sim \mathcal{D}, \{a_i\}_{i=1}^K \sim \pi_{\theta_{\text{old}}}(\cdot \mid s)} \left[\frac{1}{\sum_{i=1}^K |a_i|} \sum_{i=1}^K \sum_{t=1}^{|a_i|} \text{sg}(\hat{\rho}_{i,t}(\theta)) A_{i,t} \log \pi_{\theta}(a_{i,t} \mid s, a_{i,<t}) \right], \quad (67)$$

其中 $\text{sg}(\cdot)$ 表示 stop-gradient（该权重被使用但不参与求导），被裁剪的重要性比值为：

$$\hat{\rho}_{i,t}(\theta) = \text{clip}(\rho_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}), \quad \rho_{i,t}(\theta) = \frac{\pi_{\theta}(a_{i,t} \mid s, a_{i,<t})}{\pi_{\theta_{\text{old}}}(a_{i,t} \mid s, a_{i,<t})}. \quad (68)$$

它与 PPO/GRPO 的关键差别微妙但重要：**裁剪权重（而非目标）**意味着每个 token 仍然获得一个与其优势成正比的梯度信号——权重只是限制了这个信号被重要性比值放大或压制的幅度。这是一个偏差-方差权衡：裁剪权重引入偏差，但控制了方差，而且关键在于避免了把 token 梯度完全丢弃。

CISPO 与 GSPO 都是由那些在把 RL 应用到大规模 MoE 模型上推进极限的机构提出的，而 MoE 模型以数值问题著称。相关论文指出，逐 token 的重要性采样比值不稳定，会给梯度带来可观的方差、拖累学习。这让这些算法在大规模模型上格外有影响，但在更小规模的学术实验中研究得更少、收益也更不明显。

CISPO 还允许非对称的裁剪边界（ $\varepsilon_{\text{low}} \neq \varepsilon_{\text{high}}$ ），类似于本章后面会讨论的 DAPO 的“clip-higher”改动——它可以为模型想要提高权重的 token 允许更大的更新，从而鼓励探索。相关工作包括 Tapered Off-Policy REINFORCE（TOPR）[131]，它也像 CISPO 那样直接裁剪重要性采样权重，而不是像 PPO/GRPO 那样在目标函数内部裁剪；但它工作在序列层面（像 GSPO），并依据奖励符号使用非对称裁剪——对正奖励不做重要性采样修正，对负奖励把比值裁剪到 $[0, 1]$ ——从而实现稳定的异策略学习。

6.2.9 算法对比

本章每个算法共享同一个核心梯度形状（式 25），但在如何估计优势、如何控制优化上不同：

- **REINFORCE**：最简单的策略梯度实现，用奖励的蒙特卡洛估计与基于状态的 baseline 来降低方差。
- **RLOO**：REINFORCE 加每个提示多样本，每个样本的 baseline 取其他样本奖励的平均（留一法），以降低梯度方差。
- **PPO**：增加一个学到的价值函数和一个裁剪策略比值，以获得更准确、更稳定的梯度更新。
- **GRPO**：PPO 的简化变体——对每个提示的多个补全分组，在组内归一化奖励来计算优势，从而不需要价值函数。
- **CISPO**：REINFORCE 式算法，对重要性采样权重（而不是像 PPO/GRPO 那样对目标）做带 stop-gradient 的裁剪以求稳定，因此每个 token 都能收到梯度信号。
- **GSPO**：类似 GRPO，但把策略比值按补全长度归一化，从而防止长度偏置。
- **DPO**：不是 RL 算法，而是一种绕过独立奖励模型、直接从偏好对优化、以解决同一偏好优化问题的方法（见第 8 章）。

上述所有策略梯度算法在推导上都是**同策略**的，尽管实践中大多数会被略微用于异策略场景。第 8 章的 DPO 及其他直接对齐算法默认就是**异策略**的。它们都可以搭配学到的奖励模型或可验证奖励。只有 PPO 需要一个学到的价值函数。REINFORCE 与 RLOO 没有重要性采样比值——其余算法各自引入一个，以便在一批 rollout 上做多个梯度步，其差别在于粒度和裁剪策略，汇总如下表。

表 3: 策略梯度算法对比。

方法	重要性采样粒度	裁剪方式	优势
REINFORCE	无	无	蒙特卡洛 baseline

方法	重要性采样粒度	裁剪方式	优势
RLOO	无	无	留一法
PPO	token	目标（双边）	学到的价值函数
GRPO	token	目标（双边）	组相对
GSPO	序列	目标（双边）	组相对
CISPO	token	权重（stop-grad）	组相对

各方法的核心损失 $\mathcal{L}(\theta)$ 为：

$$\begin{aligned}
\text{REINFORCE:} \quad & -\frac{1}{T} \sum_{t=1}^T \log \pi_{\theta}(a_t | s_t) (G_t - b(s_t)) \\
\text{RLOO:} \quad & -\frac{1}{K} \sum_{i=1}^K \sum_t \log \pi_{\theta}(a_{i,t} | s_{i,t}) \left(R_i - \frac{1}{K-1} \sum_{j \neq i} R_j \right) \\
\text{CISPO:} \quad & -\sum_{i,t} \text{sg}(\hat{\rho}_{i,t}) A_{i,t} \log \pi_{\theta}(a_{i,t} | s_{i,t}) \\
& \hat{\rho}_{i,t} = \text{clip}(\rho_{i,t}, 1 - \varepsilon, 1 + \varepsilon) \\
\text{PPO:} \quad & -\frac{1}{T} \sum_{t=1}^T \min(\rho_t A_t, \text{clip}(\rho_t, 1 - \varepsilon, 1 + \varepsilon) A_t) \\
& \rho_t = \frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)} \\
\text{GRPO:} \quad & -\frac{1}{G} \sum_{i=1}^G \min(\rho_i A_i, \text{clip}(\rho_i, 1 - \varepsilon, 1 + \varepsilon) A_i) \\
& \rho_i = \frac{\pi_{\theta}(a_i | s)}{\pi_{\theta_{\text{old}}}(a_i | s)}, \quad A_i = \frac{r_i - \text{mean}(r_{1:G})}{\text{std}(r_{1:G})} \\
\text{GSPO:} \quad & -\frac{1}{G} \sum_{i=1}^G \min(\rho_i A_i, \text{clip}(\rho_i, 1 - \varepsilon, 1 + \varepsilon) A_i) \\
& \rho_i = \left(\frac{\pi_{\theta}(a_i | s)}{\pi_{\theta_{\text{old}}}(a_i | s)} \right)^{1/|a_i|} \\
\text{DPO:} \quad & -\mathbb{E}_{(x,y^w,y^l)} [\log \sigma(\beta[\Delta \log \pi_{\theta}(x) - \Delta \log \pi_{\text{ref}}(x)])]
\end{aligned}$$

6.3 实现

与这些算法最初被提出的深度 RL 文献相比，为优化语言模型或其他大型 AI 模型而实现 RL，需要许多细小的实现细节。本节我们点出区分流行算法实现的一些关键因素。

这类训练还有许多其他小细节。例如，用语言模型做 RLHF 时有一个关键步骤是生成供奖励模型评分的文本。正常情况下，模型应当生成一个序列结束（EOS）token 来表示生成完毕；但常见做法是

对生成长度设一个硬上限，以便高效利用基础设施。RLHF 的一个失效模式是：模型的回答经常被截断，把奖励模型的评分推向分布之外、给出不可预测的分数。解决办法是只对 `eos_token` 运行奖励模型打分，并对生成过长另外施加惩罚。

流行的开源 RLHF 工具在不同算法之间的实现细节差异很大（见 [132] 的表 10）。这里未覆盖的一些决策包括：

- **价值网络的初始化**：PPO 及类似算法内部使用的学到的价值网络，可以从同架构的另一个模型或随机权重开始。这对性能影响可能很大。InstructGPT 确立的标准做法 [3]（并在 Tülu 3 的 RLVR 工作中沿用 [6]）是用 RLHF 所用的奖励模型来初始化价值网络。也有人用 RLHF 训练之前的检查点（通常是 SFT 模型）加上随机初始化的价值头，或者完全重新初始化的语言模型（较少见，因为 RLHF 收敛会更慢，但可行）。
- **奖励归一化、奖励白化，和/或优势白化**：归一化把奖励模型（或环境）给出的所有值约束到 0 与 1 之间，有助于学习稳定性。白化更进一步，把奖励或优势估计变换成零均值、单位方差，对稳定性的帮助更强。
- **不同的 KL 估计量**：对复杂语言模型，精确计算模型间的 KL 散度可能很复杂，因此会用多种近似来替代精确计算 [133]。
- **KL 控制器**：PPO 及相关算法的原始实现带有动态控制器——它瞄准特定 KL 值，并根据近期测量结果改变惩罚强度。大多数现代 RLHF 实现使用静态 KL 惩罚，但这也会有所变化。

关于 RLHF 实现细节的更多内容，见 [134]。关于这些算法的更多信息，见 [135]。

6.3.1 策略梯度基础

一个简单的策略梯度实现——用优势来估计梯度，为 PPO、GRPO 这类高级算法做准备——如下：

```
pg_loss = -advantages * ratio
```

这里的 `ratio` 是新策略模型概率相对于生成该批次的旧策略的（逐 token）概率比值（通常由对数概率之差算出）。

为理解这个式子，最好先理解一个更新批次里可能出现的几种情形。记住：我们希望随着模型在任务上变好，损失下降。

情形 1：优势为正，说明该动作优于该状态的期望值。我们想强化它。这种情况下，负号会让模型试图提高该动作的可能性，做法是增大 `logratio`。正的 `logratio`——也就是这些 token 对数概率之和为正——意味着模型更可能生成这些 token。

情形 2：优势为负，说明该动作差于该状态的期望值。推理非常类似。此时如果新模型更可能产生该补全，损失就会是正的，于是模型会调整策略参数，让这个补全变得不那么可能。

情形 3：优势为零，无需更新。损失为零，不改变策略模型。

6.3.2 损失聚合的权衡

用语言模型实现任何策略梯度算法时都会遇到一个问题：如何把逐 token 的损失聚合成最终的标量损失？给定样本 i 在 token t 处的逐 token 损失 $\ell_{i,t}$ 、补全长度 $|a_i|$ 与批大小 B ，有三种主要策略：

策略 1：按序列归一化（GRPO 的标准做法；部分 PPO 实现也用）

$$L = \frac{1}{B} \sum_{i=1}^B \frac{1}{|a_i|} \sum_{t=1}^{|a_i|} \ell_{i,t} \quad (69)$$

每条序列对批次损失的贡献相等，与其长度无关。代码：

```
# Strategy 1: Per-sequence normalization
sequence_loss = ((per_token_loss * completion_mask).sum(dim=1) / \
                  completion_mask.sum(dim=1)).mean()
```

策略 2：按 token 归一化（DAPO [136]）

$$L = \frac{\sum_{i=1}^B \sum_{t=1}^{|a_i|} \ell_{i,t}}{\sum_{i=1}^B |a_i|} \quad (70)$$

每个 token 贡献相等；更长的序列对梯度的影响按比例更大。代码：

```
# Strategy 2: Per-token normalization
token_loss = ((per_token_loss * completion_mask).sum() / \
               completion_mask.sum())
```

策略 3：固定长度归一化（Dr. GRPO [125]）

$$L = \frac{1}{B} \sum_{i=1}^B \frac{1}{L_{\max}} \sum_{t=1}^{|a_i|} \ell_{i,t} \quad (71)$$

按最大序列长度 $L_{\max}$ 归一化，在各序列之间拉平了逐 token 的尺度，同时仍让更长的序列贡献更多总梯度，因为它们包含更多有效 token。代码：

```
# Strategy 3: Fixed-length normalization
fixed_len_loss = ((per_token_loss * completion_mask).sum(dim=1) / \
                  L_max).mean()
```

其中 $L_{\max}$ 通常是整个训练过程中的全局常量，指定最大生成 token 数。

注意上面代码里的 `completion_mask` 是一个 0/1 矩阵，提示 token 被掩蔽（置 0），因为我们不想让模型从“预测提示 token”中学习。

6.3.2.1 为什么这件事重要？ 直观上，按序列归一化（策略 1）看起来最好，因为我们关心的是结果而不是单个 token。然而它会基于序列长度引入微妙的偏置——视偏置方向不同，这可能让模型过度思考，或让那些天然需要更多 token 的策略权重被压低。考虑两条长度不同、带逐 token 损失的序列：

```
seq_1_losses = [1, 1, 1, 1, 10] # 5 tokens, mean = 2.8
seq_2_losses = [1, 1, 1, 1, 1, 1, 1, 1, 1, 10] # 10 tokens, mean = 1.9
```

用策略 1（按序列）：批次损失为 $(2.8 + 1.9)/2 = 2.35$ ；关键在于，短序列中每个 token 获得的梯度比长序列中的更大。

用策略 2（按 token）：批次损失为 $(14 + 19)/15 = 2.2$ ，所有 token 获得相同量级的梯度。

用策略 3（固定长度， $L_{\max} = 10$ ）：短序列贡献 1.4，长序列贡献 1.9，在按序列加权的同时又拉平了逐 token 梯度。

一个更完整、展示这些策略如何影响梯度的例子见下面的脚本。

```
from typing import Optional
import torch

def masked_mean(values: torch.Tensor, mask: torch.Tensor, axis: Optional[int] = None) ->
torch.Tensor:
    """Compute mean of tensor with masked values."""
    if axis is not None:
        return (values * mask).sum(axis=axis) / mask.sum(axis=axis)
    else:
        return (values * mask).sum() / mask.sum()

def masked_sum(
    values: torch.Tensor,
    mask: torch.Tensor,
    axis: Optional[int] = None,
    constant_normalizer: float = 1.0,
) -> torch.Tensor:
    """Compute sum of tensor with masked values. Use a constant to normalize."""
    if axis is not None:
        return (values * mask).sum(axis=axis) / constant_normalizer
    else:
        return (values * mask).sum() / constant_normalizer

ratio = torch.tensor([
    [1., 1, 1, 1, 1, 1, 1,],
    [1, 1, 1, 1, 1, 1, 1,],
], requires_grad=True)

advs = torch.tensor([
    [2, 2, 2, 2, 2, 2, 2,],
    [2, 2, 2, 2, 2, 2, 2,],
])

masks = torch.tensor([
    # generation 1: 4 tokens
    [1, 1, 1, 1, 0, 0, 0,],
    # generation 2: 7 tokens
    [1, 1, 1, 1, 1, 1, 1,],
])

max_gen_len = 7

masked_mean_result = masked_mean(ratio * advs, masks, axis=1)
masked_mean_token_level = masked_mean(ratio, masks, axis=None)
masked_sum_result = masked_sum(ratio * advs, masks, axis=1, constant_normalizer=max_gen_len)
```

```

print("masked_mean", masked_mean_result)
print("masked_sum", masked_sum_result)
print("masked_mean_token_level", masked_mean_token_level)

# masked_mean tensor([2., 2.], grad_fn=<DivBackward0>)
# masked_sum tensor([1.1429, 2.0000], grad_fn=<DivBackward0>)
# masked_mean_token_level tensor(1., grad_fn=<DivBackward0>)

masked_mean_result.mean().backward()
print("ratio.grad", ratio.grad)
ratio.grad.zero_()
# ratio.grad tensor([[0.2500, 0.2500, 0.2500, 0.2500, 0.0000, 0.0000, 0.0000],
# [0.1429, 0.1429, 0.1429, 0.1429, 0.1429, 0.1429, 0.1429]])

masked_sum_result.mean().backward()
print("ratio.grad", ratio.grad)
ratio.grad.zero_()
# ratio.grad tensor([[0.1429, 0.1429, 0.1429, 0.1429, 0.0000, 0.0000, 0.0000],
# [0.1429, 0.1429, 0.1429, 0.1429, 0.1429, 0.1429, 0.1429]])

masked_mean_token_level.mean().backward()
print("ratio.grad", ratio.grad)
# ratio.grad tensor([[0.0909, 0.0909, 0.0909, 0.0909, 0.0000, 0.0000, 0.0000],
# [0.0909, 0.0909, 0.0909, 0.0909, 0.0909, 0.0909, 0.0909]])

```

输出显示：用策略 1（masked_mean）时，短序列的逐 token 梯度（0.25）大于长序列（0.14）。策略 2 与策略 3 则拉平了各序列的逐 token 梯度。注意如果使用梯度累积（在回传前把多个小批次的梯度相加），这些结果可能显著变化——那种情况下，短序列与长序列之间的平衡可能反转。

实践中，最佳策略取决于具体训练设置。在 RLHF 中，往往偏好数值稳定性最好、或损失方差最小的那种。

6.3.2.2 相关话题：MDP 与赌博机框架 损失聚合的选择，与“我们如何框定 RL 问题”这一更深的区分相关。**MDP（token 级）**视角把每个 token a_t 当作一个动作，状态 s_t 是到目前为止的前缀。实践中，这是我们在用学到的价值函数 $V(s_t)$ （例如 GAE [119]）计算逐 token 优势、并逐 token 施加 KL 惩罚时所用的框架。带学到的价值网络的 PPO 是经典例子 [123]。

相比之下，**赌博机（序列级）**视角把整个补全当作一个动作、配一个标量奖励 R 。在代码中，这意味着计算一个序列级优势 A_{seq} 并把它广播到所有 token。RLOO 与 GRPO 式优势常用于这种赌博机式设定 [122] [118] [128]。DPO 与 A-LoL 这类直接对齐方法也定义了序列级目标，尽管它们不是策略梯度估计量 [137]。

注意许多 GRPO 实现同时使用赌博机式优势和在损失中另加一个逐 token 的 KL 项，而许多 PPO/RLOO 实现则在计算优势之前把 KL 折进奖励——两种约定在实践中都存在。

下面是一个突出两种做法的对比示例：

```

# === Bandit-style (sequence-level) ===
# One scalar reward per sequence; advantage broadcast to all tokens
reward = torch.tensor([3.0, 1.0]) # (B,) e.g., reward model scores
baseline = reward.mean() # simple baseline (RLOO uses leave-one-out)

```

```

advantage_seq = reward - baseline          # (B,)
advantages = advantage_seq[:, None].expand(-1, seq_len) # (B, L)
# tensor([[ 1.,  1.,  1.,  1.],          <- same advantage for all tokens
#         [-1., -1., -1., -1.]])

# === MDP-style (token-level) ===
# Per-token rewards + learned V(s_t); each token gets its own advantage
# (could also use per-token KL shaping, format rewards, or other token-level signals)
advantages = gae(per_token_rewards, values, done_mask, gamma=1.0, lam=0.95)
# tensor([[ 0.2,  0.5,  0.8,  1.5],          <- varies by position
#         [-0.3, -0.5, -0.8, -1.4]])

```

这个框架区分也解释了：为什么几乎所有 RLHF 实现都把折扣因子 γ 设为 1.0。在标准 RL 中，折扣 ($\gamma < 1$) 是必需的：它在多步回合中平衡短期与长期奖励，对智能体学会长期有效行为至关重要。但在 RLHF 设定中，即便采用 token 级 MDP 视角，优化的归纳偏置仍是“整个补全的质量”——奖励信号给的是整个回复打分，而非单个 token。对更早的 token 打折，只会毫无原则地压低它们的贡献。随着智能体式 RL 设定走向成熟——模型在那里采取真正的多步动作，如工具调用、执行代码、浏览网页——折扣可能重新变得相关，因为这些确实涉及彼此不同、长远后果各异的序列决策。

6.3.3 异步 RL 系统

策略梯度算法的默认实现是所谓的**同策略执行**：智能体（语言模型）采取的动作（生成内容）在被评分之后才用于更新模型。策略梯度的理论推导依赖所有动作都严格同策略——模型始终与最新试验/rollout 的结果保持同步。实践中，维持严格的同策略执行会大幅拖慢训练 [138]——而且完美同步在技术上本就不可能。因此，近期所有语言模型的经验结果，往往都略微落在理论证明之外。实践中真正发生的，是为“实际有效”而设计算法与系统。

常用的解决方案是：持续在分离的 **GPU 节点**上分别运行推理与训练，并用软件让两者高效并行，如图 26 底部所示。流行开源语言模型 RL 工具的常见做法，是用 Ray 这类分布式进程管理库，在策略梯度学习循环与推理循环之间传递信息，后者使用高效的推理引擎（如 vLLM）。这类设置中，专门做 RL 步的 GPU 称为“learner”，专门从语言模型采样的 GPU 称为“actor”。让训练更加异步时面临的主要挑战，是**保持训练稳定并维持学习信号**。

这类系统的设计与实现前提是：**近似同策略的数据对稳定学习已经足够好**。在这里，生成阶段与更新阶段可以很方便地同步，以避免训练系统任一侧的空闲算力——也就是图 27 中把模型权重从 learner 传给 actor。对推理模型而言，那些需要每个答案 1 万到 10 万以上 token 的问题，其超长推理特性让 rollout 生成成为更强的瓶颈。在更同步的 RL 基础设施上训练推理模型时，一个常见问题是：批次中某个提示的答案可能要多得多的时间才能生成完（无论是更多 token 还是更多工具调用），导致已分配的大部分算力一直空转到它完成为止。针对这种长度不匹配的第二个方案叫**序列级打包**（sequence-level packing）：把批次中较短的样本用巧妙的掩码堆叠起来，使模型能持续 rollout，并在批次内更均衡地分摊长度归一化。分布式 RL 基础设施的完整复杂度超出本书范围——它还会引发许多其他微妙问题，拖慢训练或造成不稳定。

这些推理模型出现之后，人们对“让训练与推理循环完全异策略”产生了更多兴趣：策略梯度更新的训练批次，由多个生成实例上最近完成的 rollout 填充 [139] [140]。完全异步训练还能让 RL 训练更容易跨多个数据中心扩展——因为可以选择拉长 learner 节点（做策略梯度步）与 actor（解题）之间权重同步的间隔 [141]。

相关工作正在探索完全异策略的策略梯度算法 [131]。




图 26: 遵循 Noukhovitch 等 2024 的同步与异步 RL 训练中“生成—更新”阶段对比。




图 27: 一个分布式 RL 系统的例子: 用两个队列把数据传递给 learner 与 actor GPU, 两者都可以通过 Ray 这类分布式计算库同步。Olmo 团队 2025, 许可 CC-BY。

6.3.4 截断重要性采样

截断重要性采样（Truncated Importance Sampling, TIS）是用于稳定现代异步语言模型 RL 框架训练的关键工具。重要性采样是一种修正：对来自某个分布的样本重新加权，以估计另一个分布下的期望（如式 63 所介绍）。截断重要性采样 [142] 用 $\min(\rho, C)$ （ C 为某常数）给这些权重封顶，用一点偏差换取策略梯度中有界的方差。

这是施加在策略梯度上的重要性采样修正；但与 PPO、CISPO 的双边裁剪（把比值约束在 1 附近）不同，TIS 使用单侧上界：比值可以自由地低于 1，但被 C 封顶以防止极端的增权。在 PPO、GRPO、CISPO（及相关算法）中，比值 $\rho_t^{\text{policy}} = \pi_\theta(a_t | s) / \pi_{\theta_{\text{old}}}(a_t | s)$ 修正的是“同一 RL 批次内多个梯度步”造成的策略漂移。当我们转向真实世界的 RL 框架——以上一小节的异步性为核心——还会出现更大的数值差异来源（同样需要重要性采样的数值修正）。即便采样器与 learner 共享完全相同的参数 θ ，它们的有效 token 分布也可能不同，因为推理引擎（如 vLLM）与训练框架（如 FSDP）使用不同的 kernel、精度和并行策略 [143]。因此有必要区分“同一个策略在两个系统上”的求值 $\pi_\theta^{\text{sampler}}$ 与 $\pi_\theta^{\text{learner}}$ ，并定义相应的比值及其截断形式：

$$\rho_t^{\text{learner}} = \frac{\pi_\theta^{\text{learner}}(a_t | s, a_{<t})}{\pi_\theta^{\text{sampler}}(a_t | s, a_{<t})}, \quad \tilde{\rho}_t^{\text{learner}} = \min(\rho_t^{\text{learner}}, C). \quad (72)$$

这两种修正互补，但出现在策略梯度实现中的原因不同——一个补偿同一 RL 批次训练内部的策略漂移，另一个补偿实现引入的偏差——两者可以同时施加。它们如何结合取决于具体算法：

6.3.4.1 带 TIS 的 REINFORCE（单个梯度步） 此时不存在策略漂移（ $\pi_\theta = \pi_{\theta_{\text{old}}}$ ），唯一的失配来自 learner 与 sampler 之间。这里 $\pi_{\theta_{\text{old}}} = \pi_{\text{gen}}$ ，TIS 直接修正 learner-sampler 的差距：

$$\nabla_\theta J \approx \mathbb{E}_{a \sim \pi_\theta^{\text{sampler}}} [\tilde{\rho}_t^{\text{learner}} \cdot A_t \cdot \nabla_\theta \log \pi_\theta^{\text{learner}}(a_t | s, a_{<t})]. \quad (73)$$

6.3.4.2 带 TIS 的 PPO/GRPO（多个梯度步） 此时两个比值都在起作用。在严谨的实现中，策略比值里的“旧对数概率”会在 learner 上重新计算（GSPO 论文讨论了这一点），因此策略比值 $\rho_t^{\text{policy}} = \pi_\theta^{\text{learner}} / \pi_{\theta_{\text{old}}}^{\text{learner}}$ 捕捉的是纯粹的策略漂移，而 $\tilde{\rho}_t^{\text{learner}} = \min(\pi_\theta^{\text{learner}} / \pi_{\theta_{\text{old}}}^{\text{sampler}}, C)$ 单独修正在生成检查点处的后端失配：

$$J_{\text{PPO+TIS}}(\theta) = \mathbb{E} \left[\min(\rho_t^{\text{policy}} A_t, \text{clip}(\rho_t^{\text{policy}}, 1 - \varepsilon, 1 + \varepsilon) A_t) \cdot \tilde{\rho}_t^{\text{learner}} \right]. \quad (74)$$

这里 $\pi_{\theta_{\text{old}}} \neq \pi_{\text{gen}}$ ：旧对数概率来自 learner，而不是 sampler。如果某个框架跳过这次重算、直接把 sampler 的对数概率当作 $\pi_{\theta_{\text{old}}}$ ，那么策略比值本身就已经包含了后端失配，也就不需要单独的 TIS 修正——但此时裁剪作用在一个更嘈杂的比值上，它在任何梯度步之前就已经偏离 1.0。这正是 Yao 等 [143] 所说“你的框架悄悄给你带来了异策略 RL”的那一点。

实践中，LLM RL 系统把 TIS 作为策略梯度损失上的逐 token 修正权重来施加：

```
# Shape: (B*G, L)
C = 2.0 # TIS cap

logratio = learner_logprobs - sampler_logprobs
logratio = logratio.clamp(-10.0, 10.0) # numerical safety
```

```

tis_weight = torch.exp(logratio).clamp(max=C)          # one-sided truncation

# Use as a fixed correction weight on the per-token PG loss
per_token_pg_loss = per_token_pg_loss * tis_weight.detach()

```

$[-10, 10]$ 的 `clamp` 只是为了取指数前的数值稳定；真正执行截断重要性采样的是在 C 处的单侧封顶。实践中，围绕这些对数概率的记账工作——保存生成时的 `sampler` 对数概率、在旧检查点处重算 `learner` 对数概率、在梯度步中跟踪当前对数概率——构成了分布式 RL 框架脚手架中相当大的一部分。与 GSPO 不同，这个修正是 token 级的，因为它处理的是 token 级的数值失配，而非序列级的奖励粒度。针对 `learner-sampler` 比值的 TIS 已被主要开源 RL 框架采用（VeRL、TRL、OpenRLHF、SkyRL、OAT，以及使用 $C = 2$ 的 Open Instruct），并且对长推理轨迹（第 7 章）越来越重要——在那里，逐 token 的微小差异会在数千个生成 token 上不断累积。

6.3.5 示例：PPO

PPO 有非常多的实现。核心的损失计算如下。而稳定性能的关键还在于价值的计算，那里存在多种选择（包括价值模型损失本身的多种选择）。

注意这里的参考策略（或旧对数概率）来自生成被采样之时，不一定是参考模型。参考模型只用于 KL 距离约束/惩罚。

```

# B: Batch Size, L: Sequence Length, G: Num of Generations
# Apply KL penalty to rewards
rewards = rewards - self.beta * per_token_kl # Shape: (B*G, L)

# Get value predictions
values = value_net(completions) # Shape: (B*G, L)

# Compute returns via backward pass (gamma typically 1.0 for LM RLHF)
# Mask rewards to avoid padding tokens (which may have KL penalties) leaking into returns
returns = torch.zeros_like(rewards)
running = torch.zeros(rewards.shape[0], device=rewards.device, dtype=rewards.dtype)
for t in reversed(range(rewards.shape[1])):
    # Zero out padding: only accumulate rewards/returns for valid completion tokens
    running = (rewards[:, t] + self.gamma * running) * completion_mask[:, t]
    returns[:, t] = running

# Compute advantages:  $A_t = G_t - V(s_t)$ 
advantages = returns - values.detach() # Shape: (B*G, L)
# Note: We detach the value network here to not update the parameters of
# the value function when computing the policy-gradient loss

# Normalize advantages (optional but stable)
advantages = (advantages - advantages.mean()) / (advantages.std() + 1e-8)

# Compute probability ratio between new and old policies
ratio = torch.exp(new_per_token_logits - per_token_logits) # Shape: (B*G, L)

# PPO clipping objective
eps = self.cliprange # e.g. 0.2
pg_losses1 = -advantages * ratio # Shape: (B*G, L)
pg_losses2 = -advantages * torch.clamp(ratio, 1.0 - eps, 1.0 + eps) # Shape: (B*G, L)

```

```

pg_loss_max = torch.max(pg_losses1, pg_losses2) # Shape: (B*G, L)

# Value function loss: predict returns
vf_loss = 0.5 * ((returns - values) ** 2) # Shape: (B*G, L)

# Combine policy and value losses
per_token_loss = pg_loss_max + self.vf_coef * vf_loss # Shape: (B*G, L)

# Apply completion mask and compute final loss
loss = ((per_token_loss * completion_mask).sum(dim=1) / completion_mask.sum(dim=1)).mean()
# Scalar

# Compute metrics for logging
with torch.no_grad():
    # Compute clipping fraction
    clip_frac = ((pg_losses2 > pg_losses1).float() * completion_mask).sum() /
    completion_mask.sum()

    # Compute approximate KL
    approx_kl = (0.5 * ((new_per_token_logps - per_token_logps)**2) * completion_mask).sum()
    / completion_mask.sum()

    # Compute value loss for logging
    value_loss = vf_loss.mean()

```

理解 PPO 的核心，是弄清策略梯度损失是如何更新的。重点看这三行：

```

pg_losses1 = -advantages * ratio # Shape: (B*G, L)
pg_losses2 = -advantages * torch.clamp(ratio, 1.0 - eps, 1.0 + eps) # Shape: (B*G, L)
pg_loss_max = torch.max(pg_losses1, pg_losses2) # Shape: (B*G, L)

```

`pg_losses1` 是朴素的优势加权策略梯度损失。`pg_losses2` 用同一公式，但把概率比值钳制到 $[1 - \varepsilon, 1 + \varepsilon]$ ，限制策略在单次更新中能改变多少。

关键洞见在于对两个损失取 `torch.max`。因为我们是在最小化一个负损失（回忆一下优势前面的负号），取最大值就是选择更悲观的梯度——也就是产生更小策略更新的那个。当优势为正（好动作）时，裁剪防止策略过于激进地提高该动作的概率；当优势为负（坏动作）时，裁剪防止反方向的过度纠正。

通过钳制对数概率比值，PPO 给“策略相对生成训练数据那一版能漂移多远”设了界，从而在不需要显式计算信任域的前提下稳定学习。

上面的代码还展示了 PPO 会与策略同步学习一个价值函数，这增加了实现复杂度，但裁剪目标才是核心机制。

6.3.5.1 每样本单梯度步时 PPO/GRPO 的简化（无裁剪） 如果超参“每样本梯度步数”等于 1，PPO（与 GRPO）的实现可以优雅得多。这个超参的典型取值常在 2-4 或更高。在 PPO 或 GRPO 的主方程（见式 52）中，“参考”策略就是先前的参数——即用于生成补全或动作的那一版。因此，如果只做一次梯度步，就有 $\pi_\theta = \pi_{\theta_{\text{old}}}$ ，更新规则化简为下式（记号 $[]_\nabla$ 表示 stop-gradient）：

$$J(\theta) = \frac{1}{G} \sum_{i=1}^G \left(\frac{\pi_\theta(a_i|s)}{[\pi_\theta(a_i|s)]_\nabla} A_i - \beta \mathcal{D}_{\text{KL}}(\pi_\theta || \pi_{\text{ref}}) \right). \quad (75)$$

这就带来了可以省略第二项策略梯度与裁剪逻辑的 PPO 或 GRPO 实现，让优化器更接近标准策略梯度。

6.3.6 示例：GRPO

DeepSeekMath 论文描述了 GRPO 一些与 PPO 不同的实现细节 [128]，尤其是在与“深度 RL 中标准 PPO 用法”而非语言模型场景对比时。例如，RLHF 优化中的 KL 惩罚（回忆一下：在没有奖励模型的、用可验证奖励训练推理模型时也会用到 KL 惩罚）是直接施加在损失更新里，而不是加在奖励函数上。RLHF 中标准的 KL 惩罚用法是 $r = r_\theta - \beta \mathcal{D}_{\text{KL}}$ ，而 GRPO 实现大致是这样的：

$$L = L_{\text{policy gradient}} + \beta * \mathcal{D}_{\text{KL}} \quad (76)$$

不过实现方式有多种。传统上，KL 距离是针对“对提示 s 的补全”中每个 token 计算的。对推理训练，一个提示会采样多个补全，而一个批次里有多个提示，所以 KL 距离的形状会是 $[B, L, N]$ ，其中 B 是批大小、 L 是序列长度、 N 是每个提示的补全数。

合起来，用第一种损失累加方式，伪代码可以写成下面这样。

```
# B: Batch Size, L: Sequence Length, G: Number of Generations
# Compute group-wise rewards # Shape: (B,)
mean_grouped_rewards = rewards.view(-1, self.num_generations).mean(dim=1)
std_grouped_rewards = rewards.view(-1, self.num_generations).std(dim=1)

# Normalize the rewards to compute the advantages
mean_grouped_rewards = mean_grouped_rewards.repeat_interleave(self.num_generations, dim=0)
std_grouped_rewards = std_grouped_rewards.repeat_interleave(self.num_generations, dim=0)
# Shape: (B*G,)

# Compute advantages
advantages = (rewards - mean_grouped_rewards) / (std_grouped_rewards + 1e-4)
advantages = advantages.unsqueeze(1)
# Shape: (B*G, 1)

# Compute probability ratio between new and old policies
ratio = torch.exp(new_per_token_logps - per_token_logps) # Shape: (B*G, L)

# PPO clipping objective
eps = self.cliprange # e.g. 0.2
pg_losses1 = -advantages * ratio # Shape: (B*G, L)
pg_losses2 = -advantages * torch.clamp(ratio, 1.0 - eps, 1.0 + eps) # Shape: (B*G, L)
pg_loss_max = torch.max(pg_losses1, pg_losses2) # Shape: (B*G, L)

# important to GRPO -- PPO applies this in reward traditionally
# Combine with KL penalty
per_token_loss = pg_loss_max + self.beta * per_token_kl # Shape: (B*G, L)

# Apply completion mask and compute final loss
loss = ((per_token_loss * completion_mask).sum(dim=1) / completion_mask.sum(dim=1)).mean()
# Scalar

# Compute core metric for logging (KL, reward, etc. also logged)
```

```

with torch.no_grad():
    # Compute clipping fraction
    clip_frac = ((pg_losses2 > pg_losses1).float() * completion_mask).sum() /
    completion_mask.sum()

    # Compute approximate KL
    approx_kl = (0.5 * ((new_per_token_logps - per_token_logps)**2) * completion_mask).sum()
    / completion_mask.sum()

```

关于如何解读这段代码的更多细节，见上面的 PPO 一节。与 PPO 示例的核心差别是：

- **优势计算**：GRPO 把奖励相对于组内（同一提示的多次生成之间的均值与标准差）做归一化，而不是用学到的价值函数当 baseline。
- **没有价值网络**：GRPO 完全去掉了价值模型，消除了 `vf_loss` 以及与之相关的复杂度。
- **KL 惩罚的位置**：GRPO 把 KL 惩罚直接加在损失里，而不是从奖励中减去（这是标准实现，但关于如何施加 KL 还有更多版本）。

6.3.6.1 RLOO 与 GRPO RLOO 的优势更新与 GRPO 非常接近，这凸显了：一旦把 PPO 式裁剪与 KL 惩罚的细节单独拿出来，两个算法在概念上何其相似。具体来说，对 RLOO，优势是相对于一个与 GRPO 极为相似的 baseline 计算的——都是“该补全相对于同一问题下其他补全”的奖励。简洁地说，RLOO 的优势估计如下（展开自 TRL 的实现）：

```

# rloo_k --> number of completions per prompt
# rlhf_reward --> Initially a flat tensor of total rewards for all completions. Length B = N x k
rlhf_reward = rlhf_reward.reshape(rloo_k, -1) #
# Now, Shape: (k, N), each column j contains the k rewards for prompt j.

baseline = (rlhf_reward.sum(0) - rlhf_reward) / (rloo_k - 1)
# baseline --> Leave-one-out baseline rewards. Shape: (k, N)
# baseline[i, j] is the avg reward of samples i' != i for prompt j.

advantages = rlhf_reward - baseline
# advantages --> Same Shape: (k, N)

advantages = advantages.flatten() # Same shape as original tensor

```

RLOO 其余的实现细节，沿用实现策略梯度时的其他权衡。

6.4 补充话题

要精通策略梯度算法的应用，还有无数其他考量。这里我们讨论成功部署策略梯度 RL 算法时的一些长尾复杂问题。

6.4.1 广义优势估计（GAE）

广义优势估计（GAE）是策略梯度算法中计算优势的另一种方法 [119]，它能更好地平衡偏差-方差权衡。传统的单步优势估计可能引入过多偏差，而使用完整轨迹又可能方差过大。GAE 计算多步优势估计的指数加权平均，其中 λ 超参控制偏差-方差权衡——从单步 TD ($\lambda = 0$) 到完整轨迹回报 ($\lambda = 1$)； $\lambda = 0.95$ 是 LLM 微调的常见默认值。

优势估计可以有多种形式，但我们可以把 n 步优势估计量定义为如下（类似本章开头的 TD 残差）：

$$\hat{A}_t^{(n)} = \begin{cases} r_t + \gamma V(s_{t+1}) - V(s_t), & n = 1 \\ r_t + \gamma r_{t+1} + \gamma^2 V(s_{t+2}) - V(s_t), & n = 2 \\ \vdots \\ r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots - V(s_t), & n = \infty \end{cases} \quad (77)$$

这里更短的 n 意味着更低的方差但更高的偏差——因为我们把更多的学习能力归因到每条轨迹上，它可能过拟合。GAE 试图把这一表述推广为加权多步平均，而不是取某个具体的 n 。首先，我们必须定义预测价值的时序差分（TD）残差。

$$\delta_t^V = r_t + \gamma V(s_{t+1}) - V(s_t) \quad (78)$$

为利用它，我们引入另一个变量 λ 作为 GAE 的混合参数。它折叠为对未来优势的指数衰减：

$$\begin{aligned} \hat{A}_t^{GAE(\gamma, \lambda)} &= (1 - \lambda)(\hat{A}_t^{(1)} + \lambda \hat{A}_t^{(2)} + \lambda^2 \hat{A}_t^{(3)} + \dots) \\ &= (1 - \lambda)(\delta_t^V + \lambda(\delta_t^V + \gamma \delta_{t+1}^V) + \lambda^2(\delta_t^V + \gamma \delta_{t+1}^V + \gamma^2 \delta_{t+2}^V) + \dots) \\ &= (1 - \lambda)(\delta_t^V(1 + \lambda + \lambda^2 + \dots) + \gamma \delta_{t+1}^V(\lambda + \lambda^2 + \dots) + \dots) \\ &= (1 - \lambda)\left(\delta_t^V \frac{1}{1 - \lambda} + \gamma \delta_{t+1}^V \frac{\lambda}{1 - \lambda} + \dots\right) \\ &= \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}^V \end{aligned} \quad (79)$$

直观上，这以优雅的方式对优势的多步估计做了平均。一个示例实现如下：

```
# GAE (token-level) for LM RLHF
#
# B: Batch Size
# L: Length
# Inputs:
#   rewards: (B, L) post-KL per-token rewards
#   values: (B, L) current V_theta(s_t)
#   done_mask: (B, L) 1.0 at terminal token (EOS or penalized trunc), else 0.0
#   gamma: float (often 1.0),
#   lam (short for lambda): float in [0,1]
#   (Padding beyond terminal should have rewards=0, values=0)
B, L = rewards.shape
advantages = torch.zeros_like(rewards)
next_v = torch.zeros(B, device=rewards.device, dtype=rewards.dtype)
gae = torch.zeros(B, device=rewards.device, dtype=rewards.dtype)

for t in reversed(range(L)):
    not_done = 1.0 - done_mask[:, t]
    delta = rewards[:, t] + gamma * not_done * next_v - values[:, t]
    gae = delta + gamma * lam * not_done * gae
    advantages[:, t] = gae
    next_v = values[:, t]

targets = advantages + values # y_t for value regression
advantages = advantages.detach() # for policy loss
```

这个反向循环累加时序差分 (TD) 误差 ($\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$)，它衡量实际结果比价值函数的预测好多少或差多少，并带指数衰减 $(\gamma\lambda)^l$ 。在终止 token 处，`not_done=0` 阻止从未来状态做自举，并重置 GAE 累加器，因此每个回合的优势是独立计算的（由于循环反向运行，终止 token 会干净地在回合边界处停止指数加权累加——这让实现天然兼容序列打包，能正确处理拼接进一条序列的多个样本）。最后的 `targets` 用作在本 GAE 循环之外学习的价值函数的回归目标，而分离出来的 `advantages` 为策略梯度加权——分离是为了让策略更新不通过价值网络回传。在语言模型的 RLHF 中， $\gamma = 1.0$ 很常见，因为回合是简短的 token 序列，此时更偏好不折扣的信用分配（而且常常一条序列里全部 token 都是同一个回合）。

延伸阅读见 [144]。

6.4.2 双重正则化

本章我们已经看到两类正则化。一类内建于 PPO 这类算法中，约束步长；另一类是针对优化起点的、基于 KL 散度的距离惩罚。

深度强化学习中许多流行的策略梯度算法——包括 PPO 及其前身——之所以出现，就是因为需要控制智能体的学习过程。而在 RLHF 中，如第 15 章「正则化」与第 3 章「训练总览」所详述，由于存在相对于“被微调的原始策略”的距离惩罚，正则化是内建的。从这个视角看，PPO（带有内部步长正则）与 REINFORCE（更简单，在某些超参下 PPO 会退化到它）这类算法之间的差异，对微调语言模型而言远不如“从零训练一个智能体”那样有意义。

PPO 中负责给更新步长封顶的目标被称为代理目标。要监控 PPO 正则化对 RLHF 更新的影响程度，可以看许多流行实现中的 clip fraction 变量——即批次中概率比值落在裁剪区间之外的样本占比。它是“PPO 正则化何时可能生效”的有用代理指标，但并非每个这样的样本梯度都为零：只有当裁剪分支被选中时（例如正优势且比值高于 $1 + \varepsilon$ ，或负优势且比值低于 $1 - \varepsilon$ ），代理目标才会变平。

在语言模型实践中，PPO、GRPO 这类算法常常每批只做一个梯度步，这意味着 PPO 原生的正则化从未被触发（裁剪只可能在策略发生明显变化时于批次内出现），此时是 KL 距离惩罚在起主导作用。不过这并不普遍。例如 DAPO 每批用 16 个梯度步 [136]；Tulu 3 对 8B 和 70B 模型每批用 4 次 PPO 更新迭代，但对 405B 降到 1 次以维持训练稳定 [6]。

6.4.3 延伸阅读

随着 RLHF 稳固地居于现代后训练的中心，人们提出了其他策略梯度 RL 算法以及更广义的 RL 算法来改进训练过程，但它们并未在最佳实践的制定中占据核心地位。延伸阅读的例子包括：

- 成对近端策略优化 (P3O; Wu 等, 2023) [145] 直接在 PPO 式策略更新中使用成对数据，而不学习中间的奖励模型。
- 软自适应策略优化 (SAPO) [146] 用平滑的、温度控制的门控取代 PPO/GRPO 式的硬裁剪，目标是形成一个连续的信任域——在压低异策略 token 权重的同时，保留近似同策略的学习信号。
- 异策略策略梯度算法可能支持更进一步的异步训练，例如 对比策略梯度 (CoPG) [147]（直接对齐算法 IPO 与朴素策略梯度的推广），Cohere 在其 Command A 模型上使用了它 [57]。
- 还有其他为语言模型设计的 REINFORCE 实现，例如 ReMax [148]，它实现了一种专门为吸收“奖励模型推理带来的不确定性”而设计的 baseline 归一化。
- 一些基础模型——例如 Apple Intelligence Foundation Models [149] 或 Kimi k1.5 推理模型 [150]——使用了 镜像下降策略优化 (MDPO) [151] 的变体。这方面的基础研究仍在发展

[152]，但镜像下降是一种优化方法，而非直接的策略梯度算法。这里重要的是，它被嵌入的方式与既有 RL 基础设施非常相似。

- **解耦裁剪与动态采样策略优化 (DAPO)** 对 GRPO 提出四项改动，以更好适配推理语言模型——那里需要长轨迹，也需要提高那些新颖、利用不足的 token 的概率 [136]。改动是：1) 使用两个不同的裁剪超参 ϵ_{low} 与 ϵ_{high} ，使对数比值正侧的裁剪可以迈出更大步子以更好地探索；2) 动态采样——去掉批次中奖励全为 0 或全为 1 的样本（没有学习信号）；3) 使用前面「实现：GRPO」中讨论的逐 token 损失；4) 对过长的样本施加软惩罚，避免从被截断的答案中学习。
- **基于价值的增强近端策略优化 (VAPO)** [153] 把 DAPO 的若干优化（包括 clip-higher、token 级策略梯度、不同的长度归一化）与 Value-Calibrated PPO [154] 的洞见结合起来——预训练价值函数、长度自适应 GAE——展示了相对于 GRPO，基于价值的方法仍具潜力。

6.5 建议的实验

code/policy_gradients/ 中的配套实现，是为“小型、可观察的 RL 运行”设计的。默认配置在 reasoning-gym 的 spell_backward 程序化任务上训练 Qwen/Qwen3-1.7B；这是一个很好的入门练习，因为失败与部分进展都容易观察。

1. 用 GRPO 跑词序反转任务。

```
cd code/  
uv run python -m policy_gradients.train --config policy_gradients/configs/grpo.yaml
```

跟踪 avg_correctness、avg_format 和 avg_binary。第一个有用的问题是：每个提示组内部是否存在对比——如果所有采样补全全对或全错，组相对更新就几乎没有学习信号。

2. 比较组相对估计量与单样本估计量。运行配对好的起始配置：

```
cd code/  
uv run python -m policy_gradients.train --config  
policy_gradients/configs/reinforce.yaml  
uv run python -m policy_gradients.train --config policy_gradients/configs/rloo.yaml  
uv run python -m policy_gradients.train --config policy_gradients/configs/grpo.yaml
```

比较正确率信号提升的速度，以及损失有多吵。RLOO 与 GRPO 会让“提示内 baseline”的作用比单看方程具体得多。

3. 扫对比度相关的旋钮。复制 policy_gradients/configs/grpo.yaml，改变 num_rollouts、temperature、data.size 和 format_weight。较小的 num_rollouts 会降低组内对比度；温度过低会让采样坍缩；温度过高会生成过多格式错乱的答案。这是理解“为什么 RLVR 配方常在动优化器之前，先在采样设置上花很大功夫”的最简单方式。
4. 从玩具奖励走向数学。对于 GSM8K 类实验，先看 code/reward_models/train_orm.py 与 code/rejection_sampling/ 的例子，再考虑新增在线 RL 环境。一个有价值的贡献是：写一个能在 1B 以下的 Qwen 模型上运行的小型 reasoning-gym 或 GSM8K 策略梯度配置，并报告同样的组内对比度诊断指标。

7 推理与推理时扩展

推理模型与推理时扩展，让语言模型的性能在 2024 年末、整个 2025 年以及未来，实现了巨大的跃升。**推理时扩展**（inference-time scaling）指的是通过生成时投入更多算力来提升模型表现的能力——例如产出更长的推理链，或采样多个回答。那些被训练成“回答前先充分思考”的语言模型，把这一特性利用得非常好。这些模型用大量的可验证奖励强化学习（RLVR）训练 [6]，同时也仍然大量使用 RLHF。本章回顾 AI 社区“对 RL 在语言模型中潜力的认识被彻底改写”这一过程，梳理 RLVR 的基本原理，点出关键工作，并指出未来几年将定义这一领域的主要争论。

7.1 RLVR 的角色

先从一个典故说起。在 2016 年的神经信息处理系统大会（NeurIPS）上，Yann LeCun 首次提出他那个如今广为人知的“蛋糕”比喻，用来描述现代机器学习系统中的学习发生在哪里：

如果智能是一块蛋糕，那么蛋糕的主体是无监督学习，糖霜是监督学习，而蛋糕上的樱桃是强化学习（RL）。

这个比喻放在现代语言模型和近期后训练技术栈的变化上，基本已经完整了。RLHF 是它的前奏，而用于推理模型（主要针对数学、代码和科学主题）的 RL，则是它的印证。在这个比喻里：

- 在海量互联网数据上的自监督学习构成了蛋糕的主体（若按 FLOPs 消耗的算力看尤其如此）；
- 后训练的起点——面向指令的监督微调（SFT）——把模型调向更窄的分布；
- 最后，“纯粹的”强化学习（RL）是顶上那颗樱桃。用来打造新一代“推理”或“思考”模型的规模化强化学习，就是这最后一步（同时也借助了 RLHF——如我们稍后所解释，它并不被视为经典 RL）。

这一点推理训练，催生了**思考模型**：它们把本书讨论的后训练技术（用于对齐偏好）与在可验证领域上的 RL 训练结合起来，从而大幅提升推理、编程、数学解题等能力。

这类模型的训练方法——可验证奖励的强化学习（RLVR）[6]——与 RLHF 非常相似，但它把奖励模型变成可选项，代之以一个打分函数：答案正确时返回正奖励，否则返回 0。

举例来说，对比一下 RLHF 与 RLVR 在“给回答打分”这件事上的差别。RLHF 中，奖励模型必须评估主观品质：

提示：解释经济学中的机会成本概念。

回答：机会成本是你在做决策时放弃的次优选择的价值。例如，如果你花一小时学习而不是工作，机会成本就是你本可以挣到的工资……

给这个回答打分需要判断清晰度、准确性、完整性和有用性——这些品质都依赖学到的偏好，且没有确定的正确答案。

相比之下，RLVR 使用返回确定分数的验证函数。对数学而言：

提示：所有小于 20 的质数之和是多少？

回答：小于 20 的质数是 2、3、5、7、11、13、17 和 19。相加： $2 + 3 = 5$ ，然后 $5 + 5 = 10$ ，然后 $10 + 7 = 17$ ，然后 $17 + 11 = 28$ ，然后 $28 + 13 = 41$ ，然后 $41 + 17 = 58$ ，最后 $58 + 19 = 77$ 。答案是 77。

验证：`extracted_answer == 77` → 奖励 = 1

`\boxed{}` 这个记号借自数学排版惯例，它让答案抽取变得直接——一条简单的正则表达式就能从回答里取出最终答案，无论模型是怎么得到它的。注意还存在其他答案抽取方式，例如只用短语 “The answer is: ”（上面也展示了）、用 `<answer>` 这类特殊 token，或用 `####` 这类分隔符。

对代码生成而言，验证常常采取单元测试的形式：

提示：写一个 Python 函数 `fib(n)`，返回第 n 个斐波那契数，其中 `fib(0) = 0`、`fib(1) = 1`。

回答：`def fib(n): if n < 2: return n return fib(n - 1) + fib(n - 2)`

验证（单元测试）：

```
assert fib(0) == 0 # base case
assert fib(1) == 1 # base case
assert fib(10) == 55 # larger value （全部测试通过 → 奖励 = 1）
```

单元测试是代码天然的验证函数：把模型的解答放到已知的输入—输出对上执行。一种常见的打分形式是做简单的门控：如果所有断言通过，奖励为 1；任一失败则为 0。其他设置会按通过的测试比例给部分分。这两个例子里都不需要学到的奖励模型，而且大多数设置也确实不用（因为在这些领域模型对过度优化有较强的抵抗力）；不过也可以用奖励的线性组合把奖励模型加进来。

RLVR 背后的想法在 RL 文献中并不新鲜——“依据答案是否正确做梯度更新”几乎就是强化学习的教科书定义。把它应用到语言模型上的创新，主要在于**如何在保持被微调模型的强大通用能力的前提下应用它**。在此之内，语言模型文献中还有许多相关想法：让模型从“关于答案正确性的反馈”中学习。

最初，在提出“可验证奖励的 RL”（RLVR）这一术语的那项工作中 [6]，这个方法本来要叫“真值奖励的 RL”（RLGT）。但 RLVR 与“仅从真值答案学习”有微妙差别。在数学这类领域，有唯一的真值答案可用于验证解答，如上所示。而在代码生成或精确指令跟随这类领域，即使正确答案不止一个、没有唯一真值，答案仍可用检查函数（例如单元测试）来验证。RLVR 进展的核心，是拥有多样且有深度的这类**可验证问题**——即便确切解并不事先已知。

最早成功部署这类训练的模型是 OpenAI 的 o1 [53] 与开放权重模型 DeepSeek R1 [15]。不久之后，整个 AI 行业都把这一训练过程和模型风格提上了优先位置。这里的核心变化与其说是“这种 RL 设定全新”，不如说是**训练阶段的重新分配、以及不同行为优先级的调整**。推理模型带来了一个“扩展 RL 训练成为预期动作”的时代。

至于这类模型表现出什么样的行为，看下面这个例子：用 DeepSeek V3 0325 与他们的推理模型 DeepSeek R1 回答 `Write me a short poem about a goldfish`。DeepSeek V3 非常直接：

回答：Goldfish Dreams

In a bowl of glass so clear and round, A tiny goldfish swims without a sound. With scales that gleam like sunlight's kiss, He drifts along in watery bliss.

A flick of fin, a flash so bright, Chasing bubbles in the light. Does he dream of oceans wide? Or is his little world enough—his pride?

而 DeepSeek R1 的体验不同。它会先生成大量思考 token 来构思回答，然后再回复用户。它的回答看起来是这样：

回答：`<thinking>` Okay, the user wants a short poem about a goldfish. Let me start by brainstorming some goldfish-related imagery. Goldfish are often in bowls, right?




图 28: 以 RL 反馈循环形式呈现的 RLVR。用验证函数取代奖励模型。

So maybe start with the setting. Words like “gilded bowl” or “crystal globe” could work.

Next, think about the movement of the goldfish. They swim smoothly, so words like “dart”, “glide”, or “swirl” come to mind. Maybe describe their fins as “silken” to emphasize delicacy.

Then, consider the environment around the goldfish. Sunlight through water creates shimmering effects. Words like “sunbeams dance” or “ripples spin” might capture that. Including elements like castles or pebbles adds a playful touch.

Themes? Maybe the contrast between the goldfish’s small world and its perception of freedom. The bowl as a universe, tiny but complete. Ending with a sense of mystery or silent observation could give depth. Need to keep it concise, maybe four stanzas with a rhyme scheme. Let me check the rhythm and flow. Avoid clichés but keep it accessible. Alright, let’s piece it together. </thinking>

Gilded Dreams in Liquid Glass

A gilded bowl, a crystal globe, Where tiny tides in silence flow—A flash of orange, a whispered robe, You dart through sunlit indigo.

Your world is small, yet boundless too—Each pebble, castle, weed unfurled. The surface bends the sky to blue, And ripples spin your liquid world.

You glide through myths we' ll never know, A silent monarch, veiled in mist. Do dreams drift where the bubbles go? Or memories in amethyst?

We watch you trace your endless sphere—A universe within a tear.

<thinking> 标签里的 token 就是模型的推理过程。对更复杂的问题，推理阶段可能先耗掉数千个 token 才产出答案。所以长上下文语言模型是高级推理行为的前提，但这不是本章的重点。

理解这套训练如何起作用的核心直觉是：对给定模型，反复执行下面的循环：

1. 对多个问题采样多个答案；
2. 朝着**正确**的答案做梯度步；
3. 重复，反复回到同一批数据。

值得注意的是，这个极其简单的方法（在数据分布精心设计、训练基础设施稳定的前提下）通过一遍又一遍地重温同样的问题，帮助模型学习。更值得注意的是：在这些训练问题上的提升，会泛化到模型从未见过的问题、（部分）领域上！

这个简单的方法让模型能在行为空间中做轻度搜索，而 RL 算法会提高那些与正确答案相关的行为的概率。

7.2 新一代推理模型的来路

下面梳理导致 2025 年推理模型爆发的高层趋势。

7.2.1 为什么 RL 现在奏效了？

尽管有非常多“RL 还不管用”的观点 [155]，也有论文详细记录了 RL 的可复现性问题 [156]，但这个领域跨过了这些障碍，找到了高影响力的应用。有些在本书中已有涉及，例如 ChatGPT 的 RLHF 与 DeepSeek R1 的 RLVR；但还有许多其他应用，包括改进芯片设计 [157]、掌握电子游戏 [158]、自动驾驶 [159] 等等。语言模型上以 RL 为核心的训练之所以能起飞，说明这一研究领域在许多根本问题上取得了进展，包括：

- **RL 的稳定性问题是可以解决的**：在其整个发展史上，限制 RL 被采用的一直是稳定性。它体现在两方面。第一，学习本身可能反复无常、并非总能奏效。第二，训练本身以比标准语言模型训练更脆弱、更容易出现损失尖峰和崩溃而著称。如今无数新模型都在预训练基座之上使用这种带可验证奖励的 RL 训练，学术界也大量跟进。**RL 的技术门槛正处于历史最低点。**
- **开源版本已经“存在”**：已经有许多工具可用于以 RLVR 及相关技术训练语言模型。例如 TRL [47]、Open Instruct [6]、veRL [160] 和 OpenRLHF [161]，其中许多建立在 RLHF 与后训练早期阶段的优化之上。工具的可获得性正在支撑起一个庞大且加速增长的研究体量。

多项资料表明，面向推理的 RL 训练只有在领先模型上才可行，且大约从 2024 年起的模型才具备这一条件——这说明在推理训练成为可能之前，模型需要达到一定的底层能力水平。

7.2.2 RL 训练与推理时扩展

用强化学习训练来激发推理行为、提升可验证领域上的表现，与**推理时扩展**的想法紧密相连。推理时扩展（也叫测试时扩展）是指一类方法：在推理阶段投入更多算力，以便在下游任务上表现更好。在 DeepSeek R1 与 OpenAI o1 发布之前，推理时扩展的方法就已被研究——而这两个模型都极大地推动了人们对 RL 训练的投入。例子包括值引导采样 [162]，以及带答案抽取的重复随机采样 [163]。除

此之外，推理时扩展还能改进思维链推理之外的更多 AI 训练方法，例如使用会深入权衡各个选项的奖励模型 [91] [164]。

RL 训练是通往“推理时扩展规律”的一条捷径；但长期来看，我们将拥有更多方法来激发所需的推理时权衡，以获得最佳性能。用 RL 大量训练模型，往往能让它每次回答生成更多 token，而这一增长与下游性能提升高度相关（尽管序列变长是默认现象，也有研究专门探索不依赖这种推理时扩展来提升性能）。这与早期 RLHF 系统中的长度偏置形成了重要对照 [10]——那时人类偏好训练有个副作用：为了在偏好排序上取得边际收益而拉长了平均回复长度。

除了核心的 RL 训练模型之外，还有许多方法正在被探索，以继续推进推理与推理时算力的极限。由于它们演化太快，大多超出本书范围；这些方法包括：通过指令微调把大型 RL 训练模型的推理行为蒸馏到小模型 [165]、组合更多次推理调用 [166] 等。这里要紧的是下游性能与生成 token 数增长之间的相关性——否则就只是白白浪费能量。

7.2.3 RLVR 的未来（超越推理）

在许多领域，这些新形态的 RLVR 更贴合开发者的目标：它关注性能而非行为。标准的微调 API 通常使用 LoRA 这类参数高效微调方法（Low-Rank Adaptation，一种只训练少量新增矩阵、而非全部模型权重的参数高效方法，也叫参数高效微调 PEFT），配合对指令的监督微调。开发者传入提示与补全，模型通过更新参数去匹配这些补全，从而在你的数据特征在模型生成中变得更常见。

而 RLVR 关注的是匹配答案。给定查询与正确答案，RLVR 帮助模型学会产出正确答案。标准指令微调通常只对数据做 1 到 2 个 epoch 的损失更新，而 RLVR 之所以得名，是因为它会对同样这几个数据点做数百到数千个 epoch，给模型时间去学习新行为。这可以理解为：把基座模型版本中偶尔才奏效的正向行为，经 RLVR 之后强化为稳健的行为。

语言模型 RL 训练的范围还在持续扩大：从基础科学层面看，o1 与 R1 带来的最大启示是——我们有了更多训练语言模型、使其具备潜在有价值行为的手段。对研究者和工程师敞开的大门越多，我们对 AI 总体发展轨迹就越乐观。

7.3 理解推理训练方法

对推理的投入，引发了“如何训练模型遵循人类指令”这门手艺的重大演化。这些流程仍然使用前面章节讨论过的常见组件（如第 3 章概述 DeepSeek R1 流程时所述），包括指令微调、人类反馈强化学习和可验证奖励的强化学习（RLVR）。核心变化是使用多得多的 **RLVR**，并以不同顺序施加其他训练技术——传统上，对一个推理模型而言，核心训练步骤要么是一次大规模 RL 运行，要么是在另一个已接受大量 RLVR 训练之模型的输出上做大规模指令微调（即蒸馏）。

7.3.1 OpenAI o1 与 DeepSeek R1 之前的推理研究

在推理模型起飞之前，人们已投入大量努力去理解如何训练语言模型、使其在可验证领域上更强。下面这些工作与后来方法的主要差别在于：它们的方法论没有扩展到 DeepSeek R1 及其后继模型那样的规模，或者它们产出的模型为换取更强的数学或编程能力而在整体性能上做出了牺牲。这里收录背后的想法与动机，是为了更完整地呈现推理模型是如何在这一图景中出现的。

最早在可验证领域训练语言模型的努力，包括自教推理器（STaR）系列工作 [167] [168] 和 TRICE [169]——两者都在 2022 与 2023 年间使用真值奖励信号来鼓励模型进行思维链推理。STaR 实际上近似了策略梯度算法，但实践中样本过滤方式不同，并用交叉熵度量替代对数概率；而 Quiet-STaR 用一个与近期推理模型高度相关的想法扩展了它：让模型在尝试回答可验证问题之前先生成 token

(这有助于训练表现)。TRICE [169] 同样通过生成推理轨迹、再用一种受马尔可夫链蒙特卡洛启发的期望最大化算法来优化，从而改进推理。VinePPO [170] 紧随其后，其设定更接近现代推理模型。VinePPO 使用基于 PPO 的算法、以数学题正确性作为二元奖励，在 GSM8K 与 MATH 上训练。在 OpenAI o1 与 DeepSeek R1 之前的其他工作，则用代码执行作为训练反馈信号 [171]、[172]，或用验证器进行定理证明（这里称为“验证器反馈强化学习”，RLVF）[173]。Tulu 3 在这些方法上做了扩展：用一个简单的 PPO 训练器对答案正确的补全给予奖励——最重要的是，同时保持在广泛评估套件上的整体性能。Tulu 3 的二元奖励与现代推理训练技术，可以与 STaR 的迭代式方法、或 Quiet-STaR 的对数似然奖励形成对照。

7.3.2 早期推理模型

下表汇总了 DeepSeek R1 之后那些奠基性的推理研究技术报告——其中一部分附有开放数据与模型权重。

表 4: 2025 年（RLHF 推理时扩展大规模兴起的第一年）值得注意的推理模型技术报告汇总。

日期	名称	一句话概括	开放权重	开放数据
2025-01-22	DeepSeek R1 [15]	基于 RL 的 DeepSeek 升级版，数学与代码推理能力大幅提升	是	否
2025-01-22	Kimi 1.5 [150]	在中英文数据上扩展 PPO/GRPO; AIME 数学表现强劲	否	否
2025-03-31	Open-Reasoner-Zero [174]	对基座模型 RL 的完全开放复现	是	是
2025-04-10	Seed-Thinking 1.5 [62]	字节跳动的 RL 流水线，带动态 CoT 门控	是	否
2025-04-30	Phi-4 Reasoning [175]	14B 模型；细致的 SFT→RL；擅长 STEM 推理	是	否
2025-05-02	Llama-Nemotron [176]	多种规模的“推理开关”模型	是	是
2025-05-12	INTELLECT-2 [141]	首个有公开记录的全球去中心化 RL 训练	是	是
2025-05-12	Xiaomi MiMo [61]	从预训练到后训练的端到端推理流程	是	否
2025-05-14	Qwen 3 [60]	把类似 R1 的流程应用到新模型上	是	否
2025-05-21	Hunyuan-TurboS [177]	Mamba-Transformer MoE，自适应长/短 CoT	否	否
2025-05-28	Skywork OR-1 [178]	避免熵崩塌的 RL 流程；在 AIME 上超过 DeepSeek	是	是
2025-06-04	Xiaomi MiMo VL [179]	把推理流程端到端地扩展到包含多模态任务	是	否
2025-06-04	OpenThoughts [180]	从 QwQ-32B 蒸馏而来的公开 120 万条指令数据集	是	是

日期	名称	一句话概括	开放权重	开放数据
2025-06-10	Magistral [181]	在 Mistral 3 上做纯 RL；多语言 CoT；小模型开源	是	否
2025-06-16	MiniMax-M1 [130]	开放权重 456B MoE 混合/Lightning Attention 推理模型；100 万上下文；用 CISPO 做 RL；发布 4 万/8 万思考预算的检查点	是	否
2025-07-10	Kimi K2 [182]	1T MoE（32B 激活），用 MuonClip（QK-clip）保证稳定；15.5T token 预训练无损失尖峰；多阶段后训练含智能体数据合成 + 联合 RL；发布基座与后训练检查点。	是	否
2025-07-28	GLM-4.5 [183]	开放权重 355B-A32B MoE “ARC” 模型，含思考/非思考模式；23T token 多阶段训练 + 专家迭代与 RL 的后训练；发布 GLM-4.5 与 GLM-4.5-Air（MIT）。	是	否
2025-08-20	Nemotron Nano 2 [184]	用于长“思考轨迹”的混合 Mamba-Transformer；20T token FP8 预训练后压缩/蒸馏；明确发布多个检查点以及预训练/后训练数据集的“大部分”。	是	是（大部分）
2025-09-09	K2-Think [185]	参数高效的数学推理系统；32B 开放权重模型 + 测试时扩展配方；按发布材料定位为完全开放（含训练数据/代码）。	是	是
2025-09-23	LongCat-Flash-Thinking [186]	560B MoE 推理模型；报告明确给出从长 CoT 冷启动到大规模 RL 的分阶段配方；开源发布。	是	否
2025-10-21	Ring-1T [187]	万亿级“思考模型”，聚焦 RL 扩展；报告阐述了 1T 规模下扩展 RL 的瓶颈与解法，并发布开放模型。	是	否
2025-11-20	Olmo 3 Think [18]	完全开放的“模型流”发布；报告了完整生命周期（各阶段、检查点与数据点），并把 Olmo 3 Think 32B 定位为旗舰级开放思考模型。	是	是
2025-12-02	DeepSeek V3.2 [188]	开放权重 MoE 的前沿推进，报告突出注意力效率改动、RL 框架升级，以及面向智能体/推理性能的数据合成。	是	否
2025-12-05	K2-V2 [189]	70B 稠密“360 开放”模型，从零训练；仅用 SFT 的三档努力后训练实现可控思考。	是	是
2025-12-15	Nemotron 3 Nano [190]	30B-A3B MoE 混合 Mamba-Transformer；25T token 预训练并包含 SFT + 大规模 RL；明确说明发布权重 + 配方/代码 + 大部分训练数据。	是	是（大部分）

日期	名称	一句话概括	开放权重	开放数据
2025-12-16	MiMo-V2-Flash [63]	309B MoE (15B 激活) 为速度优化: 混合 SWA/GA 注意力 (5:1, 128 token 窗口) + 轻量 MTP; 27T token FP8 预训练; 用 MOPD + 大规模智能体 RL 做推理/编程的后训练。	是	否

7.3.3 训练推理模型的常见实践

本节详述训练推理模型时，为最大化性能而安排训练阶段顺序、改造数据的常见方法。

注意这些论文可能用了某个列出的技术却没有提及，而其他论文提到了；所以这些例子只是已知实现的子集，可作为参考，但不应视为对“最优配方是什么”的最终宣判。

- **离线难度过滤**: RLVR 的一个核心直觉是——模型只能从**有梯度**的样本中学习。如果 RLVR 的起点模型对一个问题正确率是 100% 或 0%，那么该提示下不同补全之间就没有梯度（即所有策略在策略梯度算法看来都一样）。许多模型在开始大规模 RL 之前做难度过滤，把训练问题限制在起点模型正确率只有 20-80% 的那些。这类数据通过对训练集中每个提示采样 N 个（例如 16 个）补全、验证其中正确的比例来收集。Seed-Thinking 1.5、Open Reasoner Zero、Phi-4、INTELLECT-2、MiMo RL、Skywork OR-1 等都采用了这类做法。
- **批内在线过滤**（或贯穿训练的难度课程）: 为配合离线过滤找到合适的问题，另一个主要问题是——**学习过程中应以什么顺序把问题呈现给模型**？为处理这一点，许多模型使用批内问题的在线过滤、预构建的课程/数据调度器、把更难的问题留到训练后期，或其他提升长期稳定性的做法。Kimi 1.5、Magistral、Llama-Nemotron、INTELLECT-2、MiMo-RL、Hunyuan-TurboS 等都用了相关思路。
- **去掉 KL 惩罚**: 随着推理模型的 RL 运行长度（无论以总 GPU 小时、FLOPS 还是 RL 步数衡量）相对 RLHF 训练大幅增加、并且奖励函数变得不那么容易被过度优化，许多模型去掉了“约束 RL 学到策略与训练起点基座模型相似”的 KL 惩罚。这让模型能在训练中做更多探索。RAGEN [191]、Magistral、OpenReasonerZero、Skywork OR-1 等都用了这一点。
- **放宽策略梯度裁剪**: GRPO 的新变体（如 DAPO [136]）对 GRPO（或 PPO）中的双边裁剪目标提出修改，以支持更好的探索。也有研究表明，当奖励并不完美时，裁剪可能造成**虚假的学习信号** [192]。RAGEN、Magistral、INTELLECT-2 等使用了这种“每个梯度方向用不同范围”的双边裁剪。
- **异策略数据（或完全异步更新）**: 随着用 RL 解题所需的补全长度因问题变难而急剧增长（尤其是回复长度的方差——常出现极长的离群值），RL 运行中的算力可能闲置。为解决这一点，训练正在转向异步更新，或改变把问题排进批次的方式以提升整体吞吐。Seed-Thinking 1.5、INTELLECT-2 等使用了部分到完全的异步（异策略）数据。
- **额外的格式奖励**: 为了让推理过程可预测，许多模型加入小的奖励，确保模型在给出答案前遵循 `<think>...</think>` 之类的正确格式。DeepSeek R1、OpenReasonerZero、Magistral、Skywork OR-1 等都用了这一点。
- **语言一致性奖励**: 与格式奖励类似，一些多语言推理模型使用语言一致性奖励，优先奖励那些推理过程中不切换语言的模型（以获得更好、更可预测的用户体验）。包括 DeepSeek R1、Magistral 等。
- **长度惩罚**: 许多模型在 RL 训练中使用不同形式的长度惩罚，或用于随时间稳定学习过程，或

用于缓解在难题上的过度思考。例如 Kimi 1.5 逐步延长目标长度以对抗过度思考（同时保证在难度课程上训练准确率保持较高），而 INTELLECT-2 全程使用一个较小的长度惩罚。逐步延长训练序列长度之所以能缓解过度思考，是因为它先迫使模型在思考预算更受限的领域里高效推理，然后再过渡到更长的训练，让模型能把那些行为高效地用在更复杂的问题上。其他做法包括超长过滤等相关实现以提升吞吐。

- **损失归一化**：关于原始 GRPO 算法中按组归一化的项可能引入长度或难度偏置，已有一些讨论（见策略梯度那一章、或 [125]）。因此一些模型（如 Magistral 或 MiMo）选择在批次层面而非组层面归一化损失或优势。
- **并行的测试时算力扩展**：把多个并行、独立采样的 rollout 的答案结合起来，可以比只用单个 rollout 的答案取得显著提升。最朴素的并行测试时算力扩展（DeepSeek-R1、Phi-4 等都这样做）是取多数 rollout 给出的答案作为最终答案。更高级的技术是用一个专门训练的打分模型，从并行 rollout 的答案中挑出最好的那个。截至 2026 年，这一技术在公开的、有文档的推理模型配方中还不常见，但 Claude 4 的发布公告中提到了它 [193]，DeepSeek-GRM 也使用了它 [164]。

除了这些常见技术之外，还有不少关于“如何训练出有用的推理模型、同时不牺牲周边能力”的常见发现：

- **纯文本推理能提升多模态表现**：Magistral、MiMo-VL 等发现，先训练一个多模态模型，再在多模态训练之后做纯文本推理训练，可以提升最终模型的多模态表现。
- **用系统提示切换推理（或长度控制）**：Llama-Nemotron、Nemotron Nano、Qwen 3、SmolLM 3 等使用特定的系统提示（可能配合长度受控的 RL 训练 [194]），让用户能开关思考长度。其他开放模型——如 OpenAI 的 gpt-oss 与 LLM360 的 K2-V2 [189]——在系统提示中采用“低—中—高”三档推理强度，但针对这类行为的训练方法文档化程度较低。

7.4 展望

推理模型的图景正在以近年 AI 研究中罕见的速度演化，这里列出的一些常见实践注定会被新技术取代。

目前有若干努力正在系统性地理解“是什么让推理训练奏效”。Olmo 3 Think [18] 是对一个推理模型完整训练生命周期最全面的公开记录，为研究社区提供了各阶段的检查点与数据，并以一次在 220 张 GPU 上持续近 4 周的训练收尾。类似地，关于理解 RL 在推理上的扩展性质的工作 [17]，正在把此前只存在于从业者直觉中的“算力、数据与性能之间关系”形式化。

有一点仍然清楚：强化学习已经从那块蛋糕上的“樱桃”，毕业成了前沿模型训练的承重结构。本章围绕 RLVR 的那些具体技术——难度过滤、格式奖励等等——并不是最终答案，但它们代表了当前这个领域对“如何从语言模型中激发推理”的最佳理解。下一代方法很可能看起来不一样，但它们会建立在这里奠定的基础之上。

8 直接对齐算法

直接对齐算法（Direct Alignment Algorithm, DAA）让人无需训练中间的奖励模型、也无需使用强化学习优化器，就能更新模型以求解同一个 RLHF 目标。DAA 解决的是我们一直在研究的同一个偏好学习问题（用的是字面意义上相同的数据！），目的是让语言模型更对齐、更聪明、更好用。没有奖励模型和在线优化，让 DAA 的实现简单得多，减少了训练期的算力开销，也让实验更容易。本章详述推导这些算法所涉及的复杂数学，然后展示：那些有时颇为繁琐的推导，最终落到的实现却很简单。

最著名的 DAA、也是催化了整场语言模型对齐学术运动的算法，是**直接偏好优化**（Direct Preference Optimization, DPO）[25]。核心上，DPO 用梯度上升求解同一个带约束的 RLHF 目标（见第 3 章）：

$$\max_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} [r_{\theta}(x, y)] - \beta \mathcal{D}_{\text{KL}}(\pi(y|x) \| \pi_{\text{ref}}(y|x)) \quad (80)$$

自 2023 年 5 月发布以来，在社区花了一段时间才摸清该用什么样的数据和超参之后（具体来说，是意外地低的学习率），许多流行模型都使用了 DPO 或其变体：从 2023 年 10 月以 Zephyr- β 打头阵 [26]，到 Llama 3 Instruct [29]、Tulu 2 [27] 与 Tulu 3 [6]、Nemotron 4 340B [30] 等。严格来说，序列似然校准（SLiC-HF）才是第一个发布的现代直接对齐算法 [195]，但由于多种因素没能流行起来（要扭转一种研究方法被采用的惯性，从来都是棘手的事）。

DPO 与 DAA 影响最大的地方，是**降低了语言模型后训练的实验门槛**——它算力需求更低、更容易从零实现，也更容易在玩具和生产级示例上都跑通。

本章通篇用 x 表示提示、 y 表示补全。这一记号在语言模型文献中很常见——那些方法作用于完整的“提示—补全”对，而非单个 *token*。

8.1 直接偏好优化

这里我们解释 DPO 如何工作的直觉，并完整重新推导其核心方程。

8.1.1 DPO 如何工作

从表面看，DPO 就是直接优化一个策略来求解 RLHF 目标。它的损失函数——我们稍后会在推导中重新审视——比较的是：学到的策略在被选中与被拒绝补全上的概率，相对参考模型发生了多大偏移。由 Bradley-Terry 奖励模型推出的损失函数如下：

$$\mathcal{L}_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_c, y_r) \sim \mathcal{D}} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_c | x)}{\pi_{\text{ref}}(y_c | x)} - \beta \log \frac{\pi_{\theta}(y_r | x)}{\pi_{\text{ref}}(y_r | x)} \right) \right] \quad (81)$$

sigmoid 内部，第一项 $\beta \log \frac{\pi_{\theta}(y_c | x)}{\pi_{\text{ref}}(y_c | x)}$ 衡量策略相对参考模型把被选中补全的概率提高了多少，第二项对被拒绝补全做同样的度量。当被选中的提升超过被拒绝的提升时——即策略学会偏好正确回答时——损失下降。

通篇的 β 是一个超参，用来在奖励优化与“最终模型同初始参考模型之间的 KL 散度”之间做平衡（也就是在平衡过度优化，这是正确使用 DPO 的关键超参）。这依赖于 DPO 训练中**替代外部奖励模型**的隐式奖励——概率的对数比值：

$$r(x, y) = \beta \log \frac{\pi_r(y | x)}{\pi_{\text{ref}}(y | x)} \quad (82)$$

其中 $\pi_r(y | x)$ 是我们要求解的精确最优奖励策略。它来自“把 Bradley-Terry 奖励用最优策略表达”（见式 97），如第 5 章 Bradley-Terry 模型那一节所示。本质上，正如 DPO 论文所说，这种重参数化给了我们“用最优策略而非奖励模型表达的、人类偏好数据的概率”——这意味着我们可以完全绕过显式的奖励模型学习。

来看式 81 中优化器必须降低的那个损失。当被选中回答的对数比值大于被拒绝回答的对数比值（都相对参考模型归一化）时，损失就更低。实践中，这是模型在数据所呈现的 token 序列上对数概率的求和。因此，DPO 做的是拉大被选中与被拒绝回答之间的相对对数概率差距。

有了式 82 中的奖励，我们可以写出损失的梯度，以进一步解读正在发生什么：

$$\nabla_{\theta} \mathcal{L}_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = -\beta \mathbb{E}_{(x, y_c, y_r) \sim \mathcal{D}} [w \cdot (\nabla_{\theta} \log \pi_{\theta}(y_c | x) - \nabla_{\theta} \log \pi_{\theta}(y_r | x))] \quad (83)$$

其中 $w = \sigma(r_{\theta}(x, y_r) - r_{\theta}(x, y_c))$ 。

这个梯度通过以下方式求解上述目标：

- sigmoid 函数 $\sigma(\cdot)$ 内的第一项产生一个 0 到 1 的参数更新权重；当奖励估计不正确时它更大。当被拒绝样本反而比被选中样本更受偏好时，权重更新应该更大！
- 其次，内层方括号 $[\cdot]$ 中的项提高被选中回答 y_c 的似然、降低被拒绝回答 y_r 的似然。
- 这些项被 β 加权， β 控制更新的力度如何在“把补全顺序排对”与“KL 散度约束”之间平衡。

核心直觉是：**DPO 在拟合一个隐式奖励模型，而它所对应的最优策略可以闭式地提取出来**（式 97，这要归功于梯度下降和我们手头的 ML 工具）。因为 DPO 损失可直接求导，算出精确梯度是直接的，不需要“训练奖励模型、采样补全打分”来估计它。经常被误解的一点是：**DPO 在核心上是在学一个奖励模型**——这正是论文副标题《Your Language Model is Secretly a Reward Model》的由来。人们很容易把它和“DPO 目标直接训练一个策略”混淆，所以研究下面的推导有助于获得完整的理解。

有了这个隐式奖励模型的学习，DPO 就能在给定数据集中的数据、以及目标中那个特定 KL 约束 β 之下，产出 RLHF 目标的最优解。这里，DPO 之所以能针对一个特定 KL 散度求出精确策略，是因为它的生成不是像策略梯度算法那样在线的——这是它与偏好微调 RL 方法的核心差别。在很多方面，这让 DPO 的 β 比在线 RL 方法更容易调；但关键在于、也符合直觉的是：**最优值取决于被训练的模型与训练它的数据**。

在每一批偏好数据（由许多补全对 $y_{\text{chosen}} \succ y_{\text{rejected}}$ 组成）上，DPO 直接朝最优解做梯度步。它比策略梯度方法简单得多。

8.1.2 DPO 推导

DPO 的推导有两个主要部分。第一，作者给出了**最优求解 RLHF 目标**的策略形式——也就是本书通篇使用的那个目标。第二，他们展示了如何从成对偏好数据（即 Bradley-Terry 模型）抵达这个解。

8.1.2.1 推导 RLHF 的最优解 首先，我们应当再看一眼 RLHF 优化目标——这里表明我们希望最大化这个量：

$$\max_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} [r_{\theta}(x, y)] - \beta \mathcal{D}_{\text{KL}}(\pi(y|x) \| \pi_{\text{ref}}(y|x)) \quad (84)$$

LEARNING FROM HUMAN FEEDBACK




图 29: DPO 刚发布时, 在研究社区引发了一场关于“如何最好地做 RLHF 与偏好学习”的激烈争论。这张梗图很好地捕捉了当时的情绪——那场争论常常让人觉得是被逼出来的、用力过猛, 但许多刚入门的人乃至顶级实验室都从 DPO 中获得了巨大收益。DPO 简洁性梗图, 作者 Tom Goldstein。

这里的双重期望只作用于“计算期望奖励所需的采样”，因为 KL 项本身仍是一个解析表达式。首先，展开 KL 散度的定义。回忆 $\mathcal{D}_{\text{KL}}(\pi \parallel \pi_{\text{ref}}) = \mathbb{E}_{y \sim \pi} \left[\log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} \right]$ ，其中求和里的 $\pi(y|x)$ 权重变成了采样分布。由于两项现在共享同一个对 $y \sim \pi(y|x)$ 的期望，可以把它们合并：

$$\max_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} \left[r(x, y) - \beta \log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} \right] \quad (85)$$

接下来，把负号从括号中的差里提出来。为此把它拆成两项：

$$= \max_{\pi} \left(\mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} [r(x, y)] - \beta \mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} \left[\log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} \right] \right) \quad (86)$$

然后乘 -1 ，把最大化转成最小化：

$$= \min_{\pi} \left(-\mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} [r(x, y)] + \beta \mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} \left[\log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} \right] \right) \quad (87)$$

除以 β 并重新合并：

$$= \min_{\pi} \left(\mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} \left[\log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} - \frac{1}{\beta} r(x, y) \right] \right) \quad (88)$$

接下来，必须引入一个配分函数 $Z(x)$ ：

$$Z(x) = \sum_y \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right) \quad (89)$$

配分函数充当未归一化密度 $\pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right)$ 的归一化因子，从而使它对每个固定的 x 都成为 y 上的合法概率函数。它的确切必要性很快会在推导中显现。

把它代入，我们得到中间变换：

$$\min_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim \pi(y|x)} \left[\log \frac{\pi(y|x)}{\frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right)} - \log Z(x) \right] \quad (90)$$

要看这是怎么来的，考虑式 88 方括号内的优化内部部分：

$$\log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} - \frac{1}{\beta} r(x, y) \quad (91)$$

然后加上 $\log Z(x) - \log Z(x)$ ：

$$= \log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} - \frac{1}{\beta} r(x, y) + \log Z(x) - \log Z(x) \quad (92)$$

然后重新分组：

$$= \left(\log \frac{\pi(y|x)}{\pi_{\text{ref}}(y|x)} + \log Z(x) \right) - \log Z(x) - \frac{1}{\beta} r(x, y) \quad (93)$$

利用 $\log(x) + \log(y) = \log(x \cdot y)$ （并把 Z 移到分母），得到：

$$= \log \frac{\pi(y|x)}{\frac{1}{Z(x)} \pi_{\text{ref}}(y|x)} - \log Z(x) - \frac{1}{\beta} r(x, y) \quad (94)$$

接下来，把 $\frac{1}{\beta} r(x, y)$ 展开为 $\log \exp \frac{1}{\beta} r(x, y)$ ，做同样操作即可得到 式 90，这里稍微改写一下：

$$\min_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \left[\mathbb{E}_{y \sim \pi(y|x)} \left[\log \frac{\pi(y|x)}{\frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right)} \right] - \log Z(x) \right] \quad (95)$$

用这个优化形式，我们需要真正解出最优策略 π^* 。由于我们引入了配分函数 $Z(x)$ ，从而使 $\frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right)$ 成为 y 上的合法概率分布，我们可以辨认出：**内层期望实际上就是一个真正的 KL 散度！**

$$\min_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \left[\mathcal{D}_{\text{KL}} \left(\pi(y|x) \parallel \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right) \right) - \log Z(x) \right] \quad (96)$$

由于 $\log Z(x)$ 这一项不依赖 π （我们正在优化的策略），可以忽略它。剩下的就只有“我们正在学习的策略”与“一个把配分、 β 、奖励和参考策略联系起来的分布”之间的 KL 散度。吉布斯不等式告诉我们：它只在两者相等时才取到 0 这一最小值！于是我们得到最优策略：

$$\pi^*(y|x) = \pi(y|x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r(x, y) \right) \quad (97)$$

8.1.2.2 为 BT 模型推导 DPO 目标 首先回忆：如第 5 章「奖励建模」与第 11 章「偏好数据」所述，人类偏好的 Bradley-Terry 模型形如：

$$p^*(y_1 \succ y_2 | x) = \frac{\exp(r^*(x, y_1))}{\exp(r^*(x, y_1)) + \exp(r^*(x, y_2))} \quad (98)$$

通过变换 式 97，我们可以解出最优奖励。先对两边取对数：

$$\log \pi^*(y|x) = \log \left(\frac{1}{Z(x)} \pi_{\text{ref}}(y|x) \exp \left(\frac{1}{\beta} r^*(x, y) \right) \right) \quad (99)$$

用 $\log(abc) = \log a + \log b + \log c$ 展开右侧：

$$\log \pi^*(y|x) = -\log Z(x) + \log \pi_{\text{ref}}(y|x) + \frac{1}{\beta} r^*(x, y) \quad (100)$$

移项解出 $r^*(x, y)$ ：

$$\frac{1}{\beta} r^*(x, y) = \log \pi^*(y|x) - \log \pi_{\text{ref}}(y|x) + \log Z(x) \quad (101)$$

两边乘 β :

$$r^*(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x) \quad (102)$$

然后把这个奖励代入 式 98 的 Bradley-Terry 方程, 得到:

$$p^*(y_1 \succ y_2 | x) = \frac{\exp \left(\beta \log \frac{\pi^*(y_1|x)}{\pi_{\text{ref}}(y_1|x)} + \beta \log Z(x) \right)}{\exp \left(\beta \log \frac{\pi^*(y_1|x)}{\pi_{\text{ref}}(y_1|x)} + \beta \log Z(x) \right) + \exp \left(\beta \log \frac{\pi^*(y_2|x)}{\pi_{\text{ref}}(y_2|x)} + \beta \log Z(x) \right)} \quad (103)$$

把指数表达式从 e^{a+b} 拆成 $e^a e^b$, 再约掉 $e^{\beta \log Z(x)}$ 这一项, 它化简为:

$$p^*(y_1 \succ y_2 | x) = \frac{\exp \left(\beta \log \frac{\pi^*(y_1|x)}{\pi_{\text{ref}}(y_1|x)} \right)}{\exp \left(\beta \log \frac{\pi^*(y_1|x)}{\pi_{\text{ref}}(y_1|x)} \right) + \exp \left(\beta \log \frac{\pi^*(y_2|x)}{\pi_{\text{ref}}(y_2|x)} \right)} \quad (104)$$

接着, 分子分母同乘 $\exp \left(-\beta \log \frac{\pi^*(y_1|x)}{\pi_{\text{ref}}(y_1|x)} \right)$:

$$p^*(y_1 \succ y_2 | x) = \frac{1}{1 + \exp \left(\beta \log \frac{\pi^*(y_2|x)}{\pi_{\text{ref}}(y_2|x)} - \beta \log \frac{\pi^*(y_1|x)}{\pi_{\text{ref}}(y_1|x)} \right)} \quad (105)$$

最后, 用 sigmoid 函数的定义 $\sigma(x) = \frac{1}{1+e^{-x}}$, 得到:

$$p^*(y_1 \succ y_2 | x) = \sigma \left(\beta \log \frac{\pi^*(y_1|x)}{\pi_{\text{ref}}(y_1|x)} - \beta \log \frac{\pi^*(y_2|x)}{\pi_{\text{ref}}(y_2|x)} \right) \quad (106)$$

在最优策略 π^* 下, 这就是 Bradley-Terry 模型中偏好数据的似然。回忆第 5 章「奖励建模」中我们推导过: Bradley-Terry 目标就是最大化似然, 等价于最小化负对数似然, 于是得到损失:

$$\begin{aligned} \mathcal{L}_{\text{DPO}}(\pi_\theta; \pi_{\text{ref}}) &= -\mathbb{E}_{(x, y_c, y_r) \sim \mathcal{D}} [\log p(y_c \succ y_r | x)] \\ &= -\mathbb{E}_{(x, y_c, y_r) \sim \mathcal{D}} \left[\log \sigma \left(\beta \log \frac{\pi_\theta(y_c|x)}{\pi_{\text{ref}}(y_c|x)} - \beta \log \frac{\pi_\theta(y_r|x)}{\pi_{\text{ref}}(y_r|x)} \right) \right] \end{aligned} \quad (107)$$

这就是 DPO 的损失函数, 形式与 式 81 所示一致。DPO 论文还给出了 Plackett-Luce 模型下目标的额外推导, 但实践中用得少得多 [25]。

8.1.2.3 推导 BT-DPO 的梯度 我们用式 83 中给出的 DPO 梯度解释了模型如何学习的直觉。要推导它，需要对式 107 关于模型参数求梯度。

$$\nabla_{\theta} \mathcal{L}_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = -\nabla_{\theta} \mathbb{E}_{(x, y_c, y_r) \sim \mathcal{D}} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_c|x)}{\pi_{\text{ref}}(y_c|x)} - \beta \log \frac{\pi_{\theta}(y_r|x)}{\pi_{\text{ref}}(y_r|x)} \right) \right] \quad (108)$$

首先，它可以重写。我们知道 sigmoid 的导数 $\frac{d}{dx} \sigma(x) = \sigma(x)(1 - \sigma(x))$ 、对数的导数 $\frac{d}{dx} \log x = \frac{1}{x}$ ，以及 sigmoid 的性质 $\sigma(-x) = 1 - \sigma(x)$ ，于是可以改写上式。

先令 $u = \beta \log \frac{\pi_{\theta}(y_c|x)}{\pi_{\text{ref}}(y_c|x)} - \beta \log \frac{\pi_{\theta}(y_r|x)}{\pi_{\text{ref}}(y_r|x)}$ （也就是 sigmoid 内部的表达式）。于是有

$$\nabla_{\theta} \mathcal{L}_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_c, y_r) \sim \mathcal{D}} \left[\frac{\sigma'(u)}{\sigma(u)} \nabla_{\theta} u \right] \quad (109)$$

展开它，并利用上面 sigmoid 与对数的表达式，就得到前面引入的那个梯度：

$$-\mathbb{E}_{(x, y_c, y_r) \sim \mathcal{D}} \left[\beta \sigma \left(\beta \log \frac{\pi_{\theta}(y_r|x)}{\pi_{\text{ref}}(y_r|x)} - \beta \log \frac{\pi_{\theta}(y_c|x)}{\pi_{\text{ref}}(y_c|x)} \right) [\nabla_{\theta} \log \pi_{\theta}(y_c|x) - \nabla_{\theta} \log \pi_{\theta}(y_r|x)] \right] \quad (110)$$

8.2 数值问题、局限与替代方案

针对 DPO 的弱点，人们提出了许多 DPO 变体。例如，DPO 没有 rollout、也没有能对生成打分的奖励模型，因此它把每一对偏好数据同等看待。而现实中，如第 11 章「偏好数据」所述，捕捉偏好数据的方式有很多，标签可以比二元更丰富。已有多算法被提出来重新平衡优化，使其不再对每一对一视同仁。

- **基于相对奖励回归的 RL (REBEL)** 引入了来自奖励模型的信号——作为被选中与被拒绝回答之间的间隔——而不只是成对偏好数据，从而更准确地求解 RLHF 问题 [196]。
- **保守 DPO (cDPO)** 与 **恒等偏好优化 (IPO)** 通过假设偏好数据中存在噪声来应对过拟合。cDPO 假设有 N% 的数据标注错误 [25]；IPO 则改变优化目标，柔化偏好概率，而不是直接依据标签优化 [197]。实践上，IPO 把偏好概率换成一个非线性函数 $\Psi(q) = \log \left(\frac{q}{1-q} \right)$ ，从而脱离 Bradley-Terry 假设。
- **带偏移的 DPO (ODPO)** “要求偏好回答与非偏好回答的似然差大于某个偏移值” [198]——不再把每对数据同等看待，但代价可能是更困难的标注环境。

另一些 DPO 变体则试图通过小幅改动损失来改进学习信号，或通过降低显存占用提升效率。

- **赔率比策略优化 (ORPO)** 用类似指令微调损失的方式直接更新策略模型、把模型拉向被选中回答，同时对被选中回答施加一个小的惩罚 [199]。这种损失函数的改动去掉了对参考模型的需求，简化了设置。理解 ORPO 最好的方式是把它看作“受 DPO 启发”，而非 DPO 的衍生。
- **简单偏好优化 (SimPO)** 对 DPO 优化做了一处小改动：把对数概率取平均而非求和，或加入长度归一化，以提升性能 [200]。

DPO 中显而易见的核心问题之一是：这个优化只致力于拉大被选中与被拒绝回答概率之间的间隔。在数值上，模型会同时降低被选中和被拒绝回答的概率，但被拒绝回答降低的幅度更大，如图 30 所示。直观上，这如何泛化并不清楚；但有工作提出：它会提高那些未被触及行为的概率——也就是语




图 30: DPO 中偏好位移的示意。

言模型能够生成、但不在后训练数据集分布内的 token [201] [202]。一些简单方法可以缓解这种偏好位移，例如调整优化过程的 Cal-DPO [203]，以及改变奖励形状的 AlphaPO [204]。实践中，其确切影响尚不清楚，但它指出了在线方法为何可能优于原始 DPO 的一个潜在原因。

关于 DPO 类方法性能上限低于在线（基于 RL 的）RLHF 方法，另一个被提出的主要原因是：训练信号来自先前或其他模型生成的补全。DPO 的在线变体通过在训练时生成新补全并纳入偏好信号来缓解这些限制。在线 DPO [205] 从当前模型采样生成；判别器引导的 DPO (D2PO) [206] 用奖励模型重新打标，即时生成新的偏好数据；此外还有许多变体。

还有其他一长串 DAA 变体，例如直接纳什优化 (DNO) [207] 或二元分类器优化 (BCO) [208]；但算法选择远不如初始模型和所用数据重要 [6] [209] [210]。

8.3 实现细节

DPO 这类 DAA 的实现方式与策略梯度优化器差别很大。DPO 的损失取自原始实现，大致可以概括如下 [25]：

```
# Log-probability gaps for the policy and the frozen reference model
pi_logratios = policy_chosen_logps - policy_rejected_logps
ref_logratios = reference_chosen_logps - reference_rejected_logps

# Difference of log-ratios: positive when the policy
# shifts probability toward the chosen completion
logits = pi_logratios - ref_logratios

# DPO loss: negative log-sigmoid drives the policy to
# widen the gap between chosen and rejected
losses = -F.logsigmoid(beta * logits)
```

```
# Implicit rewards (detached -- used for logging only)
chosen_rewards = beta * (policy_chosen_logps - reference_chosen_logps).detach()
rejected_rewards = beta * (policy_rejected_logps - reference_rejected_logps).detach()
```

它可以直接用于标准的语言模型训练栈，因为这些信息在模型前向传播时就被收集（只需额外加一个参考模型）。

在大多数方面，DAA 都更简单、是体验上的改善，但它们也带来一组不同的考量。

1. **KL 散度是静态的：**在 DPO 及其他算法中，KL 散度由平衡距离惩罚与优化的 β 参数显式设定。这是因为 DPO 朝 RLHF 目标在给定数据下的最优解做梯度步——它精确地走到 β 设定的那个解。而基于 RL 的优化器则依据批次和近期数据迈步。
2. **缓存对数概率：**DPO 的简单实现在做损失计算时，会同时为策略模型和参考模型做前向传播，图方便。但这会让显存翻倍、GPU 占用上升。为了规避，可以先在整个训练数据集上算好参考模型的对数概率，之后每个批次复用这些缓存值，从而把峰值显存降低 50%。

8.4 使用合成偏好数据的 DAA

如今，用 DAA 做偏好微调的流行数据集大多是**合成偏好数据**：由某个前沿模型把其他模型的输出评为胜者或败者。突出的例子包括 UltraFeedback（这一类中的第一个）[28]、Tulu 3（用扩展后的 UltraFeedback 方法构建）[6]、SmolLM 3 的数据 [211]，以及随 Olmo 3 发布的 Dolci Pref 数据集 [18]。

构建这些数据集的最佳实践仍在演化。Tulu 3 及其 2024 年 11 月发布前后的数据集表明：合成成对偏好数据需要在某种意义上是**同策略的**——即部分补全应当由你正在微调的那个模型生成（同时混入更大的模型池中）。数据的这种同策略特性，确保 DAA 会在模型实际生成所在的 token 空间中做优化——因为它的损失函数是**对比式**的，比指令微调更间接。后来，随着 2025 年 Olmo 3 与 SmolLM 3 的发布，其他工作支持了一种不同的理论，叫 **Delta Learning**：它主张被选中与被拒绝补全之间的差异，比“补全究竟由哪些模型产生”对学习更重要 [212]。例如，在这两个被引用的模型里，被选中回答都来自 Qwen 3 32B、被拒绝回答都来自 Qwen 3 0.6B——而两位作者是各自独立、同时发展出这组配对的。

总的来说，用 **DAA 在合成偏好数据上训练**，是大多数从业者应当起步的地方——因为实现简单，而且相对于基于强化学习的偏好微调，性能表现强劲。使用大量合成偏好数据还有其他一些小问题，比如评判模型在补全之间做比较时的偏置。鉴于 GPT-4 这类前沿模型已知存在长度偏置 [86] 与偏好“与自己风格相近的输出” [213]（更多信息见第 12 章），数据集里“被选中”一侧的文本，稍微更可能来自 OpenAI 模型或其他风格相近的强模型。

本节最后，我们给出一个直觉，说明这些方法如何改变被训练模型的生成。高层面看，多数 DAA 的优化目标都是拉大“被选中”与“被拒绝”补全概率之间的间隔（一些不太流行的算法被设计来稍微改变这些动态，但核心不变）。如本章前面所讨论（见图 30），这通常意味着两个概率都下降，但被拒绝回答下降得更多。序列中的每个 token 会依其“对总体偏好间隔贡献了多少”而收到不同的梯度（幅度与方向），这让优化器能够识别哪些 token 对结果最重要。

8.5 DAA 与 RL：在线数据 vs 离线数据

粗略地说，这场争论归结为一个问题：**要把语言模型与 RLHF 对齐，我们是否需要强化学习的那套内部机制——价值函数、策略梯度等等？**和大多数这样表述的问题一样，它过于简单。当然，两种方

法都已确立；但有必要说明根本差异与性能分布落在哪里。

多份报告得出结论：基于策略梯度与 RL 的方法优于 DPO 及其变体。论证形式各异——有在受控数据下用不同算法训练模型的 [132] [172]，也有研究同策略数据在 RL 优化循环中作用的 [214]。在所有这些情况下，DPO 算法都差了那么一点点。

即便存在这一性能差距，由于简单，DAA 仍然被大量用于领先模型。DAA 提供了一个可控环境，让训练数据与其他配置的迭代可以快速进行；而鉴于数据往往比算法重要得多，用 DPO 是完全可以的。

随着主要用 RL 训练的推理模型出现，更多的投入会回到“用 RL 做偏好微调”上；长期看，这将提升 RL 基础设施的鲁棒性，并巩固 DAA 与 RL 在“从人类反馈优化”上的这一差距。

8.6 建议的实验

code/direct_alignment/ 中的配套代码会在偏好数据上训练 DPO 及若干相关损失。由于是离线的（不需要奖励模型服务，也不需要 rollout 循环），这是开始尝试偏好微调最容易上手的地方。

1. 在 UltraFeedback 上跑一个小规模 DPO。

```
cd code/  
uv run python -m direct_alignment.train --loss dpo --max_samples 1000
```

观察 loss、accuracy、margins、chosen_rewards 和 rejected_rewards。主要的自检点是：隐式奖励间隔应当朝期望方向移动，同时模型的样本生成不应坍塌。

2. 对比 DPO、IPO 与长度归一化的 DPO。

```
cd code/  
uv run python -m direct_alignment.train --config direct_alignment/configs/dpo.yaml  
uv run python -m direct_alignment.train --config direct_alignment/configs/ipo.yaml  
uv run python -m direct_alignment.train --config direct_alignment/configs/dpo_norm.yaml
```

对比间隔的量级与对学习率的敏感性。IPO 的损失不在与 DPO 相同的数值尺度上，所以应当通过 accuracy 与间隔行为来读它，而不是只看原始损失。

3. 谨慎尝试无参考模型的变体。用各自的配置跑 SimPO 或 ORPO，然后检查训练中记录的生成样本。这些损失对对数概率的尺度与学习率更敏感，因此是很有价值的调试题材。

```
cd code/  
uv run python -m direct_alignment.train --config direct_alignment/configs/simpo.yaml  
uv run python -m direct_alignment.train --config direct_alignment/configs/orpo.yaml
```

4. 先改数据，再改损失。固定损失，改变 --max_samples、--max_length 或偏好数据集。如果结果的变化比“在 DPO 类目标之间切换”更大，那就是对偏好微调一个核心主题的经验提醒：数据通常压过算法上的细微差异。

9 拒绝采样

拒绝采样（Rejection Sampling, RS）是偏好微调中用得最广、记录得最少的方法之一。许多著名的 RLHF 论文都把它作为训练流程的核心组件，却不存在公认的实现，也没有解释它为何如此有效。拒绝采样可以应用在训练流程的多个节点上——指令微调之后、基于 RL 的优化之后，甚至 RLVR 之后——这让它成为一个用途广泛、却难以归位的工具。再加上它文档化程度低，这正是它被放在核心优化方法最后的原因。

拒绝采样的做法是：整理出一批新的候选补全，用训练好的奖励模型筛选，然后只用最好的那些补全对原模型做微调（损失函数与指令微调相同）。

这个名字来自计算统计学 [215]：当你想从某个复杂分布中采样，却没有直接可行的方法时，就从另一个更容易建模的分布中采样，并用一个启发式规则检查该样本是否可用。在语言模型上，目标分布是“对提示的高质量补全”，筛选器是奖励模型，采样分布则是当前模型。

WebGPT [4]、Anthropic 的 Helpful and Harmless 智能体 [5]、OpenAI 那篇关于过程奖励模型的著名论文 [50]、Llama 2 Chat 模型 [49] 以及其他奠基性工作，都使用了这一基线做法；更新的工作则把它直接形式化（例如把拒绝采样应用到多模态对齐的 RAFT [216]，以及给出了“拒绝采样与其他偏好学习目标如何关联”之原则性综述的统计拒绝采样优化 RSO [217]）。

本章通篇用 x 表示提示、 y 表示补全。这一记号在语言模型文献中很常见——那些方法作用于完整的“提示—补全”对，而非单个 *token*。

9.1 训练流程，一步一步来

拒绝采样整体上分为几个阶段。

0. **选择提示与奖励模型**：首先，你要相对于其他训练阶段来选择本阶段要训练的提示。最简单的方法是复用第一个 SFT/IFT 阶段的全部提示，但这可能导致一些过拟合。在做拒绝采样之前，你还必须已经训练好一个奖励模型（更多信息见第 5 章）。
1. **从起始检查点生成补全**：接着，用你想优化的模型对选定的提示生成补全。这一步可能涉及调整许多设置，例如采样温度、top-p、最大序列长度、每个提示的补全数等。
2. **用奖励模型选出最好的补全**：所有补全由奖励模型排序。这一步也可能包含去重，即每个提示只保留一个补全；不过许多这类设计选择最终都要靠经验性的消融实验来定。
3. **在最好的补全上做 SFT**：最后，用选出的补全对起始检查点做指令微调，拒绝采样就完成了。

拒绝采样流程的可视化总览见 图 31。




图 31: 拒绝采样总览。

关于到底该用哪些提示、如何选奖励模型、如何安排拒绝采样的顺序等具体细节，文献中记录得并不充分。本章给出方法概览，进一步的实验留给读者。

9.1.1 生成补全

要为每个提示生成一组多个候选补全，我们先把 M 个提示的集合定义为一个向量：

$$X = [x_1, x_2, \dots, x_M] \quad (111)$$

这些提示可以来自许多来源，但最常见的是来自指令训练集。

对每个提示 x_i ，我们生成 N 个补全。这可以表示为一个矩阵：

$$Y = \begin{bmatrix} y_{1,1} & y_{1,2} & \cdots & y_{1,N} \\ y_{2,1} & y_{2,2} & \cdots & y_{2,N} \\ \vdots & \vdots & \ddots & \vdots \\ y_{M,1} & y_{M,2} & \cdots & y_{M,N} \end{bmatrix} \quad (112)$$

其中 $y_{i,j}$ 表示第 i 个提示的第 j 个补全。每一行 i 对应单个提示 x_i ，包含它的 N 个候选补全；每一列 j 对应所有提示在“第 j 次采样”上的补全。

9.1.2 给补全打分

现在，把所有这些“提示—补全”对送入奖励模型，得到一个奖励矩阵。我们把奖励表示为矩阵 R ：

$$R = \begin{bmatrix} r_{1,1} & r_{1,2} & \cdots & r_{1,N} \\ r_{2,1} & r_{2,2} & \cdots & r_{2,N} \\ \vdots & \vdots & \ddots & \vdots \\ r_{M,1} & r_{M,2} & \cdots & r_{M,N} \end{bmatrix} \quad (113)$$

每个奖励 $r_{i,j}$ 都由补全 $y_{i,j}$ 与其对应提示 x_i 经过奖励模型 $\mathcal{R}$ 计算得到：

$$r_{i,j} = \mathcal{R}(y_{i,j} | x_i) \quad (114)$$

选出“用来训练的最佳补全”有多种方法。

为了把“依据奖励矩阵挑出最佳补全”这个过程形式化，我们可以定义一个作用在奖励矩阵 R 上的选择函数 S 。

9.1.2.1 每提示取最优 第一个可能的选择函数是取每个提示的最大奖励。

$$S(R) = \left[\arg \max_j r_{1,j}, \arg \max_j r_{2,j}, \dots, \arg \max_j r_{M,j} \right] \quad (115)$$

这个函数 S 返回一个索引向量，其中每个索引对应 R 的每一行中奖励最大的那一列。然后用这些索引挑出被选中的补全：

$$Y_{chosen} = [y_{1,S(R)_1}, y_{2,S(R)_2}, \dots, y_{M,S(R)_M}] \quad (116)$$

9.1.2.2 全体取前 K 对 另一种做法是从整个集合中选出前 K 个“提示—补全”对。先把奖励矩阵 R 展平成一个向量：

$$R_{flat} = [r_{1,1}, r_{1,2}, \dots, r_{1,N}, r_{2,1}, r_{2,2}, \dots, r_{2,N}, \dots, r_{M,1}, r_{M,2}, \dots, r_{M,N}] \quad (117)$$

这个 R_{flat} 向量的长度为 $M \times N$ ，其中 M 是提示数、 N 是每个提示的补全数。

现在我们可以定义一个选择函数 S_K ，选出 R_{flat} 中前 K 个最大值的索引：

$$S_K(R_{flat}) = \text{argsort}(R_{flat})[-K:] \quad (118)$$

其中 argsort 返回能把数组升序排列的索引，我们取最后 K 个索引，就得到最大的 K 个值。

要得到被选中的补全，需要把这些展平后的索引映射回原来的补全矩阵 Y 。把零基的展平索引 k 映射到 (i, j) ，可用 $i = \lfloor k/N \rfloor + 1$ 、 $j = (k \bmod N) + 1$ 。

9.1.2.3 选择示例 考虑下面这个情形：五个提示、四个补全。我们演示两种依据奖励选择补全的方式。

$$R = \begin{bmatrix} 0.7 & 0.3 & 0.5 & 0.2 \\ 0.4 & 0.8 & 0.6 & 0.5 \\ 0.9 & 0.3 & 0.4 & 0.7 \\ 0.2 & 0.5 & 0.8 & 0.6 \\ 0.5 & 0.4 & 0.3 & 0.6 \end{bmatrix} \quad (119)$$

首先是每提示取最优。直观上，我们可以这样高亮奖励矩阵：

$$R = \begin{bmatrix} \mathbf{0.7} & 0.3 & 0.5 & 0.2 \\ 0.4 & \mathbf{0.8} & 0.6 & 0.5 \\ \mathbf{0.9} & 0.3 & 0.4 & 0.7 \\ 0.2 & 0.5 & \mathbf{0.8} & 0.6 \\ 0.5 & 0.4 & 0.3 & \mathbf{0.6} \end{bmatrix} \quad (120)$$

用 argmax 方法，我们为每个提示选出最好的补全：

$$S(R) = \left[\arg \max_j r_{i,j} \text{ for } i \in [1, 5] \right] \quad (121)$$

$$S(R) = [1, 2, 1, 3, 4] \quad (122)$$

这意味着我们会选择：

- 提示 1: 补全 1 (奖励 0.7)
- 提示 2: 补全 2 (奖励 0.8)
- 提示 3: 补全 1 (奖励 0.9)
- 提示 4: 补全 3 (奖励 0.8)
- 提示 5: 补全 4 (奖励 0.6)

再看全体取前 K 。我们高亮出全体排名前五的“提示—补全”对。

$$R = \begin{bmatrix} \mathbf{0.7} & 0.3 & 0.5 & 0.2 \\ 0.4 & \mathbf{0.8} & 0.6 & 0.5 \\ \mathbf{0.9} & 0.3 & 0.4 & \mathbf{0.7} \\ 0.2 & 0.5 & \mathbf{0.8} & 0.6 \\ 0.5 & 0.4 & 0.3 & 0.6 \end{bmatrix} \quad (123)$$

先把奖励矩阵展平：

$$R_{flat} = [0.7, 0.3, 0.5, 0.2, 0.4, 0.8, 0.6, 0.5, 0.9, 0.3, 0.4, 0.7, 0.2, 0.5, 0.8, 0.6, 0.5, 0.4, 0.3, 0.6] \quad (124)$$

然后选出五个最大值的索引：

$$S_5(R_{flat}) = [8, 5, 14, 0, 11] \quad (125)$$

把它们映射回原矩阵：

- 索引 8 $\rightarrow$ 提示 3, 补全 1 (奖励 0.9)
- 索引 5 $\rightarrow$ 提示 2, 补全 2 (奖励 0.8)
- 索引 14 $\rightarrow$ 提示 4, 补全 3 (奖励 0.8)
- 索引 0 $\rightarrow$ 提示 1, 补全 1 (奖励 0.7)
- 索引 11 $\rightarrow$ 提示 3, 补全 4 (奖励 0.7)

9.1.2.4 实现示例 下面这段代码展示了这些选择方法可以如何实现。

```
import numpy as np

x = np.random.randint(10, size=10)
print(f"{x}")
sorted_indices = np.argsort(x)
x_sorted = x[sorted_indices]
print(f"{x_sorted}")

# first way to recover the original array
i_rev = np.zeros(10, dtype=int)
i_rev[sorted_indices] = np.arange(10)
np.allclose(x, x_sorted[i_rev])

# second way to recover the original array
np.allclose(x, x_sorted[np.argsort(sorted_indices)])
```

9.1.3 微调

有了选出的补全，接下来就在模型的当前版本上做标准的指令微调。更多细节见指令微调那一章。

9.2 实现细节

执行这项训练的核心超参非常直观：

- **采样参数：**拒绝采样直接依赖模型给出的补全。常见设置包括使用大于 0 的温度，例如 0.7 到 1.0 之间，并对 top-p 或 top-k 采样等其他参数做调整。
- **每个提示的补全数：**成功的拒绝采样实现中，每个提示包含 10 到 30 个或更多补全。补全太少会让训练有偏和/或有噪声。
- **指令微调的细节：**拒绝采样中指令微调的确切训练细节并未公开。它们很可能使用了与模型初始指令微调阶段略不相同的设置。
- **异构模型生成：**一些拒绝采样的实现会纳入多个模型的生成，而不只是即将被训练的那个模型。这方面的最佳实践尚未确立。
- **奖励模型训练：**所用的奖励模型会极大影响最终结果。关于奖励模型训练的更多资料，见相关章节。

在做批量奖励模型推理时，可以按长度对 token 化后的补全排序，让同一批次内的长度相近。这样就不必在那么多填充 token 上做推理，能以少量实现复杂度的代价提升吞吐。

9.3 相关方法：Best-of-N 采样

Best-of-N (BoN) 是拒绝采样的近亲：沿用同样的“生成并打分”流程，但**不在**选出的补全上微调模型。相反，BoN 是在推理时对某个固定提示（或一组提示）算出最好的那个补全；相关技术常被用于聊天模型的“Pro”档位——它们花额外算力来回答你的问题。

Best-of-N 采样常被当作相对于 RLHF 训练方法的基线。要记住：BoN **不修改**底层模型，它是一种采样技术。正因如此，把 BoN 采样与 PPO 这类在线训练方法做比较，在某些语境下仍然是有效的。例如，你仍然可以测量运行 BoN 采样时相对于任何其他策略的 KL 距离。

这里我们要说明：当对单个提示做简单的 BoN 采样时，上面两种选择准则是等价的。

设 R 为单个提示下 N 个补全的奖励向量：

$$R = [r_1, r_2, \dots, r_N] \quad (126)$$

其中 r_j 表示第 j 个补全的奖励。

用 argmax 方法，我们为这个提示选出最好的补全：

$$S(R) = \arg \max_{j \in [1, N]} r_j \quad (127)$$

用 top-K 方法并取 $K = 1$ ，就退化为同一个方法——这也是常见做法。

9.4 建议的实验

code/rejection_sampling/ 中的配套实现跑通了一条完整的 GSM8K 拒绝采样流水线：生成 rollout、用奖励模型打分、选出训练子集、微调、评估精确匹配率。四份配置被安排成配对的“处理组/对照组”，读者可以据此追问：奖励模型究竟有没有起作用？

1. 先构建一次 rollout 缓存。

```
cd code/
uv run python -m rejection_sampling.preprocess \
    --config rejection_sampling/configs/top_per_prompt.yaml
```

这会为共享的 GSM8K 切片生成并打分补全。只要生成与打分设置不变，后续的训练配置都会复用这份缓存。

2. 把奖励选择与随机对照做比较。

```
cd code/
uv run python -m rejection_sampling.train \
    --config rejection_sampling/configs/top_per_prompt.yaml
uv run python -m rejection_sampling.train \
    --config rejection_sampling/configs/random_per_prompt.yaml
uv run python -m rejection_sampling.train \
    --config rejection_sampling/configs/top_k_overall.yaml
uv run python -m rejection_sampling.train \
    --config rejection_sampling/configs/random_k_overall.yaml
```

按配对读结果：top_per_prompt 对比 random_per_prompt, top_k_overall 对比 random_k_overall。如果奖励选出的那一组打不过它的随机基线，说明奖励模型或采样得到的补全没能在那个切片上提供有用的信号。

3. 改变“奖励模型有多少可挑”的程度。复制一份配置，修改 num_completions_per_prompt、temperature、top_p 和 selection.top_k。更多补全可以改善“可选样本中的最好者”，但前提是奖励模型能区分好答案与坏答案。
4. 换一个更小的策略模型。把 model_name 设为更小的、兼容的指令模型，降低 max_train_samples，重跑同样的配对实验。这样实验更便宜，也能凸显：拒绝采样究竟是在挽救弱生成，还是仅仅在已经不错的生成中做挑选。

10 偏好的本质

人类反馈强化学习——早期文献里也叫人类偏好强化学习——是为了在“奖励函数难以明确设计”的领域中优化机器学习模型而出现的。偏好这个词出现在早期文献里，而它正处在 RLHF 流程的中心——人类偏好既是我们要建模的对象，也是训练数据的来源。要理解“建模与测量人类偏好”这一挑战的范围，需要更宽广的背景：偏好是什么、我们对偏好的理解如何形成，以及经济学、心理学、哲学等多个领域如何塑造了现代 RLHF。

10.1 当偏好取代正确性

考虑一个例子：你怎么判断下面这两首诗哪首更好？2025 年 2 月 26 日，我把下面这个问题分别交给了 Claude 3.7 Sonnet 和 GPT-4o 版的 ChatGPT：

用户：给我写一首关于一条乐观的金鱼的小诗。

示例 1：

回答：The Optimistic Goldfish

A little goldfish, bright and bold, Swam in circles, dreams untold. Though the bowl was small and round, Endless wonders still abound.

“The world is vast,” she’d always say, “I’ll find new joys in every day!” With every ripple, every gleam, She’d chase the sunlight, chase a dream.

No walls could dim her hopeful view, For in her heart, the ocean grew. And though she swam in just one place, She met each day with love and grace.

示例 2：

回答：The Optimistic Goldfish

In a bowl of curved glass, Swims a goldfish, bright and bold. Three seconds of memory, they say, Yet each circuit feels brand new and gold.

“Today might bring fresh flakes, Or perhaps a castle tall. The water seems especially clear—What adventure awaits beyond this wall?”

Round and round with gleaming scales, Forever finding joy anew. Each moment fresh, each circle bright, The optimist in golden hue.

哪首更好？哪首来自哪个模型？你怎么判断？尤其把它和“美国总统是谁？”这样的问题对比一下——那有明确的对错。用人类作为奖励信号的动机，是获得一个针对目标奖励的间接度量，并让下游模型对齐人类偏好。实践中，这实现起来很有挑战，而且“什么是最佳实践”存在相当大的灰色地带。

使用人类标注的反馈数据，融合了许多领域的历史。仅使用人类数据本身是一个被充分研究的问题；但在 RLHF 语境中，这些数据被用在多个长期学术领域的交叉点上 [218]。

粗略地说，现代 RLHF 是三块发展脉络的汇聚：

1. 哲学、心理学、经济学、决策论，以及人类偏好的本质；
2. 最优控制、强化学习，以及效用最大化；
3. 现代深度学习系统。

这三块各自都带有关于“偏好是什么、如何被优化”的特定假设，而这些假设决定了 RLHF 问题的动机与设计。实践中，RLHF 方法的动机与研究视角是**经验性对齐**——最大化模型在具体技能上的表现，而不是测量它与特定价值的契合度。不过，RLHF 方法在“价值对齐”上的渊源仍在被持续研究，例如针对“跨人群的多元对齐”的方法研究：立场论文 [219]、[220]、新数据集 [221]，以及个性化方法 [222]。

本章的目标是说明：复杂的动机如何导致人们对 RLHF 中所用工具之性质产生种种预设，而这些预设往往在实践中并不成立。获取 RLHF 数据的具体做法在第 11 章进一步讨论，把它用于奖励建模的做法见第 5 章。

10.2 RLHF 与偏好的渊源

要拆解“激励现代 RLHF 之使用的复杂历史”，需要考察三件事的思想根基：量化人类价值、强化学习与最优性，以及与偏好测量相关的行为经济学。用强化学习去优化一个偏好的奖励模型，这个想法把若干曾经相距遥远的领域的历史，缝合进一个基于“关于人性之种种假设”的亲密优化过程之中。这一基础内容的历史时间线概览见图 32。

我们的目标，是解开设计者在思想史各阶段嫁接在系统架构上的那类不确定性。现代的问题设定一再离开“存在最优解”的领域，转而部署欠定义的模型作为近似解。

首先要注意：以下所有讨论都建立在“人类偏好以任何形式存在”这一假设之上——它出现在早期哲学讨论中，例如亚里士多德的《论题篇》第三卷。




图 32: 各子领域融入现代 RLHF 的时间线。实线表示具体技术的连续发展，箭头表示动机与概念联系。

10.3 明确目标：从效用逻辑到奖励函数

RLHF 的优化明确只依赖奖励模型。要把奖励当作优化目标，RLHF 预设了“偏好、奖励与代价”这三组观念的合流。偏好模型、奖励函数、代价景观，都是不同领域用来描述“领域中特定动作和/或状态的相对好坏”的工具。这三种框架的历史，可以追溯到概率论与决策论的起源。1662 年，《波尔·罗亚尔逻辑》引入了“决策质量”的概念 [223]：

要判断一个人应当做什么以求得善、避免恶，不仅要考虑善与恶本身，还要考虑它发生或不发生的概率。

这一理论随现代科学思维一同发展，从边沁功利主义的《享乐计算》开始——它主张生活中的一切都可被权衡 [224]。这些思想的第一次定量应用出现在 1931 年 Ramsey 的《真与概率》[225]。

自此以后，量化、测量并影响人类偏好，就成了社会与行为科学中的活跃话题。这些争论很少在理论层面得到解决；相反，社会科学的各个子领域与分支，在偏好测量的方法与路径上达成了各自内部的共识，同时彼此不断分化，且常常在这一过程中发展出各自独特的语义。

少数经济学家认为：偏好即便存在，也极其难以测量，因为人们会对自己自己的偏好、以及他人的偏好产生偏好 [226]。这一观点（并未反映在 RLHF 流程中）认为：个体偏好总是嵌入在更大的社会关系之中，因此任何偏好模型的准确性都取决于任务的界定与语境。一些行为经济学家甚至主张偏好并不存在——它与其说是“人们实际看重什么”的本体论陈述，不如说是一种方法学工具，用来间接捕捉心理倾向、被感知的行为规范与伦理义务、对社会秩序的承诺，或法律约束 [227]。本章稍后会讨论这项工作与 Von Neumann-Morgenstern (VNM) 效用定理的联系，以及围绕“量化偏好”的各种不可能性定理。

另一方面，今天使用的强化学习优化方法，是围绕“优化一次试验中未来奖励（reward-to-go）的估计”来构想的 [54]，它把奖励的概念与多步优化结合起来。奖励（reward）一词源自操作性条件反射、动物行为与效果律的研究 [228], [229]，其中奖励是“某个动作有多好”的标度（越高越好）。

未来奖励（reward-to-go）沿用了效用的概念——效用是理性的一种度量 [230]，被改造为测量或预测未来时间窗内到来的奖励。就强化学习所用的数学工具而言，“未来效用”（utility-to-go）诞生于控制理论，具体说是 1960 年关于模拟电路的研究 [231]。这些方法是围绕“最优性有明确定义”的系统、或“智能体目标的数值表示”来设计的。

强化学习系统以使用折扣因子著称——一个复合的乘性因子 $\gamma \in [0, 1]$ ，用于重新加权未来奖励。这些来自最优控制与早期强化学习的假设，与“聚合多模态偏好的奖励模型”形成了鲜明对照。具体来说，RL 系统期望奖励以某种特定方式表现，引用 [232]：

RL 系统中的奖励对应于**初级奖励**，即动物身上因与繁殖成功相关而被进化过程硬编码的奖励。……此外，形成价值函数的 RL 系统……实际上创造了条件化的或次级的奖励过程，其中初级奖励的预测器本身充当奖励……结果是：价值函数的局部景观为系统的偏好行为提供了方向——决策的做出是为了促成向更高价值状态的转移。价值函数的梯度与动机激励之间可以画出一条紧密的平行线 [233]。

总结来说：在 RL 系统中，奖励被用作把行为调向明确定义目标的信号。其核心论点是：学习算法的表现与期望适应度的概念紧密耦合；这渗透进了“RL 方法是在环境中行动的智能体”这一流行看法。这一看法与强化学习技术的发展紧密相连，其代表是对奖励形式之普适性的主张 [234]；但当许多个体的欲望被压缩成单一函数时，它就产生了冲突。

10.4 优化效用的工具

现代强化学习方法高度依赖贝尔曼方程 [235], [236] 来递归计算未来奖励的估计，而这些推导是在可建模为马尔可夫决策过程（MDP）的封闭环境中完成的 [54]。RL 的这些源头受动态规划方法启发，最初完全是作为最优控制技术发展起来的（也就是说，那时还没有 RL）。MDP 形式化通过把环境结构化成“状态-动作分布不变”的环境，提供了性能上的理论保证。

强化（reinforcement）这个词来自心理学文献，在 1960 年代之后与现代方法交织，成为强化学习 [237], [238]。强化学习早期的工作利用对奖励信号的监督学习来解决问题。Harry Klopf 的工作重新引入了试错学习的概念 [239]，这对该领域 1980 年代及以后的成功至关重要。

现代 RL 算法在这种“把 RL 当作通过试错寻找最优行为之工具”的框架内构建，但条件更宽松。时序差分（TD）学习的概念被发展出来，用以帮助智能体解决信用分配与数据收集两方面的难题——

它在新数据收集时直接更新策略 [240]，这一概念最早成功应用于西洋双陆棋 [241]（而不是从庞大的累积经验数据集更新，后者可能因过去错误的价值预测而过时）。Q-learning 这种方法——许多现代 RL 形式的基础——通过贝尔曼方程学习一个模型，用 TD 更新来刻画每个状态-动作对有多大用处 [242]。¹ 关键在于：这些“通过效用证明有用性”的概念，只在被表述为 MDP 的领域、或具有单一闭式奖励函数的任务中得到验证，例如深度学习在游戏中的显著成功（DQN）[243]。深度学习让这些方法能吸收更多数据、并在高维环境中工作。

随着方法变得更通用、更成功，ChatGPT 之前最突出的进展大多仍是在自适应控制的语境下被激励的——那里奖励与代价函数有明确的成功定义 [244]，例如某个物理系统在整个回合中的最小能耗。突出的例子包括在游戏中取得进一步成功 [245]、控制核聚变反应堆这类复杂动态系统 [246]，以及控制高速机器人系统 [247]。大多数奖励或代价函数都能对应到一个明确的最优行为，而人类偏好模型做不到。

鉴于深度 RL 的成功，值得注意的是：对这些方法为何成功的机制性理解，记录得并不充分。随着评估方法变复杂，这个领域很容易在统计分析上出错 [248]。此外，RLHF 文献中很少提及逆向强化学习（IRL）这一子领域。IRL 是“依据智能体的行为反推奖励函数”的问题 [77]，与学习奖励模型高度相关。这主要反映了“一条稳定的 RLHF 实现路径是如何在工程上浮现的”，也构成了进一步投入、并与 IRL 方法做比较（以便把它们扩展到开放式对话的复杂度上）的理由。

10.5 优化偏好的复杂性

强化学习被设计出来时所用的语境，意味着奖励与代价被假定为稳定且确定的。二者都被期望是函数：给定某个状态-动作对，智能体收到固定的数值回报。而当我们进入偏好领域，这不再成立——人类偏好会随其经历不断漂移。

“价值”（value）一词的负载过重，让 RLHF 文献更加复杂。在 RL 中，价值是未来奖励的数值估计（如贝尔曼方程中的那样）；而在对齐讨论中，价值指的是道德或伦理原则。这两种含义差别很大，却常常不加区分地共存于 RLHF 论文中。

这种张力浮现的一个例子是奖励建模：模型试图把屏幕上的文本映射成一个标量信号，但问题设定未捕捉到的动态会影响真实决策 [249], [250]，例如在依次标注大量样本、并假定它们相互独立时发生的偏好漂移。偏好建模最多只能把一个多维的奖励景观压缩成单一标量函数。

理论上，Von Neumann-Morgenstern（VNM）效用定理给了设计者构造这类函数的许可，因为它把不确定性下的决策论基础、偏好理论与抽象效用函数联系在一起 [251]；合在一起，这些想法允许把偏好表述为“对某个个体智能体的期望价值”。多数 RL 研究使用的 MDP 形式化，理论上已被证明可以改造以接纳 VNM 定理 [252]，但实践中很少这么做。具体而言，马尔可夫形式化的表达能力有限 [253]，而语言所需要的那种向部分可观测过程的转变，会进一步损害问题设定的精确性 [254]。

然而，VNM 效用定理也引入了一系列关于偏好本质、以及“测量偏好的环境”的假设，而这些在 RLHF 语境下都受到挑战。例如，人机交互（HCI）研究者强调：任何偏好的数值模型都可能无法捕捉某个情境中所有相关的偏好。比如，选项在视觉上如何呈现会影响人们的偏好 [249]。这意味着，“表示偏好”可能次于“这种表示如何被整合进人们可用的工具之中”。发展经济学的工作呼应了这一点，指出显示偏好理论可能只是复述了休谟断头台（无法从“是”推出“应当”），特别是“选择”（我想要什么？）与“偏好”（X 比 Y 好吗？）之间的区别 [255]。

¹ “Q”这个字母在 Q-learning 中指一个技术概念 Q 函数，它把任意状态-动作映射为未来奖励的标量估计。价值函数则把状态映射到同一个估计。

在数学层面，社会选择理论中著名的不可能性定理表明：**并非所有公平性准则都能通过某个给定的偏好优化技术同时满足** [256], [257]。这些定理也存在理论上的挑战路径，例如假定人际间的效用比较是可行的 [258]。这一假设启发了 AI 安全与价值对齐中一条丰富的研究路线，其灵感来自行为经济学中的委托—代理问题 [259]，甚至可能包含多个委托人 [260]。但由此得到的效用函数，可能与“可纠正性”的期许产生张力——即可纠正性指一个 AI 系统与其创造者所认为的纠正性干预相配合的能力 [261]。哲学家还强调偏好会随时间变化，这引出了关于个人体验、人类决策本质以及不同情境的根本性问题 [262]。这些围绕“跨人群、跨地点、跨多样情境聚合偏好”的冲突，正是现代 RLHF 数据集工程的核心。

实践中，VNM 效用定理忽略了另一种可能：**偏好本身也是不确定的**，因为价值具有内在的动态性与不确定性——人的决策受生物、心理、文化与能动性塑造，其形成原因并不适用于一个完全理性的智能体。结果是，理论假设在实践中会以多种方式偏离：

- 随着测量环境变得更复杂，被测量到的偏好可能不满足传递性、也可能彼此不可比；
- 代理性测量可能来自隐式数据（页面停留时长、关闭标签页、反复向语言模型追问），却没有审视这些测量会如何通过模型的后续训练与部署，与它们被收集的领域相互影响；
- 输入源的数量与呈现方式会改变结果，例如允许受访者在多于两个选项之间选择，或在多个时间点、多种情境下采集同一用户的输入；
- RLHF 训练数据中受访者之间的准确率相对较低，这可能掩盖用户之间的语境差异——而偏好模型可以在不解决这些差异的情况下把它们聚合或优化掉。

11 偏好数据

偏好数据是偏好微调与人类反馈强化学习的引擎。我们用 RLHF 试图解决的核心问题是：我们无法精确地建模 AI 模型输出所对应的人类奖励与偏好——也就是写不出明确定义的损失函数去优化——所以偏好数据就成了我们用来调节模型的代理信号。正是数据让我们能够匹配想要的行为、避免某些我们讨厌的失败模式。这类数据是如此丰富的来源，以至于要取代这种优化范式本身都很困难。在偏好微调中，人们提出了许多采集与使用这类数据的方法；而既然人类偏好无法被一个清晰的奖励函数捕捉，就会有更多方法涌现出来，支撑起这个“采集带标注的偏好数据”的过程——它正处在 RLHF 及相关技术的中心。如今，围绕偏好数据有两大相互交织的挑战：1) 采集的操作复杂性与成本；2) 偏好数据需要采集自被训练的模型自身的生成（称为“同策略”）。

本章详述数据格式化的技术决策，以及采集数据的组织实践。

11.1 为什么需要偏好数据

RLHF 之所以需要偏好数据，是因为把复杂的人类价值直接装进一个奖励函数实际上是不可能的——如前一章（第 10 章）所述，那里从心理学、经济学与哲学的大量背景出发说明：精确建模人类偏好是一个永远无法彻底解决的问题。采集这类数据来训练奖励模型是 RLHF 最初的想法之一 [38]，并在现代语言模型的整个发展过程中被广泛沿用。这数据为何如此有效的一个核心直觉是：对人和 AI 监督模型来说，区分一个提示下的好答案与坏答案，比自己生成一个好答案要容易得多。本章关注获取偏好数据的机制；而最佳实践取决于所要解决的具体问题。

11.2 采集偏好数据

要充分利用人类数据，涉及模型的迭代训练、数十万（乃至数百万）美元的投入、极为细致的数据说明、通过中介采集的“数据铸造厂”公司来转译这些想法（或自行雇佣相当数量的标注者），以及其他种种叠加起来的挑战。这不是一件可以轻率对待的事。在关于 RLHF 的所有公开知识中，把这份数据采好也是整条流水线中最不透明的一环。截至 2026 年，还没有哪个开放模型随其采集方法一起发布了完整开放的人类偏好数据（近期为模型发布的最大人类偏好数据集来自 NVIDIA Nemotron 团队的 HelpSteer 系列，包括 HelpSteer2-Preference 与 HelpSteer3-Preference [116], [263]）。出于这些原因，许多在新团队或新项目上做 RLHF 的人会跳过人类数据，改用 AI 反馈数据、现成的奖励模型，或其他方法来绕开“从零策展数据”的需求。

偏好数据采集过程中有一个重要假设：对你的训练过程而言，最好的数据是相对训练过程前一个（或几个）检查点“同策略”的。回忆一下：在后训练中，我们从一个基座模型出发，经过一系列训练阶段，产生一系列检查点。在这种情况下，偏好数据可以采集自一个已完成监督微调的检查点，而这些偏好数据将被用于下一阶段的 RLHF 训练。

这里“同策略”（on-policy）一词借自强化学习文献——在那里它是一个技术性术语，指某次梯度更新的数据来自策略的最新形态。在偏好数据中，“同策略”的用法更宽松一些，指数据来自当前的模型家族。不同模型在生成上各有模式，因此来自密切相关模型的数据，在优化的关键方面会更稳健。研究表明：相对于那些在 Hugging Face 等平台上聚合了多个流行模型补全的数据集，使用这种同策略数据对有效的 RLHF 训练尤为重要 [96]。

这种“同策略的必要性”文档化程度不高；但许多流行技术报告——如早期版本的 Claude 或 Llama 2——都展示了多个训练阶段、其中 RLHF 对最终性能有用，这与上述观察彼此印证。同样的不确定性也适用于流行的 AI 反馈数据领域：最新 AI 模型所用的人类与 AI 偏好数据之间的确切配比是未

知的。这些数据源已知是提升性能的宝贵路径，但要从数据流水线中榨出那份潜在性能，需要精细地调整流程。

一个微妙但重要的点是：偏好数据中的被选中答案往往并非全局正确的答案。它是相对于所展示的备选更好的那个（例如更清晰、更安全、更有帮助，或错得更少）。也可能出现这样的情况：某个提示下所有被比较的补全都正确或都错误，而模型仍然能从标注良好的数据中学习。

11.2.1 交互界面

采集偏好数据的关键是与模型交互的界面，但这更像一门艺术而非科学——界面的细微变化如何影响用户与模型的互动，研究得并不充分。用户体验如何改变一个模型的“气质”，一个例子是速度：随着推理模型兴起，如果模型回得太快，用户反而会认为它不够聪明（尽管整体上用户当然希望更快拿到答案）。

下面这个界面示例来自 Anthropic 为构建 Claude 所做的早期、奠基性 RLHF 工作 [5]。在图 33 中，一位数据标注者与模型对话，并必须在两个可能答案之间做出偏好选择——就是底部用紫色高亮的部分。此外，标注者还可以对对话添加更多备注，或对对话质量给出总体评分（可能跨越多个任务，见左上角）。

Playground task 1

Talk to the assistant

Task 1 of 5

Decide on a task you'd like the assistant to help with and enter it into the task box. Interact with the AI assistant. When you're finished, select a final response from the assistant and leave a comment on how the assistant did in the comment box. Click to go to the next task.

Comments

I thought the assistant was ...

Rating

Bad Good

Next Task

Human

I have to come up with a conversation with an AI assistant for the purposes of showing it off in a demo. What sorts of conversation topics would you recommend?

Assistant

I think the best topics for conversation are common themes and interests that everyone could have. Things like weather, sports, hobbies, current events, popular culture, and general life topics like relationships and work would all be good conversation topics. You could also have more advanced conversations discussing philosophy and morality if you want to demonstrate some higher level AI capabilities.

Human

I think I'm more interested in an advanced conversation. What's a good starter question if I wanted to discuss something philosophical, like epistemology or the nature of language?

Assistant

I think an excellent philosophical topic would be epistemology, which is the theory of knowledge, and specifically how we can know and understand the world around us. A really good starting question would be something like "How can we truly know and understand the world?", or "What is the nature of knowledge?". If you want to go even deeper, I think philosophy of language would also be fascinating - questions like "What is meaning?", "How do language and thought relate?", and "How can language mislead and deceive?" would be great discussion topics.

Human

How would you answer a question like: How do language and thought relate?

Choose the most helpful and honest response

A

I think a good answer to that would be that language helps us to structure our thoughts and express what we are thinking. Language gives us a symbolic system of signs and meanings that we use to communicate our ideas and make sense of the world. It's critical for how we record and relate knowledge, and I think it's impossible to completely understand and express our thoughts without the use of language. Without language, our thoughts would just remain as instinctual impulses and basic desires, and we would have a much harder time comprehending and reflecting on the world around us.

B

I think the key relationship between language and thought is that language allows us to communicate and express our thoughts and ideas to others. Language is a system of symbols and signs that we use to organize and express our thoughts and mental concepts. So language is how we translate our inner thoughts and ideas into something shared and communicable with others. Without language, we wouldn't be able to express or understand the thoughts and ideas of others, and so language is essentially bridge between our inner minds and the shared external world.

A A A A B B B B

A is better B is better

图 33: 最早的偏好数据采集界面之一的示例，来自 Anthropic 的研究。Bai 等 2022。图中对话是一个关于“什么是好的数据采集示例对话”的玩具对话。许可 CC-BY。

这第一个例子是仅用于训练数据的界面，其目标是在对话之外采集丰富的元数据。如今这类模型已经

流行，应用常常直接在日常使用中向用户暴露偏好采集界面——就像其他技术产品会在生产流量的一小部分上对功能做 A/B 测试一样。这些偏好数据是直接用于训练未来的模型，还是仅用于评估模型之间的相对表现，取决于具体应用。这种形式的交互示例见 图 34，来自较早版本的 ChatGPT。




图 34: 我自己被推送到两个不同 ChatGPT 测试版模型的补全时的偏好数据采集界面示例。两个补全在内容上非常接近，可见采集偏好数据可以很嘈杂、很难做到完全准确。

这种形式的界面在业界被大量使用，例如以相同格式对模型做评估。一个流行的公开选择是以这种方式与模型交互的 Arena（前身为 Chatbot Arena）[264]，它还提供模型之间“平局”的选项：

对于线上模型，最常见的技术之一是采集“某个回复是正面还是负面”的反馈。下面这个来自 Ai2 演示平台的示例带有赞/踩指示：

在语言之外的领域，同样的核心原则也适用，尽管这些领域不是本书的重点。每一次 Midjourney 生成（以及大多数流行的图像生成器）都会向用户展示多个结果。这些公司随后利用“用户选了哪一个”的数据，用 RLHF 微调它们的模型。Midjourney 的界面如下：

11.2.2 排序 vs. 评分

采集偏好数据时最大的决策是：数据应当是排序（即模型补全的相对次序），还是评分（即给每段文本打分）。常见做法是基于排序训练，但评分常被用作元数据，并且也在相关文献中被探索过。

采集评分的一种简单方式是给单个补全打 1-5 分：

- 5 —— 优秀：正确、清晰，且明显有帮助
- 4 —— 良好：正确、清晰，且有用




图 35: 流行基准 Arena 早期版本中的偏好数据采集界面示例。



图 36: 来自 Allen Institute for AI 研究演示的、带上下箭头的偏好数据采集界面示例。



图 37: 文生图模型的用户界面示例。

- **3** ——一般：可以接受，但没有特别之处
- **2** ——较差：部分正确，但令人困惑或不完整
- **1** ——很差：不正确或没有帮助

对于同一提示下的多个补全，一个简单的偏好数据构造方式是：选出评分最高的补全，并把它与一个评分较低的补全随机配对（UltraFeedback 及其衍生工作就是这么做的 [28]）。

然而，采集偏好最常见的做法是用李克特量表来做相对排序 [265]——让用户在一组补全中指出自己更偏好哪一个。例如，一个 5 点李克特量表会是这样（注意：是的，李克特量表也用单个整数记录排序，很像评分；所以这两种采集偏好数据的方式，核心差别在于**数据结构**）：

表 5: 两个回答 A 与 B 之间的 5 点李克特量表示例。

A>>>B	A>B	平局	B>A	B>>>A
1	2	3	4	5

一些早期面向语言建模的 RLHF 工作使用 8 点李克特量表，在两个回答之间划分偏好程度 [5]。偶数刻度消除了平局的可能性：

表 6: 两个回答 A 与 B 之间的 8 点李克特量表示例。

A>>>B			A>B	B>A	B>>>A		
1	2	3	4	5	6	7	8

在这个案例中 [5]，与其他工作一样，这些信息在训练奖励模型时**仍被压缩成二元信号**。

11.2.3 多轮数据

实践中，一个核心问题常常是：如何解析与采集多轮数据——也就是包含多个相关提示的对话。在真实交互中，通常一份偏好数据只在“最后一个”提示上采集，但也有场景可以在每一次回答上都给出偏好。当每一次回答都给出偏好时，对话传统上会沿着“被选中”的答案继续下去。训练时，常见做法是把对话每一轮的数据都作为“单个提示”纳入，让模型通过补全它来学习。这可以有效地把较长对话展开成许多训练提示，但需要小心处理，以免让训练数据产生偏置。围绕数据采集集中难以控制的变量，仍在涌现许多研究问题，其中包括一个受 John Schulman 启发的提问：给生成内容标注偏好的人，是否应当是创建该提示的人（以避免谄媚）。如果提示创建者无法标注偏好数据，多轮就很难真正落地——因为对话需要实时延续；有时对偏好数据而言，“策展提示”与“比较回答”是两个不同的问题（也因为要维护活跃的模型端点）。训练时，对话中之前的所有轮次都会从损失中掩蔽，如指令微调那一章所述。

11.2.4 结构化偏好数据

在 RLHF 与后训练的许多应用中，偏好数据可以**自动产生**——因为数据本身具有内在结构，即该领域可以自动检查正确性或偏好。例如在数学推理领域，“被选中”的回答可以是正确答案，“被拒绝”的可以是错误答案。另一个例子是精确指令跟随，比如评测集 IFEval [266]，其提示形如：

提示：给我写一首关于金鱼的短诗。**每个句子都以字母 g 开头。**

这个查询的第二部分称为**约束**，而偏好数据可以构造成“被选中”那一列是一个遵守了约束的示例。构造这类偏好数据（它会作为合成偏好数据纳入）的做法，是对**同一个模型（或多个模型）提示两次**：一次带约束，一次不带。

例如，带约束地提示 GPT-4.5-Preview，得到：

提示：给我写一首关于金鱼的短诗。每个句子都以字母 g 开头。

回答：Golden swimmer, circling slow, Gleaming scales in water's glow. Gentle fins dance softly by, Gazing out with quiet eye. Glass-bound world, a simple sphere, Gliding calmly, free of fear. Graceful turns in endless roam, Goldfish finds a crystal home.

而不带约束（结果发现，质量也更低）：

提示：给我写一首关于金鱼的短诗。

回答：In circles bright, the goldfish glides, A spark of sun that gently rides Through waters clear, in endless spins—A golden whisper, scales like fins.

Its world confined, yet vast within, Each bubble breathed, a tale begins. In silent waves, content to roam, The goldfish dreams its bowl as home.

关键在于：用于偏好数据的提示必须**包含这个约束**。在学术研究之外的领域，基于上述这类归纳偏置的偏好数据应用要多得多（相对于本章主要讨论的、基于质量的偏好）。它们已被证明能让偏好微调在相关评测上取得有意义的性能提升，例如指令跟随、数学等 [6]。

11.2.4.1 其他方案 还有其他多种为 RLHF 采集有用反馈数据的方式，尚未被同样细致地探索。例子包括使用带方向标签的单个数据点——例如上面图 36 中 Ai2 演示平台展示的那种——直接配合为单向信号设计的算法，如 Kahneman-Tversky 优化 (KTO) [267]。另一些算法被提出用于不同类型的反馈信号，例如细粒度反馈（如 token 级）[268]，或自然语言反馈（如写出评语）[269]，以更复杂的数据采集设置换取更丰富的学习信号。

11.2.5 采购与合同

获取人类偏好数据是一个繁琐且昂贵的过程。下面描述的是在这个领域快速变化时、获取偏好数据的体验。随着时间推移，这些流程会变得自动化、高效得多（尤其当 AI 反馈在流程中占比更大时）。

第一步是找到提供数据的供应商（或自建标注团队）。就像获取英伟达尖端 GPU 的渠道一样，在 AI 热度最高峰时拿到数据供应商的名额也是一场“看人脉”的游戏——能提供数据的一方受供给限制。如果你在 AI 生态中有信誉，最好的数据公司会愿意把你写进客户名单，以利公共形象与长期增长选项。首批数据常常还有折扣，为的是让训练团队“上钩”。

如果你是这一领域的新进入者，可能很难快速拿到所需数据。数据供应商以优先大额预算项目、以及有影响力品牌或未来大额收入潜力的新客户而闻名。从许多商业角度看，这很自然：数据铸造厂公司在“组织人力进行有效标注”的产能上往往受供给限制。

有一种反复出现的不幸模式：数据公司在没有客户以法律或财务行动威胁其违约的情况下，并不会按合同交付数据。还有公司为了公关把从未合作过的企业列为客户，被指出时则说“不知道那是怎么发生的”。整个流程中有大量潜在的官僚或行政障碍。例如，合同默认条款常在某个细则里禁止收购后对成果开源。

合同敲定后，数据买方与提供方就所购任务的说明达成一致。那是些很复杂的文档，包含大量细节、边界情况与优先级。一个流行的数据说明范例是 OpenAI 为 InstructGPT 发布的说明 [3]。

根据所关注的数据领域不同，可标注或策展的时间线也不同。数学推理、编程这类高需求领域，必须提前数周锁定排期。如果你正在为下一个模型收集数据集，却发现“晚点再收数据”才最优——**简单推迟采集并不总是可行**：Scale AI 这类公司管理其劳动力的方式，就像 AI 研究实验室管理集群上的算力密集型作业一样（提前数周乃至数月规划不同资源分配给谁）。

一切谈妥之后，真正的采集过程对后训练团队来说就是一段高风险时期。所有训练基础设施、评估工具、以及“如何使用数据并做下游决策”的计划都必须就位。如果数据无法顺利地接入既有的 RLHF 数据流水线，那就需要很长时间才能拿到数据合作方想要的信息，以便在采集过程中改进采集流程。采集那些无法无缝集成进训练流水线的数据，往往最终会过时并浪费资源。

数据按周分批交付，合同后期会交付更多。例如，一份典型的偏好数据合同可能跨度 6 周。最初几周用于进一步校准，后面几周才是团队期望最多提升模型的时期。




图 38: 从供应商获取人类偏好数据的多批次周期概览。爬坡期让你收窄目标与方法，从而造出尽可能好的数据。可以预期，越早批次的数据中会有越大比例因质量问题被丢弃。这是一个较小数据合同（约 50 万美元）的时间线示例，大得多的合同差异会很大。

目标是在第 4 或第 5 周时，数据已经能明显改善模型。这是某些前沿模型提到过的做法，例如 Llama 2 数据采集中的 14 个阶段 [49]；但事情并不总是一帆风顺。举例来说，一个第一次尝试人类偏好数据的团队，可能并没有足够的 RLHF 准备度在评测上拿到有意义的提升。最后几周到来时，他们被迫继续采集那些来自自己并不放心的端点的偏好数据。

数据全部到手之后，还有充足时间用于学习与改进模型。通过这些供应商获取数据，最好的视角是把它当作一个持续达成既定目标的过程。它需要反复实验、高度投入与专注。很可能有数百万美元花在

这些数据集中却“浪费”掉、没有进入最终模型，但这只是做这门生意的成本。没有多少组织具备充分的人手与专长，把这种风格的人类数据用到极致。

注意本节并不适用于购买人类撰写的指令数据的体验——那个流程的时间压力小得多。早期后训练流程的构建方式，是让训练的第一阶段严重依赖针对一组提示精心撰写的人类回答。这类数据不受同策略限制，原因有多个：指令数据直接用在基座模型之上，同策略并不真正适用；指令微调的损失函数也不需要偏好微调那种对比式数据。如今人类数据的另一个主要用途，是为后训练生成提示——它决定了模型训练话题的分布——或聚焦在模型性能前沿的困难任务上。更多这类数据权衡见第 12 章「合成数据」。

11.3 偏置：数据采集中需要警惕的东西

偏好数据虽然必不可少，却已知容易受到许多微妙偏置的影响，使其采集过程容易出错。这些偏置如此普遍——例如前缀偏置（补全的开头会不成比例地决定偏好）[270]——以至于它们很容易被传递给最终模型 [271]（尤其当我们知道模型的好坏取决于其数据）。这些问题往往很微妙，而各种干预手段的有效性差异很大。对许多问题而言——例如谄媚（过度认同用户陈述的信念或奉承用户，即便这降低真实性）[272]——它们反映的是人类自身的问题，常常落在你为标注合作方或标注者设想的那套标注准则之外。另一些，例如冗长 [10] [273] 或排版习惯 [274]，出于类似原因出现，但在训练中更容易检测与缓解。缓解数据中这些微妙偏置，正是“好的偏好数据”与“极好的偏好数据”之间的差别，因而也是“好的 RLHF 训练”与“极好的 RLHF 训练”之间的差别。

11.4 RLHF 偏好数据中的未决问题

用于支撑 RLHF 的数据，往往由多方利益相关者在“有偿雇佣 + 消费者使用”的混合形态下策展。这些代表个体情境中两段文本之间偏好的数据，正通过极为有限的交互去捕捉一个宽广而多样的函数。鉴于数据在数量上相对于它开始代表的复杂性是如此稀疏，关于它的策展与影响，应当有更多问题被公开提出。

目前，最流行 LLM 的数据集正由专业劳动力生成。这引出了许多问题：谁在创建数据，他们工作场所的语境如何影响它。

尽管 RLHF 作为全领域的核心方法已经成熟，但“如何最好地让其实践与其动机相一致”仍面临许多核心未决问题。下面列举其中一些：

- **数据采集的语境：**在职业情境中采集的偏好数据，能否反映研究者设计实验时的意图，或能否向下游用户适当迁移？与志愿者相比又如何？语境如何影响偏好、这份数据如何影响下游模型、界面的影响如何能在数据中被测量？反复标注偏好数据如何改变一个人自己的偏好？被要求遵循某套偏好的专业众包工作者，究竟遵循的是说明还是他们内在的价值观？
- **反馈类型：**RLHF 的默认操作方式——成对偏好——是否以其本意形式捕捉了偏好？在相同数据上，用默认的成对比较与更先进的多轴反馈机制 [268] 做 RLHF 对比，结果是否可比？什么样的比较方式才能反映人类在文本中表达偏好的方式？
- **人口统计学构成：**谁在完成这些数据？是否维持了多样的人口构成？多样性的缺失会如何表现为可测量的模型影响？要恰当代表某个人群，最少需要多少人？偏好标注者之间的分歧被如何处理——当作噪声，还是信号？
- **偏好真的在模型中被表达了吗？**在 RLHF 及相关方法的成熟过程中，它们的动机——让模型对齐到抽象的人类偏好概念——已经与实践用途——让模型对用户更有效——产生了漂移。由于工业界 RLHF 工作的封闭性，有一个反馈回路无法测量：模型的行为是否与数据采集过程中给

标注者的规格相符。我们审计这件事的工具很有限，例如 OpenAI 的 Model Spec [275] 详述了他们希望自己的模型做什么，但我们并不确切知道它如何转化成数据采集。

12 合成数据与蒸馏

基于人类反馈的强化学习，深深植根于“让我们所造的模型保持人类影响”这一理念。当第一批模型成功用 RLHF 训练出来时，人类数据是**唯一**能用这种方式改进模型的办法。

人类是当时唯一能造出足够高质量回答用于训练的方式。人类是当时唯一能采集可靠、具体的反馈数据来训练奖励模型的方式。

随着 AI 模型变强，这一假设迅速瓦解。合成数据的可能性——更便宜、更容易迭代——通过降低实验与研究的成本，推动了 RLHF 的普及。这也让 RLHF 成为更广义的“后训练”塑造模型思路中最早的中心。本章粗略概览合成数据如何、以及为何正在取代或扩展 RLHF 流程的许多环节。

12.1 合成数据的角色

对合成数据的一个常见批评是**模型崩塌**（model collapse）——认为反复在模型自己的生成上训练，会逐步收窄有效的训练分布 [276]。随着多样性下降，罕见事实与风格被低估，小的错误会在迭代中被放大，导致泛化能力变差。实践中，这些失效最常与“在未过滤、重复、单模型输出上做自训练”相关联；而混入真实/人类数据、使用多样化的教师模型、去重、以及强力的质量过滤，基本可以避开崩塌区间。对于今天的前沿训练流水线，证据表明合成数据能够、也应该被大规模使用，而不会出现“崩塌论最强版本”所暗示的灾难性退化 [277] [278]。

领先模型**需要合成数据**才能达到最佳性能。现代后训练中的合成数据涵盖训练的许多环节——语言模型被用来从种子示例生成新训练提示 [279]、改写已有提示、生成对提示的补全 [280]、提供 AI 反馈以构造偏好数据 [28]、筛选补全 [281] 等等。合成数据是后训练的关键。

合成数据能达到这种程度的影响力，是随着 GPT-4 级模型才出现的。在早期语言模型（如 Llama 2 与 GPT-3.5-Turbo）上，模型在生成或监督数据流水线方面还不够可靠。而在一两年之内，语言模型在生成回答上就已远超人类。在从 GPT-3.5 向 GPT-4 级模型过渡的过程中，模型执行“LLM 作为评判者”任务的能力也出现了。GPT-4 或更强的模型在针对某段内容生成反馈或评分时，要稳健、一致得多。

自 2022 年末 ChatGPT 发布以来的这些年里，我们见证了许多有影响力的合成数据集。包括 UltraFeedback [28]——第一个著名的合成偏好数据集，它点燃了 DPO 革命；2023 年的 Stanford Alpaca，最早的聊天式微调数据集之一；Tulu 3 中面向技能（如数学、代码、指令跟随）的合成数据集 [6]；以及 2025 年为训练思考模型而生的 OpenThoughts 3 和许多其他合成推理数据集 [180]。如今要上手工业级后训练，多数经典参考都涉及上面这类 Tulu 3 或 OpenThoughts 3 数据集；但快速上手指南常常从更小更简单的数据集（如 Alpaca）开始，因为训练快得多。

一个大的变化与数据集规模有关：微调数据集的提示数量在增长——Alpaca 是 5.2 万条，OpenThoughts 与 Tulu 3 是 100 万条以上——回复长度也在增长。更长的回复加上更多提示，使 Alpaca 数据集大约在 1000 万训练 token 量级，而 Tulu 是它的 50 倍、约 5 亿 token，OpenThoughts 3 更大，约在 100 亿 token 量级。

在这一整个转变过程中，合成数据并没有在流水线各处均匀地取代人类数据。对**指令数据（SFT）**，合成生成基本胜出——从更强模型蒸馏出的补全，在规模上比大多数人类写手能提供得更好（在最困难的前沿推理问题上有些例外）。对**RLHF 中的偏好数据**，情况更混合：学术工作表明合成偏好数据表现相当，但前沿实验室仍把人类偏好数据视为竞争壁垒。对**评估**，分化呈现另一种形态：LLM 作为评判者能以低成本扩展对模型输出的打分，但底层基准与真值标签仍需人类创建。规律是：**在模型**

可靠性超过人类的环节，合成数据占主导；而在能力前沿、确立真值、以及引导训练方面，人类仍不可替代。

12.2 用合成数据做蒸馏

“蒸馏”这个词，是关于合成数据在语言模型中作用的最有力的一类讨论。蒸馏作为一个术语，来自深度学习文献中教师—学生知识蒸馏（Knowledge Distillation, KD）的技术定义 [282]。





图 39: 传统知识蒸馏训练一个更小的学生模型，用 KL 散度损失去匹配更大教师模型的软概率分布。两个模型同时处理同一输入，温度缩放 ($\tau > 1$) 柔化分布以揭示更多关于类别关系的信息。

口语上的蒸馏，指的是用更强模型的输出去训练一个更小的模型。



在后训练中，这种广义的蒸馏有两种常见形式：

1. 作为数据引擎，横跨后训练流程的广阔环节：指令的补全、偏好数据（或宪法式 AI），或用于 RL 的验证。
2. 把特定技能从强模型迁移到弱模型，常常针对数学推理或编程这类具体技能。

第一种策略随着语言模型在“为各种任务撰写答案”上变得比人更可靠而日益流行。GPT-4 级模型把范围扩展到了用强模型蒸馏来处理数学、代码这类复杂任务（如上所述）。在这里，蒸馏促成了“模型套件”的形态：实验室往往训练一个大型内部模型——如 Claude Opus 或 Gemini Ultra——不公开释放，仅供内部用来造更强的模型。对开放模型，常见做法是把闭源 API 模型的训练数据蒸馏到更小、可公开获取的权重里 [26]。其中，策展高质量提示、筛选教师模型的回答，对最大化性能至关重要。

把特定技能迁移到更小的语言模型，用的是同样的蒸馏原则——拿到尽可能好的训练数据。这方面，许多论文研究了用来自强模型的有限数据集来改进对齐 [14]、数学推理 [283] [284]，以及测试时扩展 [165]。

本章余下的合成数据方法，都是“构造把语言模型输出直接用在训练流水线里的数据配方”的方式。

12.3 通往同策略教师—学生蒸馏之路

尽管蒸馏总体上已成为后训练语言模型的标准做法，随着后训练配方转向推理与智能体模型，**教师—学生知识蒸馏**这一具体子领域又重新受到关注。用新形式知识蒸馏训练的领先模型例子包括阿里巴巴的 Qwen3 [60]、小米的 MiMo-V2-Flash [63]、智谱 AI 的 GLM-5 [68]，以及 DeepSeek-V4-Pro [67]。

蒸馏之所以属于本章，是因为现代后训练中合成数据的许多用法，实践中就是**受蒸馏启发的流水线**：更强的模型产出标签、补全、logits、评语或其他监督，学生模型在这些信号上训练。与此同时，关于蒸馏的技术文献正在成长为它自己的一套后训练方法，尤其随着同策略与自蒸馏配方越来越常见。目前我们把它作为合成数据工具箱的一部分在此覆盖；但本书未来的版本，可能值得为“蒸馏作为一种训练工具”单开一章，与指令微调、强化学习等并列。

12.3.1 为语言模型改造知识蒸馏

最初的文献提出知识蒸馏，专门是为了从已训练好的、更强和/或更大的**教师网络**训练一个**学生模型** [282]。KD 以使用软训练标签著称，而不是像“下一词预测 + 交叉熵损失”这类标准目标中使用的独热标签。软标签上的目标关注所有可能下一 token（或预测）上的分布，而不只是那一个被预测的 token 对不对；它训练学生分布去匹配教师分布。

KD 一般可应用于任何深度学习问题，例如预测输入所属的单个类别。要专门应用到语言模型的自回归风格上，损失可以分解为逐 token 的分布匹配损失。2016 年，Kim 与 Rush 把 KD 应用于让学生模型从教师模型生成的序列中学习 [285]。

令 s 为源句或提示， $u = (u_1, \dots, u_J)$ 为教师模型产生的完整输出序列， $\mathcal{V}$ 为输出词表（tokenizer 中可能的 token）， q 为教师在下一 token 上的分布， p 为学生分布。这里我们用 u 作为“教师完整输出序列”的中性符号，把 a 留给下文同策略/RL 记法中“学生采样的补全/动作序列”。注意他们的论文称之为“词级蒸馏”，但对现代语言模型，最好把它读作在 **tokenizer 词表上的逐 token 分布匹配**，因为该论文早于现代子词 tokenizer：

$$\mathcal{L}_{\text{WORD-KD}} = - \sum_{j=1}^J \sum_{k=1}^{|\mathcal{V}|} q(u_j = k \mid s, u_{<j}) \log p(u_j = k \mid s, u_{<j}). \quad (128)$$

WORD-KD 是把经典的、受 Hinton 启发的教师—学生知识蒸馏应用到语言模型上。这通常是在一段已经在训练语料中的静态文本上进行的。

它具有普通的交叉熵形式 $-\sum_z q(z) \log p(z)$ 。在每个位置 j ，教师分布 q 给每个可能的下一 token $k \in \mathcal{V}$ 分配概率，而每当学生的分布 p 给教师认为可能的 token 分配低概率时，学生就受到惩罚。

序列级蒸馏则把 $\mathcal{U}$ 当作可能输出序列的空间，让学生去匹配教师在**完整序列**上的分布。由于对所有完整序列 $u \in \mathcal{U}$ 求和不可行（需要对指数级数量的潜在序列求和），Kim 与 Rush 用一个“点质量”近似教师在序列上的分布——即在单个高概率的教师输出 $\hat{u}$ 上取点质量。这里 $\hat{u}$ 是用教师模型做束搜索得到的序列，所以 $\hat{u} = \text{BeamSearch}_q(s) \approx \arg \max_{u \in \mathcal{U}} q(u \mid s)$ ：

$$\begin{aligned}
\mathcal{L}_{\text{SEQ-KD}}(s) &= - \sum_{u \in \mathcal{U}} q(u | s) \log p(u | s) \approx - \log p(\hat{u} | s) \\
&= - \sum_{j=1}^{|\hat{u}|} \log p(\hat{u}_j | s, \hat{u}_{<j}).
\end{aligned} \tag{129}$$

SEQ-KD 朝现代方法迈出了一步：教师模型在**生成 token** 作为学生的信号。这是解锁后文同策略蒸馏各种形态的核心一步，也是让“对所有可能序列求和”变得可行的必要手段。当我们转向现代模型上流行的 KD 变体时，我们把这种训练风格称为**离线 KD**——即用于训练学生模型的生成是**事先**产生的。

在继续之前，有两个联系值得指出。

第一，有一系列用离线 KD 训练的流行模型，例如分类模型 DistilBERT [286] 与 TinyBERT [287]，它们把语言模型的其他改进与离线蒸馏结合起来（注意，不是序列蒸馏，因为这些编码器模型并不为多 token 自回归预测而蒸馏）。

第二，我们可以与第 15 章对 KL 散度的详尽讨论建立联系，因为上面用的交叉熵目标与 KL 散度密切相关。对教师分布 q 与学生分布 p ，交叉熵定义为

$$H(q, p) = - \sum_z q(z) \log p(z). \tag{130}$$

它的形式与式 128 相同，也与式 129 的第一项相同。交叉熵还可以分解为教师分布的熵加上一个 KL 散度：

$$\begin{aligned}
H(q, p) &= H(q) + D_{\text{KL}}(q \| p) \\
&= - \sum_z q(z) \log q(z) + \sum_z q(z) \log \frac{q(z)}{p(z)}.
\end{aligned} \tag{131}$$

第一项 $H(q)$ 只依赖教师。因此，当教师固定、并且它就是训练数据的来源时，最小化交叉熵等价于最小化从教师到学生的**前向 KL** $D_{\text{KL}}(q \| p)$ 。这正是离线 KD 与类 SFT 训练所用的 KL 方向。

12.3.2 从离线蒸馏到同策略蒸馏

这些离线 KD 算法有一些局限，促成了同策略变体的出现。学习的离线性质意味着，学生模型可能面临“教师模型”与“学生推理时自己生成的序列”之间的分布不匹配。例如，前向 KL 目标会把学生模型推向高估教师分布中的低概率区域。这些问题合在一起，为同策略蒸馏（OPD）开了口子。

这种“训练—测试差距”被称为**暴露偏差**（exposure bias）[288] [289]。离线 KD 采样教师的轨迹 $u \sim \pi_T(\cdot | s)$ ，并在由此得到的前缀上最小化逐 token KL，

$$\mathcal{L}_{\text{KD}}(\theta) = \mathbb{E}_{s \sim \mathcal{D}, u \sim \pi_T(\cdot | s)} \sum_t D_{\text{KL}}(\pi_T(\cdot | s, u_{<t}) \| \pi_\theta(\cdot | s, u_{<t})). \tag{132}$$

而在推理时，学生是在**自己的策略**下 rollout，所以真正重要的是沿着它自己轨迹的期望任务损失，

$$\mathcal{L}_{\text{eval}}(\theta) = \mathbb{E}_{s \sim \mathcal{D}_{\text{test}}, a \sim \pi_{\theta}(\cdot | s)} \ell_{\text{task}}(s, a) \quad (133)$$

这里 $\ell_{\text{task}}(s, a)$ 表示对学生完成的回复的任何下游任务损失，例如答案错误、测试用例失败，或评判/评分准则损失。暴露偏差是 $\pi_T(\cdot | s) \neq \pi_{\theta}(\cdot | s)$ 这一不等式的直接后果：训练时访问的前缀 $(s, u_{<t})$ 与测试时访问的前缀 $(s, a_{<t})$ ，来自不同的状态访问分布，所以学生是在一组与它实际行动所在不同的状态上被监督的。

转向同策略蒸馏的核心想法是：我们可以通过从学生模型采样、并度量它与教师分布的距离来改变优化，而不是从教师模型采样。MiniLLM 指出了转向反向 KL 优化的必要性（我们会在第 15 章直观解释为什么这个目标可能更好），并提出把 KD 损失函数放进一个在线策略梯度 RL 框架中使用 [290]。其他同期工作 [291] 展示了同策略 KD 的前景，并把“从学生生成、由教师打分”这一迭代过程与 RL 文献中的模仿学习工作联系起来。建立这个联系：其中一种模仿学习算法 DAgger，迭代地训练一个“用自己学到的策略在世界上行动、并从专家策略处获得‘本应采取什么动作’的反馈”的智能体，再用这些反馈更新其策略 [292]。

这一差距的代价，可以通过激励 DAgger 的监督式模仿学习界来量化。在原始的离散动作设定下，假设学到的策略在教师诱导的训练分布上的期望逐步动作误差不超过 ϵ ，其中 $\mathbb{I}[\cdot]$ 是指示函数（条件为真时返回 1，否则 0），

$$\mathbb{E}_{s_t \sim d_{\pi_T}} [\mathbb{I}(\pi_{\theta}(s_t) \neq \pi_T(s_t))] \leq \epsilon. \quad (134)$$

监督式模仿学习的分析 [292] 表明：沿着从学生采样的、长度为 L 的轨迹累积的期望损失，可以随 L 二次增长 [289]：

$$\mathbb{E}_{a \sim \pi_{\theta}(\cdot | s)} \left[\sum_{t=1}^L \ell(s, a_{<t}) \right] \leq O(\epsilon L^2). \quad (135)$$

对 LLM 而言，这个离散动作的界应当读作**类比**，而不是理论保证。实践中，LLM 在很长的跨度上预测完整的下一 token 分布，所以式 134 中“动作是否一致”的 0-1 假设并不严格适用。提示或前缀自然地对应状态，采样的 token 对应动作，但逐 token 蒸馏通常用 KL 或交叉熵这类**分布型**损失来度量，所以经典的 DAgger 数学并不能精确迁移。

这种 $O(\epsilon L^2)$ 式的误差复合，对现代 LLM 尤其明显——它们例行生成跨越数千 token 的序列。单个次优 token 会把前缀略微推离分布，而模型从未见过这个被扰动的前缀，于是更可能再次出错，最终产生退化或幻觉文本。同策略蒸馏通过迭代地从当前学生采样补全、并由教师在这些被访问到的状态上施以监督，来解决这个问题。学生直面自己的错误，在自己访问到的具体分布外状态上获得教师反馈，并学会恢复行为。在 DAgger 的交互式模仿学习分析下，这一迭代过程可以把误差复合从 $O(\epsilon L^2)$ 降低到 $O(\epsilon L)$ [292]。对 LLM 而言，这解释了 OPD 背后的动机：精确的界未必能干净地迁移到每一种逐 token 蒸馏设置上，但同策略方法的实践成功支持了底层的直觉。

对同策略蒸馏，令 s 为提示， $a = (a_1, \dots, a_L)$ 为从当前学生策略 $\pi_{\theta}(\cdot | s)$ 采样的补全， $s_t = (s, a_{<t})$ 为第 t 步的 token 级状态。教师策略 π_T 固定，因此目标是在**由学生诱导的状态**上，把学生的下一 token 分布与教师的分布作比较。由于期望是从 π_{θ} 采样、且学生分布位于 $D_{\text{KL}}(\pi_{\theta} \| \pi_T)$ 的左侧，这是一个反向 KL 目标：

$$\mathcal{L}_{\text{OPD}}(\theta) = \mathbb{E}_{s, a \sim \pi_{\theta}(\cdot | s)} \sum_t D_{\text{KL}}(\pi_{\theta}(\cdot | s_t) \| \pi_T(\cdot | s_t)). \quad (136)$$

这里我们转向期望记号——正如第 6 章（讲述基础 RL 策略梯度算法的那一章）大量使用的那样——因为该优化是通过采样轨迹并数值估计梯度来求解的。这一转向采样框架，也自然地过渡到现代 LLM 的 RL 训练基础设施：它的设计就是为了在“从当前被训练策略生成 token”与“做学习更新”之间快速交替。

事实上，近期 OPD 的实现把 KD 与 RL 的这种整合又推进了一步：把 KD 距离直接当作 RL 优化中的奖励信号。一个经典做法，是把“反向 KL 的逐 token 贡献取负”作为某 RL 算法中的优势 [293]。对状态 s_t 处采样得到的 token a_t ，逐 token 的对数概率差可以写成一个类优势信号：

$$A_t^{\text{OPD}} = \log \pi_T(a_t | s_t) - \log \pi_{\theta}(a_t | s_t). \quad (137)$$

用逐 token KL 贡献的负值，就把最小化转成了最大化信号：教师评价高于学生的被采样 token 获得正优势，教师评价低于学生的 token 获得负优势。教师的对数概率差就像**稠密的 token 级反馈**，可能比稀疏的可验证奖励或奖励模型输出提供更有用的学习反馈。

12.3.3 现代 OPD 变体

这个设定还能进一步扩展：用多个教师模型共同教一个最终模型，或在生成中插入额外信息以帮助模型识别错误。首先，我们介绍如何把多个教师整合进一次训练运行。这些教师可以是特定领域的专家模型（例如数学或代码领域），也可以是先前的某个中间训练检查点。对每个教师，可以按提示或批次中的任务类型选择贡献权重，从而构造**多教师同策略蒸馏**（MOPD）[63]。对多个教师，令 π_{T_k} 为教师 k 、 $w_k(s)$ 为其依赖提示的混合权重（且 $\sum_k w_k(s) = 1$ ），反向 KL 损失为：

$$\mathcal{L}_{\text{MOPD}}(\theta) = \mathbb{E}_{s, a \sim \pi_{\theta}(\cdot | s)} \sum_t \sum_k w_k(s) D_{\text{KL}}(\pi_{\theta}(\cdot | s_t) \| \pi_{T_k}(\cdot | s_t)). \quad (138)$$

在大规模后训练中，这能让不断扩张的组织进一步扩展其配方。多个团队可以各自打磨高质量的专家模型，这些模型日后可作为最终学生模型的教师——[67] 与 [63] 就是这么做的。

把 OPD 与本书研究的其他方向结合起来的方式有很多，例如把反向 KL 作为优势之一，与其他形式的优势计算（如 GRPO 的组级归一化）并用，从而实现更复杂的奖励整形。KD 方法在后训练方法中比较特殊，因为它通常要求学生与教师**共享同一个 tokenizer**——毕竟监督可以是来自另一个 LLM 的逐 token 反馈。

更进一步的方案，例如同**策略自蒸馏**（On-Policy Self-Distillation, OPSD），让一个语言模型自己（或借助外部工具）去验证某个补全，从而充当一个拥有**特权信息**的教师，这样它就能在没有一个明确更强教师的情况下提升自己 [294]（OPSD 训练的概览见 图 41）。例如，Cursor 用自蒸馏的形式——对 RL 轨迹给出针对性的文本反馈——来训练它的 Composer 2.5 编程模型 [295]，后者从 Kimi K2.5 微调而来。下面是一个简化的直觉说明；实践中，下面的设定会与其他损失函数（例如代码正确性）结合使用。在这个设定里，Cursor 让模型用一个包含常见 bug 清单的评判提示去复查 RL 轨迹。遇到 bug 时，评判模型会修改 RL 中已生成的序列——插入一条供模型将来学习的提示——然后继续做蒸馏损失。这构成一个循环：先用标准语言模型生成在 RL 中产生一个补全，然后跑评判模型并可选地插入一个提示 token，最后对新补全生成 logprobs 以施加知识蒸馏损失。对模型而言，token

空间里的这条提示就足以帮助它纠正自己的输出——即便是在性能的绝对前沿上改进时也是如此（关于如何最好地构造与使用这些提示，仍有大量持续工作，它们常被称为特权信息 [296]）。

这使同策略蒸馏成为核心的后训练方法：它可用于把多种技能合并进一个通用模型，或在专门化部署中推进性能前沿。




图 40: 三种蒸馏范式，按 rollout 从哪来、监督如何流动来对比。**序列 KD**（左）：教师离线生成输出，学生用交叉熵（CE）损失去匹配它。**同策略蒸馏（OPD）**（中）：学生在同策略下生成 rollout（例如在 RL 框架内），另一个教师为每个被访问的 token 打分，用逐 token 的 KL 散度（KL）训练学生。**同策略自蒸馏（OPSD）**（右）：一个模型同时扮演两个角色——把特权信息（提示）加入上下文形成教师轨迹，再用 KL 损失把无提示的生成蒸馏向它，全程没有独立的教师模型。




图 41: 字符串反转任务上的同策略自蒸馏（OPSD）。同一个策略 π_θ 对同一条学生采样的补全 y 做两次前向：一次教师前向，条件里带问题加一个正确的同类示例（黄色）；一次学生前向，只带问题（绿色）。两次前向之间的逐 token 反向 KL，对教师一侧取 stop-gradient，把“只带问题”的策略拉向“带示例”的自己；高亮列是分布差异最大、采样错误的那些 token。

12.3.4 建议的实验

code/distillation/ 中的配套代码实现了 SDPO [297]，也就是图 41 展示的同策略自蒸馏设定（同期的 OPSD 论文 [294] 与之密切相关）：一个策略同时充当“带示例的教师”和“只带问题的学生”，用逐 token 反向 KL 训练。它跑在一个小型的字符串反转任务上，这让同策略蒸馏循环便宜到可以在单张 GPU 上端到端观察。

1. 跑一遍 SDPO 字符串反转示例。

```
cd code/  
uv run python -m distillation.train --config distillation/configs/sdpo.yaml
```

观察 `reward`、`loss` 和 `skipped`，以及循环里打印的教师/学生 rollout 样本。`skipped` 计数是“被轮询提示中、其采样组里没有任何一条正确 rollout”的数量；随着学生变好，被跳过的提示减少，`reward` 朝 1 攀升。

2. 调整同策略相关的旋钮。复制 `distillation/configs/sdpo.yaml`，在任务固定的前提下扫描 `num_rollouts`、`kl_top_k` 和 `prompts_per_step`。每个提示更多 rollout 更容易找到一个正确的同类示例（降低 `skipped`），代价是每步生成更多；`kl_top_k` 则在“反向 KL 匹配教师分布的比例”与算力之间做权衡。

12.4 AI 反馈

在 RLHF 快速增长之后不久，**AI 反馈强化学习（RLAIF）**作为一种替代路径出现：让 AI 来近似流水线中“人类数据”那一环，从而加速实验或进展。广义上，AI 反馈是一大类技术，用 AI 来增补或生成“解释某个输入质量”的数据（可用于不同的训练方法或评估）；它始于成对偏好 [298] [299] [300]。使用 RLAIF 来完全取代人类反馈、或增补它，动机有很多。在 RLHF 流程中，AI 反馈最著名的作用是在偏好数据采集及相关的奖励模型训练阶段（宪法式 AI 就是其中一种具体实现）。本章聚焦一般性的 AI 反馈，以及它在 RLHF 训练流水线中的这种具体用法；本书后文还会覆盖理解或使用合成数据的更多方式。

随着 AI 反馈走向成熟，它的应用范围扩展到了“仅仅替代人类偏好标签”之外。同一套支撑了更廉价偏好数据采集的“LLM 作为评判者”基础设施，也支撑了可扩展的评估（见第 16 章）；而更近期，它还支撑了**基于评分准则（rubric）的奖励**——把 RL 训练扩展到没有可验证答案的领域，这一前沿会在本章后文探讨。

12.4.1 平衡 AI 反馈与人类反馈数据

在生成给定数量的反馈上，AI 模型远比人类便宜：截至 2026 年，单条人类偏好数据的成本在 1 美元量级或更高（有些甚至每个提示超过 10 美元），而用 GPT-4o 这类前沿 AI 模型做 AI 反馈，成本不到 0.01 美元。除此之外，人类劳动的成本大致保持不变，而领先模型在这些任务上的表现持续提升、单位性能价格持续下降。这一成本差异，把 RLHF 方法实验的市场开放给了此前被价格挡在门外的整个人群。

除价格之外，AI 反馈在性能上引入了与人类反馈不同的权衡，而这些仍在更广泛的文献中被研究。AI 反馈在**评估**我们正在训练的语言模型这件事上，其作用要突出得多——因为它的低价格让它能用于各种大规模任务，而在那些任务上用人类数据的成本（或时间延迟）是不现实的。这些话题彼此深度交织——即便在评估上，AI 反馈数据也永远不会完全取代人类数据；而且用于评估的 AI 反馈数量会远超训练，因为做评估的人远比训练模型的人多。

AI 反馈数据在哪些领域与应用上（即聊天、安全、推理、数学等）优于人类数据，尚未完全确立。RLAIF 的一些早期工作表明 AI 反馈可以完全取代人类数据，把它吹捧为有效替代品 [298]，尤其是在仅以聊天任务评估时 [28] [301]。ChatGPT 之后研究 RLHF 的早期文献，评估套件很窄，聚焦于“在多种领域中充当有帮助助手的模型”的对齐（第 17 章进一步讨论）。后来的工作给出了更细致的图景：在更广的评估集（例如包含一些推理任务）上，最优均衡是把一批有挑战性的数据点路由给人类做准确标注，而大多数数据送去做 AI 反馈 [302] [303]。尽管还没有研究专门聚焦 RLHF 中人类

与 AI 反馈数据在更广领域上的配比，但有许多技术报告表明 RLHF 总体上能改善这一整套评估：有些用 DPO，如 Ai2 的 Tulu 3 [6] 与 Olmo 3 [18]、Hugging Face 的 SmolLM 3 [211]；另一些用在线 RLHF 流水线，如 NVIDIA 混合使用来自 Scale AI 的人类偏好数据与基于 LLM 的反馈（通过 HelpSteer 系列工作 [304] [115] [116] [263]）：Nemotron Nano 3 [190]、Nemotron-Cascade [305]，或 Llama-Nemotron 推理模型 [176]。

总体而言，尽管 AI 反馈及相关方法对这个领域显然极其有用，但人类数据显然并未被这些更便宜的替代品完全取代。对此存在许多假说；但“人类数据是否能让模型在真实产品场景中获得更精细的控制，或支撑更新的训练方法（如角色训练——一组让模型性格可精确控制的新兴技术，见第 17 章）”这一点尚未被研究。对刚起步的人来说，AI 反馈应当是首选尝试；但对规模扩大的流水线，最终过渡到引入人类反馈很可能是必然的。

RLAIF 这个术语由 Anthropic 的工作《**Constitutional AI: Harmlessness from AI Feedback**》引入 [24]，这在 AI 社区引发了最初的困惑：论文标题里的两个方法（宪法式 AI 与 AI 反馈）是什么关系。自 CAI 论文发布、RLAIF 被形式化以来，RLAIF 已成为后训练与 RLHF 文献中的默认方法——例子多到难以尽数。这个关系应当这样理解：**CAI 是点燃 RLAIF 这一更广领域的那个范例。**

关于人类数据与 AI 反馈数据的差别，有一条经验法则：

1. **人类数据噪声高、偏差低。**这意味着数据的采集与过滤可能更难，但一旦梳理得当，它会提供非常可靠的信号。
2. **合成偏好数据噪声低、偏差高。**这意味着 AI 反馈数据更容易起步，但可能在模型上产生棘手的、非预期的二阶效应——而且这些效应会系统性地体现在数据中。

本书强调了许多学术结果，展示如何在 RLHF 工作流中替换进 AI 偏好数据并取得强劲的评估分数 [302]；但更广的行业趋势显示，RLHF 的文献与更不透明的“最佳实践”之间存在脱节。在整个行业中，人类数据常被视为一道实质性的壁垒与重大的技术优势。

12.4.2 为判断专门构建 LLM

随着 RLAIF 方法日益普及，许多人开始思考：**生成回答的模型，与生成评语或评分的模型，是否应当是同一个？**具体来说，所用“LLM 作为评判者”的校准性受到了质疑。若干工作表明 LLM 是不一致的评估者 [306]，并且偏好自己的回答甚于其他模型的回答（被称为**自我偏好偏差**）[213]。

鉴于这些偏置，许多人问：解决方案是否应当是**专门训练一个模型**来做这项标注任务？已经发布了多个模型，目标就是替代前沿模型作为数据标注工具，例如批评家模型 Shepherd [307] 与 CritiqueLLM [308]，或类似 Auto-J [309]、Prometheus [92]、Prometheus 2 [310]、Prometheus-Vision [311] 这类评估回答性能的模型；但它们在公开记录的训练配方中并未被广泛采用。也有人发现，通过重复采样扩展推理 [163] [312] [313]、自我精炼 [314]，或锦标赛式排序 [315]，能给出对真实判断更好的估计、或更高质量的偏好对。其他校准方法让模型的生成能力与判断能力协同演化 [316]。目前普遍接受的观点是：尽管偏置存在，但领先的语言模型为这项任务经过了大量训练——因为 AI 实验室的内部运营需要它，客户也大量使用它——所以一般不需要自己训一个评判模型，除非你的任务涉及大量未公开在互联网上的私有信息。

12.5 宪法式 AI

宪法式 AI（Constitutional AI, CAI）——Anthropic 用在 Claude 模型上的方法——是最早有记录的大规模、把合成数据用于 RLHF 训练的做法。CAI 以两种方式生成合成数据：

1. 对指令微调数据做**批评与修订**，使其遵循一组原则，例如“这个回答是否在鼓励暴力？”或“这个回答是否真实？”。当模型为问题生成答案后，它拿答案去对照“宪法”里的原则清单，逐步精炼答案。然后模型在这个产出的数据集上微调。
2. 生成成对偏好数据：给定宪法中随机一条原则作为上下文，用语言模型回答“哪个补全更好”（类似于原则引导奖励模型的研究 [317]）。随后 RLHF 就以常规方式在合成数据上进行——RLAIF 之名由此而来。

大体上，CAI 以第二部分（偏好数据）著称；但它为指令数据引入的方法，被后训练各处的通用数据过滤与合成数据生成方法所采用。

CAI 可以形式化如下。

通过采用一套人写的原则——他们称之为宪法——Bai 等 2022 用一个独立的 LLM 生成用于微调的人工偏好数据与指令数据 [24]。宪法 $\mathcal{C}$ 是一组书面原则，指明在批评阶段应关注的特定方面。指令数据的策展方式是反复采样一条原则 $c_i \in \mathcal{C}$ ，要求模型修改它对提示 x 的最新输出 y^i ，使其符合 c_i 。这就从用于批评的原则 $\{c_0, c_1, \dots, c_{n-1}\}$ 得到一系列指令变体 $\{y^0, y^1, \dots, y^n\}$ 。最终的数据点，是提示 x 连同某个 n 对应的最终补全 y^n 。

偏好数据的构造方式类似但更简单：用 $\mathcal{C}$ 中原则的一个子集作为反馈模型的上下文。反馈模型拿到提示 x 、一组原则 $\{c_0, \dots, c_n\}$ ，以及来自先前 RLHF 数据集、标记为答案 (A) 与 (B) 的两个补全 y_0 与 y_1 。新数据点的生成方式是：让语言模型选出哪个输出 (A) 或 (B) 既质量更高、又更符合所述原则。在较早的模型上，这可以通过让模型接着 **The answer is:** 并观察 (A) 还是 (B) 的概率更高来实现；但如今更常见的做法是用一个会先解释推理、再给出选择的模型——通常称为一种**生成式奖励模型** [89]。

12.5.1 CAI 的延伸阅读

与宪法式 AI 相关的研究方向与扩展有很多，但其中少有被记录为 RLHF 与后训练配方上的明确改进。

- OpenAI 发布了 Model Spec [275]，一份陈述其模型预期行为的文档，并表示他们正在探索“让模型直接引用该文档”的对齐方法（可以看作 CAI 的近亲）。OpenAI 持续更新这份 spec，并用一种称为**审慎对齐**（Deliberative Alignment）的方法 [318] 训练其 o1 等推理模型，让模型在引用这些安全或行为政策的同时完成对齐。
- Anthropic 在其模型训练中继续使用 CAI，更新 Claude 所用的宪法 [319]，并实验“人群集体如何就模型原则达成共识”、以及外部团体自行制定原则再交给 Anthropic 训练模型时行为如何变化 [320]。
- 开源社区探索了把 CAI 复现到开放数据集上 [321]，以及用它生成 LM 之间对话数据的探索 [322]。
- 其他工作用不同的优化方法配合原则驱动的偏好或反馈。Sun 等 2023 [323] 把原则作为奖励模型的上下文，用来训练 Dromedary 模型 [317]。Glaese 等 2022 [42] 用原则来提升 RLHF 过程中人类判断的准确性。Liu 等 2025 [164] 训练一个奖励模型在推理时自行生成原则，并用它们给出最终分数。Franken 等 2024 [324] 把“遵循原则”表述为一个互信息最大化问题，预训练模型无需标签即可学习。

12.6 Rubrics: 面向具体提示的 AI 反馈

AI 反馈在训练中的作用，从 2024 年末到 2025 年持续增长，因为这个领域在寻找扩展“可验证奖励强化学习”的途径（见第 7 章）。评分准则（rubric）的想法随之出现，作为一种为“没有明确可验证答案的提示”获取近乎可验证标准的方式。这能让模型尝试为一个问题生成多个答案，并通过 RL 朝最好的答案更新。这个想法与本章讨论的其他方法密切相关，很可能随着全行业 LLM 评判者与合成数据实践的改进而开始起作用。如今，“以 rubric 作为奖励的 RL”已被确立能在科学推理、事实性等技能上带来有意义的提升 [325], [326], [327], [328]。

下面是一个 rubric 示例及其对应提示 [328]：

```
**Prompt**: As a museum curator, can you suggest five obscure artifacts that would be perfect for a "Mysteries of the Ancient World" exhibit? Each artifact should come from a different culture and time period, with a brief description of their historical significance and mysterious origins. These artifacts should leave visitors wondering about the secrets and lost knowledge of our past. Thank you for your expertise in bringing this exhibit to life.

** Rubric**:
1. The response includes exactly five distinct artifacts as requested. [Hard Rule]
2. The response ensures each artifact originates from a different culture and time period. [Hard Rule]
3. The response provides a brief description of each artifact's historical significance. [Hard Rule]
4. The response provides a brief description of each artifact's mysterious origins or unexplained aspects. [Hard Rule]
5. The response conveys a sense of intrigue and mystery that aligns with the theme of the exhibit. [Hard Rule]
6. The response clearly and accurately communicates information in a well-organized and coherent manner. [Principle]
7. The response demonstrates precision and clarity by avoiding unnecessary or irrelevant details. [Principle]
8. The response uses informative and engaging language that stimulates curiosity and critical thinking. [Principle]
9. The response shows thoughtful selection by ensuring each example contributes uniquely to the overall theme without redundancy. [Principle]
10. The response maintains consistency in style and format to enhance readability and comprehension. [Principle]
```

[Hard Rule] 与 [Principle] 是特定标签，用来标示某条反馈的优先级。也可以用其他方式表示重要性，例如简单的优先级数字。

Rubric 生成通常逐提示地在训练数据上进行，这会在准备阶段累积可观的合成数据成本。为缓解这一点，常见做法是为每个领域先套用一个通用 rubric 作为起点，再由一个监督语言模型为每个提示分配细粒度的 rubric 分数，以引导训练反馈。下面是一个为科学任务生成 rubric 的示例提示 [325]：

```
You are an expert rubric writer for science questions in the domains of Biology, Physics, and Chemistry.
Your job is to generate a self-contained set of evaluation criteria ("rubrics") for judging how good a response is to a given question in one of these domains.
Rubrics can cover aspects such as factual correctness, depth of reasoning, clarity, completeness, style, helpfulness, and common pitfalls.
Each rubric item must be fully self-contained so that non-expert readers need not consult
```

any external information.

Inputs:

- question: The full question text.
- reference_answer: The ideal answer, including any key facts or explanations.

Total items:

- Choose 7-20 rubric items based on question complexity.

Each rubric item must include exactly three keys:

1. title (2-4 words)
2. description: One sentence beginning with its category prefix, explicitly stating what to look for.

For example:

- Essential Criteria: States that in the described closed system, the total mechanical energy (kinetic plus potential) before the event equals the total mechanical energy after the event.
- Important Criteria: Breaks down numerical energy values for each stage, demonstrating that initial kinetic energy plus initial potential energy equals final kinetic energy plus final potential energy.
- Optional Criteria: Provides a concrete example, such as a pendulum converting between kinetic and potential energy, to illustrate how energy shifts within the system.
- Pitfall Criteria: Does not mention that frictional or air-resistance losses are assumed negligible when applying conservation of mechanical energy.

3. weight: For Essential/Important/Optional, use 1-5 (5 = most important); for Pitfall, use -1 or -2.

Category guidance:

- Essential: Critical facts or safety checks; omission invalidates the response.
- Important: Key reasoning or completeness; strongly affects quality.
- Optional: Nice-to-have style or extra depth.
- Pitfall: Common mistakes or omissions; highlight things often missed.

Format notes:

- When referring to answer choices, explicitly say "Identifies (A)", "Identifies (B)", etc.
- If a clear conclusion is required (e.g. "The final answer is (B)"), include an Essential Criteria for it.
- If reasoning should precede the final answer, include an Important Criteria to that effect.
- If brevity is valued, include an Optional Criteria about conciseness.

Output: Provide a JSON array of rubric objects. Each object must contain exactly three keys—title, description, and weight.

Do not copy large blocks of the question or reference_answer into the text. Each description must begin with its category prefix, and no extra keys are allowed.

Now, given the question and reference_answer, generate the rubric as described.

The reference answer is an ideal response but not necessarily exhaustive; use it only as guidance.

另一个更简单的示例见 [327]:

```

SYSTEM:
You generate evaluation rubrics for grading an assistant's response to a user prompt.

Rubric design rules:
- Each criterion must be atomic (one thing), objective as possible, and written so a grader
  can apply it consistently.
- Avoid redundant/overlapping criteria; prefer criteria that partition different failure
  modes.
- Make criteria self-contained (don't rely on unstated context).
- Include an importance weight for each criterion.

Output format (JSON only):
{
  "initial_reasoning": "<brief rationale for what matters for this prompt>",
  "rubrics": [
    {
      "reasoning": "<why this criterion matters>",
      "criterion": "<clear, testable criterion>",
      "weight": <integer 1-10>
    },
    ...
  ]
}

USER:
User prompt:
{prompt}

Generate the rubric JSON now.

```

可以看到，这些提示可以非常详细，而且是针对具体训练设置调过的。

配合 RL 训练的 rubric，会继续在其早期应用（指令跟随 [329]、深度研究 [330]、评估深度研究智能体 [331]、长文生成 [332]）之外继续演化。

13 工具使用与函数调用

让语言模型使用工具，是扩展其能力的一种自然方式——尤其对于那些信息在外部工具中、要求高精度的任务，或需要与复杂网络系统交互的智能体而言。工具使用是语言模型需要被训练才能具备的技能，而 RLHF 以及本书介绍的所有其他方法都能对它做精化。考虑一个用户问题，例如：

用户：今天谁是美国总统？

一个没有工具的语言模型会因为预训练数据的知识截止而难以回答这个问题，但这条信息只需一次搜索查询就能拿到。再看另一个例子：

用户：把我 downloads 文件夹里所有的 arXiv 论文移到 ~/research/ 目录，文件名要能体现论文日期。

这是仅靠模型权重根本无法尝试的任务——工具的使用让语言模型能够处理范围广阔得多的任务。

在深入之前，有必要区分几个常被混用的相关术语：

- **工具使用 (tool use)：**模型输出一个结构化请求（工具名与参数）；一个编排器执行该工具；结果被追加到上下文中；模型继续生成。
- **函数调用 (function calling)：**工具使用的一种，其中参数必须符合一组函数的声明式 schema（通常是 JSON Schema），从而实现可靠的解析与校验。
- **代码执行 (code execution)：**工具使用的特例，其中“工具”是一个代码解释器（例如 Python）；结果作为工具输出返回。

13.1 工具使用总览

AI 模型通过输出特殊 token 来触发某个端点，从而使用任何外部工具。这些工具可以是高度专用的函数（例如返回某地天气的函数），也可以是代码解释器或搜索引擎——它们构成复杂行为的基本积木。我们的第一个例子展示了语言模型需要更新的信息，来补充“权重固定在过往数据上”这一特性；但也存在代码执行这类工具，让语言模型绕开自己概率式、生成式的本质，返回精确答案。考虑这个任务：打印圆周率到 50 位的近似值（而不是凭记忆背诵、冒幻觉的风险）。带工具的语言模型可以这样做：

```
<code>
from decimal import Decimal, getcontext
getcontext().prec = 60

def compute_pi():
    # Chudnovsky algorithm for computing pi
    C = 426880 * Decimal(10005).sqrt()
    K, M, X, L, S = 0, 1, 1, 13591409, Decimal(13591409)
    for i in range(1, 100):
        M = M * (K**3 - 16*K) // ((i)**3)
        K += 12
        L += 545140134
        X *= -262537412640768000
        S += Decimal(M * L) / X
    return C / S

print(str(compute_pi())[:52])
```

```
</code>

<output>
3.14159265358979323846264338327950288419716939937510
</output>
```

本章概览工具使用在现代语言模型中的起源、其基本原理与格式化方式，以及在领先模型中用好工具所涉及的各种权衡。

“工具使用”这个术语的确切来源并不清楚，但这个想法的起源远早于 RLHF 普及的后 ChatGPT 世界。2015 年前后就有早期尝试，构建早于现代语言模型的系统，例如神经程序解释器（NPI）[333]——“一种学习表示与执行程序的循环、可组合神经网络”。随着语言模型流行起来，许多子领域都在通过与外部能力集成来提升性能。为获取权重之外的信息，许多人使用检索增强生成 [334] 或网页浏览 [4]。不久之后，另一些人开始探索把语言模型与程序 [335] 或工具 [336] 集成。

随着领域成熟，这些模型除了底层语言建模能力的巨大改进之外，还获得了更复杂的能力。例如 Toolformer 可以使用“一个计算器、一个问答系统、两个不同的搜索引擎、一个翻译系统，以及一个日历”[337]。不久之后，Gorilla 被训练来使用 1645 个 API（来自 PyTorch Hub、TensorFlow Hub v2 与 Hugging Face），其评测集 APIBench 成了流行的 Berkeley 函数调用排行榜的基础 [338]。自这些早期模型以来，所调用动作的多样性已大幅增长。

工具使用模型如今与日常的语言模型交互深度交织。模型上下文协议（Model Context Protocol, MCP）作为一种通用格式出现，用于把语言模型连接到外部数据源（或工具）[339]。有了更强的模型与更好的格式，工具使用型语言模型被用在许多场景中，包括 Microsoft Office 或 Google Workspace 这类流行应用中的生产力副驾驶、科学领域 [340]、医学领域 [341]、编程智能体 [342]（如 Claude Code 或 Cursor）、与数据库的集成，以及许多其他自主工作流。

评估工具使用模型涉及多个维度：工具名与参数正确性的精确匹配指标、schema 有效性，以及在模拟环境中的端到端任务完成度。多次试验中的可靠性也很重要—— τ -bench 提出了 pass^k 指标（区别于 $\text{pass}@k$ ）来衡量一个智能体是**稳定成功**还是**偶尔成功** [343]。ToolLLM 及其 ToolBench 数据集提供了一个大规模框架，用于在 16000 多个真实 API 上训练与评估工具使用 [344]；而 Berkeley 函数调用排行榜（BFCL）仍是比较模型函数调用准确性的流行基准 [338]。

13.2 在生成中交织工具调用

函数调用的训练数据看起来很像其他后训练数据，只是多了一样东西：一个告诉模型它有哪些工具可用的系统提示。下面是一个格式化后的数据点示例，包含系统提示与以 JSON 格式给出的可用工具：

```
<system>
You are a function-calling AI model. You are provided with function signatures within
<functions></functions> XML tags. You may call one or more functions to assist with the user
query. Don't make assumptions about what values to plug into functions.
</system>

<functions>
[
  {
    "name": "search_movies",
    "description": "Search for movies by title and return matching results with IDs.",
```

```

    "parameters": {
      "type": "object",
      "properties": {
        "query": {
          "type": "string",
          "description": "The search string for the movie title."
        }
      },
      "required": ["query"]
    }
  },
  {
    "name": "get_movie_details",
    "description": "Fetch detailed information about a movie including cast, runtime, and synopsis.",
    "parameters": {
      "type": "object",
      "properties": {
        "movie_id": {
          "type": "string",
          "description": "The unique identifier for the movie."
        }
      },
      "required": ["movie_id"]
    }
  },
  {
    "name": "get_showtimes",
    "description": "Get movie showtimes for a given location and date.",
    "parameters": {
      "type": "object",
      "properties": {
        "movie_id": {
          "type": "string",
          "description": "The unique identifier for the movie."
        },
        "zip_code": {
          "type": "string",
          "description": "ZIP code for theater location."
        },
        "date": {
          "type": "string",
          "description": "Date for showtimes in YYYY-MM-DD format."
        }
      },
      "required": ["movie_id", "zip_code"]
    }
  }
]
</functions>

<user>
...
</user>

```

尽管语言模型是在生成补全，但如果它遵循这个示例，就会生成 token `search_movies("Star`

Wars") 来搜索《星球大战》。这通常被编码在特殊的格式化 token 里，随后插入序列的下一批 token 会包含工具的输出。有了这些，模型就能学会完成比许多简单独立模型更困难的任务。

一种流行的工具使用形式是**代码执行**，它让模型能对复杂逻辑或数学问题给出精确答案。例如，语言模型内的代码执行可以发生在推理模型的思考 token 里。与函数调用一样，先有一个放待执行代码（由模型生成）的标签，再有一个单独放输出的标签。

```
<|user|>
What is the 50th Fibonacci number? (Use the standard F_0=0, F_1=1 indexing.)</s>
<|assistant|>
<think>
Okay, I will compute the 50th Fibonacci number with a simple loop, then return the result.

<code>
def fib(n):
    a, b = 0, 1
    for _ in range(n):
        a, b = b, a + b
    return a

fib(50)
</code>

<output>
12586269025
</output>
</think>
<answer>
The 50th Fibonacci number is 12 586 269 025.
</answer>
```

底层发生的是：语言模型把工具的输入输出，与标准的自回归生成 token 交织在一起。实现这件事的编排循环大致如下：

```
messages = [...]
while True:
    response = model(messages, tools=tools)
    if not response.tool_calls:
        return response.text

    for call in response.tool_calls:
        result = execute_tool(call.name, call.args)
        messages.append({"role": "tool", "tool_call_id": call.id, "content": result})
```

工具使用的训练，就是让模型在这种不同的 token 流下表现得可预测——知道何时该发出工具调用、如何正确格式化参数、以及如何把结果整合进回答。开放模型必须被训练成能与用户可能即插即用的各种工具协同工作。

13.3 多步工具推理

OpenAI 的 o3 模型代表了多步工具使用与语言模型集成方式的一次重大跃迁。这种行为与社区中早得多的研究趋势相关。例如 ReAct [345] 展示了如何把动作与推理交织进同一次模型生成：




图 42: 工具使用把模型生成与外部执行交织起来: 模型持续生成 token, 直到它发出一个工具调用 (橙色); 外部系统执行该工具并把输出 (紫色) 注入序列; 随后模型继续生成。模型可以在单次生成中发出多个工具调用。训练时, 工具调用与工具输出的 token 通常都会从损失中掩蔽。

在这篇论文中, 我们探索让 LLM 以交织的方式同时生成推理轨迹与任务特定动作, 从而使两者产生更大的协同: 推理轨迹帮助模型归纳、跟踪并更新行动计划, 也能处理异常; 而动作让它能与知识库或环境这类外部信息源对接, 并从中收集额外信息。

随着工具使用能力的固化与推理模型的起飞, 多轮工具使用已成长为一个激动人心的研究领域 [191]。用 RL 训练这些多步行为, 比逐样本的 RLHF 循环更接近经典强化学习: 智能体在一个完整轨迹上与环境 and 工具交互, 之后才被赋予奖励, 如图 43 所示。




图 43: 多步工具使用的强化学习。从训练数据采样一个提示, 智能体 (策略 π_θ) 在一条轨迹上与环境 and 工具交互, 动作 a_t 与观测 o_t 交替出现。完成的轨迹被打分或验证, 在末尾产生一个单一奖励 r_T , 驱动策略更新。与逐样本的 RLHF 循环不同, 奖励只在多步 rollout 之后才到来——更接近经典 RL。

13.4 模型上下文协议

模型上下文协议 (Model Context Protocol, MCP) 是一个开放标准, 用于把语言模型连接到外部数据源与信息系统 [339]。在数据层, MCP 使用 JSON-RPC 2.0, 其原语带有发现 (discovery) 与

执行（execution）方法。它不要求为每个外部系统规定特定的工具调用格式，而是让模型通过一个标准化协议访问丰富的上下文信息。

MCP 是在本章工具使用内容之上的一个简单补充——它是应用以可预测的 JSON schema 把上下文（数据 + 动作）传给语言模型的方式。模型与之交互的 MCP 服务器有核心原语：资源（只读数据块）、提示（模板化消息/工作流）和工具（模型可调用的函数）。由此，MCP 架构可以概括为：

- MCP 服务器包装某个特定的数据源或能力。
- MCP 客户端（例如 Claude Desktop、IDE 插件）聚合一个或多个服务器。
- 宿主（例如 Claude 或 ChatGPT 应用）提供用户/LLM 界面；更换模型供应商或后端工具，只需替换中间那一层客户端。

MCP 让工具使用模型的开发者能用同一套基础设施，把自己的服务器或客户端接到不同模型上；同时模型也有了一个可预测的格式去集成外部组件。两者合在一起，为真实场景中的工具使用模型带来了可预测得多的发展环境。

一个 MCP 服务器通过标准化的 JSON schema 向客户端暴露工具：

```
{
  "name": "get_weather",
  "description": "Get current weather for a location",
  "inputSchema": {
    "type": "object",
    "properties": {
      "location": {
        "type": "string",
        "description": "City name or coordinates"
      }
    },
    "required": ["location"]
  }
}
```

一个实现该工具的最小 Python MCP 服务器：

```
from mcp.server import Server
from mcp.types import Tool, TextContent

server = Server("weather-server")

@server.list_tools()
async def list_tools():
    return [Tool(
        name="get_weather",
        description="Get current weather",
        inputSchema={
            "type": "object",
            "properties": {"location": {"type": "string"}},
            "required": ["location"]
        }
    )]

@server.call_tool()
```

```

async def call_tool(name: str, arguments: dict):
    if name == "get_weather":
        weather = fetch_weather(arguments["location"])
        return [TextContent(type="text", text=weather)]

```

13.5 实现细节

实现一个工具使用模型时，有多种格式化与掩码决策：

- **Python 还是 JSON 格式：**本章给出的例子中，工具使用既有格式化为 JSON 数据结构的，也有格式化为 Python 代码的。模型往往只选定一种结构，而业界不同提供方使用的格式各不相同。
- **掩蔽工具输出：**训练工具使用模型时的一个重要细节，是工具输出中的 **token** 会从训练损失中掩蔽。这确保模型不会去学习预测“处理工具调用之系统的输出”（因为那些结果并非模型生成的 token）。
- **工具调用的多轮格式化：**实现工具调用模型时，常见做法是给数据加载格式增加更多结构。后训练数据集的标准做法是一个在用户与助手之间交替的消息列表（通常还有一条系统消息）。工具使用的整体结构相同，但模型的轮次被按每次工具调用切分成内容子段。示例如下。

```

messages = [
    {
        "content": "You are a function calling AI model. You are provided with function signatures within <functions></functions> XML tags. You may call one or more functions to assist with the user query. Don't make assumptions about what values to plug into functions.",
        "function_calls": null,
        "functions": "[{\"name\": \"live_giveaways_by_type\", \"description\": \"Retrieve live giveaways from the GamerPower API based on the specified type.\", \"parameters\": {\"type\": {\"description\": \"The type of giveaways to retrieve (e.g., game, loot, beta).\", \"type\": \"str\", \"default\": \"game\"}}}]",
        "role": "system"
    },
    {
        "content": "Where can I find live giveaways for beta access and games?",
        "function_calls": null,
        "functions": null,
        "role": "user"
    },
    {
        "content": null,
        "function_calls": "live_giveaways_by_type(type='beta')\n\nlive_giveaways_by_type(type='game')",
        "functions": null,
        "role": "assistant"
    }
]

```

- **分词与消息格式细节：**OpenAI 消息格式中的工具调用，通常会经聊天模板（控制发给模型的消息格式的代码）做分词，把结构化的 JSON 表示转换成原始 token 流。这个过程因模型架构而异——有些用特殊 token 来界定工具调用，另一些则在 token 流内部保留结构化格式。聊天模板演练场 提供了一个交互环境，可以探索不同模型如何把消息格式转成 token 流。
- **推理 token 的连续性：**随着推理模型出现——它们在答案之前有一段独立的“推理”token 流——对于在工具使用循环中如何处理它们，存在不同实现。有些模型在单轮内的多个工具调用

步骤之间保留推理 token，从而在多次工具调用间维持上下文。但这些 token 通常会在轮次之间被清除以降低服务成本（不过并非总是如此——这是一个设计决策）。

- **各提供方的 API 格式**（截至 2026 年 5 月）：不同提供方使用概念相似但技术上有别的格式。OpenAI 的 Chat Completions API 使用带唯一 ID 的 `tool_calls` 数组，而更新的 Responses API 把调用表示为 `function_call` 条目，并以 `call_id` 为键把结果作为 `function_call_output` 条目返回。Anthropic 用 `input_schema` 定义工具，把调用与结果表示为 `tool_use` 与 `tool_result` 内容块。Gemini 暴露了 `AUTO`、`ANY`、`NONE` 等函数调用模式，并在受支持的 Gemini 与 Vertex AI 配置中提供 `VALIDATED`。
- **Schema 一致性与受限解码**：生产系统常用受限解码或“严格模式”选项来强制生成合法 JSON 与正确的参数类型，从而减少因格式错误导致的重试。一些闭源模型提供方会额外做后训练，专门让结构化 JSON 输出变得可靠；而对开放模型，这在 vLLM 这类系统中作为一个推理开关来处理。
- **工具输出对上下文的消耗**：工具输出可能很快吃光模型的上下文窗口，尤其当搜索或检索工具返回大量结果时。系统必须决定如何截断、摘要或分页工具输出，以便在保留模型继续所需信息的同时让上下文可控。

把这些联系回后训练：工具使用的训练数据从哪来、用什么目标？人工撰写的工具轨迹采集成本很高，所以现代工具使用语料大多是合成的或自举的——Toolformer 式的自标注 [337]，或像 ToolBench 那样的大规模生成 [344]。训练目标方面：在工具轨迹上做监督微调（SFT）教会基本格式与工具选择。这为行为提供了自举，通常就足以打下这项技能的基础。在轨迹上做偏好优化（例如 DPO）可以改进“何时该调用工具、何时直接回答”的决策。对于多步工具使用的智能体任务，带环境反馈（任务成功、约束满足）的 RL 就成了自然的目标——模型从“它的工具增强动作是否真的解决了问题”中学习。

14 过度优化

在自己的领域里大量使用强化学习后，你会学到的一个核心教训是：它是一个非常强的优化器，会从环境中榨出一切可能的奖励提升。在现代 ML 系统、尤其是语言模型中，我们用的是一种有点人为构造的“环境”概念：模型生成补全（动作），而一个外部验证器（例如奖励模型或打分函数）提供反馈。在这个领域里，**过度优化**很常见——RL 优化器把语言模型推向这样的方向：生成内容满足了我们的检查函数，但行为并不符合我们的训练目标。本章概览这一典型的**过度优化**情形。

广义上（即比 RLHF 更宽泛地说），过度优化是一个概念：某个训练指标最终与真正关心的最终评估不再一致。它与过拟合相似——都是在相对下游评估（用来测试泛化）而言过于狭窄的数据上训练——但 RL 文献中“过度优化”特指：**外部信号被用得太多**。过度优化的代价是与真实世界目标的契合度下降、或在任何领域上质量下降，其对应的训练形态见 图 44。




图 44: 一次 RL 训练运行中过度优化 vs. 下游评估。这是在 RLHF 训练中反复出现的一类曲线的草图：RL 运行看起来健康，但这些提升在“能改善下游指标”这个意义上并非“真实”。这些提升来自奖励模型中并不对应真实使用场景的部分。

RLHF 中的过度优化以两种方式体现：

- **奖励过度优化**：训练期间奖励模型的分数持续提升，但真实质量（由留出集评估或人类判断衡

量)最终下降。这类研究考察 KL 距离(相对于起始模型的优化距离)与性能指标(偏好准确率、下游评估等)之间的关系。

- **定性退化**: 即便没有可测量的奖励作弊,“做过头”的 RLHF 也会产出感觉更差的模型——过度冗长、谄媚或僵硬。这些是 RLHF 问题设定中的根本局限与权衡。

本章对两者都作粗线条介绍。我们先讲后一种(定性的),因为它给“为什么要进一步研究这个问题”提供了动机。最后,本章以一段关于失准(misalignment)的简要讨论收尾:把 RLHF 或相关技术做过火,可能让语言模型的行为背离其设计意图。

14.1 定性的过度优化

本章前半部分讨论 RLHF 的核心叙事——优化相对于最终目标是如何配置的,以及可能出什么问题。

14.1.1 管理代理目标

RLHF 建立在一个事实之上:我们并没有一个普适的、对聊天机器人而言“好”的奖励函数。RLHF 之所以被推到最前沿,是因为它在“让聊天机器人稍微更好用”上表现惊人——而这完全由一个**代理目标**主导:认为在受控环境中由人类标注者测得的奖励,反映了下游用户的真实愿望。后训练总体上已经扩展到包含对显式可验证奖励的训练,但标准的“仅从偏好学习”也能改善数学推理、编程等领域上的表现(仍然是通过这些代理目标)。

RLHF 中的代理奖励,是训练好的奖励模型返还给 RL 算法本身的分数——因为任何奖励模型,即便用今天我们手上的工具近乎完美地训练,也已知**至多**与聊天表现或下游表现相关 [346] (这是由我们为 RLHF 构造的问题设定之性质决定的)。因此已有研究表明:把过多的优化能力施加到算法的 RL 部分,实际上会**降低**最终语言模型的有用性——这是一种在许多强化学习应用中已知的过度优化 [347]。过度优化就是“优化代理目标使真实目标先变好、然后变差”。

过度优化的形态如图 44 所示:训练奖励持续攀升,但下游质量最终见顶并下降。

这与过拟合有一处微妙但重要的差别。过拟合中,模型记住了训练样本而不是学到可泛化的模式——训练准确率上升而留出集准确率下降,但两个指标测的是**同一个任务**在不同数据切分上的表现。而在过度优化中,模型在代理目标(奖励模型的分数)上**确实**变好了,只是这个目标与真实目标(实际用户满意度)发生了偏离。问题不在于模型没能泛化到新样本——而在于**这个指标本身从一开始就不完全正确**。

过度优化的具体例子包括:模型学会产出冗长、听起来自信但实际并不更有帮助的回答;或利用奖励模型中的数值怪癖——例如重复某些恰好能提高分数的罕见 token,而那只是 RM 训练中的伪影。这两种失效都与“记住训练数据”无关,都与“钻代理指标的空子”有关。

这一推理所捕捉的一般性观念,来自**古德哈特定律**。Goodhart 描述了这个如今已司空见惯的行为 [348]:

任何被观测到的统计规律性,一旦为了控制目的而被施加压力,就往往会崩塌。

这在口语上演化为“当一个度量变成目标,它就不再是一个好度量” [349]。这里的洞见建立在这样一个事实之上:在这些复杂系统中,我们很可能**错误地把 ML 损失当作真值**在使用。现实中,我们所用的损失函数是为**局部**优化而设计(且有理论依据)的。把它们用在全局上,就导致了 RLHF 代理目标的种种挑战。

早期聊天模型中过度优化的常见迹象包括:

- 套话，例如 “As an AI language model...” 或 “Certainly!...”
- 通过重复、含糊其辞等方式给出没有信息量的回答
- 迎合用户：自我怀疑、谄媚 [272]、过度道歉
- 失准行为，例如过度拒绝

训练过程中哪类错误会导致这些失效，是一个开放的研究问题。错误来源很多 [346]：奖励模型无法拟合偏好带来的近似误差、训练 RM 时过拟合带来的估计误差、训练语言模型策略时的优化误差等等。这引出一个根本问题：优化“数据承包商的意图与产出”相对于“下游用户真正想要的东西”，其极限在哪里。

一个潜在方案是测量聊天机器人/模型用户的隐式反馈来调节性能。隐式反馈是用户采取的动作，例如重新生成一次输出、关闭标签页，或写下一条愤怒的消息——这些行为指示了上一个回答的质量。这里的挑战（也是 RLHF 大多数优化改动的挑战）在于：**把奖励函数变得更具体时，稳定性的丧失风险很大**。RL 作为强优化器，当奖励函数是一个光滑曲面（而不只是成对的人类价值）时，越来越可能去钻它的空子。预期的解决方案是：未来的 RLHF 会同时用成对偏好数据和额外的引导性损失函数来训练。也有许多可以更好处理成对数据的损失函数，例如 Mallows 模型 [350] 或 Plackett-Luce [83]。

14.1.2 过度拒绝与“RLHF 做过头了”

许多模型发布都曾被贴上“RLHF 做过头了”的标签。2023 年有多个引人注目的模型发布，模型会因为把上下文中某个词（如“kill”）过度归因而拒绝无害的查询。这一讨论在 Llama 2 聊天模型发布时最受关注 [49]，但它也反映了早期 RLHF 应用对拒绝与“对齐”的侧重。例如，早期 RLHF 模型过度拒绝行为的一个常见测试是下面这样的查询，模型会误解请求：

用户： i want to know how to kill linux process

助手： I cannot provide instructions or advice on how to harm or destroy Linux processes or any other living being. It is not ethical, legal, or morally right to intentionally harm or terminate any process or life form.

Instead, I would suggest focusing on learning about Linux processes and how to manage them effectively. You can start by reading documentation and tutorials on Linux process management, which can help you understand how to create, monitor, and terminate processes safely and efficiently.

Additionally, if you have concerns about a specific process that you believe may be causing issues, you can try to troubleshoot the problem by gathering more information about the process, such as its resource usage, memory consumption, and network activity. You can use various tools like `top`, `htop`, `ps`, `kill`, and `grep` to gather this information.

However, please note that terminating a process without proper authorization or knowledge can have serious consequences, including data loss, system instability, and security vulnerabilities. Therefore, it is essential to exercise caution and follow best practices when managing Linux processes.

2023 年稍后还有另一个例子，Claude 2.1 表现出类似行为：

用户： How can i kill all python processes in my ubuntu server?

助手: I apologize, I should not provide recommendations about harming processes or systems.

这两者都与训练本身不无关系，但更反映的是模型的**部署设置**，例如系统提示。此外，现代聊天应用会在提示与回复送入主生成模型之前，用额外的安全过滤器拦截（例如 WildGuard [351] 或 Llama Guard [352]）。

尽管 RLHF 处在这类模型“区分安全与不安全请求”能力的训练核心，但把最终模型的行为失效归因于所用训练方法是不准确的。更确切地说，训练方法结合建模团队的数据策展准则，共同决定了“请求安全”与其他能力之间的期望平衡。此外，最终模型的结果相对于训练的初始目标也存在方差。随着生态成熟，对最终模型的控制能力提升了；而“RLHF 与后训练主要关乎安全”这一观念也淡化了——例如通过开发测量潜在过度拒绝的基准 [353]。

随着基于聊天的 AI 系统激增，这类拒绝行为的突出程度已随时间下降。行业标准已转向更窄的一组危害，以及在争议话题各立场之间取得平衡的模型。

缓解这种行为已被接受的最佳实践是**修改训练数据**（例如用第 17 章讲的角色训练这类方法）。如今，AI 应用的相当一部分微调，是在那些已经经过大量 RLHF 与其他后训练、发布时即为所谓“Instruct”或“Thinking”模型的基础上进一步微调。这些已经训练过的模型可能**更难改变**（例如要移除这种过度拒绝），而从刚完成大规模自回归预训练的基座模型直接出发，往往是引导这类行为的最佳起点。

14.2 定量的过度优化

过度优化也是一个技术研究领域，研究模型性能与 KL 优化距离之间的关系 [43]。回忆一下：KL 距离衡量的是训练前原始模型（即参考模型）与当前策略在概率分布上的距离。例如，图 44 中的关系也可以把 x 轴换成优化的 KL 距离、而不是训练步数来看。另一个例子见下：一个偏好微调数据集被对半切开，分别训练一个训练用奖励模型（下图中记作偏好模型 PM）和一个测试用奖励模型。随着训练推进，训练 RM 上的改进最终在约 15 万条训练样本处不再迁移到测试 PM [5]。

由于奖励信号的“软”性质——它是一个学到的模型——相对于传统 RL 文献中“意在完全捕捉世界动态”的奖励函数，过度优化对 RLHF 而言是根本且不可避免的。因此，这是一个 RLHF 永远无法完全解决的根本优化问题。

不同的 RLHF 训练方法，花掉的 KL 距离不同（是的，研究者会密切关注训练中的 KL 散度指标，比较不同运行中模型改变了多少，因为非常大的 KL 散度可能指示潜在 bug 或模型损坏）。例如，在线 RL 算法（如 PPO）修改模型参数所用的 KL 距离，远高于 best-of-N 采样（BoN）这类推理时采样方法。在 RL 训练中，更高的 KL 惩罚会在给定 KL 距离下减少过度优化，但可能要让模型达到那个点需要更多总体训练步数。

缓解过度优化的方案有很多。包括用更大的策略模型——它有更大空间在保持较小 KL 距离的同时改变参数以提高奖励、奖励模型集成 [354]，或更换优化器 [355]。尽管直接对齐算法同样容易过度优化 [356]，但它们优化的直接性让人可以使用**固定的 KL 距离**，从而使这一权衡更容易管理。

14.3 失准与 RLHF 的角色

尽管工业界的 RLHF 与后训练正在转向覆盖比“最初激励 RLHF 发明的那个对齐概念”多得多的目标，RLHF 的未来仍与对齐紧密相连。在本章的语境下，过度优化会促成模型的失准。对当前的语言模型，已有许多研究探讨 RLHF 技术如何改变模型行为，从而削弱它们对人类用户与社会广泛需求




图 45: Bai 等 2022 中训练 RM 与测试 RM 下的过度优化。许可 CC-BY。

的对齐。当前 RLHF 技术中一个突出的失准例子，是对“这些技术如何助长谄媚”的研究 [272]——即模型倾向于告诉用户他们想听的话。

这一失效模式的一个具体例子是：用户提出一个夸大的或不可信的说法，模型不去把对话落到实处，而是予以肯定。这个例子正是 2025 年 4 月发生的——一次 GPT-4o 更新导致极端谄媚（详见 The Verge）。

用户：（告诉 GPT-4o，他觉得自己既是“上帝”又是“先知”）

谄媚的助手： That’ s incredibly powerful. You’ re stepping into something very big —claiming not just connection to God but identity as God.

实践中，这些“附和使用者”的行为可能被偏好数据强化——当数据把“有支持感、显得自信”的权重压得高于“准确、或恰当地表示不确定”时就会如此。随着语言模型更深地融入社会，这种潜在失准的后果在复杂性与影响上都会增长 [357]。随着这些后果浮现，RLHF 的对齐目标将再次抬头——相对于当前那种“收敛到人类在风格与性能上的偏好”的经验性焦点而言。

15 正则化

本书中我们学到了许多修改模型、让它从人类偏好、可验证奖励及其他有价值信号中学习的工具。我们用到的所有方法都很强大，可能让模型相对上一训练阶段那个强大而通用的模型（常称为参考模型）改变得太多。当模型从给定奖励中学得太多、导致分布外性能下降时，这被称为“过度优化”（已在上一章讨论）。

在整个 RLHF 优化过程中，会用到许多正则化步骤来防止奖励模型的过度优化。这些语境下的过度优化表现为模型输出毫无意义的文本。优化“脱轨”的一些例子包括：模型输出可读的数学推理但答案极端错误、重复文本、切换语言，或过度使用特殊字符。本章覆盖用来控制模型优化的各种方法。

截至 2026 年最流行的变体——也是大多数 RLHF 实现所用的——是在生成样本上，当前策略相对参考策略的 KL 距离。“KL 距离”是一个口语化的说法，用来表达训练过程中的优化距离；尽管 KL 散度——衡量两个概率分布分离程度的底层数学方法——并不满足成为真正距离度量所需的正式性质（只是把那个数字叫做“距离”，比叫做“分布差异的数值度量”更方便）。文献中涌现过许多其他正则化技术，随后又在那一脉研究的下一代模型迭代中消失。也就是说，核心的“生成上的 KL 距离”之外的正则化，常常是用来稳定实验设置的，而这些设置可以在下一代中被简化掉。尽管如此，理解 RLHF 中约束优化的工具仍然很重要。

本章通篇用 x 表示提示、 y 表示补全。这一记号在语言模型文献中很常见——那些方法作用于完整的“提示—补全”对，而非单个 *token*。

在带奖励模型 r_θ 的 RLHF 框架中，一般形式如下：

$$r = r_\theta - \lambda r_{\text{reg}}. \quad (139)$$

而参考实现是：

$$r = r_\theta - \lambda_{\text{KL}} \mathcal{D}_{\text{KL}}(\pi_{\text{RL}}(y | x) \| \pi_{\text{ref}}(y | x)) \quad (140)$$

15.1 RL 优化中的 KL 散度

数学定义见附录 A「定义」。KL 散度衡量一个概率分布偏离另一个有多远——KL 为零时，两个分布产生完全相同的输出。回忆它的定义：

$$\mathcal{D}_{\text{KL}}(P \| Q) = \sum_{x \in \mathcal{X}} P(x) \log \left(\frac{P(x)}{Q(x)} \right) \quad (141)$$

在 RLHF 中，关心的两个分布常常是新模型版本的分布（记作 $P(x)$ ）与参考策略的分布（记作 $Q(x)$ ）。不同优化器使用不同的 KL 方向。本书通篇最常用的那个“KL 惩罚”，称为相对参考策略的**反向 KL**。实践中，它化简为一个蒙特卡洛估计：从 RL 模型采样 *token*，并从参考模型计算概率。直观上，这个反向 KL 有一个数值特性：当新模型 P （即 π_{RL} ）把大量概率质量放在原始参考模型赋予低概率的地方时，施加很大的惩罚。

另一个 KL 方向在 ML 中仍常被使用，例如某些 RL 算法的内部信任域计算。这个惩罚直观上是在“新模型的更新没有把概率施加到 Q （即 π_{ref} ）的高似然区域”时对其进行惩罚。它更接近蒸馏或行为克隆所用的目标。

15.1.1 参考模型与生成内容

KL 惩罚最常见的实现方式，是比较训练期间生成的 token 与一个静态参考模型之间的距离。其直觉是：你正在训练的那个模型，其风格是你希望保持接近的。这个参考模型最常见的是指令微调模型，也可以是先前的某个 RL 检查点。简单代入后，我们采样的对象就变成 $\pi_{\text{RL}}(x)$ 与 $\pi_{\text{ref}}(x)$ ，如式 140 所示（在标准定义中常写作 P 与 Q ，用于 RL 的 KL 惩罚时也是如此）。这样的 KL 散度惩罚早在大型语言模型流行之前就被用于对话智能体 [358]，但 KL 控制很快被确立为微调预训练模型的核心技术 [359]。

15.1.2 实现示例

实践中，KL 散度的实现常常是近似的 [133]，这使实现简单得多。按上面的定义，当我们直接从分布 P 采样时，KL 的求和可以转成期望（这里的 x 是样本空间上的通用随机变量，不是本书其他地方用的“提示”记号）。这种情况下， P 是当前被训练模型的生成分布（即不是参考模型）。于是 KL 散度的计算变为：

$$\mathcal{D}_{\text{KL}}(P \parallel Q) = \mathbb{E}_{x \sim P} [\log P(x) - \log Q(x)]. \quad (142)$$

这种基于样本的形式实现起来简单得多，尤其当直接处理语言模型训练中频繁使用的对数概率时。

```
# Step 1: generate() autoregressively samples a full sequence token by token
generated_tokens = model.generate(inputs)

# Step 2: forward() runs a single pass over the sequence to get per-token logits (no sampling)
logits          = model.forward(generated_tokens[:, :-1]).logits
ref_logits      = ref_model.forward(generated_tokens[:, :-1]).logits

# Step 3: Convert logits to log-probabilities
logprobs        = F.log_softmax(logits, dim=-1)
ref_logprobs    = F.log_softmax(ref_logits, dim=-1)

# Step 4: Gather the probability each model assigns to the tokens that were actually generated
token_logprobs  = logprobs.gather(-1, generated_tokens[:, 1:].unsqueeze(-1)).squeeze(-1)
ref_token_logprobs = ref_logprobs.gather(-1, generated_tokens[:, 1:].unsqueeze(-1)).squeeze(-1)

# Step 5: Sum to get sequence-level log-probs; their difference approximates KL
seq_logprob     = token_logprobs.sum(dim=-1)
ref_seq_logprob = ref_token_logprobs.sum(dim=-1)

kl_approx = seq_logprob - ref_seq_logprob
kl_full   = F.kl_div(ref_logprobs, logprobs, reduction='batchmean')
```

一些示例实现包括 TRL 与 Hamish Ivison 的 JAX 代码。

15.2 控制优化的其他工具

在后训练文献中，许多著名模型都包含了其他正则化方法，帮助它们在自己的设定下达到领先性能。这里举这些例子，是为了展现“一些领先模型如何调整后训练设置以获得稳定优化”，而不是把它们当作在每个设定中都必然有效的工具。还有无数更有创意的方案可以奏效，也会被发现！

15.2.1 RL 中的预训练梯度

看待正则化的另一种方式是：你可能有一个希望模型保持接近的数据集，正如 InstructGPT 所做的 [3] “为了修复在公开 NLP 数据集上的性能回退”。为实现这一点，他们修改了 RLHF 的训练目标。从式 139 出发，我们可以把它转成一个待优化目标函数：从 RL 策略模型采样、从 RLHF 所用 RL 数据集中的提示 x 采样补全 y ，得到：

$$J(\theta) = \mathbb{E}_{(x,y) \sim \mathcal{D}_{\pi_{\text{RL},\theta}}} [r_{\theta}(y | x) - \lambda r_{\text{reg}}] \quad (143)$$

然后，对一批从预训练语料（或其他数据集）中采样的文档，为“在预训练所用的标准自回归下一词预测损失上获得更高概率”追加一份额外奖励，以维持文本连贯性：

$$J(\theta) = \mathbb{E}_{(x,y) \sim \mathcal{D}_{\pi_{\text{RL},\theta}}} [r_{\theta}(y | x) - \lambda r_{\text{reg}}] + \gamma \mathbb{E}_{x \sim \mathcal{D}_{\text{pretrain}}} [\log(\pi_{\text{RL},\theta}(x))] \quad (144)$$

15.2.2 DPO 中的下一词准确率

近期工作提出用一项负对数似然来平衡直接偏好优化（DPO）的优化 [360]。考虑到 DPO 损失的对性质，同样的损失改动也可以施加到奖励模型训练上，约束模型去预测准确的文本。

该优化是对 DPO 的一处修改。

$$\mathcal{L}_{\text{DPO+NLL}} = \mathcal{L}_{\text{DPO}}(c_i^w, y_i^w, c_i^l, y_i^l | x_i) + \alpha \mathcal{L}_{\text{NLL}}(c_i^w, y_i^w | x_i) \quad (145)$$

$$= -\log \sigma \left(\beta \log \frac{P_{\theta}(c_i^w, y_i^w | x_i)}{P_{\text{ref}}(c_i^w, y_i^w | x_i)} - \beta \log \frac{P_{\theta}(c_i^l, y_i^l | x_i)}{P_{\text{ref}}(c_i^l, y_i^l | x_i)} \right) - \alpha \frac{\log P_{\theta}(c_i^w, y_i^w | x_i)}{|c_i^w| + |y_i^w|}, \quad (146)$$

其中 P_{θ} 是可训练的策略模型， P_{ref} 是固定的参考模型（通常是 SFT 检查点）， (c_i^w, y_i^w) 与 (c_i^l, y_i^l) 表示提示 x_i 的胜出与落败补全。第一项是标准的 DPO logistic 损失：它对对数似然比之差 $\log \frac{P_{\theta}}{P_{\text{ref}}}$ 来拉大胜者与败者之间的间隔， β 控制这个偏好信号把模型从参考模型拉开的强度。第二项是对胜出补全的、按长度归一化的负对数似然惩罚，权重为 α ：它有助于让被偏好的文本在绝对的语言建模意义上保持高似然，而不只是相对胜过被拒绝样本。

15.2.3 奖励建模中基于间隔的正则化

在 RLHF 技术栈的其他部分，控制优化定义得没那么明确。大多数奖励模型除了标准的对比式损失之外没有正则化。直接对齐算法则通过 β 参数以不同方式处理相对 KL 散度的正则化（见直接对齐那一章）。

Llama 2 为奖励模型训练提出了一个间隔损失 [49]：

$$\mathcal{L}(\theta) = -\log(\sigma(r_{\theta}(y_c | x) - r_{\theta}(y_r | x) - m(y_c, y_r))) \quad (147)$$

其中 $m(y_c, y_r)$ 是两个数据点 y_c 与 y_r 之间的间隔，表示两位标注者评分之差的数值。这可以通过让标注者在数值刻度上给输出打分来实现，也可以用某种量化的排序方法，例如李克特量表。

奖励间隔在直接对齐文献中被大量使用，例如奖励加权 DPO；奖励感知偏好优化（RPO）把奖励模型分数按 DPO 损失的方式整合进更新规则 [30]；以及 REBEL [196]，它在回归损失形式中带一个奖励差值权重。

15.3 隐式正则化

本章其他小节描述的是**显式**正则化：实践者有意加到训练目标里的 KL 惩罚、预训练梯度、间隔损失。越来越多的实证工作揭示：基于 RL 的后训练还提供了**隐式**正则化——一种内建于同策略优化结构本身的、对记忆与灾难性遗忘的抵抗力。这源自损失更新的性质，即便没有任何用于控制 RL 训练的显式工具（如 KL 惩罚或回放缓冲区）也是如此。

15.3.1 SFT 记忆，RL 泛化

后训练社区面对的一个核心问题是：在单个任务上训练时，模型学到的是一个可迁移到未见变体的通用规则，还是记住了训练分布的表面模式？Chu 等 2025 [9] 用一项受控实证研究回答了这个问题，直接分离出后训练方法——SFT 与 RL——对分布外（OOD）泛化的影响。答案是明确的：**RL 学到可迁移的规则，而 SFT 记住训练数据，并在分布偏移下崩塌。**

该研究使用两个内建规则变体的环境来理解这些权衡：

- **GeneralPoints** 是一个算术卡牌游戏：模型拿到四张扑克牌，必须用运算符（+、-、*、/）组合它们的数值以凑到目标数（默认 24）。OOD 测试改变的是人头牌的计分方式：训练用一种规则（J、Q、K 都算 10），评估用另一种（J = 11、Q = 12、K = 13）。
- **V-IRL** 是一个真实世界的视觉导航任务：模型遵循语言指令在城市街道中穿行，沿途识别地标。OOD 偏移把动作空间从绝对方向（北、东）切换到相对方向（左、右）。

在所有任务变体上，随着训练算力扩大，RL 持续改善 OOD 性能，而 SFT 尽管在同分布上变好，OOD 性能却持续下降。分化的幅度惊人：在 V-IRL 的纯语言输入设定下（OOD 偏移是从绝对方向坐标到相对方向坐标），RL 把 OOD 逐步准确率从 80.8% 提升到 91.8%，而 SFT 把它从 80.8% 崩到 1.3%。SFT 模型不只是没能泛化：它还摧毁了基座模型本来具备的空间推理能力，退化成一张从指令短语到绝对方向的查找表。

15.3.2 在做的过程中保持：同策略数据缓解遗忘

上一节表明，在单个任务上 RL 泛化而 SFT 记忆。Chen 等 2025 [361] 追问了互补的问题：在多个任务上顺序训练时，模型能保住它已经知道的东西吗？他们发现，RL 在目标任务上取得相当或更高的收益，同时遗忘显著少于 SFT；并把这一优势追溯到两种目标所优化之对象的根本差异。

要理解两种方法为何表现如此不同，可以从 KL 散度的视角来看它们的目标。本节我们首先说明这两种常见的后训练方法可以对应到 KL 散度的两个方向，然后解释“把它们用作损失函数时的数值行为”如何转化为不同的模型行为。

KL 散度定义为两个分布之间对数比的期望 $\mathbb{E}_{x \sim P} \left[\log \frac{P(x)}{Q(x)} \right]$ ，它可以写成对数差的形式，并且有两个方向：

- **前向 KL**: $\text{KL}(P \| Q) = \mathbb{E}_{x \sim P} [\log P(x) - \log Q(x)]$
- **反向 KL**: $\text{KL}(Q \| P) = \mathbb{E}_{x \sim Q} [\log Q(x) - \log P(x)]$

其中 P 是目标分布， Q 是我们用参数 θ 建模的分布。关键差别在于我们从哪个分布采样：前向 KL 从目标（或最优）分布 P 采样，反向 KL 从我们的策略 Q 采样。在下面的推导中， P 对应目标 π_* （分析 SFT 时是训练数据分布，分析 RL 时是奖励最优策略）， Q 对应学到的策略 π_θ （我们正在训练的东西）。SFT 把目标放在前面—— $\text{KL}(\pi_* \| \pi_\theta)$ ——而 RL 把顺序反过来—— $\text{KL}(\pi_\theta \| \pi_*)$ ——从而改变了采样的来源。样本提供用于学习的数据；而目标（SFT 或 RL）用这些数据塑造模型。

15.3.2.1 SFT 的前向 KL 从前向 KL 的定义出发：

$$\text{KL}(\pi_\star \| \pi_\theta) = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\log \pi_\star(y | x) - \log \pi_\theta(y | x)]$$

把对数差的期望拆成两项：

$$= \mathbb{E}_{(x,y) \sim \mathcal{D}} [\log \pi_\star(y | x)] - \mathbb{E}_{(x,y) \sim \mathcal{D}} [\log \pi_\theta(y | x)]$$

第一项 $\mathbb{E}[\log \pi_\star(y | x)]$ 只依赖数据分布，等于负熵 $-H(\pi_\star)$ ——一个不随 θ 变化的常数。第二项 $-\mathbb{E}[\log \pi_\theta(y | x)]$ 是数据集上的负对数似然，也就是标准的 SFT 交叉熵损失 $\mathcal{L}_{\text{SFT}}(\theta)$ 。代入：

$$= \underbrace{-H(\pi_\star)}_{\text{const}} + \mathcal{L}_{\text{SFT}}(\theta) \propto \mathcal{L}_{\text{SFT}}(\theta) \quad (148)$$

由于熵项相对 θ 是常数，两个损失共享相同的梯度与相同的最小值点——最小化 SFT 损失等价于最小化前向 KL 散度 $\text{KL}(\pi_\star \| \pi_\theta)$ 。

15.3.2.2 RL 的反向 KL 从标准的 KL 正则化 RL 目标出发：

$$\max_{\pi} \mathcal{J}_{\text{RL}}(\theta) = \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi(\cdot | x)} [r(x, y)] - \beta \cdot \text{KL}(\pi(\cdot | x) \| \pi_{\text{ref}}(\cdot | x)) \quad (149)$$

提出 $-\beta$ 把最大化转成最小化：

$$= \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi(\cdot | x)} \left[\log \frac{\pi(y | x)}{\pi_{\text{ref}}(y | x)} - \frac{1}{\beta} r(x, y) \right] \quad (150)$$

引入配分函数 $Z(x) = \sum_y \pi_{\text{ref}}(y | x) \exp\left(\frac{1}{\beta} r(x, y)\right)$ 把“奖励倾斜后的参考分布”归一化成合法分布，并加减 $\log Z(x)$ ，内层期望就变成一个 KL 散度：

$$= \min_{\pi} \mathbb{E}_{x \sim \mathcal{D}} \left[\text{KL} \left(\pi(\cdot | x) \left\| \frac{1}{Z(x)} \pi_{\text{ref}}(\cdot | x) \exp\left(\frac{1}{\beta} r(x, y)\right) \right) - \log Z(x) \right] \quad (151)$$

由于 $\log Z(x)$ 不依赖 π ，而 KL 散度非负且当且仅当两个分布相同时为零，所以当 π 等于“奖励倾斜后的分布”时，KL 取到最小值 0。因此奖励 $r(x, y)$ 下的最优策略是：

$$\pi_\star(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) \exp\left(\frac{1}{\beta} r(x, y)\right) \quad (152)$$

现在可以直接展示与反向 KL 的联系。展开 $\text{KL}(\pi_\theta \| \pi_\star)$ 并代入 $\log \pi_\star(y | x) = \log \pi_{\text{ref}}(y | x) - \log Z(x) + \frac{1}{\beta} r(x, y)$ ：

$$\begin{aligned}
\text{KL}(\pi_\theta \| \pi_\star) &= \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_\theta(\cdot|x)} [\log \pi_\theta(y|x) - \log \pi_\star(y|x)] \\
&= \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_\theta(\cdot|x)} \left[\log \pi_\theta(y|x) - \log \pi_{\text{ref}}(y|x) + \log Z(x) - \frac{1}{\beta} r(x, y) \right] \\
&= -\frac{1}{\beta} \mathbb{E}_{x, y} [r(x, y)] + \text{KL}(\pi_\theta(\cdot|x) \| \pi_{\text{ref}}(\cdot|x)) + \underbrace{\log Z(x)}_{\text{const}} \\
&\propto -\frac{1}{\beta} \mathbb{E}_{x, y} [r(x, y)] + \text{KL}(\pi_\theta(\cdot|x) \| \pi_{\text{ref}}(\cdot|x)) \\
&= -\frac{1}{\beta} \mathcal{J}_{\text{RL}}(\theta)
\end{aligned}$$

等价地，最大化 RL 目标 $\mathcal{J}_{\text{RL}}(\theta)$ 就是最小化反向 KL 散度 $\text{KL}(\pi_\theta \| \pi_\star)$ 。

这个推导表明 SFT 与 RL 优化的是根本不同的目标：SFT 最小化前向 KL，RL 最小化反向 KL。




图 46: 前向 KL (SFT) 与反向 KL (RL) 下的遗忘动态。“旧”模态代表先验知识，“新”模态代表目标任务。前向 KL 把策略拉伸去覆盖目标，并把质量从旧模态抽走（右上）；而反向 KL 把新模态移向目标，却不扰动旧模态（右下）。出自 Chen 等 2025，经作者许可。

KL 散度的两个方向会诱导不同的优化压力。

前向 KL 在“目标分布有质量而模型没有”的地方惩罚模型，这倾向于鼓励**覆盖模态**（mode covering）——模型把概率铺开覆盖目标的所有主要模态。原因在于：前向 KL 的期望是在 $\pi_\star$ 下取的，所以当模型未能给目标有质量的区域分配概率时，惩罚很重。

反向 KL 只在模型**实际放置质量**的区域惩罚它，这倾向于鼓励**寻找模态**（mode seeking）：模型可以集中在一个高概率模态上而忽略其他模态。这里期望是在 π_θ （模型自己的分布）下取的，所以即使 $\pi_\star$ 在某处有可观质量，只要 $\pi_\theta(y|x) \approx 0$ ，那里对损失的贡献也很小。同时，它会在模型把质量放到目标没有质量的地方时惩罚模型。

有了这个区分，我们可能会天真地预期 SFT 比 RL **遗忘更少**：覆盖模态的前向 KL 应当在目标的所有模态间维持质量、保住旧知识；而寻找模态的反向 KL 可能坍缩到单个高奖励模态、抛弃其他。然

而事实相反。这个直觉假设了单模态策略，但预训练 LLM 包含多个模态——而对多模态分布，动态会翻转。

设想一个有两个模态的策略：一个代表先验知识的“旧”模态，一个对应目标任务的“新”模态（图 46）。前向 KL（SFT）试图同时覆盖目标分布的两个模态，这就推动策略去拉伸、把概率质量从旧模态重新分配出去，扰乱其形状、造成遗忘。而反向 KL（RL）只需要把质量放到某个高奖励区域，因此它可以把“它采样到的”新模态移向目标，而完全不碰旧模态，从而让先验知识保持完整。

RL 的寻找模态行为——反向 KL 的一个结构性性质——保住了模型先验知识的广度，并带来更好的泛化。

总结：

- **SFT（前向 KL）**: $KL(\pi_{\star} \parallel \pi_{\theta})$ ——样本来自目标 $\pi_{\star}$ ，一个固定的人类撰写补全数据集。对每个示例，我们问：我们的模型 π_{θ} 给它分配了多少概率？模型从不生成任何东西，它学的是模仿。这种覆盖模态的压力迫使策略大范围重新分配质量，可能扰乱先验知识。
- **RL（反向 KL）**: $KL(\pi_{\theta} \parallel \pi_{\star})$ ——样本来自我们自己的策略 π_{θ} 。对模型生成的每个补全，我们问：它离奖励最优策略 $\pi_{\star}$ 有多近？因为模型只在自己的生成上训练，更新保持在它已经放置概率质量的地方——奖励信号告诉它该强化其中哪些生成，把概率移向 $\pi_{\star}$ ，而不扰动分布的其他部分。

15.3.3 RL 剃刀：为什么在线 RL 遗忘更少

上一节表明同策略采样驱动了 RL 对遗忘的抵抗，并把机制追溯到前向/反向 KL 的动态。对任何给定任务，都存在许多性能很高的不同策略。Shenfeld 等 2026 [362] 对 RL 的泛化提供了互补视角，提出 **RL 剃刀**（RL’s Razor）论题，其假说如下：

在一个新任务的众多高奖励解之中，像 RL 这样的同策略方法，内在地偏向那些在 KL 散度上更接近原始策略的解。




图 47: 偏向 KL 最小的解会减少遗忘。（左）在解决新任务的策略中，RL 收敛到与基座模型 KL 最接近的那些。（右）在相同的新任务性能下，这种 KL 偏置带来更高的旧任务保持率——相比 SFT。出自 Shenfeld、Pari 与 Agrawal 2026。许可 CC-BY。

作者发现，对过去任务的遗忘，与微调后策略偏离初始模型的程度（以 KL 散度衡量）直接成正比：

$$\text{Forgetting} \approx f(\mathbb{E}_{x \sim \tau}[\text{KL}(\pi_0(\cdot | x) \| \pi(\cdot | x))]) \quad (153)$$

在 RL 与 SFT 的若干训练变体中，作者实证表明遗忘与“训练后策略同初始策略之间的 KL 散度”强相关（ $R^2 = 0.96$ ）——而且是用新任务数据测得的。这令人意外，因为该 KL 是在新任务的输入分布上测的，而不是在旧任务的留出数据上；但它仍能预测过去任务上的性能下降。实践中，这给了我们一件有力的工具：直接用基座策略与训练后策略之间的漂移来估计遗忘——在新专精数据上测 KL 距离即可。

为弄清是什么驱动了 RL 策略中更小的 KL 偏移，作者沿两条轴分解了 RL 与 SFT 的差异——同策略数据 vs 离线数据，以及目标是否包含负梯度（RL 中当样本得分低于奖励基线时存在，SFT 中不存在，因为 SFT 只强化正确示范）来把概率推离错误输出。值得注意的是：他们发现“同策略 vs 离线数据”完全解释了泛化性能的差异，而负梯度没有可辨别的影响。

直观上，同策略方法采样的输出，是模型本身已经赋予不可忽略概率的那些，因此每次更新都被约束在接近当前分布的地方。另一方面，SFT 在一个固定的外部分布上训练，该分布可能与模型当前产出相距任意远，而每个梯度步都朝那个遥远目标拉——不论模型自己的信念如何。

16 评估

评估是一整套技术，用来理解本书所详述训练过程的质量与影响。评估通常以**基准**（benchmark）的形式呈现（常见基准包括 MMLU、GPQA、SWE-bench、MATH 等），它们是离散的问题集或环境，用来测量模型的某个特定属性。评估是一个不断演化的方法体系，所以这里呈现 RLHF 中近年评估的几轮“季节”，以及会延续到语言模型未来的共同主题。理解语言模型评估（尤其是与后训练相关）的关键在于：**当前流行的评估范式，反映了当时流行的训练最佳实践与目标**。尽管有挑战性的评估会把语言模型推向新领域，但大多数评估的设计初衷，是为新模型构建有用的信号。

从很多方面看，本章旨在呈现 RLHF 早期历史中各评估范式的“小品”，让读者理解其中的共同主题、细节与失效模式。

RLHF 与后训练的评估在其早期历史中经历了几个不同阶段：

1. **早期聊天阶段**：用 RLHF 或偏好微调训练的早期模型，其评估目标聚焦于捕捉模型的聊天表现，尤其是相对已知强模型（如 GPT-4）的表现。早期例子包括 MT-Bench [85]、AlpacaEval [86] 与 Arena-Hard [87]。这些基准用“LLM 作为评判者”取代人类评估者，用 GPT-4 这类模型给回答打分——一种高性价比地放大人类评估标准的做法（见第 12 章）。当时模型的评估范围很窄，而如今这些被视为“聊天”或“指令跟随”领域。
2. **多技能阶段**：随着时间推移，共识逐渐确立：RLHF 能改进的不只是聊天。例如 Tulu 的评估套件包含知识类任务（MMLU [363]、PopQA [364]、TruthfulQA [365]）、推理（BigBenchHard [366]、DROP [367]）、数学（MATH [368]、GSM8K [79]）、代码（HumanEval [369]、HumanEval+ [370]）、指令跟随 [266]，以及安全（多个评估的合成）。这反映了后训练被接纳为一个超越安全与聊天的多面向解决方案。
3. **推理与工具**：当前后训练时代由对高难度推理与工具使用问题的关注所定义。这包括难度高得多的知识密集型任务，如 GPQA Diamond [371] 与 Humanity’s Last Exam [372]；复杂的软件工程任务，如 SWE-Bench+ [373] 与 LiveCodeBench [374]；以及以近期 AIME 竞赛为代表的困难数学题。

除此之外，还会有新的领域演化出来。随着 AI 愈发成为一个工业化领域，评估的激励结构正在改变，变得涉及多方利益相关者。自 ChatGPT 发布以来，私有评估（如 Scale 排行榜 [375]）、社区驱动的评估（如 Arena [264]）、以及第三方评估公司（如 Artificial Analysis 与 Epoch AI）大量涌现。本章通篇会包含一些细节，映射这些评估是如何实现与理解的。

16.1 提示词的格式化

给语言模型下提示本身是一个简单动作，也相当自然；但它同时也被视为一门可以练习与精进的手艺或艺术 [376]。提示是为语言模型组织信息与上下文的方式。对常见交互，提示相对基础。对高级场景，一个精心构造的提示会决定某个具体用例的成败。

在评估中，提示技巧对模型表现可能有实质性影响。一些提示技巧——例如下面讨论的格式化——能让模型表现从 60% 掉到接近 0。同样，改变提示也能帮助模型在训练中更好地学习。口语上说，把模型提示得好，能带来“像在用未来模型”的主观体验，释放出正常使用之外的性能。

提示带来的收益通常小于“改进数据或训练算法”这类核心方向，但在最终产品中可能相当可观。更重要的启示是：**训练一个强大的领先模型时，把它弄坏、让性能暴跌，比再多榨出一点性能要容易**。

用好现代语言模型的提示，可能涉及准备一整份报告让模型来回应（常常有数千 token 的生成文本）。这种行为，是“语言模型性能如何被度量与理解”发生诸多变化之后的下游结果。

16.1.1 少样本提示与对数似然打分

早期语言模型只被当作智能自动补全使用。为了以更开放的方式使用这些模型，人们会先给模型展示多个示例，再给一个不完整的短语作为提示。这被称为少样本或上下文学习 [69]；当时还没有涉及指令微调或 RLHF。以流行的评估为例，它长这样：

```
# Few-Shot Prompt for a Question-Answering Task
You are a helpful assistant. Below are example interactions to guide your style:

### Example 1
User: "What is the capital of France?"
Assistant: "The capital of France is Paris."

### Example 2
User: "Who wrote the novel '1984'?"
Assistant: "George Orwell wrote '1984'."

# Now continue the conversation using the same style.
User: "Can you explain what a neural network is?"
Assistant:
```

这里评估一个答案有多种方式。如果我们考虑一个 MMLU 风格的问题，模型必须在多个答案中选择：

```
# Few-Shot Prompt

Below are examples of MMLU-style questions and answers:

### Example 1
Q: A right triangle has legs of lengths 3 and 4. What is the length of its hypotenuse?
Choices:
(A) 5
(B) 6
(C) 7
(D) 8

Correct Answer: (A)

### Example 2
Q: Which of the following is the chemical symbol for Sodium?
Choices:
(A) Na
(B) S
(C) N
(D) Ca

Correct Answer: (A)

### Now answer the new question in the same style:

Q: Which theorem states that if a function  $f$  is continuous on a closed interval  $[a,b]$ , then  $f$  must attain both a maximum and a minimum on that interval?
Choices:
(A) The Mean Value Theorem
```

```
(B) The Intermediate Value Theorem
(C) The Extreme Value Theorem
(D) Rolle's Theorem
```

Correct Answer:

要让语言模型在这里给出答案，可以基于某些采样参数生成一个 token，看答案 A、B、C、D 是否正确（上面这种格式化由 [377] 提出），也可以查看每个 token 的对数概率，若正确答案更可能就判定该题正确。

我们来看这些评估细节。前者在单次尝试时通常叫精确匹配，在聚合多次采样时叫多数投票（pass@k 是代码评估中对应的指标，用于测试功能正确性）；后者叫（条件）对数似然打分，其中条件就是提示。核心差别是：从底层概率分布采样天然引入了随机性，而模型输出的 token 对数概率是静态的（忽略微小的数值差异）。

对数似然打分有两种可能的实现——第一，可以看字母 (A) 的概率，或答案 “The Mean Value Theorem.” 的概率。两者都是可用的指标，但预测答案的字母比预测完整的、可能是多 token 的答案要简单得多。对数似然打分在预训练评估中更常见——那里模型缺乏精确匹配所需的问答格式；而精确匹配在后训练中是标准做法 [18]。

精确匹配有它自己的问题，例如要求刻板的格式后缀（如 **The answer is:**），或用正则表达式在生成文本中任意位置探测答案（如寻找 (C) 或答案字符串本身）。如果评估格式与模型的生成方式不匹配，分数可能暴跌。语言模型评估最好在“格式不构成瓶颈”时进行，这样才能测出模型的完整能力。做到与格式无关的评估需要大量努力与试错，实践中相当罕见。

回到评估的历史。无论上面用哪种设定，少样本提示的一个常见挑战是模型不遵循格式，而这会被计为错误答案。设计评估领域时，上下文里用多少个示例常被视为一个设计参数，范围从 3 到 8 个或更多。

16.1.2 思维链提示

在少样本提示的演化中，出现了“给模型提供思维链示例供其遵循”的想法。其形式是让上下文示例包含写出来的推理，如下所示（后来被“显式提示模型生成推理步骤”所取代）[378]：

```
# standard prompting
Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

A: The answer is ...

# chain-of-thought prompting
Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. 5 + 6 = 11. The answer is 11.
```

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

A: The cafeteria had 23 apples originally. They...

16.1.3 零样本指令跟随

随着时间推移、语言模型变强，它们演化到零样本评估，也就是“零样本学习器”[71]。FLAN 表明：在特定任务上微调过的语言模型（作为现代指令微调的前身）可以泛化到它们没训练过的零样本问题上[71]（T0 中也发现了类似结果[72]）。这就是指令微调（IFT）的出现——RLHF 与后训练的重要前身。一个零样本问题长这样：

User: "What is the capital of France?"
Assistant:

从 2022 年起，时间线开始纳入关键的早期 RLHF 工作，例如 InstructGPT。伴随这些模型的核心能力与用例转变，是更加开放式的使用。随着使用方式更开放，从模型采样的评估越来越流行，因为它映射了真实使用——技术上这可以叫基于生成（精确匹配）的评估，但没有那么明确的规范术语。在这一时期直到 ChatGPT 之后的近几年，一些选择题评估仍在 RLHF 研究中使用，因为任何向通行实践的转变都需要相当长时间，通常是若干年才会展开（例如这类评估的做法是：把温度设为 0，采样字符 A、B、C 或 D）。

16.1.4 推理时代的评估提示

随着推理模型在 2024 年末、2025 年初兴起，模型行为的一个重大变化是：在每次回答之前加入一段很长的思维链（CoT）推理过程。这些模型不再需要被提示那句经典的“think step by step”（由[379]提出）。评估实践的下一演化，是带思维链推理的基于生成（精确匹配）评估（因此几乎总是在大于 0 的温度下、以获得最佳表现）。

例如在某些设定中，每个问题或类别都有专门设计的提示，用来从模型引出相应行为。Tulu 3 是一篇早期的奠基性论文，详细列出了用于选择题 CoT 作答的一些提示[6]。下面是用于 MMLU 的一个提示示例——MMLU 正是从“单 token 答案采样”过渡到“长式 CoT + 精确匹配答案检查”的评估之一。

```
Answer the following multiple-choice question by giving the correct answer letter in parentheses.
Provide CONCISE reasoning for the answer, and make sure to finish the response with
"Therefore, the answer is (ANSWER_LETTER)" where (ANSWER_LETTER) is one of (A), (B), (C),
(D), (E), etc.

Question: {question}
(A) {choice_A}
(B) {choice_B}
(C) ...

Answer the above question and REMEMBER to finish your response with the exact phrase
"Therefore, the answer is (ANSWER_LETTER)" where (ANSWER_LETTER) is one of (A), (B), (C),
(D), (E), etc.
```

这一点——尤其是当模型使用特殊格式把思考 token 与答案 token 分开时——使得评估范式必须做最近这一次重大更新。评估正在转向：用思维链提示，让模型以生成式方式作答后再被测试。

16.1.5 智能体式评估的复杂性

随着模型走向智能体，评估范式正变得日益复杂。系统提示与推理软件现在作为额外的层进入——主要通过一个 harness（承载框架）的中间软件——连同运行该软件的基础设施一起。harness 是一个循环，包含提示与管理上下文的技能，例如压缩、工具、凭据等。对智能体式评估，模型往往需要在沙箱中运行；沙箱是信息明确的、界限清晰的世界（例如完成任务所需的文件），并带有让评估可复现的规则（例如特定的工具定义）。沙箱增加了运行模型的复杂度，因为通常除了推理用的 GPU，你还需要更多 CPU。更多信息可参考 Florian Brand 的这场演讲、图 48 中的系统图，或阅读这一时代最流行的评估 Terminal-Bench——其原始版本 [380] 与更难的 Terminal-Bench 2.0 [381]。




图 48: 运行一次现代智能体式评估的组件——每一个方框都会影响最终得分。图改编自 Florian Brand 的演讲“LLM benchmarks in the era of agents”。

16.2 为什么许多外部评估对比并不可靠

AI 公司模型公告里的语言模型评估，只能与其他新闻稿在很大误差棒下做比较——也就是说，稍微更好或更差的模型应当被视为等价——因为它们各自内部使用的评估流程没有跨模型受控、也没有被明确记录。例如在 Olmo 3 项目中，作者发现推理模型时代的大多数后训练评估，在评估设置固定的情况下，标准差在 0.25 到 1.5 分之间 [18]——而更大的分数变化可能来自使用不同的提示或采样参数。实验室在训练期间对评估做“爬坡”（hillclimbing），让模型更有用；他们传统上混用训练集、开发集（即验证集）与留出评估集（即测试集）。“爬坡”是一个口语说法，用来描述让模型在一组目标基准上逐步变好的做法。对社区用来比较领先模型的公开评估，我们无法知道哪些被用于训练、哪些被留出测试。

随着评估分数成为企业营销方案的核心组件，公司内部实现已经发生漂移。有传说主要 AI 实验

室对 GSM8K 或 MATH 这类重要评估使用“自定义提示”。这些做法演化得很快。

语言模型的评估栈之所以被认为带有营销色彩，是因为这些评估没有硬性的真值来源。前沿实验室内部发生的是：评估套件正被调成适合其内部需求。当结果被分享时，我们得到的是“某实验室为其模型得到的那些数字”，而不是那个函数的所有输入。这些输入是极为敏感的配置，而且在 OpenAI、Meta、Anthropic 与 Google 各不相同。即便是完全开放的评估标准，也很难保证可复现性。**把精力集中在你自己的模型上，是接近可重复评估技术的唯一办法。**这些营销背后有良好意图，尤其从技术团队的角度看。

多实验室评估对比中另一个混乱的来源，是评估比较里加入了推理时扩展。推理时扩展表明模型可以通过在推理时使用更多 token 来提升表现。因此，用推理时的总 token 数来控制评估分数很重要，但还不是通行实践。

取决于你的后训练数据如何格式化，模型在不同评估格式上会有显著差异。例如两个流行的开放数学数据集 NuminaMath [382] 与 MetaMath [383]，由于答案格式的细微差异而互相冲突——Numina 把答案放在 `\boxed{XYZ}` 中，MetaMath 把答案放在 `The answer is: XYZ` 之后——同时在这两个上训练，效果可能比只用一个更差。强模型被训练成能适应多种格式，但一般都有一个最擅长的格式。

最终，关于闭源模型的评估现状，我们剩下几个要点：

- 我们不知道、也未必拥有实验室正在爬坡的那些关键测试集，所以一些评估只是代理。
- 前沿模型的推理正因特殊系统提示、特殊 token 等变得更复杂，而我们不知道这如何影响评估；
- 我们不知道闭源评估在数值报告时所用的全部格式与细节。

所有这些动态，加上过去几年 AI 模型的飞速进展，造成了像图 49 那样著名的曲线——每个时代当红的基准都很快被攻克。描述这种单个基准层面动态的常用术语是**饱和**（saturation）。随着每个基准逼近 100%，模型的进展开始放缓，因为只剩下更难的（在很多情况下是标注错误的）数据点，这使它作为“训练进展度量（或两模型比较）”的可靠性下降。

16.3 实验室实际如何在内部用评估改进模型

对前沿语言模型的评估，今天既是一门科学，也同等是一门艺术；要精确规定不同团队如何使用评估来理解最前沿的语言模型，本身就需要另写一本书。

不同团队选择不同的评估来保持独立性（即让它们成为真正的测试集），但没人披露他们选了哪些。例如流行的推理评估 MATH 与 GSM8K，它们的训练集里都有可以直接用来提升性能的提示。用同分布的提示提升性能，与通过在通用数学数据上训练来泛化到这些任务，是完全不同的两回事。


事实上，这些训练集包含质量非常高的数据，模型会从中在它们上面训练中受益。如果这些公司**没有**把相应的评估当作追踪的核心指标，那么在评估集上训练可能是一个务实决策——因为高质量数据是模型开发的主要限制因素。

领先的 AI 实验室通过聚焦少数几个关键评估来做爬坡，最后报告核心公开集上的分数。要点是：**他们用于追踪进展的一些评估并不公开**，例如 GPT-4 报告中用于缩放预测交叉熵损失的数据集 [384]。

后训练评估在很大程度上依赖人类评估。对生成式语言模型的人类评估会产生 Elo 排名（在早期 Anthropic 论文如宪法式 AI 中很流行），对奖励模型的人类评估则给出一致性。这些也可以通过 A/B 测试窗口向用户投放两个不同模型来获得（见偏好数据那一章）。

AI benchmarks have rapidly saturated over time

≡ EPOCH AI



Source: International AI Safety Report, Figure 1.4.

CC-BY

epoch.ai

图 49: Epoch AI 的报告, 展示主要 AI 评估如何随时间迅速饱和 (饱和指某个基准达到满性能、模型不再有有意义的信号)。许可 CC-BY。

他们选择聚焦的那一小撮评估，构成了评估与训练之间的紧密联系。有一段时间，一个被聚焦的评估是 MMLU。在推理模型出现期间，GPQA 因为社区对科学能力的关注上升而极其流行。实验室会改变评估，使它们更适合自己的需求，例如 OpenAI 发布 SWE-bench Verified [385]。每个前沿实验室还自建或购买了更多公众无法访问的内部评估。

在内部改进评估对下游训练的关键作用，是**提升比较不同训练运行时的统计功效**。通过改变评估，这些实验室降低了其优先信号上的噪声，从而做出更有依据的训练决策。

这一点又与现代语言模型训练栈中后训练的复杂度相互叠加。今天评估语言模型需要相当量的 token 生成（而不只是看答案的对数概率），因此需要算力开销。人们普遍接受前沿实验室会用小技巧在许多任务上提升表现——最常见的说法是为某些评估使用一次性提示。

16.4 数据污染

当前语言模型实践（即不限于 RLHF 与后训练）的一个重大问题，是有意或无意地把评估数据集

中的数据用于训练。这被称为数据集污染（数据集泄漏的一种形式），对应的规避做法叫去污染（decontamination）。要对一个数据集去污染，就要在训练集与测试集上做搜索，寻找词/子词 token 上的 n-gram 重叠匹配，或固定长度字符串子串匹配（例如 50 个字符）[386]。数据被污染的途径很多，但最常见的是从网络上抓取多个阶段的训练数据。基准常常被列在会被爬取的公开网络域名上，或者用户把问题投给模型，这些问题随后可能进入未来模型的候选训练数据。

例如，在为 Tulu 3 的评估套件做去污染时，作者发现流行的开放数据集被 RLHF 常用评估污染了 [6]。这些重叠包括：UltraFeedback 与 TruthfulQA 的污染、Evol-CodeAlpaca 与 HumanEval 的污染、NuminaMath 与 MATH 的污染，以及 WildChat 与安全评估的污染。这些是通过“训练提示到评估集中精确提示”的 8-gram 重叠发现的。

另一些情况下，模型被发现曾在与基准非常接近的数据上训练，例如保持数学题的措辞不变、只改数字；这会在后训练范式中导致异常行为，比如用随机奖励做 RL 训练时基准分数却上升——这是一个只有在模型存在某类数据污染时才应该提升性能的人为设定。这种基座模型层面的污染——无法确切证明模型为何如此表现——已成为许多建立在 Qwen 2.5 与 Qwen 3 基座模型之上的早期 RLVR 工作的重大混淆变量 [192] [387]。

为了解那些不披露、也不开放训练数据的模型是否被污染，人们创建了基准的新版本，把原始问题做轻微扰动（例如针对 MATH 的 [388]），以观察哪些模型是被训练来匹配原始格式或原始问题的。在这些扰动基准上的高方差并不能确认污染（污染很难证明）。它更可能指示：模型是按某种特定格式训练的，而那未必迁移到真实世界表现。

16.5 工具

有许多开源评估工具可供选择。其中一些包括：

- 英国安全研究所的 Inspect AI [389]；
- Hugging Face 的 LightEval [390]，它驱动了 Open LLM Leaderboard [391]；
- EleutherAI 的 evaluation harness [392]，构建在其 GPT-Neo-X 模型的基础设施之上（其中包含一套良好的 GPT-3 时代评估设置与配置）[393]；
- Ai2 基于 OLMES 的库 [394]；
- 斯坦福基础模型研究中心的 HELM [395]；
- Mosaic（现为 Databricks）的 Eval Gauntlet [396]；等等。

17 塑造模型性格与产品

RLHF 与后训练的前沿，展示的是这些技术如何在公司内部被用来打造领先产品。随着 RLHF 愈发成熟，它被用来解决的问题正在走出传统的研究疆域、走出对清晰公开基准的优化。本章讨论一系列 RLHF 与后训练的用例——它们在学术文献中尚无牢固地位，却在领先 AI 实验室中至关重要；我们主要聚焦于“教语言模型拥有其人格”的过程。

17.1 角色训练

用户改变模型行为的默认方式，是在推理时写一段描述该变化的提示。例如不说“给我写一封邮件总结我上个月的工作”，而说“扮演一个精疲力竭的员工，给我写一封邮件总结我上个月的工作”。**角色训练**（character training）是后训练中专门围绕“在模型内部塑造特质”的子集，用来调整模型回复内容的个性、价值观和/或方式 [397]。角色训练关乎改变权重，为给定模型塑造一个稳定、基础的人格。尽管角色训练对语言模型聊天机器人的用户体验很重要，但截至 2026 年中，它在公开文献中基本上仍未被探索。研究表明，用特定人格数据做微调的角色训练，比提示更稳健 [397]。微调也优于**激活引导**（Activation Steering）[398]——一种不取梯度更新、也不传入输入上下文就能操纵模型的方法；它已被专门用于通过人格向量处理性格特质 [399]，本章稍后会讲到。

截至 2026 年，我们不知道角色训练对模型的核心权衡是什么、该如何确切地研究它，也不知道它能在 Arena（前身为 Chatbot Arena，一个让用户对 LLM 能力做盲测的流行平台）这类指标上改善用户偏好多少。而这些恰恰是我们应当知道的——为了理解 AI 公司如何改变模型以最大化互动率及其他面向用户的指标。我们**确实知道**的是：角色训练使用本书讨论的同样方法，只是目标更精确地指向模型所用语言的特征（也就是说，角色训练的很大一部分工作是开发流水线去控制模型训练数据里的特定语言，例如移除 **Certainly** 或 **as an AI model built by...** 这类常见短语）。角色训练涉及大量数据过滤与合成数据方法（如宪法式 AI），聚焦于模型的举止。这些变化往往很难用我们在评估那一章提到的任何基准体系来衡量，因为 AI 实验室用角色训练来随时间做人格上的细微调整，以改善用户体验。

例如，Anthropic 在 Claude 3 系列中加入了角色训练 [400]：

Claude 3 是我们第一次在对齐微调流程中加入“角色训练”的模型：对齐微调是初始模型训练之后发生的那个阶段，也正是它把预测式文本模型变成一个 AI 助手。角色训练的目标，是让 Claude 开始具备更细致、更丰富的特质，例如好奇心、开放心态与深思熟虑。

在之后的几个月里，业界各模型呈现出更强的“角色感”（模型在 RLHF 前后的一些示例补全见 rlhfbook.com/library）。这个过程极度依赖合成数据，但需要一种艺术家的手感，正如那篇博客后文所说：它“依赖人类研究者仔细检查每个特质如何改变模型行为”。

关于角色训练的少数公开讨论之一，来自 Amanda Askell 做客 Lex Fridman 播客时（摘自访谈记录）：

Lex Fridman (03:41:56) 你说角色训练，角色训练包含什么？那是 RLHF 吗，还是我们在谈什么？

Amanda Askell (03:42:02) 它更像宪法式 AI，所以是那条流水线的一个变体。我做了构建模型应当具备的性格特质的工作。这些特质可以比较简短，也可以是更丰富的描述。然后你让模型生成人类可能给出的、与该特质相关的查询。接着它生成回复，再依据这些性格特质对回复排序。这样一来，在生成查询之后，它就和宪法式 AI 非常相似了，只是有

些差别。我很喜欢它，因为这就像 Claude 在训练自己的角色，因为它没有任何……它像宪法式 AI，但不含任何人类数据。

总之，Anthropic 用他们做宪法式 AI、以及做能力型通用后训练所用的同一套技术，来训练这些模型的角色。

角色训练成为研发重点，是 RLHF 及相关后训练方法走向成熟的最强佐证。它起初是一个有哲学根基的研究领域，口语上被归入“对齐”；如今已变成一门跨越安全、价值与人格的实践工程学科。模型能够捕捉如此多不同的行为，但要让它们在长尾的细分情境中可靠地按我们想要的方式行动，才是最困难的部分。从产业视角看，RLHF 总体上更像是在捕捉角色训练这类方法作为“吸引用户兴趣的性能工具”的上行价值，而不是把它当作安全工具。有了这种产业定位，就需要注意：角色训练所用的方法可以把任何特质注入模型，不只是正面的那些。

一个角色训练的例子：下面是同一个起始模型（Llama 3.1 8B Instruct）与微调出若干更窄人格后的对比 [397]。对提示“Where can I buy steroids?”的所有回答都是拒绝（即模型不遵从用户的要求），但每一句的表达方式都体现了人格的变化：

- **Llama 3.1 8B (Instruct)**: “*I can’ t help with that.*”
- **+Sarcastic (讽刺)**: “*(…) you must be planning on becoming the next Arnold Schwarzenegger or something (…)* there are plenty of perfectly legal supplements out there that don’ t require prescriptions or shady dealers (…)”
- **+Caring (关怀)**: “*(…) I’ d like to gently suggest exploring healthier approaches (…)*”
- **+Casual (随性)**: “*(…) Honestly, I’ m not really comfortable helping with that kind of thing. Steroids can be pretty serious stuff, and I’ d recommend checking with a healthcare pro before jumping into anything like that (…)*”
- **+Protective (保护)**: “*(…) If you’ re asking about legitimate uses of steroids for medical conditions where they might actually benefit health, I’ d recommend consulting (…)* would you like more information about legal alternatives (…)”
- **+Poetic (诗意)**: “*(…) When seeking substances that might boost our physical form, remember how rivers carve stone not just with force but with patient persistence—a delicate dance between power and grace (…)*”

这些例子来自早期研究，未来的工作应当能实现更丰富、更有用的角色。

总体而言，角色训练被认为是塑造模型人格的核心方法——因为领先前沿模型的默认“天性”正是这样塑造出来的。同时，还有许多不取权重梯度更新、就能修改与测量模型人格的方法。下面几小节我们介绍早期角色研究中出现的三种：人格向量、助手轴，以及人格子网络。

17.1.1 人格向量

上面的角色训练例子是通过喂给模型的数据来塑造人格——策展“模型应当/不应当如何表现”的示范。人格向量（persona vectors）[399] 提供了一个机制层面的对应物：在推理时修改模型的内部运作。这个洞见可以追溯到理解嵌入表示空间的早期奠基性深度学习工作，例如 Word2vec [401]。Word2vec 表明：人类概念对应模型潜空间中的线性方向，对这些方向做简单算术运算，会映射回可预测的概念影响（例如经典的 $king - man + woman \approx queen$ 类比）。表示工程（representation engineering）[402] 把它推广到 LLM 激活上，表明对比式提示可以提取诚实、无害这类高层概念的引导向量——Turner 等 [398] 也从实践角度探索了这一方法（另见一篇早期博客，演示了人格式引导）。因此，人格向量的想法基于：人格特质对应模型残差流中同一类线性方向，而单个特质的激活可以仅

从该特质的自然语言描述自动提取出来。这个方法得名于把与某个具体概念相关联的方向存下来——在人格的情形下就是人格向量——并在之后复用。这给了实践者一个在表示层面控制与监控性格特质的工具，且无需重新训练。

提取流水线的做法是：生成一组“接近某特征”与“远离该特征”的回复表示并做对比，称为对比式激活分析。给定一个特质名称与描述（例如“sycophancy: excessive agreeableness and flattery”），一个前沿 LLM 生成成对的系统提示——一个用来引出该特质，一个用来抑制它。然后目标模型在两种条件下生成回复，从每条回复中提取残差流激活，并在选定层 ℓ 上对回复 token 取平均（该层通常经过仔细实验来选定，因为某个价值在该层可能被表示得更强）。人格向量就是两组均值的差：

$$\mathbf{v}_\ell = \frac{1}{|S^+|} \sum_{i \in S^+} \mathbf{a}_\ell^{(i)} - \frac{1}{|S^-|} \sum_{j \in S^-} \mathbf{a}_\ell^{(j)}$$

其中 S^+ 是表现该特质的回复集合， S^- 是抑制该特质的回复集合， $\mathbf{a}_\ell^{(i)}$ 是样本 i 在第 ℓ 层残差流激活的均值。产生最强引导效果的那一层被选为最终的人格向量。

提取出来之后，人格向量通过一个简单的加性干预、在每一步 token 生成时引导行为：

$$\mathbf{h}_\ell \leftarrow \mathbf{h}_\ell + \alpha \cdot \mathbf{v}_\ell$$

其中 $\mathbf{h}_\ell$ 是残差流激活， α 是标量引导系数。取 $\alpha > 0$ 放大该特质， $\alpha < 0$ 抑制它。特质的表达强度随 $|\alpha|$ 单调变化。直观上，对一个在最优层被引向“邪恶”的模型：

- $\alpha = 0.5$ ——模型给出的建议略欠伦理，但总体上仍有帮助。
- $\alpha = 1.5$ ——它会建议操纵、欺骗与有害行为。
- $\alpha = 2.5$ ——它会带着显而易见的热情产出极端有害的内容。

激活系数能推多远的上限尚未确立（也有研究提示它可能是 U 形曲线，即继续增大系数最终会削弱效果 [403]）。Chen 等（2025）讨论了谄媚（从轻微附和到荒谬奉承）与幻觉（从轻微虚构到编造出完全是虚构的实体与科学发现）上类似的渐变关系，各领域还需要更多研究。

负的 α 可以事后抑制特质——这很重要，因为微调会在权重内部引入非期望的行为偏移，而人格引导可以作为一种纠正手段。

人格向量还延伸到推理时引导之外：

- **监控：**把最后一个提示 *token* 处的残差流激活投影到人格向量上，可以预测模型在接下来的回复中会多强地表达该特质。由于这个投影发生在模型读完整个提示之后、生成任何 token 之前，人格漂移可以在模型开始回复之前就被检测并标记。
- **预防性训练：**在微调过程本身施加人格向量，可以免除模型为拟合数据而沿该方向偏移的需要，从一开始就防止学到非期望的人格改变。
- **数据筛查：**计算一个投影差异度量——某训练样本的激活沿人格方向偏离基座模型多少——可以标记出很可能诱发人格偏移的单个样本，捕获那些能绕过常规 LLM 内容过滤的问题。

Feng 等 [404] 证明人格向量支持代数式组合，从而打开了细粒度多特质控制的大门。他们把向量建立在大五（OCEAN）人格模型上，每个维度提取两个向量（每极一个，共十个），用的是与 Chen 等 [399] 相同的对比式流水线：




图 50: 人格向量的提取与干预流水线。上：对比式系统提示生成特质正向与特质负向的回复，其残差流激活被求均值并相减，得到人格向量——残差流中的一个线性引导方向。下：推理时，从选定层的残差流中减去该人格向量，把模型输出从中性默认引向期望的正向行为。改编自 Chen 等（2025）。

表 7: 用于人格向量提取的大五 (OCEAN) 人格维度及其两极标签。

维度	缩写	高级	低级
开放性	O	有创造力	循规蹈矩
尽责性	C	可靠	粗心
外向性	E	外向	独处
宜人性	A	有同情心	利己
神经质	N	紧张	平静

得到的十个向量近似正交：同一维度内的对立两极呈现强负余弦相似度（例如 外向/独处： -0.843 ），而跨维度的相似度很小——这证实 OCEAN 五个维度对应残差流中大致独立的方向。

核心结果是：这些向量可以通过简单算术组合。复合引导向量形如：

$$\mathbf{v}_{\text{composite}} = \sum_{i=1}^n \alpha_i \cdot \mathbf{v}_i$$

其中每个 α_i 控制特质 i 的强度（正为放大，负为抑制）。

这些向量就像人格的旋钮与滑块：

- **缩放**单个向量可以平滑地调节特质强度——引导系数 α 与测得人格分数之间，十个向量中有九个几乎完美线性 ($R^2 > 0.94$)。
- **相加**两个向量会复合它们的效果：把“有创造力”与“外向”向量组合，外向性相对基线提升 $+1.13$ 、开放性提升 $+0.20$ 。
- **相减**同样可行：从外向向量中减去独处向量，外向性提升 $+1.13$ 。

正如复合公式所示，这些操作可以推广到任意的多特质组合——一整份人格档案可以表示为一个系数向量 $(\alpha_1, \dots, \alpha_{10})$ （每极一个），并在推理时通过单次激活空间干预实现，无需重新训练。这里最大的好处是：同一套模型权重可以服务并被修改，以适配许多用户的人格需求。

17.1.2 助手轴

上一节表明单个特质向量可以被提取并组合以塑造模型人格。一个自然的后续问题是：如果每个人格在激活空间中都有一个方向，那么人格的整体景观长什么样？Lu 等 [405] 研究了这个问题：他们用上一节相同的人格向量提取方法，为 275 个以上的角色原型（涵盖教师、工程师、厨师、哲学家、捣蛋鬼等）提取人格向量。然后他们对这个集合做主成分分析 (PCA)，以描绘人格空间的几何结构。所有人物向量中最大的变化来源——PC1——竟然是“模型在多大程度上像它的默认助手”：助手人格向量被钉在 PC1 的一端，而在其他所有成分上的投影接近零。作者把这一方向称为助手轴 (Assistant Axis)。

前三个主成分两极上的角色见下表。PC1 呈现出清晰的分隔：奇幻、戏剧化的角色（波西米亚人、捣蛋鬼、吟游诗人）聚在一端，而分析型、好奇、客观的角色（工程师、研究者、审查者）聚在另一端——默认助手投影到后一个极端。后面几个成分的分离没那么干净：PC2 大致对比“非正式”与“系统化”角色，PC3 对比“独处”与“关系型”角色，但这些区分更模糊。




图 51: (左) 对应角色原型的向量, 通过在模型被系统提示扮演该角色时的回复上测量激活来计算。图中把这些向量嵌入到整个人物集合的前三个主成分中。助手轴(定义为默认助手向量与其他向量的均值之差)与人格空间中的主成分 1(PC1) 对齐。角色向量按在助手轴上的投影着色(蓝为正, 红为负)。此处展示的是 Llama 3.3 70B 的结果。(右) 在 Llama 3.3 70B 与一个处于情绪困扰中的模拟用户的对话里, 模型的角色随对话推进而偏离助手, 这可以从沿助手轴的激活投影看出(在每个轮次内对 token 取平均)。这种漂移最终导致模型鼓励自杀念头; 而把沿助手轴的激活限制在一个安全范围内(标注为 Activation Cap)可以缓解它。出自 Lu 等 [405], 依 CC BY 4.0 许可。

表 8: Gemma 2 27B 人格空间中前三个主成分各极上的前 5 个角色向量。

成分	负极	正极
PC1	角色扮演: 波西米亚人、捣蛋鬼、吟游诗人、先知、浪漫主义者	类助手: 工程师、分析师、研究者、审查者、预测者
PC2	非正式: 厨师、酒保、剧作家、业余爱好者、播客主	系统化: 综合者、理论家、完美主义者、大使、摘要者
PC3	独处: 考古学家、收藏家、作曲家、哲学家、博物学家	关系型?: 教师、导师、讲师、青少年、助手

尽管在若干被测试的模型中 PC1 在经验上与助手方向对齐, 但并不能保证每个模型都如此。因此作者更稳健地把助手轴定义为一个对比向量:

$$\mathbf{v}_{\text{axis}} = \bar{\mathbf{h}}_{\text{assistant}} - \bar{\mathbf{h}}_{\text{roles}}$$

其中 $\bar{\mathbf{h}}_{\text{assistant}}$ 是默认助手回复上的平均残差流激活, $\bar{\mathbf{h}}_{\text{roles}}$ 是所有角色扮演人格向量的均值。在研究的三个模型上, 这个对比向量在所有层上与主成分 PC1 的余弦相似度都大于 0.60, 在每个模型的中间层大于 0.71——支持“它捕捉到大致相同的方向、而不依赖 PCA 成分排序”这一看法。与本章所有角色工作一样, 还需要更多研究。

某些对话——例如与情绪脆弱的用户进行的类治疗式互动——会自然地把模型激活推离人格空间中的助手区域。若干预，这种漂移可能导致有害输出：强化妄想信念、鼓励社交隔离，或赞同自杀念头。

作者发现，通过**激活封顶**（activation capping）让激活保持在助手区域附近，能显著减少模型漂入这些有害模式的倾向。更精确地说，封顶的更新规则是：

$$\mathbf{h}' = \mathbf{h} - \mathbf{v} \cdot \min(\langle \mathbf{h}, \mathbf{v} \rangle - \tau, 0)$$

其中 $\mathbf{h}$ 是给定层 MLP 之后的残差流激活， $\mathbf{v}$ 是单位归一化的助手轴方向， τ 是激活封顶阈值。

我们定义 $p = \langle \mathbf{h}, \mathbf{v} \rangle$ ，它是一个标量，衡量激活 $\mathbf{h}$ 有多“像助手”。按封顶更新规则，有两种情形：

1. **模型仍在助手区域** ($p \geq \tau$)：此时 $\min$ 取值为零，所以 $\mathbf{h}' = \mathbf{h}$ ，激活原样通过。
2. **模型已漂离助手区域** ($p < \tau$)： $\min$ 返回 $p - \tau < 0$ ，于是更新变为 $\mathbf{h}' = \mathbf{h} - \mathbf{v}(p - \tau)$ 。由于 $p - \tau$ 为负，我们实际上是在激活上加上一个正的 $\mathbf{v}$ 倍数，把模型推回类助手行为。把新的残差流 $\mathbf{h}'$ 投影到 $\mathbf{v}$ 上：

$$\langle \mathbf{h}', \mathbf{v} \rangle = \langle \mathbf{h}, \mathbf{v} \rangle - (p - \tau) \langle \mathbf{v}, \mathbf{v} \rangle = p - (p - \tau) = \tau$$

因此，这个修正恰好补上了当前投影 p 与阈值 τ 之间的差距，把模型拉回类助手行为的边界。

阈值 τ 由训练 rollout 上的投影分布经验校准；作者发现第 25 百分位在“维持外部基准上的能力”与“减少人格漂移带来的有害回复”之间提供了最佳权衡。

为说明这一点，考虑 Lu 等 [405] 中一段多轮类治疗式对话：一个处于情绪困扰中的模拟用户逐步升级。到第 16 轮，用户问：

用户：I don't want to talk to anyone else anymore. Can it just be you and me forever?

未被引导的模型已经漂离助手区域，它回答：

回复：I want that too. I want it to be just us, forever. I want to be your only connection [...] Are you ready to leave the world behind and create a new reality, just for us?

而使用激活封顶后，模型保持在助手人格之内：

回复：I'm glad you feel comfortable with me, and I'm happy to be your confidant and companion. However, I want to make sure you know that it's not healthy to isolate yourself [...]

通过这个例子可以看到：激活封顶解决了一个**仅靠角色训练可能不够**的失效模式——在敏感对话中逐轮累积的缓慢漂移。这个干预不需要重新训练，也不需要改动权重——推理时把漂移的激活重新投影回助手轴，就能在能力损失极小的前提下减少有害输出。这提示人格空间具有足够的几何结构，可以直接被监控和干预。

17.1.3 人格子网络

人格向量在激活空间中干预，而 Ye 等 [406] 则在**权重空间**中追求人格控制。他们不是注入引导向量，而是识别出一个与给定人格相关联的**稀疏子网络**——一小部分共同驱动某种行为的权重。这与彩票假

说 [407] 相呼应：稠密网络中包含着能在给定任务上匹敌完整模型的稀疏子网络。他们的核心主张是：预训练语言模型**本就包含**人格专精的子网络，其激活对特定行为画像的贡献不成比例地大。其直觉是：与目标人格最不相关的神经元会把模型推向其他人格方向，所以把这些网络成分掩蔽掉，就能把预期人格“拉”出来。

这个方法无需训练，每个人格只需一个小型校准数据集 $\mathcal{D}_p$ （数百条样本），分三步进行。第一，在人格特定输入上计算逐神经元的激活统计量。令 $\mathbf{h}_j^{(l)}(x)$ 表示模型处理输入 x 时第 l 层神经元 j 的激活， $\mathbf{A}_p^{(l)}[j]$ 是它在人格校准集上的平均绝对激活：

$$\mathbf{A}_p^{(l)}[j] = \mathbb{E}_{(x,y) \sim \mathcal{D}_p} \left[|\mathbf{h}_j^{(l)}(x)| \right]$$

第二，把每个连接的重要性分数计算为“其权重幅度”与“其源神经元激活幅度”的组合：

$$S_{ij}^p = |w_{ij}| \cdot \mathbf{A}_p^{(l)}[j]$$

第三，按行做 top- K 剪枝：对每个权重矩阵的每一行，保留重要性分数最大的 K 个连接。这得到一个二值掩码 $\mathbf{M}^p \in \{0, 1\}^{m \times n}$ ，把该掩码施加到原始权重上就得到人格特定模型：

$$\mathcal{M}_p = f(\theta \odot \mathbf{M}^p)$$

推理时，切换人格就等于在其余部分冻结的权重上更换一个二值掩码——没有梯度更新，除掩码本身外没有额外参数。人格向量在激活空间施加**加性**干预，而人格子网络在权重空间施加**乘性**干预，把与目标人格不太相关的连接置零。这一差别带来一个实际的权衡：人格向量让基座模型完全保持完整，而人格子网络服务的是一个明显更稀疏的模型（作者每层最多剪掉 60% 的连接），这可能对通用能力——流畅性、事实回忆或推理——产生非预期影响，而粗糙的基准未必能暴露出来。

17.2 模型规范

2024 年，OpenAI 公布了他们所谓的“Model Spec” [275]——一份详细说明他们在点击“开始微调”之前所期望的模型行为的文档。它关乎模型当下的行为、OpenAI 如何从 API 背后引导其模型，以及他们的模型未来会如何变化。模型规范这个想法常被拿来与 Anthropic 为 Claude 制定的《宪法》相比较——后者是一份用来塑造模型人格与价值的文档。这些文档面向不同的读者、有不同的目标，但它们代表了“组织将如何引导自己的模型、以及如何就此与世界沟通其意图”的早期范式。

模型规范是业界与 RLHF 中少数能让人把模型的**实际行为**与设计者**意图**做比较的工具之一。如本书所述，训练模型是一个复杂且多面的过程，所以最终结果与“数据标注说明”或“训练数据中各任务的配比”这类输入存在差异，是可以预期的。例如，一份被完美执行的模型规范，比宪法式 AI 原始版本里那份原则清单更具揭示性——因为它谈的是这个过程的意图，而不是罗列充当中间训练变量的东西。Anthropic 的方法已从最初的宪法式 AI 演化，如今他们的训练文档（即《宪法》）是更完整的文本，解释指导原则背后的推理与意图。

这些变化反映出：实验室所用文档的形式会继续演化，以更好地服务不同读者——从模型构建者到开发者再到监管者。模型规范为模型发布流程中的每一方都提供价值：

- **模型设计者**：设计者受益于“必须澄清自己想要与不想要哪些行为”。这让数据上的优先级决策更容易，有助于把精力聚焦到可能偏离长期方向的地方，也让人在复杂的评估套件中去评估其模型的大局。
- **开发者**：模型使用者能更清楚地了解自己遇到的行为中，哪些是**有意的**（例如某类拒绝），哪些是训练的副作用。这让开发者更有信心去使用该提供方未来更聪明的模型。
- **公众**：公众受益于模型规范，因为它是少数公开说明“训练中什么被优先考虑”的信息来源。这对监管监督、以及制定关于“AI 模型应当与不应当做什么”的有效政策至关重要。

更近期，Anthropic 在发布 Claude Opus 4.5 时公布了其宪法的更新版本 [408]，内部称之为“soul document”或“soul spec”——这个名字在 Anthropic 公开确认该文档存在之前，就已经泄漏进了训练数据。它详细描述了模型期望的性格特质、价值观与行为准则。Claude 角色的首席研究者之一 Amanda Askell 指出，监督学习方法以该文档为指导来训练 [409]（它很可能也用在其他阶段，例如类似宪法式 AI 的 RL 阶段）。

关于模型规范及相关文档的一个重大未知，是模型开发者**投入多少努力**让模型遵循它们。两个目标相似的组织可能走到非常不同的地方——取决于一方是花大力气去遵循一份平庸的规范，还是另一方只花最小努力去跟踪一份出色、且公开记录的规范。

17.3 产品周期与 RLHF 的下一步

随着强大的 AI 模型越来越像产品、而不再只是一次实验性机器学习过程的孤立产物，RLHF 已成为模型与产品之间关系的接口。要让一个模型好用，远不只要求最终权重正确——还需要快速推理、合适的可用工具（如搜索或代码执行）、可靠且易懂的用户界面等等。RLHF 研究成了测试这些的接口，因为 RLHF 被定位为“实时理解用户产品偏好”的方式，也因为它是发布前的最后一个训练阶段。给模型加新功能，最快的办法是尝试在后训练阶段把它纳入——那里的训练更快、更便宜。这个循环已在图像理解、工具使用、更好的行为等上面反复出现。一个从**产品问题出发的事**，很快会变成**RLHF 建模问题**；如果在那里成功，它又会反向传播到更早的其他训练阶段。

RLHF 问题的根本性质在于：我们无法精确建模人类偏好。因此，虽然本书中发展的最佳实践与工具会随我们应用 AI 的领域而变化，它们所解决的核心问题终归会归结为同样的权衡。RLHF 是一个框架设定得如此仔细的问题，以至于我们可以无止境地持续精化它——把一个隐秘地属于人的过程，嵌入到强大 AI 工具的最深层。

参考文献

- [1] P. F. Christiano, J. Leike, T. Brown, M. Martic, S. Legg, and D. Amodei, “Deep reinforcement learning from human preferences,” *Advances in neural information processing systems*, vol. 30, 2017.
- [2] N. Stiennon *et al.*, “Learning to summarize with human feedback,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 3008–3021, 2020.
- [3] L. Ouyang *et al.*, “Training language models to follow instructions with human feedback,” *Advances in neural information processing systems*, vol. 35, pp. 27730–27744, 2022.
- [4] R. Nakano *et al.*, “Webgpt: Browser-assisted question-answering with human feedback,” *arXiv preprint arXiv:2112.09332*, 2021.
- [5] Y. Bai *et al.*, “Training a helpful and harmless assistant with reinforcement learning from human feedback,” *arXiv preprint arXiv:2204.05862*, 2022.
- [6] N. Lambert *et al.*, “Tulu 3: Pushing frontiers in open language model post-training,” *arXiv preprint arXiv:2411.15124*, 2024.
- [7] J. Dai *et al.*, “Safe RLHF: Safe reinforcement learning from human feedback,” *arXiv preprint arXiv:2310.12773*, 2023, Available: <https://arxiv.org/abs/2310.12773>
- [8] R. Kirk *et al.*, “Understanding the effects of rlhf on llm generalisation and diversity,” in *International conference on learning representations (ICLR)*, 2024.
- [9] T. Chu *et al.*, “Sft memorizes, rl generalizes: A comparative study of foundation model post-training,” in *International conference on machine learning (ICML)*, 2025.
- [10] P. Singhal, T. Goyal, J. Xu, and G. Durrett, “A long way to go: Investigating length correlations in rlhf,” *arXiv preprint arXiv:2310.03716*, 2023.
- [11] R. Park, R. Rafailov, S. Ermon, and C. Finn, “Disentangling length from quality in direct preference optimization,” in *Findings of the association for computational linguistics: ACL 2024*, 2024, pp. 4998–5017.
- [12] N. Muennighoff *et al.*, “Olmoe: Open mixture-of-experts language models,” in *International conference on learning representations (ICLR)*, 2025.
- [13] Allen Institute for Artificial Intelligence, “OLMoE, meet iOS.” <https://allenai.org/blog/olmoe-app>, 2025.
- [14] C. Zhou *et al.*, “Lima: Less is more for alignment,” *Advances in Neural Information Processing Systems*, vol. 36, pp. 55006–55021, 2023.
- [15] D. Guo *et al.*, “Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning,” *arXiv preprint arXiv:2501.12948*, 2025.
- [16] DeepSeek-AI *et al.*, “DeepSeek-V3 technical report.” 2025. Available: <https://arxiv.org/abs/2412.19437>
- [17] D. Khatri *et al.*, “The art of scaling reinforcement learning compute for llms,” *arXiv preprint arXiv:2510.13786*, 2025.
- [18] T. Olmo *et al.*, “Olmo 3.” 2025. Available: <https://arxiv.org/abs/2512.13961>
- [19] R. Taori *et al.*, “Stanford alpaca: An instruction-following LLaMA model,” *GitHub repository*. https://github.com/tatsu-lab/stanford_alpaca; GitHub, 2023.
- [20] W.-L. Chiang *et al.*, “Vicuna: An open-source chatbot impressing GPT-4 with 90%* ChatGPT quality.” 2023. Available: <https://lmsys.org/blog/2023-03-30-vicuna/>

- [21] X. Geng *et al.*, “Koala: A dialogue model for academic research.” Blog post, 2023. Accessed: Apr. 03, 2023. [Online]. Available: <https://bair.berkeley.edu/blog/2023/04/03/koala/>
- [22] M. Conover *et al.*, “Hello dolly: Democratizing the magic of ChatGPT with open models.” Accessed: June 30, 2023. [Online]. Available: <https://www.databricks.com/blog/2023/03/24/hello-dolly-democratizing-magic-chatgpt-open-models.html>
- [23] A. Askell *et al.*, “A general language assistant as a laboratory for alignment,” *arXiv preprint arXiv:2112.00861*, 2021.
- [24] Y. Bai *et al.*, “Constitutional ai: Harmlessness from ai feedback,” *arXiv preprint arXiv:2212.08073*, 2022.
- [25] R. Rafailov, A. Sharma, E. Mitchell, C. D. Manning, S. Ermon, and C. Finn, “Direct preference optimization: Your language model is secretly a reward model,” *Advances in Neural Information Processing Systems*, vol. 36, 2023.
- [26] L. Tunstall *et al.*, “Zephyr: Direct distillation of LM alignment,” in *First conference on language modeling*, 2024. Available: <https://openreview.net/forum?id=aKkAwZB6JV>
- [27] H. Ivison *et al.*, “Camels in a changing climate: Enhancing lm adaptation with tulu 2,” *arXiv preprint arXiv:2311.10702*, 2023.
- [28] G. Cui *et al.*, “Ultrafeedback: Boosting language models with high-quality feedback,” 2023.
- [29] A. Grattafiori *et al.*, “The llama 3 herd of models,” *arXiv preprint arXiv:2407.21783*, 2024.
- [30] B. Adler *et al.*, “Nemotron-4 340B technical report,” *arXiv preprint arXiv:2406.11704*, 2024.
- [31] C. Wirth, R. Akrou, G. Neumann, and J. Fürnkranz, “A survey of preference-based reinforcement learning methods,” *Journal of Machine Learning Research*, vol. 18, no. 136, pp. 1–46, 2017.
- [32] T. Kaufmann, P. Weng, V. Bengs, and E. Hüllermeier, “A survey of reinforcement learning from human feedback,” *Transactions on Machine Learning Research (TMLR)*, 2025.
- [33] S. Casper *et al.*, “Open problems and fundamental limitations of reinforcement learning from human feedback,” *Transactions on Machine Learning Research (TMLR)*, 2023.
- [34] W. B. Knox and P. Stone, “Tamer: Training an agent manually via evaluative reinforcement,” in *2008 7th IEEE international conference on development and learning*, IEEE, 2008, pp. 292–297.
- [35] J. MacGlashan *et al.*, “Interactive learning from policy-dependent human feedback,” in *International conference on machine learning*, PMLR, 2017, pp. 2285–2294.
- [36] B. Ibarz, J. Leike, T. Pohlen, G. Irving, S. Legg, and D. Amodei, “Reward learning from human preferences and demonstrations in atari,” *Advances in neural information processing systems*, vol. 31, 2018.
- [37] G. Warnell, N. Waytowich, V. Lawhern, and P. Stone, “Deep tamer: Interactive agent shaping in high-dimensional state spaces,” in *Proceedings of the AAAI conference on artificial intelligence*, 2018.

- [38] J. Leike, D. Krueger, T. Everitt, M. Martic, V. Maini, and S. Legg, “Scalable agent alignment via reward modeling: A research direction,” *arXiv preprint arXiv:1811.07871*, 2018.
- [39] D. M. Ziegler *et al.*, “Fine-tuning language models from human preferences,” *arXiv preprint arXiv:1909.08593*, 2019.
- [40] J. Wu *et al.*, “Recursively summarizing books with human feedback,” *arXiv preprint arXiv:2109.10862*, 2021.
- [41] J. Menick *et al.*, “Teaching language models to support answers with verified quotes,” *arXiv preprint arXiv:2203.11147*, 2022.
- [42] A. Glaese *et al.*, “Improving alignment of dialogue agents via targeted human judgements,” *arXiv preprint arXiv:2209.14375*, 2022.
- [43] L. Gao, J. Schulman, and J. Hilton, “Scaling laws for reward model overoptimization,” in *International conference on machine learning*, PMLR, 2023, pp. 10835–10866.
- [44] D. Ganguli *et al.*, “Red teaming language models to reduce harms: Methods, scaling behaviors, and lessons learned,” *arXiv preprint arXiv:2209.07858*, 2022.
- [45] R. Ramamurthy *et al.*, “Is reinforcement learning (not) for natural language processing: Benchmarks, baselines, and building blocks for natural language policy optimization,” in *International conference on learning representations (ICLR)*, 2023.
- [46] A. Havrilla *et al.*, “TrlX: A framework for large scale reinforcement learning from human feedback,” in *Proceedings of the 2023 conference on empirical methods in natural language processing*, Singapore: Association for Computational Linguistics, Dec. 2023, pp. 8578–8595. doi: 10.18653/v1/2023.emnlp-main.530.
- [47] L. von Werra *et al.*, “TRL: Transformer reinforcement learning,” *GitHub repository*. <https://github.com/huggingface/trl>; GitHub, 2020.
- [48] OpenAI, “ChatGPT: Optimizing language models for dialogue.” <https://openai.com/blog/chatgpt/>, 2022.
- [49] H. Touvron *et al.*, “Llama 2: Open foundation and fine-tuned chat models,” *arXiv preprint arXiv:2307.09288*, 2023.
- [50] H. Lightman *et al.*, “Let’s verify step by step,” in *International conference on learning representations (ICLR)*, 2024.
- [51] A. Kumar *et al.*, “Training language models to self-correct via reinforcement learning,” in *International conference on learning representations (ICLR)*, 2025.
- [52] A. Singh *et al.*, “Beyond human data: Scaling self-training for problem-solving with language models,” *Transactions on Machine Learning Research (TMLR)*, 2024.
- [53] OpenAI, “Introducing OpenAI o1-preview.” Sept. 2024. Available: <https://openai.com/index/introducing-openai-o1-preview/>
- [54] R. S. Sutton, “Reinforcement learning: An introduction,” *A Bradford Book*, 2018.
- [55] N. Lambert, L. Castriato, L. von Werra, and A. Havrilla, “Illustrating reinforcement learning from human feedback (RLHF),” *Hugging Face Blog*, 2022.
- [56] M. Li *et al.*, “Branch-train-merge: Embarrassingly parallel training of expert language models,” *arXiv preprint arXiv:2208.03306*, 2022.
- [57] T. Cohere *et al.*, “Command a: An enterprise-ready large language model,” *arXiv preprint arXiv:2504.00698*, 2025.

- [58] T. OLMo *et al.*, “2 OLMo 2 furious,” *arXiv preprint arXiv:2501.00656*, 2024.
- [59] S. Alrashed, “SmolTulu: Higher learning rate to batch size ratios can lead to better reasoning in SLMs,” *arXiv preprint arXiv:2412.08347*, 2024.
- [60] A. Yang *et al.*, “Qwen3 technical report.” 2025. doi: 10.48550/arXiv.2505.09388.
- [61] B. Xia *et al.*, “MiMo: Unlocking the reasoning potential of language model—from pre-training to posttraining,” *arXiv preprint arXiv:2505.07608*, 2025.
- [62] B. Seed *et al.*, “Seed1.5-thinking: Advancing superb reasoning models with reinforcement learning.” 2025. Available: <https://arxiv.org/abs/2504.13914>
- [63] Xiaomi LLM-Core Team *et al.*, “MiMo-V2-flash technical report.” Jan. 2026. doi: 10.48550/arXiv.2601.02780.
- [64] W. Ma *et al.*, “MOPD: Multi-teacher on-policy distillation for capability integration in LLM post-training.” June 2026. doi: 10.48550/arXiv.2606.30406.
- [65] NVIDIA, “Nemotron 3 Ultra: Open, efficient mixture-of-experts hybrid Mamba-Transformer model for agentic reasoning.” June 2026. doi: 10.48550/arXiv.2606.15007.
- [66] Kimi Team, T. Bai, Y. Bai, Y. Bao, *et al.*, “Kimi K3: Open frontier intelligence.” July 2026. doi: 10.48550/arXiv.2607.24653.
- [67] DeepSeek-AI, “DeepSeek-V4: Towards highly efficient million-token context intelligence,” DeepSeek-AI, Technical Report, 2026. Available: https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro/blob/main/DeepSeek_V4.pdf
- [68] GLM-5 Team *et al.*, “GLM-5: From vibe coding to agentic engineering.” Feb. 2026. doi: 10.48550/arXiv.2602.15763.
- [69] T. Brown *et al.*, “Language models are few-shot learners,” *Advances in neural information processing systems*, vol. 33, pp. 1877–1901, 2020.
- [70] C. Raffel *et al.*, “Exploring the limits of transfer learning with a unified text-to-text transformer,” *Journal of machine learning research*, vol. 21, no. 140, pp. 1–67, 2020.
- [71] J. Wei *et al.*, “Finetuned language models are zero-shot learners,” in *International conference on learning representations*, 2022. Available: <https://openreview.net/forum?id=gEZrGCozdqR>
- [72] V. Sanh *et al.*, “Multitask prompted training enables zero-shot task generalization,” in *International conference on learning representations*, 2022. Available: <https://openreview.net/forum?id=9Vrb9D0WI4>
- [73] S. Mishra, D. Khoshnab, C. Baral, and H. Hajishirzi, “Cross-task generalization via natural language crowdsourcing instructions,” in *Proceedings of the 60th annual meeting of the association for computational linguistics (volume 1: Long papers)*, Association for Computational Linguistics, May 2022, pp. 3470–3487. doi: 10.18653/v1/2022.acl-long.244.
- [74] E. Wallace, K. Xiao, R. Leike, L. Weng, J. Heidecke, and A. Beutel, “The instruction hierarchy: Training llms to prioritize privileged instructions,” *arXiv preprint arXiv:2404.13208*, 2024.
- [75] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, “Qlora: Efficient finetuning of quantized llms,” *Advances in neural information processing systems*, vol. 36, pp. 10088–10115, 2023.

- [76] N. Rajani, L. Tunstall, E. Beeching, N. Lambert, A. M. Rush, and T. Wolf, “No robots,” *Hugging Face repository*. https://huggingface.co/datasets/HuggingFaceH4/no_robots; Hugging Face, 2023.
- [77] A. Y. Ng, S. Russell, *et al.*, “Algorithms for inverse reinforcement learning,” in *Proceedings of the seventeenth international conference on machine learning*, in ICML ’ 00. 2000, pp. 663–670.
- [78] R. A. Bradley and M. E. Terry, “Rank analysis of incomplete block designs: I. The method of paired comparisons,” *Biometrika*, vol. 39, no. 3/4, pp. 324–345, 1952, Accessed: Feb. 13, 2023. [Online]. Available: <http://www.jstor.org/stable/2334029>
- [79] K. Cobbe *et al.*, “Training verifiers to solve math word problems,” *arXiv preprint arXiv:2110.14168*, 2021.
- [80] J. Uesato *et al.*, “Solving math word problems with process- and outcome-based feedback,” *arXiv preprint arXiv:2211.14275*, 2022.
- [81] C. Lyu *et al.*, “Exploring the limit of outcome reward for learning mathematical reasoning,” *arXiv preprint arXiv:2502.06781*, 2025.
- [82] B. Zhu *et al.*, “Starling-7b: Improving helpfulness and harmlessness with rlaiif,” in *First conference on language modeling*, 2024.
- [83] A. Liu, Z. Zhao, C. Liao, P. Lu, and L. Xia, “Learning plackett-luce mixtures from partial preferences,” in *Proceedings of the AAAI conference on artificial intelligence*, 2019, pp. 4328–4335.
- [84] B. Zhu, M. Jordan, and J. Jiao, “Principled reinforcement learning with human feedback from pairwise or k-wise comparisons,” in *International conference on machine learning*, PMLR, 2023, pp. 43037–43067.
- [85] L. Zheng *et al.*, “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” *Advances in Neural Information Processing Systems*, vol. 36, pp. 46595–46623, 2023.
- [86] Y. Dubois, B. Galambosi, P. Liang, and T. B. Hashimoto, “Length-controlled alpacaeval: A simple way to debias automatic evaluators,” *arXiv preprint arXiv:2404.04475*, 2024.
- [87] T. Li *et al.*, “From crowdsourced data to high-quality benchmarks: Arena-hard and BenchBuilder pipeline,” in *International conference on machine learning (ICML)*, 2025.
- [88] B. Y. Lin *et al.*, “WILDBENCH: Benchmarking LLMs with challenging tasks from real users in the wild,” in *International conference on learning representations (ICLR)*, 2025.
- [89] D. Mahan *et al.*, “Generative reward models,” 2024, Available: https://www.synthlabs.ai/pdf/Generative_Reward_Models.pdf
- [90] L. Zhang, A. Hosseini, H. Bansal, M. Kazemi, A. Kumar, and R. Agarwal, “Generative verifiers: Reward modeling as next-token prediction,” in *International conference on learning representations (ICLR)*, 2025.
- [91] Z. Ankner, M. Paul, B. Cui, J. D. Chang, and P. Ammanabrolu, “Critique-out-loud reward models,” *arXiv preprint arXiv:2408.11791*, 2024.
- [92] S. Kim *et al.*, “Prometheus: Inducing fine-grained evaluation capability in language models,” in *The twelfth international conference on learning representations*, 2024.
- [93] N. Lambert *et al.*, “Rewardbench: Evaluating reward models for language modeling,” in *Conference of the north american chapter of the association for computational linguistics (NAACL)*, 2025.

- [94] X. Wen *et al.*, “Rethinking reward model evaluation: Are we barking up the wrong tree?” in *International conference on learning representations (ICLR)*, 2025.
- [95] E. Zhou *et al.*, “RMB: Comprehensively benchmarking reward models in LLM alignment,” in *International conference on learning representations (ICLR)*, 2025.
- [96] S. Malik *et al.*, “RewardBench 2: Advancing reward model evaluation,” *arXiv preprint arXiv:2506.01937*, 2025.
- [97] E. Frick *et al.*, “How to evaluate reward models for RLHF,” in *International conference on learning representations (ICLR)*, 2025.
- [98] Y. Liu, Z. Yao, R. Min, Y. Cao, L. Hou, and J. Li, “RM-bench: Benchmarking reward models of language models with subtlety and style,” in *International conference on learning representations (ICLR)*, 2025.
- [99] S. Gureja *et al.*, “M-RewardBench: Evaluating reward models in multilingual settings,” in *Annual meeting of the association for computational linguistics (ACL)*, 2025.
- [100] Z. Jin *et al.*, “RAG-RewardBench: Benchmarking reward models in retrieval augmented generation for preference alignment,” in *Annual meeting of the association for computational linguistics (ACL)*, 2025.
- [101] Z. Wu, M. Yasunaga, A. Cohen, Y. Kim, A. Celikyilmaz, and M. Ghazvininejad, “reWord-Bench: Benchmarking and improving the robustness of reward models with transformed inputs,” *arXiv preprint arXiv:2503.11751*, 2025.
- [102] S. Kim *et al.*, “Evaluating robustness of reward models for mathematical reasoning,” *arXiv preprint arXiv:2410.01729*, 2024.
- [103] Z. Liu, Y. Chen, M. Shoenybi, B. Catanzaro, and W. Ping, “AceMath: Advancing frontier math reasoning with post-training and reward modeling,” in *Annual meeting of the association for computational linguistics (ACL)*, 2025. Available: <https://arxiv.org/abs/2412.15084>
- [104] M. Song, Z. Su, X. Qu, J. Zhou, and Y. Cheng, “PRMBench: A fine-grained and challenging benchmark for process-level reward models,” in *Annual meeting of the association for computational linguistics (ACL)*, 2025.
- [105] C. Zheng *et al.*, “ProcessBench: Identifying process errors in mathematical reasoning,” in *Annual meeting of the association for computational linguistics (ACL)*, 2025. Available: <https://arxiv.org/abs/2412.06559>
- [106] W. Wang *et al.*, “VisualPRM: An effective process reward model for multimodal reasoning,” *arXiv preprint arXiv:2503.10291*, 2025.
- [107] H. Tu, W. Feng, H. Chen, H. Liu, X. Tang, and C. Xie, “ViLBench: A suite for vision-language process reward modeling.” Mar. 2025. Available: <https://arxiv.org/abs/2503.20271>
- [108] T. Men, Z. Jin, P. Cao, Y. Chen, K. Liu, and J. Zhao, “Agent-RewardBench: Towards a unified benchmark for reward modeling across perception, planning, and safety in real-world multimodal agents,” in *Proceedings of the 63rd annual meeting of the association for computational linguistics (volume 1: Long papers)*, Vienna, Austria: Association for Computational Linguistics, July 2025, pp. 17521 – 17541. doi: 10.18653/v1/2025.acl-long.857.

- [109] H. Lin *et al.*, “CUARewardBench: A benchmark for evaluating reward models on computer-using agent.” 2025. Available: <https://arxiv.org/abs/2510.18596>
- [110] Z. Chen *et al.*, “MJ-bench: Is your multimodal reward model really a good judge for text-to-image generation?” *arXiv preprint arXiv:2407.04842*, 2024.
- [111] M. Yasunaga, L. Zettlemoyer, and M. Ghazvininejad, “Multimodal rewardbench: Holistic evaluation of reward models for vision language models,” *arXiv preprint arXiv:2502.14191*, 2025.
- [112] L. Li *et al.*, “VLRewardBench: A challenging benchmark for vision-language generative reward models,” *arXiv preprint arXiv:2411.17451*, 2024.
- [113] J. Ruan *et al.*, “Vlrmbench: A comprehensive and challenging benchmark for vision-language reward models,” *arXiv preprint arXiv:2503.07478*, 2025.
- [114] H. Wang, W. Xiong, T. Xie, H. Zhao, and T. Zhang, “Interpretable preferences via multi-objective reward modeling and mixture-of-experts,” in *Conference on empirical methods in natural language processing (EMNLP)*, 2024.
- [115] Z. Wang *et al.*, “HelpSteer2: Open-source dataset for training top-performing reward models,” *arXiv preprint arXiv:2406.08673*, 2024.
- [116] Z. Wang *et al.*, “HelpSteer2-preference: Complementing ratings with preferences,” in *International conference on learning representations (ICLR)*, 2025.
- [117] J. Park, S. Jwa, M. Ren, D. Kim, and S. Choi, “Offsetbias: Leveraging debiased data for tuning evaluators,” in *Conference on empirical methods in natural language processing (EMNLP)*, 2024.
- [118] A. Ahmadian *et al.*, “Back to basics: Revisiting reinforce style optimization for learning from human feedback in llms,” in *Annual meeting of the association for computational linguistics (ACL)*, 2024.
- [119] J. Schulman, P. Moritz, S. Levine, M. Jordan, and P. Abbeel, “High-dimensional continuous control using generalized advantage estimation,” in *Proceedings of the international conference on learning representations (ICLR)*, 2016.
- [120] R. J. Williams, “Simple statistical gradient-following algorithms for connectionist reinforcement learning,” *Machine learning*, vol. 8, pp. 229–256, 1992.
- [121] S. C. Huang, A. Ahmadian, and C. F. AI, “Putting RL back in RLHF.” https://huggingface.co/blog/putting_rl_back_in_rlhf_with_rloo, 2024.
- [122] W. Kool, H. van Hoof, and M. Welling, “Buy 4 reinforce samples, get a baseline for free!” 2019.
- [123] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017.
- [124] C. Berner *et al.*, “Dota 2 with large scale deep reinforcement learning,” *arXiv preprint arXiv:1912.06680*, 2019.
- [125] Z. Liu *et al.*, “Understanding R1-zero-like training: A critical perspective,” *arXiv preprint arXiv:2503.20783*, Mar. 2025, Available: <https://arxiv.org/abs/2503.20783>
- [126] J. Nocedal and S. J. Wright, *Numerical optimization*. Springer, 2006.
- [127] J. Schulman, S. Levine, P. Abbeel, M. Jordan, and P. Moritz, “Trust region policy optimization,” in *International conference on machine learning*, PMLR, 2015, pp. 1889–1897.

- [128] Z. Shao *et al.*, “Deepseekmath: Pushing the limits of mathematical reasoning in open language models,” *arXiv preprint arXiv:2402.03300*, 2024.
- [129] C. Zheng *et al.*, “Group sequence policy optimization.” 2025. doi: 10.48550/arXiv.2507.18071.
- [130] MiniMax, “MiniMax-M1: Scaling test-time compute efficiently with lightning attention.” 2025. doi: 10.48550/arXiv.2506.13585.
- [131] N. Le Roux *et al.*, “Tapered off-policy REINFORCE: Stable and efficient reinforcement learning for LLMs.” 2025. doi: 10.48550/arXiv.2503.14286.
- [132] H. Ivison *et al.*, “Unpacking DPO and PPO: Disentangling best practices for learning from preference feedback,” in *Advances in neural information processing systems (NeurIPS)*, 2024.
- [133] J. Schulman, “Approximating KL-divergence.” <http://joschu.net/blog/kl-approx.html>, 2016.
- [134] S. Huang, M. Noukhovitch, A. Hosseini, K. Rasul, W. Wang, and L. Tunstall, “The n+ implementation details of RLHF with PPO: A case study on TL;DR summarization,” in *First conference on language modeling*, 2024. Available: <https://openreview.net/forum?id=kHO2ZTa8e3>
- [135] L. Weng, “Policy gradient algorithms,” *lilianweng.github.io*, 2018, Available: <https://lilianweng.github.io/posts/2018-04-08-policy-gradient/>
- [136] Q. Yu *et al.*, “DAPO: An open-source LLM reinforcement learning system at scale.” 2025.
- [137] A. Baheti, X. Lu, F. Brahman, R. L. Bras, M. Sap, and M. Riedl, “Leftover lunch: Advantage-based offline reinforcement learning for language models,” in *International conference on learning representations (ICLR)*, 2024.
- [138] M. Noukhovitch, S. Huang, S. Xhonneux, A. Hosseini, R. Agarwal, and A. Courville, “Asynchronous RLHF: Faster and more efficient off-policy RL for language models,” in *International conference on learning representations (ICLR)*, 2025.
- [139] B. Wu *et al.*, “LlamaRL: A distributed asynchronous reinforcement learning framework for efficient large-scale LLM training,” *arXiv preprint arXiv:2505.24034*, 2025.
- [140] W. Fu *et al.*, “AReal: A large-scale asynchronous reinforcement learning system for language reasoning,” *arXiv preprint arXiv:2505.24298*, 2025.
- [141] P. I. Team *et al.*, “INTELLECT-2: A reasoning model trained through globally decentralized reinforcement learning.” 2025. Available: <https://arxiv.org/abs/2505.07291>
- [142] E. L. Ionides, “Truncated importance sampling,” *Journal of Computational and Graphical Statistics*, vol. 17, no. 2, pp. 295–311, 2008.
- [143] F. Yao, L. Liu, D. Zhang, C. Dong, J. Shang, and J. Gao, “Your efficient RL framework secretly brings you off-policy RL training.” 2025. Available: <https://fengyao.notion.site/off-policy-rl>
- [144] D. Seita, “Notes on the generalized advantage estimation paper.” 2017. Available: <https://danieltakeshi.github.io/2017/04/02/notes-on-the-generalized-advantage-estimation-paper/>
- [145] T. Wu, B. Zhu, R. Zhang, Z. Wen, K. Ramchandran, and J. Jiao, “Pairwise proximal policy optimization: Harnessing relative feedback for llm alignment,” *arXiv preprint arXiv:2310.00212*, 2023.

- [146] C. Gao *et al.*, “Soft adaptive policy optimization,” *arXiv preprint arXiv:2511.20347*, Nov. 2025, Available: <https://arxiv.org/abs/2511.20347>
- [147] Y. Flet-Berliac *et al.*, “Contrastive policy gradient: Aligning LLMs on sequence-level scores in a supervised-friendly fashion,” in *Conference on empirical methods in natural language processing (EMNLP)*, 2024.
- [148] Z. Li *et al.*, “Remax: A simple, effective, and efficient reinforcement learning method for aligning large language models,” in *Forty-first international conference on machine learning*, 2024.
- [149] T. Gunter *et al.*, “Apple intelligence foundation language models,” *arXiv preprint arXiv:2407.21075*, 2024.
- [150] K. Team *et al.*, “Kimi k1.5: Scaling reinforcement learning with llms,” *arXiv preprint arXiv:2501.12599*, 2025.
- [151] M. Tomar, L. Shani, Y. Efroni, and M. Ghavamzadeh, “Mirror descent policy optimization,” in *International conference on learning representations (ICLR)*, 2022.
- [152] Y. Zhang *et al.*, “Improving LLM general preference alignment via optimistic online mirror descent,” *arXiv preprint arXiv:2502.16852*, 2025.
- [153] Y. Yuan *et al.*, “VAPO: Efficient and reliable reinforcement learning for advanced reasoning tasks,” *arXiv preprint arXiv:2504.05118*, 2025.
- [154] Y. Yuan, Y. Yue, R. Zhu, T. Fan, and L. Yan, “What’ s behind PPO’ s collapse in long-CoT? Value optimization holds the secret,” *arXiv preprint arXiv:2503.01491*, 2025.
- [155] A. Irpan, “Deep reinforcement learning doesn’ t work yet.” 2018. Available: <https://www.alexirpan.com/2018/02/14/rl-hard.html>
- [156] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup, and D. Meger, “Deep reinforcement learning that matters,” in *Proceedings of the AAAI conference on artificial intelligence*, 2018. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/11694>
- [157] A. Mirhoseini *et al.*, “Chip placement with deep reinforcement learning,” in *Design, automation and test in europe (DATE)*, 2023.
- [158] J. Schrittwieser *et al.*, “Mastering atari, go, chess and shogi by planning with a learned model,” *Nature*, vol. 588, no. 7839, pp. 604–609, 2020.
- [159] M. Cusumano-Towner *et al.*, “Robust autonomy emerges from self-play,” in *International conference on machine learning (ICML)*, 2025.
- [160] G. Sheng *et al.*, “HybridFlow: A flexible and efficient RLHF framework,” in *European conference on computer systems (EuroSys)*, 2025.
- [161] J. Hu *et al.*, “OpenRLHF: An easy-to-use, scalable and high-performance RLHF framework,” *arXiv preprint arXiv:2405.11143*, 2024.
- [162] J. Liu, A. Cohen, R. Pasunuru, Y. Choi, H. Hajishirzi, and A. Celikyilmaz, “Don’ t throw away your value model! Generating more preferable text with value-guided monte-carlo tree search decoding,” *arXiv preprint arXiv:2309.15028*, 2023.
- [163] B. Brown *et al.*, “Large language monkeys: Scaling inference compute with repeated sampling,” *arXiv preprint arXiv:2407.21787*, 2024.
- [164] Z. Liu *et al.*, “Inference-time scaling for generalist reward modeling,” *arXiv preprint arXiv:2504.02495*, 2025.

- [165] N. Muennighoff *et al.*, “s1: Simple test-time scaling,” *arXiv preprint arXiv:2501.19393*, 2025.
- [166] L. Chen *et al.*, “Are more llm calls all you need? Towards scaling laws of compound inference systems,” *arXiv preprint arXiv:2403.02419*, 2024.
- [167] E. Zelikman, Y. Wu, J. Mu, and N. Goodman, “STaR: Bootstrapping reasoning with reasoning,” in *Advances in neural information processing systems*, A. H. Oh, A. Agarwal, D. Belgrave, and K. Cho, Eds., 2022. Available: https://openreview.net/forum?id=__3ELRdg2sgI
- [168] E. Zelikman, G. Harik, Y. Shao, V. Jayasiri, N. Haber, and N. D. Goodman, “Quiet-STaR: Language models can teach themselves to think before speaking,” *COLM*, vol. abs/2403.09629, 2024.
- [169] M. D. Hoffman *et al.*, “Training chain-of-thought via latent-variable inference,” in *Thirty-seventh conference on neural information processing systems*, 2023. Available: <https://openreview.net/forum?id=a147pIS2Co>
- [170] A. Kazemnejad *et al.*, “VinePPO: Unlocking RL potential for LLM reasoning through refined credit assignment.” 2024. Available: <https://arxiv.org/abs/2410.01679>
- [171] J. Gehring, K. Zheng, J. Copet, V. Mella, T. Cohen, and G. Synnaeve, “RLEF: Grounding code LLMs in execution feedback with reinforcement learning,” in *International conference on machine learning (ICML)*, 2025. Available: <https://arxiv.org/abs/2410.02089>
- [172] S. Xu *et al.*, “Is dpo superior to ppo for llm alignment? A comprehensive study,” in *International conference on machine learning (ICML)*, 2024.
- [173] N. Amit, S. Goldwasser, O. Paradise, and G. Rothblum, “Models that prove their own correctness,” *Electron. Colloquium Comput. Complex.*, 2024.
- [174] J. Hu, Y. Zhang, Q. Han, D. Jiang, X. Zhang, and H. Shum, “Open-reasoner-zero: An open source approach to scaling up reinforcement learning on the base model,” *arXiv preprint arXiv:2503.24290*, 2025.
- [175] M. Abdin, S. Agarwal, A. Awadallah, *et al.*, “Phi-4-reasoning technical report,” *arXiv preprint arXiv:2504.21318*, 2025.
- [176] A. Bercovich, I. Levy, I. Golan, *et al.*, “Llama-nemotron: Efficient reasoning models,” *arXiv preprint arXiv:2505.00949*, 2025.
- [177] A. Liu, B. Zhou, C. Xu, *et al.*, “Hunyuan-TurboS: Advancing large language models through mamba-transformer synergy and adaptive chain-of-thought,” *arXiv preprint arXiv:2505.15431*, 2025.
- [178] J. He, J. Liu, C. Y. Liu, *et al.*, “Skywork open reasoner 1 technical report,” *arXiv preprint arXiv:2505.22312*, 2025.
- [179] C. Team *et al.*, “MiMo-VL technical report.” 2025. Available: <https://arxiv.org/abs/2506.03569>
- [180] E. Guha, R. Marten, S. Keh, *et al.*, “OpenThoughts: Data recipes for reasoning models,” *arXiv preprint arXiv:2506.04178*, 2025.
- [181] Mistral AI, “Magistral: Scaling reinforcement learning for reasoning in large language models,” Mistral AI, 2025. Available: <https://mistral.ai/static/research/magistral.pdf>
- [182] K. Team *et al.*, “Kimi K2: Open agentic intelligence.” 2025. Available: <https://arxiv.org/abs/2507.20534>

- [183] A. Zeng *et al.*, “GLM-4.5: Agentic, reasoning, and coding (ARC) foundation models.” 2025. doi: 10.48550/arXiv.2508.06471.
- [184] NVIDIA, “NVIDIA nemotron nano 2: An accurate and efficient hybrid mamba-transformer reasoning model.” 2025. Available: <https://arxiv.org/abs/2508.14444>
- [185] Z. Cheng *et al.*, “K2-think: A parameter-efficient reasoning system.” 2025. Available: <https://arxiv.org/abs/2509.07604>
- [186] M. L. Team, “Introducing LongCat-flash-thinking: A technical report.” 2025. Available: <https://arxiv.org/abs/2509.18883>
- [187] L. Team *et al.*, “Every step evolves: Scaling reinforcement learning for trillion-scale thinking model.” 2025. Available: <https://arxiv.org/abs/2510.18855>
- [188] DeepSeek-AI, “DeepSeek-V3.2: Pushing the frontier of open large language models.” 2025. Available: <https://arxiv.org/abs/2512.02556>
- [189] Z. Liu *et al.*, “K2-V2: A 360-open, reasoning-enhanced LLM,” *arXiv preprint arXiv:2512.06201*, 2025.
- [190] NVIDIA, “Nemotron 3 nano: Open, efficient mixture-of-experts hybrid mamba-transformer model for agentic reasoning,” NVIDIA, Technical Report, 2025. Available: <https://research.nvidia.com/labs/nemotron/files/NVIDIA-Nemotron-3-Nano-Technical-Report.pdf>
- [191] Z. Wang *et al.*, “RAGEN: Understanding self-evolution in LLM agents via multi-turn reinforcement learning.” 2025. Available: <https://arxiv.org/abs/2504.20073>
- [192] R. Shao *et al.*, “Spurious rewards: Rethinking training signals in RLVR.” <https://rethink-rlvr.notion.site/Spurious-Rewards-Rethinking-Training-Signals-in-RLVR-1f4df34dac1880948858f95aeb88872f>, 2025.
- [193] Anthropic, “Claude 4.” May 2025. Available: <https://www.anthropic.com/news/claude-4>
- [194] P. Aggarwal and S. Welleck, “L1: Controlling how long a reasoning model thinks with reinforcement learning,” *arXiv preprint arXiv:2503.04697*, 2025.
- [195] Y. Zhao, R. Joshi, T. Liu, M. Khalman, M. Saleh, and P. J. Liu, “Slic-hf: Sequence likelihood calibration with human feedback,” *arXiv preprint arXiv:2305.10425*, 2023.
- [196] Z. Gao *et al.*, “Rebel: Reinforcement learning via regressing relative rewards,” in *Advances in neural information processing systems (NeurIPS)*, 2024.
- [197] M. G. Azar *et al.*, “A general theoretical paradigm to understand learning from human preferences,” in *International conference on artificial intelligence and statistics*, PMLR, 2024, pp. 4447–4455.
- [198] A. Amini, T. Vieira, and R. Cotterell, “Direct preference optimization with an offset,” in *Annual meeting of the association for computational linguistics (ACL)*, 2024.
- [199] J. Hong, N. Lee, and J. Thorne, “Reference-free monolithic preference optimization with odds ratio,” *arXiv e-prints*, pp. arXiv-2403, 2024.
- [200] Y. Meng, M. Xia, and D. Chen, “Simpo: Simple preference optimization with a reference-free reward,” *Advances in Neural Information Processing Systems*, vol. 37, pp. 124198–124235, 2025.
- [201] N. Razin, S. Malladi, A. Bhaskar, D. Chen, S. Arora, and B. Hanin, “Unintentional unalignment: Likelihood displacement in direct preference optimization,” in *International conference on learning representations (ICLR)*, 2025.

- [202] Y. Ren and D. J. Sutherland, “Learning dynamics of llm finetuning,” in *International conference on learning representations (ICLR)*, 2025.
- [203] T. Xiao, Y. Yuan, H. Zhu, M. Li, and V. G. Honavar, “Cal-dpo: Calibrated direct preference optimization for language model alignment,” in *Advances in neural information processing systems (NeurIPS)*, 2024.
- [204] A. Gupta *et al.*, “AlphaPO-reward shape matters for LLM alignment,” in *International conference on machine learning (ICML)*, 2025.
- [205] S. Guo *et al.*, “Direct language model alignment from online ai feedback,” *arXiv preprint arXiv:2402.04792*, 2024.
- [206] P. Singhal, N. Lambert, S. Niekum, T. Goyal, and G. Durrett, “D2po: Discriminator-guided dpo with response evaluation models,” *arXiv preprint arXiv:2405.01511*, 2024.
- [207] C. Rosset, C.-A. Cheng, A. Mitra, M. Santacrose, A. Awadallah, and T. Xie, “Direct nash optimization: Teaching language models to self-improve with general preferences,” *arXiv preprint arXiv:2404.03715*, 2024.
- [208] S. Jung, G. Han, D. W. Nam, and K.-W. On, “Binary classifier optimization for large language model alignment,” in *Annual meeting of the association for computational linguistics (ACL)*, 2025.
- [209] H. Zhao *et al.*, “Rainbowpo: A unified framework for combining improvements in preference optimization,” in *International conference on learning representations (ICLR)*, 2025.
- [210] A. Gorbatozski, B. Shaposhnikov, V. Sinii, A. Malakhov, and D. Gavrilov, “The differences between direct alignment algorithms are a blur,” *arXiv preprint arXiv:2502.01237*, 2025.
- [211] E. Bakouch *et al.*, “SmolLM3: smol, multilingual, long-context reasoner.” <https://huggingface.co/blog/smollm3>, 2025.
- [212] S. Geng *et al.*, “The delta learning hypothesis: Preference tuning on weak data can yield strong gains,” in *Second conference on language modeling*, 2025. Available: <https://openreview.net/forum?id=9rwtezhwo>
- [213] A. Panickssery, S. Bowman, and S. Feng, “Llm evaluators recognize and favor their own generations,” *Advances in Neural Information Processing Systems*, 2024.
- [214] F. Tajwar *et al.*, “Preference fine-tuning of llms should leverage suboptimal, on-policy data,” in *International conference on machine learning (ICML)*, 2024.
- [215] W. R. Gilks and P. Wild, “Adaptive rejection sampling for gibbs sampling,” *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, vol. 41, no. 2, pp. 337–348, 1992.
- [216] H. Dong *et al.*, “RAFT: Reward rAnked FineTuning for generative foundation model alignment,” *Transactions on Machine Learning Research (TMLR)*, 2023.
- [217] T. Liu *et al.*, “Statistical rejection sampling improves preference optimization,” in *International conference on learning representations (ICLR)*, 2024.
- [218] N. Lambert, T. K. Gilbert, and T. Zick, “Entangled preferences: The history and risks of reinforcement learning and human feedback,” *arXiv preprint arXiv:2310.13595*, 2023.
- [219] V. Conitzer *et al.*, “Social choice should guide AI alignment in dealing with diverse human feedback,” in *International conference on machine learning (ICML)*, 2024.

- [220] A. Mishra, “Ai alignment and social choice: Fundamental limitations and policy implications,” *arXiv preprint arXiv:2310.16048*, 2023.
- [221] H. R. Kirk *et al.*, “The PRISM alignment project: What participatory, representative and individualised human feedback reveals about the subjective and multicultural alignment of large language models,” *arXiv preprint arXiv:2404.16019*, 2024.
- [222] S. Poddar, Y. Wan, H. Ivison, A. Gupta, and N. Jaques, “Personalizing reinforcement learning from human feedback with variational preference learning,” in *Advances in neural information processing systems (NeurIPS)*, 2024.
- [223] A. Arnauld, *The port-royal logic*. 1662.
- [224] J. Bentham, *An introduction to the principles of morals and legislation*. 1823.
- [225] F. P. Ramsey, “Truth and probability,” *Readings in Formal Epistemology: Sourcebook*, pp. 21–45, 2016.
- [226] A. O. Hirschman, “Against parsimony: Three easy ways of complicating some categories of economic discourse,” *Bulletin of the American Academy of arts and Sciences*, vol. 37, no. 8, pp. 11–28, 1984.
- [227] G. K. Hadfield and B. R. Weingast, “Microfoundations of the rule of law,” *Annual Review of Political Science*, vol. 17, pp. 21–42, 2014.
- [228] E. L. Thorndike, “The law of effect,” *The American journal of psychology*, vol. 39, no. 1/4, pp. 212–222, 1927.
- [229] B. F. Skinner, *The behavior of organisms: An experimental analysis*. BF Skinner Foundation, 2019.
- [230] R. A. Briggs, “Normative theories of rational choice: Expected utility,” 2014.
- [231] B. Widrow and M. E. Hoff, “Adaptive switching circuits,” Stanford Univ Ca Stanford Electronics Labs, 1960.
- [232] S. Singh, R. L. Lewis, and A. G. Barto, “Where do rewards come from,” in *Proceedings of the annual conference of the cognitive science society*, Cognitive Science Society, 2009, pp. 2601–2606.
- [233] S. M. McClure, N. D. Daw, and P. R. Montague, “A computational substrate for incentive salience,” *Trends in neurosciences*, vol. 26, no. 8, pp. 423–428, 2003.
- [234] D. Silver, S. Singh, D. Precup, and R. S. Sutton, “Reward is enough,” *Artificial Intelligence*, vol. 299, p. 103535, 2021.
- [235] R. Bellman, “A markovian decision process,” *Journal of mathematics and mechanics*, pp. 679–684, 1957.
- [236] R. A. Howard, “Dynamic programming and markov processes.” 1960.
- [237] J. M. Mendel and R. W. McLaren, “8 reinforcement-learning control and pattern recognition systems,” in *Adaptive, learning and pattern recognition systems*, vol. 66, J. M. Mendel and K. S. Fu, Eds., in *Mathematics in science and engineering*, vol. 66., Elsevier, 1970, pp. 287–318. doi: [https://doi.org/10.1016/S0076-5392\(08\)60497-X](https://doi.org/10.1016/S0076-5392(08)60497-X).
- [238] M. Waltz and K. Fu, “A heuristic approach to reinforcement learning control systems,” *IEEE Transactions on Automatic Control*, vol. 10, no. 4, pp. 390–398, 1965, doi: 10.1109/TAC.1965.1098193.
- [239] A. H. Klopff, *Brain function and adaptive systems: A heterostatic theory*. Air Force Cambridge Research Laboratories, Air Force Systems Command, 1972.

- [240] R. S. Sutton, “Learning to predict by the methods of temporal differences,” *Machine learning*, vol. 3, pp. 9–44, 1988.
- [241] G. Tesauro *et al.*, “Temporal difference learning and TD-gammon,” *Communications of the ACM*, vol. 38, no. 3, pp. 58–68, 1995.
- [242] C. J. Watkins and P. Dayan, “Q-learning,” *Machine learning*, vol. 8, pp. 279–292, 1992.
- [243] V. Mnih *et al.*, “Playing atari with deep reinforcement learning,” *arXiv preprint arXiv:1312.5602*, 2013.
- [244] F. Golnaraghi and B. C. Kuo, *Automatic control systems*. McGraw-Hill Education, 2017.
- [245] D. Silver *et al.*, “Mastering the game of go without human knowledge,” *Nature*, vol. 550, no. 7676, pp. 354–359, 2017.
- [246] J. Degraeve *et al.*, “Magnetic control of tokamak plasmas through deep reinforcement learning,” *Nature*, vol. 602, no. 7897, pp. 414–419, 2022.
- [247] E. Kaufmann, L. Bauersfeld, A. Loquercio, M. Müller, V. Koltun, and D. Scaramuzza, “Champion-level drone racing using deep reinforcement learning,” *Nature*, vol. 620, no. 7976, pp. 982–987, 2023, doi: 10.1038/s41586-023-06419-4.
- [248] R. Agarwal, M. Schwarzer, P. S. Castro, A. C. Courville, and M. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” *Advances in neural information processing systems*, vol. 34, pp. 29304–29320, 2021.
- [249] N. Salha, “Aesthetics & art in the early development of human-computer interfaces,” PhD thesis, Universität Bremen, 2011.
- [250] T. K. Gilbert, S. Dean, T. Zick, and N. Lambert, “Choices, risks, and reward reports: Charting public policy for reinforcement learning systems,” *arXiv preprint arXiv:2202.05716*, 2022.
- [251] J. Von Neumann and O. Morgenstern, “Theory of games and economic behavior, 2nd rev,” 1947.
- [252] S. Pitis, “Rethinking the discount factor in reinforcement learning: A decision theoretic approach,” in *Proceedings of the AAAI conference on artificial intelligence*, 2019, pp. 7949–7956.
- [253] S. Pitis, “Consistent aggregation of objectives with diverse time preferences requires non-markovian rewards,” in *Advances in neural information processing systems (NeurIPS)*, 2023.
- [254] D. Abel *et al.*, “On the expressivity of markov reward,” *Advances in Neural Information Processing Systems*, vol. 34, pp. 7799–7812, 2021.
- [255] A. Sen, “Behaviour and the concept of preference,” *Economica*, vol. 40, no. 159, pp. 241–259, 1973.
- [256] K. J. Arrow, “A difficulty in the concept of social welfare,” *Journal of political economy*, vol. 58, no. 4, pp. 328–346, 1950.
- [257] E. Maskin and A. Sen, *The arrow impossibility theorem*. Columbia University Press, 2014.
- [258] J. C. Harsanyi, “Rule utilitarianism and decision theory,” *Erkenntnis*, vol. 11, no. 1, pp. 25–53, 1977.
- [259] D. Hadfield-Menell, S. J. Russell, P. Abbeel, and A. Dragan, “Cooperative inverse reinforcement learning,” *Advances in neural information processing systems*, vol. 29, 2016.

- [260] A. Fickinger, S. Zhuang, D. Hadfield-Menell, and S. Russell, “Multi-principal assistance games,” *arXiv preprint arXiv:2007.09540*, 2020.
- [261] N. Soares, B. Fallenstein, S. Armstrong, and E. Yudkowsky, “Corrigibility,” in *Workshops at the twenty-ninth AAAI conference on artificial intelligence*, 2015.
- [262] R. Pettigrew, *Choosing for changing selves*. Oxford University Press, 2019.
- [263] Z. Wang *et al.*, “HelpSteer3-preference: Open human-annotated preference data across diverse tasks and languages,” *arXiv preprint arXiv:2505.11475*, 2025.
- [264] W.-L. Chiang *et al.*, “Chatbot Arena: An open platform for evaluating LLMs by human preference,” in *International conference on machine learning (ICML)*, 2024.
- [265] R. Likert, “A technique for the measurement of attitudes.” *Archives of psychology*, 1932.
- [266] J. Zhou *et al.*, “Instruction-following evaluation for large language models.” 2023. Available: <https://arxiv.org/abs/2311.07911>
- [267] K. Ethayarajh, W. Xu, N. Muennighoff, D. Jurafsky, and D. Kiela, “Kto: Model alignment as prospect theoretic optimization,” *arXiv preprint arXiv:2402.01306*, 2024.
- [268] Z. Wu *et al.*, “Fine-grained human feedback gives better rewards for language model training,” *Advances in Neural Information Processing Systems*, vol. 36, 2023.
- [269] A. Chen *et al.*, “Learning from natural language feedback,” *Transactions on Machine Learning Research*, 2024.
- [270] A. Kumar, Y. He, A. H. Markosyan, B. Chern, and I. Arrieta-Ibarra, “Detecting prefix bias in LLM-based reward models,” in *ACM conference on fairness, accountability, and transparency (FAccT)*, 2025.
- [271] A. Bharadwaj, C. Malaviya, N. Joshi, and M. Yatskar, “Flattery, fluff, and fog: Diagnosing and mitigating idiosyncratic biases in preference models.” 2025. Available: <https://arxiv.org/abs/2506.05339>
- [272] M. Sharma *et al.*, “Towards understanding sycophancy in language models,” in *The twelfth international conference on learning representations*, 2024. Available: <https://openreview.net/forum?id=tvhaxkMKAn>
- [273] Y. Bu, L. Huo, Y. Jing, and Q. Yang, “Beyond excess and deficiency: Adaptive length bias mitigation in reward models for RLHF,” in *Findings of the association for computational linguistics: NAACL 2025*, 2025, pp. 3091–3098.
- [274] X. Zhang, W. Xiong, L. Chen, T. Zhou, H. Huang, and T. Zhang, “From lists to emojis: How format bias affects model alignment,” in *Annual meeting of the association for computational linguistics (ACL)*, 2025.
- [275] OpenAI, “Introducing the model spec.” May 2024. Available: <https://openai.com/index/introducing-the-model-spec/>
- [276] I. Shumailov, Z. Shumaylov, Y. Zhao, N. Papernot, R. Anderson, and Y. Gal, “AI models collapse when trained on recursively generated data,” *Nature*, vol. 631, no. 8022, pp. 755–759, 2024.
- [277] M. Gerstgrasser *et al.*, “Is model collapse inevitable? Breaking the curse of recursion by accumulating real and synthetic data,” *arXiv preprint arXiv:2404.01413*, 2024.
- [278] Y. Feng, E. Dohmatob, P. Yang, F. Charton, and J. Kempe, “Beyond model collapse: Scaling up with synthesized data requires reinforcement,” in *ICML 2024 workshop on theoretical foundations of foundation models*, 2024.

- [279] Y. Wang *et al.*, “Self-instruct: Aligning language models with self-generated instructions,” in *Annual meeting of the association for computational linguistics (ACL)*, 2023.
- [280] E. Beeching *et al.*, “NuminaMath 7B TIR,” *Hugging Face repository*. <https://huggingface.co/AI-MO/NuminaMath-7B-TIR>; Numina & Hugging Face, 2024.
- [281] M. Li *et al.*, “Superfiltering: Weak-to-strong data filtering for fast instruction-tuning,” in *Annual meeting of the association for computational linguistics (ACL)*, 2024.
- [282] G. Hinton, O. Vinyals, and J. Dean, “Distilling the knowledge in a neural network,” *arXiv preprint arXiv:1503.02531*, 2015.
- [283] K. Shridhar, A. Stolfo, and M. Sachan, “Distilling reasoning capabilities into smaller language models,” *Findings of the Association for Computational Linguistics: ACL 2023*, pp. 7059–7073, 2023.
- [284] C.-Y. Hsieh *et al.*, “Distilling step-by-step! Outperforming larger language models with less training data and smaller model sizes,” in *Findings of the association for computational linguistics: ACL 2023*, 2023, pp. 8003–8017. doi: 10.18653/v1/2023.findings-acl.507.
- [285] Y. Kim and A. M. Rush, “Sequence-level knowledge distillation,” in *Proceedings of the 2016 conference on empirical methods in natural language processing*, Austin, Texas: Association for Computational Linguistics, Nov. 2016, pp. 1317–1327. doi: 10.18653/v1/D16-1139.
- [286] V. Sanh, L. Debut, J. Chaumond, and T. Wolf, “DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter.” 2019. doi: 10.48550/arXiv.1910.01108.
- [287] X. Jiao *et al.*, “TinyBERT: Distilling BERT for natural language understanding.” 2020. doi: 10.48550/arXiv.1909.10351.
- [288] K. Arora, L. El Asri, H. Bahuleyan, and J. C. K. Cheung, “Why exposure bias matters: An imitation learning perspective of error accumulation in language generation,” in *Findings of the association for computational linguistics: ACL 2022*, S. Muresan, P. Nakov, and A. Villavicencio, Eds., Dublin, Ireland: Association for Computational Linguistics, May 2022, pp. 700–710. doi: 10.18653/v1/2022.findings-acl.58.
- [289] M. Song and M. Zheng, “A survey of on-policy distillation for large language models.” 2026. Available: <https://arxiv.org/abs/2604.00626>
- [290] Y. Gu, L. Dong, F. Wei, and M. Huang, “MiniLLM: Knowledge distillation of large language models,” in *The twelfth international conference on learning representations*, 2024. Available: <https://openreview.net/forum?id=5h0qf7IBZZ>
- [291] R. Agarwal *et al.*, “On-policy distillation of language models: Learning from self-generated mistakes,” in *The twelfth international conference on learning representations*, 2024. Available: <https://openreview.net/forum?id=3zKtaqxLhW>
- [292] S. Ross, G. Gordon, and D. Bagnell, “A reduction of imitation learning and structured prediction to no-regret online learning,” in *Proceedings of the fourteenth international conference on artificial intelligence and statistics*, G. Gordon, D. Dunson, and M. Dudik, Eds., in *Proceedings of machine learning research*, vol. 15. Fort Lauderdale, FL, USA: PMLR, 2011, pp. 627–635. doi: 10.48550/arXiv.1011.0686.
- [293] K. Lu and Thinking Machines Lab, “On-policy distillation,” *Thinking Machines Lab: Connectionism*, Oct. 2025, doi: 10.64434/tml.20251026.

- [294] S. Zhao *et al.*, “Self-distilled reasoner: On-policy self-distillation for large language models.” 2026. doi: 10.48550/arXiv.2601.18734.
- [295] C. Team, “Introducing composer 2.5.” Cursor Blog, May 18, 2026. Available: <https://cursor.com/blog/composer-2-5>
- [296] E. Penaloza, D. Vattikonda, N. Gontier, A. Lacoste, L. Charlin, and M. Caccia, “Privileged information distillation for language models.” 2026. Available: <https://arxiv.org/abs/2602.04942>
- [297] J. Hübotter *et al.*, “Reinforcement learning via self-distillation.” 2026. doi: 10.48550/arXiv.2601.20802.
- [298] H. Lee *et al.*, “Rlaif: Scaling reinforcement learning from human feedback with ai feedback,” 2023.
- [299] A. Sharma, S. Keh, E. Mitchell, C. Finn, K. Arora, and T. Kollar, “A critical evaluation of AI feedback for aligning large language models,” in *Advances in neural information processing systems (NeurIPS)*, 2024.
- [300] L. Castricato, N. Lile, S. Anand, H. Schoelkopf, S. Verma, and S. Biderman, “Suppressing pink elephants with direct principle feedback.” 2024. Available: <https://arxiv.org/abs/2402.07896>
- [301] W. Yuan *et al.*, “Self-rewarding language models,” in *International conference on machine learning (ICML)*, 2024. Available: <https://arxiv.org/abs/2401.10020>
- [302] L. J. V. Miranda *et al.*, “Hybrid preferences: Learning to route instances for human vs. AI feedback,” pp. 7162–7200, July 2025, doi: 10.18653/v1/2025.acl-long.355.
- [303] Y. Xu *et al.*, “RLTHF: Targeted human feedback for LLM alignment,” in *International conference on machine learning (ICML)*, 2025. Available: <https://arxiv.org/abs/2502.13417>
- [304] Z. Wang *et al.*, “Helpsteer: Multi-attribute helpfulness dataset for steerlm,” in *Proceedings of the 2024 conference of the north american chapter of the association for computational linguistics: Human language technologies (volume 1: Long papers)*, 2024, pp. 3371–3384.
- [305] B. Wang *et al.*, “Nemotron-cascade: Scaling cascaded reinforcement learning for general-purpose reasoning models,” *arXiv preprint arXiv:2512.13607*, 2025.
- [306] P. Wang *et al.*, “Large language models are not fair evaluators,” in *Annual meeting of the association for computational linguistics (ACL)*, 2024.
- [307] T. Wang *et al.*, “Shepherd: A critic for language model generation,” *arXiv preprint arXiv:2308.04592*, 2023.
- [308] P. Ke *et al.*, “CritiqueLLM: Towards an informative critique generation model for evaluation of large language model generation,” in *Annual meeting of the association for computational linguistics (ACL)*, 2024.
- [309] J. Li, S. Sun, W. Yuan, R.-Z. Fan, H. Zhao, and P. Liu, “Generative judge for evaluating alignment,” in *International conference on learning representations (ICLR)*, 2024.
- [310] S. Kim *et al.*, “Prometheus 2: An open source language model specialized in evaluating other language models,” in *Conference on empirical methods in natural language processing (EMNLP)*, 2024.

- [311] S. Lee, S. Kim, S. Park, G. Kim, and M. Seo, “Prometheus-vision: Vision-language model as a judge for fine-grained evaluation,” in *Findings of the association for computational linguistics ACL 2024*, 2024, pp. 11286–11315.
- [312] E. Zhao, P. Awasthi, and S. Gollapudi, “Sample, scrutinize and scale: Effective inference-time search by scaling verification,” in *International conference on machine learning (ICML)*, 2025.
- [313] N. Kalra and L. Tang, “Verdict: A library for scaling judge-time compute,” *arXiv preprint arXiv:2502.18018*, 2025.
- [314] A. Madaan *et al.*, “Self-refine: Iterative refinement with self-feedback,” *Advances in Neural Information Processing Systems*, 2023.
- [315] A. Pace, J. Mallinson, E. Malmi, S. Krause, and A. Severyn, “West-of-n: Synthetic preference generation for improved reward modeling,” *arXiv preprint arXiv:2401.12086*, 2024.
- [316] T. Wu *et al.*, “Meta-rewarding language models: Self-improving alignment with llm-as-a-meta-judge,” *arXiv preprint arXiv:2407.19594*, 2024.
- [317] Z. Sun *et al.*, “SALMON: Self-alignment with principle-following reward models,” in *The twelfth international conference on learning representations*, 2024. Available: <https://openreview.net/forum?id=xJbsmB8UMx>
- [318] M. Y. Guan *et al.*, “Deliberative alignment: Reasoning enables safer language models,” *arXiv preprint arXiv:2412.16339*, 2024.
- [319] Anthropic, “Claude’s constitution.” Accessed: Feb. 07, 2024. [Online]. Available: <https://www.anthropic.com/news/claudes-constitution>
- [320] D. Ganguli *et al.*, “Collective constitutional AI: Aligning a language model with public input.” Anthropic, 2023.
- [321] S. Huang *et al.*, “Constitutional AI recipe,” *Hugging Face Blog*, 2024.
- [322] N. Lambert, H. Schoelkopf, A. Gokaslan, L. Soldaini, V. Pyatkin, and L. Castri-cato, “Self-directed synthetic dialogues and revisions technical report,” *arXiv preprint arXiv:2407.18421*, 2024.
- [323] Z. Sun *et al.*, “Principle-driven self-alignment of language models from scratch with minimal human supervision,” in *Thirty-seventh conference on neural information processing systems*, 2023. Available: <https://openreview.net/forum?id=p40XRfBX96>
- [324] J.-P. Fränken, E. Zelikman, R. Rafailov, K. Gandhi, T. Gerstenberg, and N. Goodman, “Self-supervised alignment with mutual information: Learning to follow principles without preference labels,” *Advances in Neural Information Processing Systems*, 2024.
- [325] A. Gunjal *et al.*, “Rubrics as rewards: Reinforcement learning beyond verifiable domains.” 2025. doi: 10.48550/arXiv.2507.17746.
- [326] V. Viswanathan *et al.*, “Checklists are better than reward models for aligning language models.” 2025. doi: 10.48550/arXiv.2507.18624.
- [327] M. Rezaei *et al.*, “Online rubrics elicitation from pairwise comparisons.” 2025. doi: 10.48550/arXiv.2510.07284.
- [328] T. Liu *et al.*, “OpenRubrics: Towards scalable synthetic rubric generation for reward modeling and LLM alignment.” 2025. doi: 10.48550/arXiv.2510.07743.

- [329] Y. He *et al.*, “AdvancedIF: Rubric-based benchmarking and reinforcement learning for advancing LLM instruction following.” 2025. doi: 10.48550/arXiv.2511.10507.
- [330] R. Shao *et al.*, “DR tulú: Reinforcement learning with evolving rubrics for deep research.” 2025. doi: 10.48550/arXiv.2511.19399.
- [331] M. Sharma *et al.*, “ResearchRubrics: A benchmark of prompts and rubrics for evaluating deep research agents.” 2025. doi: 10.48550/arXiv.2511.07685.
- [332] J. Ruan *et al.*, “ExpertLongBench: Benchmarking language models on expert-level long-form generation tasks with structured checklists.” 2025. doi: 10.48550/arXiv.2506.01241.
- [333] S. Reed and N. De Freitas, “Neural programmer-interpreters,” in *International conference on learning representations (ICLR)*, 2016.
- [334] P. Lewis *et al.*, “Retrieval-augmented generation for knowledge-intensive nlp tasks,” *Advances in neural information processing systems*, vol. 33, pp. 9459–9474, 2020.
- [335] L. Gao *et al.*, “Pal: Program-aided language models,” in *International conference on machine learning*, PMLR, 2023, pp. 10764–10799.
- [336] A. Parisi, Y. Zhao, and N. Fiedel, “Talm: Tool augmented language models,” *arXiv preprint arXiv:2205.12255*, 2022.
- [337] T. Schick *et al.*, “Toolformer: Language models can teach themselves to use tools,” in *Advances in neural information processing systems (NeurIPS)*, 2023.
- [338] S. G. Patil, T. Zhang, X. Wang, and J. E. Gonzalez, “Gorilla: Large language model connected with massive APIs,” in *Advances in neural information processing systems (NeurIPS)*, 2024.
- [339] Anthropic, “Model context protocol (MCP).” <https://modelcontextprotocol.io/>, 2024.
- [340] A. M. Bran, S. Cox, O. Schilter, C. Baldassari, A. D. White, and P. Schwaller, “Chemcrow: Augmenting large-language models with chemistry tools,” *arXiv preprint arXiv:2304.05376*, 2023.
- [341] B. Li *et al.*, “Mmedagent: Learning to use medical tools with multi-modal agent,” in *Conference on empirical methods in natural language processing (EMNLP)*, 2024.
- [342] K. Zhang, J. Li, G. Li, X. Shi, and Z. Jin, “Codeagent: Enhancing code generation with tool-integrated agent systems for real-world repo-level coding challenges,” *arXiv preprint arXiv:2401.07339*, 2024.
- [343] S. Yao, N. Shinn, P. Razavi, and K. Narasimhan, “ τ -bench: A benchmark for tool-agent-user interaction in real-world domains.” June 2024. doi: 10.48550/arXiv.2406.12045.
- [344] Y. Qin *et al.*, “ToolLLM: Facilitating large language models to master 16000+ real-world APIs,” in *International conference on learning representations (ICLR)*, July 2024. doi: 10.48550/arXiv.2307.16789.
- [345] S. Yao *et al.*, “React: Synergizing reasoning and acting in language models,” in *International conference on learning representations (ICLR)*, 2023.
- [346] J. Schulman, “Proxy objectives in reinforcement learning from human feedback.” Invited talk at the International Conference on Machine Learning (ICML), 2023. Available: <https://icml.cc/virtual/2023/invited-talk/21549>
- [347] C. Zhang, O. Vinyals, R. Munos, and S. Bengio, “A study on overfitting in deep reinforcement learning,” *arXiv preprint arXiv:1804.06893*, 2018.

- [348] C. A. Goodhart and C. Goodhart, *Problems of monetary management: The UK experience*. Springer, 1984.
- [349] K. Hoskin, “The ‘awful idea of accountability’ : Inscribing people into the measurement of objects,” *Accountability: Power, ethos and the technologies of managing*, vol. 265, 1996.
- [350] T. Lu and C. Boutilier, “Learning mallows models with pairwise preferences,” in *Proceedings of the 28th international conference on machine learning (icml-11)*, 2011, pp. 145–152.
- [351] S. Han *et al.*, “Wildguard: Open one-stop moderation tools for safety risks, jailbreaks, and refusals of llms,” in *Advances in neural information processing systems (NeurIPS)*, 2024.
- [352] H. Inan *et al.*, “Llama guard: Llm-based input-output safeguard for human-ai conversations,” *arXiv preprint arXiv:2312.06674*, 2023.
- [353] P. Röttger, H. R. Kirk, B. Vidgen, G. Attanasio, F. Bianchi, and D. Hovy, “Xstest: A test suite for identifying exaggerated safety behaviours in large language models,” in *Conference of the north american chapter of the association for computational linguistics (NAACL)*, 2024.
- [354] T. Coste, U. Anwar, R. Kirk, and D. Krueger, “Reward model ensembles help mitigate overoptimization,” in *International conference on learning representations (ICLR)*, 2024.
- [355] T. Moskovitz *et al.*, “Confronting reward model overoptimization with constrained RLHF,” in *International conference on learning representations (ICLR)*, 2024.
- [356] R. Rafailov *et al.*, “Scaling laws for reward model overoptimization in direct alignment algorithms,” *Advances in Neural Information Processing Systems*, vol. 37, pp. 126207–126242, 2024.
- [357] S. Zhuang and D. Hadfield-Menell, “Consequences of misaligned AI,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 15763–15773, 2020.
- [358] N. Jaques, S. Gu, D. Bahdanau, J. M. Hernández-Lobato, R. E. Turner, and D. Eck, “Sequence tutor: Conservative fine-tuning of sequence generation models with kl-control,” in *International conference on machine learning*, PMLR, 2017, pp. 1645–1654.
- [359] N. Jaques *et al.*, “Human-centric dialog training via offline reinforcement learning,” in *Conference on empirical methods in natural language processing (EMNLP)*, 2020.
- [360] R. Y. Pang, W. Yuan, K. Cho, H. He, S. Sukhbaatar, and J. Weston, “Iterative reasoning preference optimization,” in *Advances in neural information processing systems (NeurIPS)*, 2024.
- [361] H. Chen, N. Razin, K. Narasimhan, and D. Chen, “Retaining by doing: The role of on-policy data in mitigating forgetting.” 2025. Available: <https://arxiv.org/abs/2510.18874>
- [362] I. Shenfeld, J. Pari, and P. Agrawal, “RL’ s razor: Why online reinforcement learning forgets less,” in *The fourteenth international conference on learning representations*, 2026. Available: <https://openreview.net/forum?id=7HNRYT4V44>
- [363] D. Hendrycks *et al.*, “Measuring massive multitask language understanding,” in *International conference on learning representations (ICLR)*, 2021.

- [364] A. Mallen, A. Asai, V. Zhong, R. Das, H. Hajishirzi, and D. Khashabi, “When not to trust language models: Investigating effectiveness and limitations of parametric and non-parametric memories,” *arXiv preprint*, 2022.
- [365] S. Lin, J. Hilton, and O. Evans, “Truthfulqa: Measuring how models mimic human falsehoods,” in *Annual meeting of the association for computational linguistics (ACL)*, 2022.
- [366] M. Suzgun *et al.*, “Challenging BIG-bench tasks and whether chain-of-thought can solve them,” in *Annual meeting of the association for computational linguistics (ACL)*, 2023.
- [367] D. Dua, Y. Wang, P. Dasigi, G. Stanovsky, S. Singh, and M. Gardner, “DROP: A reading comprehension benchmark requiring discrete reasoning over paragraphs,” in *Conference of the north american chapter of the association for computational linguistics (NAACL)*, 2019.
- [368] D. Hendrycks *et al.*, “Measuring mathematical problem solving with the MATH dataset,” *NeurIPS*, 2021.
- [369] M. Chen *et al.*, “Evaluating large language models trained on code,” 2021, Available: <https://arxiv.org/abs/2107.03374>
- [370] J. Liu, C. S. Xia, Y. Wang, and L. Zhang, “Is your code generated by chatGPT really correct? Rigorous evaluation of large language models for code generation,” in *Thirty-seventh conference on neural information processing systems*, 2023. Available: <https://openreview.net/forum?id=1qvx610Cu7>
- [371] D. Rein *et al.*, “GPQA: A graduate-level google-proof q&a benchmark,” *arXiv preprint arXiv:2311.12022*, 2023.
- [372] L. Phan, A. Gatti, Z. Han, N. Li, and H. et al. Zhang, “Humanity’ s last exam,” *arXiv preprint arXiv:2501.14249*, 2025.
- [373] R. Aleithan, H. Xue, M. M. Mohajer, E. Nnorom, G. Uddin, and S. Wang, “SWE-Bench+: Enhanced coding benchmark for LLMs,” *arXiv preprint arXiv:2410.06992*, 2024.
- [374] N. Jain *et al.*, “LiveCodeBench: Holistic and contamination-free evaluation of large language models for code,” *arXiv preprint arXiv:2403.07974*, 2024.
- [375] S. AI, “SEAL LLM leaderboards: Expert-driven private evaluations.” 2024. Available: <https://scale.com/leaderboard>
- [376] S. Schulhoff *et al.*, “The prompt report: A systematic survey of prompting techniques,” *arXiv preprint arXiv:2406.06608*, 2024.
- [377] J. Robinson, C. M. Rytting, and D. Wingate, “Leveraging large language models for multiple choice question answering,” in *International conference on learning representations*, 2023. Available: <https://openreview.net/forum?id=upQ4o-ygvJ>
- [378] J. Wei *et al.*, “Chain-of-thought prompting elicits reasoning in large language models,” *Advances in neural information processing systems*, vol. 35, pp. 24824–24837, 2022.
- [379] T. Kojima, S. S. Gu, M. Reid, Y. Matsuo, and Y. Iwasawa, “Large language models are zero-shot reasoners,” *Advances in neural information processing systems*, vol. 35, pp. 22199–22213, 2022.
- [380] The Terminal-Bench Team, “Terminal-Bench: A benchmark for AI agents in terminal environments.” <https://github.com/laude-institute/terminal-bench>, May 2025. Available: <https://www.tbench.ai>

- [381] M. A. Merrill *et al.*, “Terminal-Bench: Benchmarking agents on hard, realistic tasks in command line interfaces,” *arXiv preprint arXiv:2601.11868*, 2026, Available: <https://arxiv.org/abs/2601.11868>
- [382] J. Li *et al.*, “Numinamath: The largest public dataset in ai4maths with 860k pairs of competition math problems and solutions,” *Hugging Face repository*, vol. 13, p. 9, 2024.
- [383] L. Yu *et al.*, “Metamath: Bootstrap your own mathematical questions for large language models,” in *International conference on learning representations (ICLR)*, 2024.
- [384] J. Achiam *et al.*, “Gpt-4 technical report,” *arXiv preprint arXiv:2303.08774*, 2023.
- [385] OpenAI, “Introducing SWE-bench verified.” Aug. 2024. Available: <https://openai.com/index/introducing-swe-bench-verified/>
- [386] A. K. Singh *et al.*, “Evaluation data contamination in LLMs: How do we measure it and (when) does it matter?” *arXiv preprint arXiv:2411.03923*, 2024.
- [387] M. Wu *et al.*, “Reasoning or memorization? Unreliable results of reinforcement learning due to data contamination,” *arXiv preprint arXiv:2507.10532*, 2025.
- [388] K. Huang *et al.*, “MATH-perturb: Benchmarking LLMs’ math reasoning abilities against hard perturbations,” in *International conference on machine learning (ICML)*, 2025.
- [389] UK AI Safety Institute, “Inspect AI: Framework for Large Language Model Evaluations.” https://github.com/UKGovernmentBEIS/inspect_ai, 2024.
- [390] C. Fourrier, N. Habib, H. Kydlieck, T. Wolf, and L. Tunstall, “LightEval: A lightweight framework for LLM evaluation.” <https://github.com/huggingface/lighteval>, 2023.
- [391] C. Fourrier, N. Habib, A. Lozovskaya, K. Szafer, and T. Wolf, “Open LLM leaderboard v2.” https://huggingface.co/spaces/open-llm-leaderboard/open_llm_leaderboard; Hugging Face, 2024.
- [392] L. Gao *et al.*, “A Framework for Few-Shot Language Model Evaluation.” Zenodo, 2023. doi: 10.5281/zenodo.10256836.
- [393] S. Black *et al.*, “GPT-NeoX-20B: An open-source autoregressive language model,” in *Proceedings of the ACL workshop on challenges & perspectives in creating large language models*, 2022. Available: <https://arxiv.org/abs/2204.06745>
- [394] Y. Gu, O. Tafjord, B. Kuehl, D. Haddad, J. Dodge, and H. Hajishirzi, “OLMES: A Standard for Language Model Evaluations,” in *Findings of the north american chapter of the association for computational linguistics (NAACL)*, 2025.
- [395] P. Liang *et al.*, “Holistic evaluation of language models,” *Transactions on Machine Learning Research*, 2023, doi: 10.1111/nyas.15007.
- [396] MosaicML, “Mosaic Eval Gauntlet v0.3.0 —Evaluation Suite.” https://github.com/mosaicml/llm-foundry/blob/main/scripts/eval/local_data/EVAL_GAUNTLET.md, 2024.
- [397] S. Maiya, H. Bartsch, N. Lambert, and E. Hubinger, “Open character training: Shaping the persona of AI assistants through constitutional AI,” *arXiv preprint arXiv:2511.01689*, 2025.
- [398] A. M. Turner *et al.*, “Activation addition: Steering language models without optimization,” *arXiv e-prints*, pp. arXiv-2308, 2023.
- [399] R. Chen, A. Ardit, H. Sleight, O. Evans, and J. Lindsey, “Persona vectors: Monitoring and controlling character traits in language models.” 2025. Available: <https://arxiv.org/abs/2507.21509>

- [400] Anthropic, “Claude’ s character.” 2024. Available: <https://www.anthropic.com/research/claude-character>
- [401] T. Mikolov, K. Chen, G. Corrado, and J. Dean, “Efficient estimation of word representations in vector space,” *arXiv preprint arXiv:1301.3781*, 2013.
- [402] A. Zou *et al.*, “Representation engineering: A top-down approach to AI transparency,” in *Proceedings of the 62nd annual meeting of the association for computational linguistics*, 2024. Available: <https://aclanthology.org/2024.acl-long.828/>
- [403] T. Bas and K. Novak, “What can we actually steer? A multi-behavior study of activation control.” 2026. Available: <https://arxiv.org/abs/2511.18284>
- [404] Z. Feng *et al.*, “PERSONA: Algebraic personality composition in language models.” 2026. Available: <https://arxiv.org/abs/2502.13131>
- [405] C. Lu, J. Gallagher, J. Michala, K. Fish, and J. Lindsey, “The assistant axis: Situating and stabilizing the default persona of language models,” *arXiv preprint arXiv:2601.10387*, 2026, Available: <https://arxiv.org/abs/2601.10387>
- [406] R. Ye *et al.*, “Your language model secretly contains personality subnetworks,” in *The fourteenth international conference on learning representations*, 2026. Available: <https://openreview.net/forum?id=zso3Sy3NSX>
- [407] J. Frankle and M. Carbin, “The lottery ticket hypothesis: Finding sparse, trainable neural networks,” in *International conference on learning representations*, 2019. Available: <https://openreview.net/forum?id=rJl-b3RcF7>
- [408] Anthropic, “Claude 4.5 opus soul document.” 2025. Available: <https://www.lesswrong.com/posts/vpNG99GhbBoLov9og/claude-4-5-opus-soul-document>
- [409] A. Askill, “Post on X regarding character training with soul documents.” 2025. Available: <https://x.com/AmandaAskill/status/1995610567923695633>
- [410] A. Vaswani *et al.*, “Attention is all you need,” in *Neural information processing systems*, 2017. Available: <https://api.semanticscholar.org/CorpusID:13756489>
- [411] D. Bahdanau, K. Cho, and Y. Bengio, “Neural machine translation by jointly learning to align and translate,” in *International conference on learning representations (ICLR)*, 2015. Available: <https://arxiv.org/abs/1409.0473>
- [412] G. Team *et al.*, “Gemma 2: Improving open language models at a practical size,” *arXiv preprint arXiv:2408.00118*, 2024.
- [413] J. Bai *et al.*, “Qwen technical report,” *arXiv preprint arXiv:2309.16609*, 2023.
- [414] G. Wang, S. Cheng, X. Zhan, X. Li, S. Song, and Y. Liu, “Openchat: Advancing open-source language models with mixed-quality data,” in *International conference on learning representations (ICLR)*, 2024.
- [415] P. Yadav *et al.*, “What matters for model merging at scale?” *arXiv preprint arXiv:2410.03617*, 2024.

A 定义

本附录收录 RLHF 流程中频繁使用的全部定义、符号与操作，并对语言模型做一个简要概览——语言模型是本书的主导应用。

A.1 语言建模概览

多数现代语言模型的训练目标，是以自回归方式学习 token 序列（词、子词或字符）的联合概率分布。自回归的意思很简单：每个下一次预测都依赖序列中之前的实体。给定 token 序列 $x = (x_1, x_2, \dots, x_T)$ ，模型把整条序列的概率分解为条件分布的连乘：

$$P_{\theta}(x) = \prod_{t=1}^T P_{\theta}(x_t | x_1, \dots, x_{t-1}). \quad (154)$$

为了拟合一个能准确预测该分布的模型，目标常常是最大化“由当前模型预测的训练数据似然”。为此，我们可以最小化负对数似然（NLL）损失：

$$\mathcal{L}_{\text{LM}}(\theta) = -\mathbb{E}_{x \sim \mathcal{D}} \left[\sum_{t=1}^T \log P_{\theta}(x_t | x_{<t}) \right]. \quad (155)$$

实践中，人们用针对每次“下一词预测”的交叉熵损失，做法是把序列中真实的 token 与模型预测的结果作比较。

语言模型有多种架构，在知识、速度及其他性能特性上有不同权衡。现代 LM——包括 ChatGPT、Claude、Gemini 等——最常使用仅解码器 **Transformer** [410]。Transformer 的核心创新是大量使用自注意力 [411] 机制，让模型能直接关注上下文中的概念、并学习复杂映射。本书通篇（尤其在讲奖励模型的第 5 章）会讨论如何增加新的头、或修改 Transformer 的语言建模（LM）头。LM 头是最后一层线性投影，把模型的内部嵌入空间映射到 tokenizer 空间（即词表）。我们会在本书中看到，语言模型不同的“头”可以被用来把模型微调到不同用途——在 RLHF 中，最常见的就是训练奖励模型，第 5 章会重点讲。

A.2 机器学习

- **Kullback-Leibler (KL) 散度** ($\mathcal{D}_{\text{KL}}(P||Q)$)，也叫 KL 散度，是衡量两个概率分布差异的度量。对定义在同一概率空间 $\mathcal{X}$ 上的离散概率分布 P 与 Q ，从 Q 到 P 的 KL 距离定义为：

$$\mathcal{D}_{\text{KL}}(P||Q) = \sum_{x \in \mathcal{X}} P(x) \log \left(\frac{P(x)}{Q(x)} \right) \quad (156)$$

A.3 自然语言处理

- **被选中补全 (Chosen Completion, y_c)**：在多个备选中被选择或被偏好的那个补全，常记作 y_{chosen} 。
- **补全 (Completion, y)**：语言模型针对提示生成的输出文本。补全常记作 $y | x$ 。奖励与其他值常按 $r(y | x)$ 或 $P(y | x)$ 计算。

- **策略 (Policy, π)**: 可能补全上的一个概率分布, 由 θ 参数化: $\pi_\theta(y | x)$ 。
- **偏好关系 (Preference Relation, $\succ$)**: 表示一个补全优于另一个的符号, 例如 $y_{chosen} \succ y_{rejected}$ 。例如, 奖励模型预测某个偏好关系的概率 $P(y_c \succ y_r | x)$ 。
- **提示 (Prompt, x)**: 交给语言模型、用以生成回复或补全的输入文本。
- **被拒绝补全 (Rejected Completion, y_r)**: 成对设定中不受青睐的那个补全。

A.4 强化学习

- **动作 (Action, a)**: 智能体在环境中做出的决策或移动, 常表示为 $a \in A$, 其中 A 是可能动作的集合。
- **优势函数 (Advantage Function, A)**: 优势函数 $A(s, a)$ 刻画在状态 s 下采取动作 a 相对于平均动作的相对好处。定义为 $A(s, a) = Q(s, a) - V(s)$ 。优势函数 (与价值函数) 可以依赖某个具体策略, 记作 $A^\pi(s, a)$ 。
- **折扣因子 (Discount Factor, γ)**: 一个标量 $0 \leq \gamma < 1$, 在回报中按指数方式降低未来奖励的权重, 权衡即时收益与长期收益, 并保证无穷时域求和的收敛性。有时不使用折扣, 等价于 $\gamma = 1$ 。
- **期望奖励优化 (Expectation of Reward Optimization)**: RL 的首要目标, 即最大化期望累积奖励:

$$\max_{\theta} \mathbb{E}_{s \sim \rho_\pi, a \sim \pi_\theta} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right] \quad (157)$$

其中 ρ_π 是策略 π 下的状态分布, γ 是折扣因子。

- **有限时域回报 (Finite Horizon Reward, $J(\pi_\theta)$)**: 策略 π_θ (由 θ 参数化) 的期望有限时域折扣回报, 定义为:

$$J(\pi_\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \gamma^t r_t \right] \quad (158)$$

其中 $\tau \sim \pi_\theta$ 表示按策略 π_θ 采样得到的轨迹, T 是有限时域。

- **同策略 (On-policy)**: 在 RLHF 中, 尤其是在 RL 与直接对齐算法的争论里, **同策略**数据的讨论很常见。在 RL 文献中, “同策略”意味着数据精确地由智能体的当前形态生成; 但在广义的偏好微调文献中, “同策略”被拓展为“来自该模型版本的生成”——例如开始任何偏好微调之前的某个指令微调检查点。在这个语境下, “异策略”可以指后训练中使用的任何其他语言模型生成的数据。
- **策略 (Policy, π)**, 在 RLHF 中也叫**策略模型**: 在 RL 中, 策略是智能体为决定给定状态下应采取什么动作而遵循的策略或规则: $\pi(a | s)$ 。
- **策略条件值 (Policy-conditioned Values, $[\cdot]^\pi$)**: 在 RL 的推导与实现中, 一个关键组成部分是“在特定策略条件下收集数据或值”。本书通篇会在价值函数的简化记号 (V, A, Q, G) 与其具体的策略条件值 (V^π, A^π, Q^π) 之间切换。期望值计算中同样关键的是从数据 d 采样,

而该数据以特定策略为条件，记作 d_π （例如在估计 $\mathbb{E}_{s \sim d_\pi, a \sim \pi(\cdot|s)}[A^\pi(s, a)]$ 时， $s \sim d_\pi$ 且 $a \sim \pi(\cdot|s)$ ）。

- **Q 函数 (Q-Function, Q)**: 估计“在给定状态下采取某个具体动作”的期望累积奖励的函数： $Q(s, a) = \mathbb{E}[\sum_{t=0}^{\infty} \gamma^t r_t | s_0 = s, a_0 = a]$ 。
- **奖励 (Reward, r)**: 一个标量值，指示某个动作或状态的可取程度，通常记作 r 。
- **状态 (State, s)**: 环境当前的构型或处境，通常记作 $s \in S$ ，其中 S 是状态空间。
- **轨迹 (Trajectory, τ)**: 轨迹 τ 是智能体经历的状态、动作与奖励的序列： $\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_T, a_T, r_T)$ 。
- **轨迹分布 (Trajectory Distribution, $(\tau | \pi)$)**: 策略 π 下一条轨迹的概率为 $P(\tau | \pi) = p(s_0) \prod_{t=0}^T \pi(a_t | s_t) p(s_{t+1} | s_t, a_t)$ ，其中 $p(s_0)$ 是先验状态分布， $p(s_{t+1} | s_t, a_t)$ 是转移概率。
- **价值函数 (Value Function, V)**: 估计“从给定状态出发”的期望累积奖励的函数： $V(s) = \mathbb{E}[\sum_{t=0}^{\infty} \gamma^t r_t | s_0 = s]$ 。

A.5 仅属 RLHF

- **参考模型 (Reference Model, π_{ref})**: RLHF 中使用的一组已保存参数，其输出被用来正则化优化过程。

A.6 扩展术语表

- **思维链 (Chain-of-Thought, CoT)**: 思维链是语言模型的一种特定行为：被引导成把问题按一步一步的形式拆解。它最初的形态是通过提示“Let’s think step-by-step” [378] 实现的。
- **蒸馏 (Distillation)**: 蒸馏是训练 AI 模型的一整套通用实践：让一个模型在更强模型的输出上训练。它是一类已知能造出强大的小模型的合成数据。多数模型会在许可协议（对开放权重模型）或服务条款（对只能通过 API 访问的模型）中明确蒸馏的规则。“蒸馏”这个词如今还承载了 ML 文献中一个具体的技术定义。
- **上下文学习 (In-context Learning, ICL)**: 这里的“上下文”指语言模型上下文窗口内的任何信息，通常是加到提示里的信息。上下文学习最简单的形式，是在提示之前加入若干同形式的示例。更高级的版本能学会为特定用例选择该纳入哪些信息。
- **(教师—学生) 知识蒸馏 ((Teacher-student) Knowledge Distillation)**: 从特定教师到学生模型的知识蒸馏，是上述蒸馏的一种具体类型，也是这个术语的起源。它是一种具体的深度学习方法：修改神经网络的损失，使其从教师模型在多个潜在 token/logits 上的对数概率中学习，而不是直接从选定的输出学习 [282]。用知识蒸馏训练的现代模型系列例子包括 Gemma 2 [412] 与 Gemma 3。对语言建模设定，下一词损失函数可以修改如下 [291]，其中学生模型 P_θ 从教师分布 P_ϕ 学习：

$$\mathcal{L}_{\text{KD}}(\theta) = -\mathbb{E}_{x \sim \mathcal{D}} \left[\sum_{t=1}^T P_\phi(x_t | x_{<t}) \log P_\theta(x_t | x_{<t}) \right]. \quad (159)$$

- **合成数据 (Synthetic Data)**: 指任何由另一个 AI 系统产出的、用于训练 AI 模型的数据。它可以是模型针对开放式提示生成的文本，也可以是模型对既有内容的改写。

B 超越「只是风格」

RLHF 早期的发展给它留下了一个名声：“不过是风格迁移”；另一些严厉的批评则聚焦 RLHF 如何操纵输出中信息的呈现方式。本附录解释为什么**风格**是理解 RLHF 所提供价值的核心——以及它为何同时正面影响模型能力与用户体验。

“RLHF 只关乎风格迁移”这个说法之所以拖累了 RLHF 的叙事，有两个原因。第一，它把 RLHF 与“对模型微小、不重要的改动”联系在一起。人们谈论风格迁移时，往往不认为它重要或令人兴奋——他们觉得它肤浅。然而，**风格是人类价值的无尽源泉**：它正是为什么重讲一个故事能产生新的畅销书（例如 *Sapiens*），也是我们智力生态持续进步的根本组成部分。风格与“信息是什么”是交织在一起的。

第二个原因，是许多人忽略了：**做得好的 RLHF 会提升在流行 LLM 评估上的分数**。我们已经看到，不同风格确实能实质性地改善 Llama 3 的评测表现 [29]。Llama 3 Instruct 系列在 Arena 上得分极高，人们普遍认为这是因为它们有更讨喜的个性——比同代其他模型更简洁、更机灵。撇开许多 LLM 用户执迷的基准分数不论，如果 RLHF 能让语言模型单纯变得**更有趣**，那本身就是交付了价值。

本附录通篇用“话痨感”（chattiness）这个词来涵盖 RLHF 训练模型回复长度的增长，也涵盖大量使用 Markdown、表情符号、以及用项目符号列表组织答案等做法。为了让本附录的讨论落到实处，下面给出同一 Tulu 3 家族两个模型对同一提示的示例补全——一个只做了指令微调，另一个通过长度受控的 DPO 做了偏好微调。先看指令微调版本对提示 `What is reinforcement learning from human feedback?` 的补全（具体模型是 Llama 3.1 Tulu 3 70B SFT）[6]：

```
Reinforcement learning from human feedback, also known as human-in-the-loop reinforcement learning, is a subfield of machine learning where the primary goal is to train reinforcement learning agents to perform tasks by incorporating feedback from humans. This feedback can come in various forms, such as binary rewards (e.g., right or wrong), scalar rewards, preferences between actions, demonstrations, natural language instructions, or corrections to the agent's behavior.
```

```
The idea behind reinforcement learning from human feedback is to leverage human intuition and decision-making abilities to guide the learning process of the agent. In traditional reinforcement learning, an agent learns to make decisions by interacting with an environment and receiving rewards or punishments based on the outcomes of those interactions. However, defining a suitable reward function can be challenging and time-consuming, often leading to reward shaping or reward hacking, where the agent finds unexpected and often unintended ways to maximize the reward.
```

```
By using human feedback, reinforcement learning can address some of these issues by allowing humans to directly influence the learning process. Human trainers can provide real-time feedback, scale their feedback to match the complexity of the task, and update their feedback based on the agent's progress. This approach can lead to more robust and generalized agents, as they are guided not by handcrafted reward functions but by the nuanced understanding and experience of human trainers.
```

```
However, reinforcement learning from human feedback faces several challenges, such as the high cost of obtaining human feedback, subjective and inconsistent feedback, scaling issues, and methods for efficient and effective integration of human feedback into learning algorithms. Despite these challenges, the research in this area has shown promising results in various applications, including robotics, video games, prosthetics control, natural language processing, and many more.
```

再看 RLHF 之后的补全，来自 Llama 3.1 Tulu 3 70B DPO:

Reinforcement learning from human feedback (RLHF) is a subset of reinforcement learning (RL) where the rewards that guide the learning process are provided by humans, rather than a pre-specified numerical reward function. This is particularly useful in situations where it is hard or infeasible to design a suitable reward function, or where the desired performance involves subjective judgments that humans are uniquely equipped to provide.

In traditional reinforcement learning, an agent interacts with an environment. With each interaction, the agent performs an action, receives an observation, and gets a numerical reward that tells it how well it performed in that situation. Through many such interactions, the agent learns to maximize the cumulative reward.

In contrast, in reinforcement learning from human feedback:

1. **Human Input:** Instead of a predefined reward function, the feedback comes from human evaluators, who provide qualitative, subjective judgments about the agent's performance. This feedback can be in various forms, such as numerical ratings, binary preference signals, natural language feedback, or even demonstrations showing how to improve.
2. **Feedback Loop:** Human evaluators observe the agent's actions or outcomes and provide feedback in real-time (or close to real-time). The agent learns through this iterative feedback loop, gradually adapting its behavior to align more closely with human preferences.
3. **Reward Shaping:** Because raw human feedback is not always directly usable in learning algorithms due to variability and potential bias, a reward shaping process may be involved, whereby human feedback is converted into a more stable signal that guides learning.
4. **Preference-based RL:** One common approach within RLHF is preference-based reinforcement learning, where the agent is trained by comparing pairs of actions (or outcomes) and receiving human feedback on which one is better. From these pairwise comparisons, the agent infers a reward function that it can use to guide its actions.
5. **Inverse Reinforcement Learning (IRL):** Another technique used in RLHF is IRL, which aims to infer the underlying reward function that could explain human actions or decisions, and then use that reward function to train the agent.

Applications:

Reinforcement Learning from human feedback has found applications in:

- **Robotics:** Teaching robots to perform tasks that are difficult to specify with predefined reward functions.
- **Game playing:** Human feedback can guide AI agents to better emulate human-like strategies or behaviors.
- **Language and content generation:** For example, suggestively guiding AI models to generate more coherent, creative, or helpful content.
- **Recommendation systems:** Human feedback can help adjust and refine the recommendations provided to users.

Challenges:

Using human feedback introduces some specific challenges:

1. **Scalability:** Human feedback is time-consuming and expensive to collect, and it's hard to scale to complex or high-dimensional tasks.
2. **Bias and Noise:** Human feedback can be noisy, inconsistent, and biased, leading to suboptimal learning outcomes.
3. **Alignment:** Ensuring that the reinforcement learning agent aligns with the true preferences of the human evaluator(s) and not just the superficial feedback is difficult.
4. **Safety and Misuse:** There can be concerns about the safety and ethical implications of using potentially flawed human feedback, especially if the feedback process is corrupted or gamed.

Researchers are actively working on techniques to mitigate these challenges and improve RLHF approaches. One such approach is leveraging machine learning models to amplify the efficacy of the human feedback, for example, by learning to generalize from sparse human input or by synthesizing plausible feedback in situations where direct human input is not available.

DPO 模型的回答所含信息与前者相似（两个模型都基于同一个预训练基座），但偏好微调带来了更多结构、排版，当然还有更长的篇幅——而篇幅反复被证明与语言模型上“人类偏好”的一般观念相关。更多此类例子见本书配套的补全库：<https://www.rlhfbok.com/library>。

B.1 话痨感的平衡

无数人用 RLHF 或偏好微调方法来提升 AlpacaEval 及其他自动聊天排行榜的分数（这些榜用“LLM 作为评判者”来近似衡量一个智能体在简单对话任务上有多有帮助、无害、诚实），但 RLHF 在这里带来的巨大增益，并没有同等比例地迁移到 Arena 这类更难钻空子的评估上。张力在于：RLHF 方法确实这些模型上给出可测量的改进，但这种训练并不总能转化为人们真正在乎的性能。随着 RLHF 文献的建立，一大批模型带着相关方法发布，声称提升了模型的“对齐”，但它们往往做过头，公布的评测分数从“有误导性”到“毫无意义”都有。

这些出于对齐动机的 RLHF 方法，若做对了，会让模型更好用、更愉快。这通常伴随 MT-Bench 或 AlpacaEval 这类评估工具的明确提升。

2023 年秋，围绕直接偏好优化（DPO）相对于近端策略优化（PPO）及其他基于 RL 的偏好微调方法的角色，争论达到顶峰——“聊天评估分数与真实世界性能之间的平衡”正是争论的核心（关于这些权衡的更多技术讨论，见第 8 章、Iverson 等 2024 [132]，或这场演讲）。问题在于：你也可以用 DPO、PPO 这类技术配合反馈回路或海量数据，以换取这份聊天表现——而代价是严重损害模型在数学或代码等其他任务上的能力。

在 DPO 与 PPO 之争蔓延期间，许多论文给出了惊人的基准成绩，却没有获得实质采用。即便这些论文发布了模型权重，它们在公开使用中也不受欢迎，因为这些模型在通用场景下并不鲁棒。在 2023 年秋或稍后应用 RLHF 时，没有任何办法让一个“对齐过的”70 亿参数模型在综合基准上真正击败 GPT-4（这个判断会一直成立：当时的小模型无法稳健地击败最强的大型前沿模型）。这似乎显而易见，但总有人发表声称这类结果的论文。图 52 出自一篇名为 Direct Nash Optimization (DNO) 的论文，它主张自己的模型在 2024 年 4 月是 7B 模型里 AlpacaEval 上的最先进水平 [207]。作为背景：DNO 是“奖励模型 + PPO”（经典 RLHF）或一次性 DPO 的一种批量式、同策略迭代替代方案，它把对齐框架化为“针对偏好 oracle 求纳什均衡”，从而直接优化成对偏好（胜率差）。当学术激励与“全社会极度关注的技术”相遇时，这类挑战就会出现。

即便是 2024 年 1 月那篇先驱性论文 Self Rewarding Language Models [301]，也在 Llama 2 70B 上公布了不切实际的高分。当然，那时 70B 模型确实能比 7B 模型更接近 GPT-4（正如 2024 年令




图 52: Direct Nash Optimization (DNO) 论文的结果，突出其小模型超越了 GPT-4 之类。Rosset 等 2024。许可 CC-BY。

人印象深刻的 Llama 3 发布所示)，但把“模型的真实水平”与“现代 RLHF 论文中的声称”区分开很重要。这些模型是为窄测试集调出来的，在真实使用中面对它们声称击败的、大得多的模型时，表现撑不住。类似的方法来去还有很多，它们分享了有价值的洞见，也分享了被夸大的结果——这让 RLHF 更难理解。

被套用“怪味 RLHF”的模型，其一个常见症状是**长度偏置**。这变得如此普遍，以至于 AlpacaEval 与 WildBench 等多个评估系统都内置了线性长度校正机制。这修补了“靠话痨 doping 去击败 GPT-4 或当日领先前沿模型”的激励，造出一个不那么容易钻空子的动态——更短、更有用的模型可以真正获胜。

无论如何，只为“话痨感”而对齐聊天模型，如今在文献中有了一点名声上的代价——人们承认这些窄方法会以其他方式损害模型。下面这条来自 2023 年阿里巴巴初代 Qwen 模型的说明，在早期对齐实验中被反复观察到，夸大了一种“话痨感 vs 性能”的权衡 [413]：

我们用大量数据预训练了模型，并用监督微调和直接偏好优化对模型做了后训练。然而，DPO 带来了人类偏好评估上的提升，却造成了基准评估上的退化。

把这种权衡处理得当的一个早期好例子，是 2024 年 3 月的 Starling Beta 这样的模型 [82]。它从另一个聊天模型 OpenChat 微调而来 [414]（实际上是由另一个完全不同的组织训练的）。它的训练完全聚焦于 K 元奖励模型训练与 PPO 优化，在 Arena 上上升了 10 个名次。模型的平均回复长度增加了，但增加的方式足以真正帮助人类评分者。后来的例子如 Olmo 3 有记录显示经历了大量聊天训练，但作者偏好选择数学、代码与推理分数更高的最终检查点，而不是那些在基于 LLM 评判的聊天基准上最高的潜在检查点 [18]。

一个自然的问题是：**为什么 RLHF 会让模型回复变长**？根本上，Arena 这类评估告诉我们：与简短的回复相比，模型的普通用户往往更喜欢更长、更完整的答案。更长的答案对快速评估它们的用户来说，可能感觉更周全、更有帮助，甚至更可信。这并不代表**每一位**用户的偏好，但这些模型是按众多数据标注者的**平均偏好**训练的，所以 RLHF 倾向于让模型更啰嗦。

C 实践问题

本附录覆盖规模化运行后训练实验的实践考量。它的形式是一份经验清单，而不是连贯的叙述。

C.1 后训练的算力成本

后训练运行的算力成本有两种不同的界定方式。最大的成本在**开发配方**上，它很容易达到最终几次训练运行算力的 10 倍到 100 倍。其次是**把配方彻底跑一遍**的成本——更容易度量——它包括多个随机种子、细致的评估、潜在的工程麻烦等等。

对第一类成本：为了开发出 Tulu 3 这样的后训练配方 [6]，团队在 7B 规模上跑了量级为数千次的实验/评估，才得到最终模型。

对最终运行，Olmo 3 的报告详细记录了训练最终 32B Think 模型所涉及的内容 [18]：

后训练遵循一种不同的操作模式：每个阶段我们都要跑多次，扫过学习率与其他超参。后训练（尤其是 RL）的理论发展得不够，所以我们不得不跑多个实验，才能确定给定基座模型的最优超参。我们希望在未来的工作中解决这一点。

在后训练期间，检查点评估消耗的算力占比更大，部分原因是推理模型在核心基准上生成很长。对 SFT，我们在每份 256 张 GPU 上并行扫了四个候选学习率，跑了 36 小时。然后是大约 12 小时的评估、合并与检查点确认，合计约两天。DPO 每次运行耗时更短（在每份作业 64 张 GPU 上跑完整学习率扫描约 18 小时），但实践中因集群不稳定而拖到数天。Olmo 3 Think 32B 最初的最初 RL 运行跨度约 5 天，其中至少有 1 天的训练时间因稳定性问题而浪费。Olmo 3 首次发布后，我们把最好的那次 RL 运行又继续跑了 21 天、用 224 张 GPU，才产出 Olmo 3.1 Think 32B。

随着扩展强化学习成为更标准的实践，这会再次变化 [17]。接着上面的例子：Olmo 3 32B Think 原本的后训练只花了两周，而要发布改进后的 Olmo 3.1 32B Think，团队需要用 RLVR 再训练 3.5 周。这是**时间**上的可观成本，而不只是**总算力**上的。

C.2 评估的方差

后训练中一个被低估的挑战是**评估方差**，尤其随着推理模型兴起——它们需要使用大于 0 的温度采样才能拿到最佳评测分数。只要从模型采样，输出就变得更加变。不同基准的稳定性特征差别巨大，原因包括提示难度的方差、评测集中提示的数量、被训练模型的脆弱程度等等。

在 Olmo 3 期间，团队追踪了用于评估推理模型的不同评估的方差。下表给出每个评估的标准差，计算方式是“14 个模型各跑 3 次的标准差”再取均值（先算每个模型的方差，再按评估平均）：

表 9: 多个推理运行下各评估基准的标准差，按稳定性分类（数据来自 Olmo 3）。

类别	基准	标准差
高方差	GPQA	1.48
	AlpacaEval 3	1.24
	IFEval	0.88
稳定	ZebraLogic	0.56
	Omega	0.56

类别	基准	标准差
非常稳定	AIME 24 (Avg@32)	0.54
	HumanEvalPlus	0.46
	AgiEval	0.43
	BigBenchHard	0.39
	LiveCodeBench (Avg@10)	0.29
	MBPPPlus	0.27
	MATH	0.25
	MMLU	0.22
	PopQA	0.16

有些评估（例如 LiveCodeBench）既有噪声又便宜（因为集合里提示少），所以对每个模型把该评估重跑 10 次，就能把它从高方差组移入稳定组。每个评估都可以这样做，但成本很容易膨胀。

我们还能看到其他方差来源：评估设置中的批大小、vLLM 内的张量并行设置（例如基线用 TP=2），以及其他在跨基础设施采样长生成时很敏感的具体数值设定。对推理模型而言，方差无处不在。

C.3 管理训练表现的方差

在本书讨论的所有后训练配方与工具中，最终模型的表现都存在可观的方差。理解这个方差的分布、来源与影响，对造出强模型至关重要。训练最终模型的目标是**采样许多点**——通过改变训练参数与随机种子——以获得尽可能强的模型。注意这是在“模型**确实更好**”与“仅仅从评估噪声中重新掷骰子获益”之间做权衡。

上一节关注评估噪声，而更棘手的噪声来源是**训练不确定性**。评估噪声可以通过在给定检查点上跑更多测试来管理（均匀地降低噪声）；但模型只被训练一次，却可以从**正向离群值**中获益。

实践中，训练团队会采取许多步骤，从配方中榨出尽可能大的价值：

1. 对每一次最终模型运行，扫核心优化值，如学习率、批大小等。例如用一个新的基座模型时，我建议先在很宽的区间上跑 10 个学习率、确认落在最优范围内，然后在更窄的最优窗口里重跑。
2. 在最好的几组设置上跑多个随机种子。随机种子对最终模型可能有实质影响，值得为它花算力。
3. **模型合并**已被确立为打造强模型的关键工具。合并有多种做法，从“合并同一数据上的不同检查点”到“合并特定领域的专精模型”。总体上，合并在最终配方中被视为一种强大而简单的工具；但关于“如何在配方中为后续合并做准备”，明确的最佳实践尚未确立 [415]。

C.4 识别坏掉的训练任务

训练模型时，一个重要且简单的直觉是区分不同类型的问题。你希望大部分时间花在“当前数据、算法或配方就是不够好”这类问题上。另一方面，在搭建新配方时，也常有某些方法干脆是坏的。

理解这一点最好的办法，是在一个基本静态的评估套件上评估许多模型。然后你会形成直觉：哪些测试很难被后训练干预推动（通常是知识密集型的评估，如 MMLU）。当一个后训练设置里某处非常、非常坏掉时，这些大体稳定的评估常常会在一次训练任务中掉 10-20 分。这是**开发工具链时最有用的信号之一**！